



UNIVERSIDAD DE EL SALVADOR
FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA DE INGENIERÍA DE SISTEMAS INFORMÁTICOS

**Clasificación de Enfermedades, Plagas y Deficiencias
Nutricionales en Hojas de Maíz mediante Deep Learning en
Dispositivos Móviles: Optimización, Ensamble, Evaluación
Rigurosa, Sesgos y Prototipo Desplegado**

Etapa 2

Integrantes:

Josias Abner Rivas Fuentes – RF20010
David Alejandro Deras Cerros – DC19019
Elmer Edenilson Rosales Molina – RM20001

San Salvador, El Salvador
Septiembre de 2026

Índice

Resumen	2
1 Introducción y Recapitulización de la Etapa 1	4
2 Optimización de Hiperparámetros	6
2.1 Metodología de búsqueda y espacio de configuración	6
2.2 Eficiencia mediante poda temprana (MedianPruner)	7
2.3 Hallazgos clave e impacto vs. Baseline Etapa 2	7
2.4 Comportamiento cruzado entre arquitecturas	8
3 Modelos Avanzados y Ensamble Multimodelo	10
3.1 Arquitecturas y diversidad inductiva	10
3.2 Mecanismo de agregación: Soft Voting	11
3.3 Resultados y sensibilidad fitosanitaria (Recall = 95.06%)	11
3.4 Estrategia de despliegue dual	13
4 Evaluación Rigurosa y Métricas Finales	14
4.1 Evaluación sobre el conjunto de prueba retenido	14
4.2 El experimento cruzado 2×2 : Estratificada vs. Agrupada	14
4.3 Estabilidad entre semillas	16
5 Análisis de Sesgos y Ética	17
5.1 Equidad entre entornos: Laboratorio vs. Campo Real	17
5.2 Prueba de oclusión espacial (Clever Hans Check)	19
5.3 Auditoría visual con Grad-CAM y SHAP	21
6 Prototipo Funcional y Desplegado	24
6.1 Optimización para el borde: Cuantización Int8 a 3.56 MB	24
6.2 Pruebas de latencia en hardware real (Motorola edge 40 neo)	24
6.3 Interfaz y soluciones de Experiencia de Usuario (UX)	25
7 Análisis de Impacto Social y Recomendaciones de Política Pública	30
7.1 Recomendaciones de política pública aplicables	30
7.1.1 1. Adopción a futuro de DoctorMaiz como herramienta oficial de extensión	30
7.1.2 2. Red Nacional de Alerta Fitosanitaria Temprana	30
7.1.3 3. Creación del Banco Nacional Participativo de Datos Agrícolas	31
7.1.4 4. Campañas comunitarias de alfabetización digital agropecuaria	31
7.1.5 5. Soberanía tecnológica y protección de datos campesinos	31
8 Conclusiones y Trabajo Futuro	32
8.1 Conclusiones principales	32
8.2 Trabajo futuro y transición a campo	33
9 Referencias	34

Resumen

Este documento presenta los resultados correspondientes a la **Etapla 2** del proyecto de investigación aplicada enfocado en el diagnóstico de patologías foliares en cultivos de maíz para pequeños productores de El Salvador. Partiendo de los hallazgos de la Etapa 1 —donde se validaron tres arquitecturas convolucionales ligeras (*baselines*) sobre un conjunto topado a 10 020 imágenes identificando a la deficiencia de potasio como principal cuello de botella—, en esta segunda fase se escaló el entrenamiento al corpus consolidado completo de **33 438 imágenes** en 9 clases, integrando cuatro nuevos conjuntos de datos dirigidos a fortalecer las patologías minoritarias.

Se implementó una optimización bayesiana de hiperparámetros utilizando *Optuna* con poda temprana (*MedianPruner*) sobre GPUs en la nube, logrando mejoras de hasta +0.93 puntos porcentuales y ahorrando 8 horas de cómputo en GPU. Se desarrolló un ensamble heterogéneo por votación suave (*Soft Voting*) combinando EfficientNet-Lite0, EfficientNet-B0 y ShuffleNet-V2, alcanzando una exactitud del **98.29%**, un Macro F_1 de **0.9567** y un Macro Recall de **95.06%** sobre 5 015 imágenes de prueba retenida, minimizando los falsos negativos de bioseguridad. La evaluación rigurosa mediante un experimento cruzado 2×2 reveló que el protocolo de partición pesa veintidós veces más que los hiperparámetros: mientras la evaluación tradicional arroja un Macro F_1 de 0.94, la validación honesta fuera de fuente (validación cruzada agrupada por procedencia en 5 pliegues) se sitúa en 0.60, demostrando la existencia de atajos visuales de procedencia en los datasets públicos.

La auditoría de equidad (*Fairness*) confirmó paridad entre laboratorio y campo real sobre las clases comparables ($DIR = 0.9604$ en Macro F_1 y 0.9901 en exactitud), pero evidenció mediante ablación espacial que el anillo periférico de la foto retiene el 79.46% de acierto con el centro de la escena tapado, y que la atribución de SHAP sobre el tejido foliar apenas supera su nivel de azar (+0.037 de exceso medio). Para responder a este reto, se construyó y probó en hardware físico (Motorola edge 40 neo) la aplicación móvil offline **DoctorMaiz** en React Native, con un modelo cuantizado a Int8 (3.56 MB) que infiere en apenas 60 ms, guiando el encuadre con un

marco foliar e integrando un detector de anomalías fuera de dominio (OOD) por distancia de Mahalanobis. Finalmente, se analizan las implicaciones socioeconómicas en el agro salvadoreño y se proponen cinco políticas públicas concretas para su adopción en el CENTA y el Ministerio de Agricultura y Ganadería.

Palabras clave: deep learning móvil, maíz, optimización bayesiana, ensamble multimodelo, sesgo de procedencia, equidad algorítmica, Edge AI, políticas públicas agrícolas.

Enlaces del proyecto. El código, los pesos exportados y la documentación completa están disponibles públicamente:

- Clasificador (*pipeline* de entrenamiento, evaluación y exportación): <https://github.com/daiv05/maize-doctor-classifier>
- Aplicación móvil **DoctorMaiz** (React Native, inferencia *offline*): <https://github.com/Edenilson-Molina/maize-doctor-app>
- Segmentador foliar (detección y segmentación de instancias de hoja): <https://github.com/abner-rivas/maize-doctor-segmenter-leaf>
- API (cuenta de usuario, sincronización opcional y avisos de actualización): <https://github.com/daiv05/maize-doctor-api>
- Sitio web y documentación técnica: <https://doctor-maiz.deras.dev/es>
- Dataset consolidado en Hugging Face: <https://huggingface.co/datasets/daiv05/corn-leaf-diseases-pests-and-deficiencies>
- Artefactos de evaluación y modelos exportados: https://drive.google.com/drive/folders/10eZdWggfp7nVkaYHW_oOuCma5xbwhns6?usp=drive_link

1 Introducción y Recapitulización de la Etapa 1

El cultivo de maíz representa la base alimentaria y económica de más de dos millones de salvadoreños en el sector rural. De acuerdo con datos del Ministerio de Agricultura y Ganadería (MAG), más del 82% de los productores operan en régimen de subsistencia en parcelas familiares menores a dos manzanas. En estas condiciones, una infección desatendida de tizón foliar o un ataque de gusano cogollero puede destruir entre el 50% y el 70% del rendimiento agrícola en pocas semanas, como se reflejó en la caída acumulada de un tercio de la producción nacional entre 2021 y 2023.

En la **Etapa 1** de este proyecto de investigación se sentaron las bases para abordar esta problemática mediante inteligencia artificial (*Edge AI*). Se recopiló y depuró un corpus inicial de 31 622 imágenes provenientes de repositorios públicos internacionales y se fijaron modelos de referencia (*baselines*) entrenados bajo un régimen controlado con un tope de 1 500 imágenes por clase (10 020 imágenes efectivas). Esos experimentos iniciales demostraron la viabilidad del enfoque: las tres arquitecturas ligeras evaluadas preentrenadas en ImageNet alcanzaron la meta preliminar de Macro $F_1 \geq 0.85$, lideradas por EfficientNet-B0 (0.9146), ShuffleNet-V2 (0.9030) y EfficientNet-Lite0 (0.8951).

No obstante, los análisis de la primera etapa pusieron al descubierto limitaciones severas que definieron la hoja de ruta para la presente Etapa 2:

1. **El cuello de botella de potasio y deficiencias:** Casi todo el error de los baselines se concentró en `potassium_deficiency` (con F_1 entre 0.49 y 0.62) y en la confusión recíproca dentro del bloque de clorosis nutricional (N/P/K). Se determinó que no era un fallo de capacidad de las redes, sino una escasez aguda de fotografías.
2. **Desbalance extremo del corpus:** La relación de desbalance alcanzaba un ratio de hasta 32.9 a 1 frente a la clase de hojas sanas.
3. **Falta de optimización formal y entrenamiento a escala real:** Los modelos iniciales operaron con hiperparámetros estándar sin afinar y sobre datos capados, posponiendo el

entrenamiento exhaustivo sobre el 100% del dataset.

4. **Incertidumbre sobre la generalización y el despliegue móvil:** Faltaba auditar cómo respondían los modelos ante fotografías de fuentes nunca vistas y trasladar los pesos de PyTorch a un prototipo móvil real que operase sin internet en el teléfono de un campesino.

Para responder a estos retos, en esta **Etapas 2** se amplió el corpus a **33 438 imágenes** incorporando cuatro repositorios dirigidos a deficiencias, se ejecutó un estudio bayesiano de optimización de hiperparámetros, se construyó un ensamble multimodelo de alta sensibilidad, se sometió el sistema a auditorías éticas y de procedencia, y se completó el despliegue operativo en una aplicación móvil Android nativa.

2 Optimización de Hiperparámetros

En esta etapa se desarrolló un pipeline automatizado de **Optimización Bayesiana de Hiperparámetros (HPO)** implementado con la librería **Optuna**, ejecutando múltiples ensayos (*trials*) en paralelo sobre instancias GPU NVIDIA A10G (24 GB VRAM) en la nube mediante Modal.

2.1 Metodología de búsqueda y espacio de configuración

La función objetivo del optimizador se orientó a maximizar el **Macro F_1 -Score** sobre el conjunto de validación oficial, penalizando de forma equitativa los fallos en patologías minoritarias. El muestreo probabilístico se realizó mediante el estimador de árbol de Parzen multivariado (*TPE Sampler*), que modela las dependencias e interacciones mutuas entre variables continuas y categóricas.

El espacio de búsqueda abarcó siete dimensiones operativas clave (Tabla 1):

Tabla 1: Espacio de búsqueda de hiperparámetros explorado con Optuna

Hiperparámetro	Espacio / Rango	Justificación Técnica
learning_rate	Log-uniforme: $[10^{-5}, 10^{-3}]$	Control de convergencia y estabilidad del gradiente en AdamW.
batch_size	Categórico: {16, 32, 64}	Estabilidad estocástica y saturación de memoria en GPU.
weight_decay	Log-uniforme: $[10^{-6}, 10^{-2}]$	Regularización L_2 para prevenir memorización de fondos.
class_weights	Categórico: {none, inv, sqrt_inv}	Ponderación de la pérdida frente al desbalance de clases.
label_smoothing	Uniforme: [0.0, 0.15]	Regularización para evitar sobreconfianza en probabilidades.
warmup_epochs	Entero: [1, 5]	Calentamiento lineal para preservar pesos de ImageNet.
clahe	Booleano: {True, False}	Ecuilización adaptativa para compensar sombras en campo.

2.2 Eficiencia mediante poda temprana (MedianPruner)

Uno de los principales factores de éxito en el estudio fue la incorporación del algoritmo de poda temprana **MedianPruner**. Este mecanismo compara el Macro F_1 intermedio de cada ensayo en épocas tempranas contra la mediana histórica de los ensayos precedentes. Si un modelo muestra una trayectoria deficiente hacia la época 3, el ensayo se detiene de forma automática (*PRUNED*), evitando desperdiciar tiempo de cómputo en combinaciones no prometedoras.

De los 15 ensayos corridos sobre la arquitectura de referencia EfficientNet-B0, 7 fueron podados rápidamente, completando únicamente los 6 ensayos más competitivos. Los ensayos podados requirieron en promedio 33 minutos frente a los 101 minutos de un ensayo completo, lo que representó un **ahorro neto de 7.9 horas de ejecución en GPU**.




Figura 1: Historial de optimización de Optuna sobre EfficientNet-B0.




Figura 2: Importancia de hiperparámetros evaluada por Random Forest.

2.3 Hallazgos clave e impacto vs. Baseline Etapa 2

El análisis de importancia derivado del estudio (Figura 2) y la comparación de resultados arrojaron tres conclusiones de alto valor:

1. **Dominancia del tamaño de lote y tasa de aprendizaje (> 75% del impacto):** La combinación de un lote mayor (`batch_size` = 64) con una tasa de aprendizaje moderadamente más alta (4.55×10^{-4}) estabilizó el gradiente promedio, facilitando que el optimizador

escapara de mínimos locales ruidosos.

2. **Superioridad matemática de `sqrt_inverse`:** La ponderación sin pesos (`none`) causó pérdidas severas en las deficiencias, mientras que la inversa estricta (`inverse`) sobrepenalizó a la clase sana. La raíz cuadrada inversa logró el balance óptimo para el desbalance del corpus.
3. **Descarte de CLAHE:** Optuna determinó que la ecualización adaptativa no aportaba ventajas (`clahe = False`), demostrando que las capas convolucionales aprenden invarianza a la iluminación de forma intrínseca.

La configuración óptima obtenida (Trial #12) mejoró al baseline de esta nueva etapa (con el dataset completo) sobre el conjunto de prueba independiente (Tabla 2).

Tabla 2: Comparativa cuantitativa: Baseline Etapa 2 Sin Optuna vs. Configuración Optimizada (Optuna)

Métrica / Hiperparámetro	Sin Optuna	Optimizada Optuna	Delta / Impacto
Macro F_1 en Validación	0.9551	0.9553	+0.02 pp
Macro F_1 en Prueba Retenida	0.9426	0.9483	+0.57 pp netos
Learning Rate	1.00×10^{-4}	4.55×10^{-4}	4.5× más ágil con Warmup
Batch Size	32	64	Mayor saturación de GPU
Ponderación de Pérdida	Sin ponderar	<code>sqrt_inverse</code>	Mitiga desbalance de clases
Label Smoothing	0.00	0.10	Probabilidades calibradas

2.4 Comportamiento cruzado entre arquitecturas

Un hallazgo metodológico de gran relevancia técnica ocurrió al transferir los hiperparámetros del Trial #12 a las otras dos arquitecturas del proyecto:

- En **ShuffleNet-V2-x1.0**, la configuración optimizada elevó el Macro F_1 de 0.9237 a **0.9330** (+0.93 pp).
- En **EfficientNet-Lite0** (la arquitectura destinada a la aplicación móvil), la configuración produjo el efecto contrario, reduciendo el Macro F_1 a 0.9343.

La causa es de naturaleza estructural: `EfficientNet-Lite0` prescinde de los bloques de atención *Squeeze-and-Excitation* y reemplaza las activaciones *swish* por ReLU6 para permitir cuantización rápida a enteros de 8 bits. Al no poseer capas de atención que recalibren dinámicamente los canales, no tolera tasas de aprendizaje elevadas y prefiere converger con suavidad en la época 35 bajo su tasa base (10^{-4} y lote 32), alcanzando **0.9468** en la corrida desplegada y 0.9430 ± 0.0122 como valor esperado sobre tres semillas. Por tanto, en concordancia con el principio de rigor empírico, se decidió mantener a `Lite0` en sus parámetros base para producción y adoptar los optimizados para las redes acompañantes del ensamble.

3 Modelos Avanzados y Ensamble Multimodelo

Para alcanzar el máximo nivel de bioseguridad en el diagnóstico, se adoptó una estrategia multimodelo basada en técnicas modernas de *Deep Learning*. Entrenar una única red neuronal concentra el riesgo diagnóstico en los sesgos representacionales de esa arquitectura. Por el contrario, un ensamble heterogéneo permite que distintas familias convolucionales compensen mutuamente sus zonas ciegas.

3.1 Arquitecturas y diversidad inductiva

Se seleccionaron tres arquitecturas convolucionales avanzadas con sesgos inductivos (*inductive bias*) profundamente dispares:

1. **EfficientNet-B0 (MBConv con atención):** Diseño con escalado compuesto de profundidad y ancho, provisto de módulos Squeeze-and-Excitation que asignan pesos de importancia a cada canal convolucional (4.02 millones de parámetros).
2. **ShuffleNet-V2-x1.0 (Channel Split y Shuffle):** Arquitectura ultra-eficiente que divide las características en dos ramas y baraja los canales para comunicar información sin elevar el costo de acceso a memoria (1.26 millones de parámetros).
3. **EfficientNet-Lite0 (MBConv sin atención):** Variante adaptada para dispositivos móviles, libre de activaciones trascendentes y orientada a la cuantización Int8 (3.38 millones de parámetros).

Las tres redes se entrenaron sobre el conjunto completo de 33 438 imágenes utilizando programador de tasa de aprendizaje por coseno con calentamiento lineal (*Cosine Annealing with Warmup*) durante 3 épocas y parada temprana con paciencia de 8 épocas (Figura 3).




Figura 3: Curvas de convergencia de pérdida y Macro F_1 durante el entrenamiento en Modal.

3.2 Mecanismo de agregación: Soft Voting

El ensemble opera mediante votación suave (*Soft Voting*), promediando las distribuciones de probabilidad posterior emitidas por la función Softmax de cada red:

$$P_{\text{ens}}(y = c \mid x) = \frac{1}{M} \sum_{m=1}^M P_m(y = c \mid x) \quad (1)$$

donde $M = 3$ y $c \in \{1, \dots, 9\}$. La clase predicha final corresponde a la que maximiza el consenso: $\hat{y} = \arg \max_c P_{\text{ens}}(y = c \mid x)$.

3.3 Resultados y sensibilidad fitosanitaria (Recall = 95.06%)

Al evaluar el ensemble frente a los modelos individuales sobre el conjunto de prueba independiente (5 015 imágenes), la combinación superó a todas las arquitecturas en cada una de las métricas globales (Tabla 3 y Figura 4).

Tabla 3: Desempeño cuantitativo del Ensemble vs. Modelos Individuales en Test

Modelo / Configuración	Accuracy	Macro F_1	Precision	Recall
ShuffleNet-V2-x1.0	97.31%	0.9330	0.9388	0.9298
EfficientNet-Lite0 (móvil desplegada)	97.91%	0.9468	0.9533	0.9413
EfficientNet-B0 (referencia individual)	97.97%	0.9483	0.9589	0.9400
Soft Voting Ensemble (3 modelos)	98.29%	0.9567	0.9642	0.9506
<i>Ganancia neta vs. Mejor individual</i>	<i>+0.32 pp</i>	<i>+0.84 pp</i>	<i>+0.53 pp</i>	<i>+1.06 pp</i>




Figura 4: Comparativa de métricas del ensemble frente a los modelos individuales en prueba.

El aporte más contundente del ensemble reside en el **Macro Recall de 95.06%**. En fitopatología, el costo de un falso negativo es devastador: no alertar al agricultor sobre una lesión incipiente significa permitir la propagación del hongo. Como demuestra la matriz de confusión (Figura 5), patologías altamente destructivas como la **necrosis letal del maíz (MLN)** alcanzaron un **Recall perfecto del 100%** (963 aciertos sobre 963 casos, sin un solo caso omitido), mientras que la roya común y el tizón superaron el 98% de detección.




Figura 5: Matriz de confusión normalizada del ensamble sobre las 5 015 muestras de prueba.

3.4 Estrategia de despliegue dual

Estos resultados sustentan una arquitectura de despliegue en dos niveles:

- **Nivel 1 (Móvil Offline):** En la parcela sin internet, el teléfono ejecuta `EfficientNet-Lite0` cuantizado a `Int8`, entregando respuestas en 60 ms con un sólido F_1 de 0.9468.
- **Nivel 2 (Nube / API para Extensión):** Cuando hay conectividad o cuando técnicos agrícolas revisan diagnósticos en el servidor, un backend podría correr el **ensamble completo** alcanzando el 95.67% de F_1 para resolver casos complejos.

Cabe aclarar que para este proyecto solo se desplegó el nivel 1 en la aplicación móvil **Doctor-Maiz**, mientras que el nivel 2 queda como una opción futura para extensión de servicios.

4 Evaluación Rigurosa y Métricas Finales

Una evaluación honesta en visión artificial requiere poner a prueba los límites del sistema frente a diferentes protocolos de partición de datos, examinando si los indicadores reflejan estabilidad matemática o simples coincidencias en los datos de prueba.

4.1 Evaluación sobre el conjunto de prueba retenido

El conjunto de evaluación final se conformó con **5 015 imágenes** estrictamente independientes. La Tabla 4 detalla el comportamiento del modelo desplegado (*EfficientNet-Lite0*) y del ensamble multimodelo a través de las nueve categorías.

Tabla 4: Rendimiento fitosanitario desglosado por clase en el conjunto de prueba retenido

Clase Agronómica	Muestras	Lite0 (F_1)	B0 (F_1)	ShuffleNet (F_1)	Ensamble (F_1)
Necrosis Letal (MLN)	963	0.9990	0.9984	0.9974	1.0000
Planta Sana (Healthy)	1 311	0.9936	0.9954	0.9901	0.9958
Roya Común (Common Rust)	338	0.9866	0.9896	0.9867	0.9882
Gusano Cogollero	728	0.9814	0.9877	0.9815	0.9856
Tizón Foliar (NCLB)	1 025	0.9797	0.9769	0.9728	0.9809
Mancha Gris (GLS)	290	0.9451	0.9194	0.9120	0.9388
Deficiencia de Fósforo	140	0.9403	0.9527	0.9275	0.9632
Deficiencia de Nitrógeno	127	0.8664	0.8939	0.8613	0.9057
Deficiencia de Potasio	93	0.8290	0.8208	0.7674	0.8475
Promedio Macro F_1	5 015	0.9468	0.9483	0.9330	0.9567

Las patologías foliares tradicionales superan el 98% de F_1 . La resolución del cuello de botella de la Etapa 1 es patente: `potassium_deficiency`, que en la primera etapa caía a 0.49, asciende ahora a **0.8475** en el ensamble y a 0.8290 en Lite0, gracias a la ampliación de imágenes y a la pérdida ponderada `sqrt_inverse`.

4.2 El experimento cruzado 2×2 : Estratificada vs. Agrupada

Para auditar si el modelo aprendió a generalizar o memorizó las sesiones de los datasets, se diseñó un experimento cruzado 2×2 de validación cruzada en 5 pliegues sobre

EfficientNet-Lite0, contrastando la partición estratificada ordinaria frente a una partición agrupada por procedencia (*SourceGroupedKFold*) que impide cualquier solapamiento de fuentes entre entrenamiento y validación (Figura 6).




Figura 6: Experimento cruzado 2×2 : partición estratificada vs. agrupada por fuente.

Tabla 5: Resultados del experimento cruzado 2×2 de validación cruzada

Configuración	CV Estratificada (5 folds)	CV Agrupada por Fuente	Caída (Δ)
Configuración Base	0.9311 ± 0.0099	0.6026 ± 0.1240	-0.3286
Configuración de B0	0.9463 ± 0.0052	0.6499 ± 0.1508	-0.2964
Fuentes en validación	14 de 14 (100% solapadas)	0 solapadas con entrenamiento	—

El impacto del protocolo de partición (-0.33) es veintidós veces mayor que el impacto del ajuste de hiperparámetros ($+0.015$).

En la partición estratificada tradicional, las 14 fuentes aparecen simultáneamente en entrenamiento y prueba, arrojando una falsa sensación de precisión con un intervalo diminuto (± 0.0099). Pero al evaluar fuera de fuente, con las 14 procedencias repartidas en 5 pliegues disjuntos mediante *StratifiedGroupKFold*, el Macro F_1 real desciende a 0.6026 ± 0.1240 . Esta brecha cuantitativa de 0.34 puntos confirma que un clasificador entrenado únicamente bajo los conjuntos públicos recopilados en este proyecto se apoya sustancialmente en la firma visual de la fuente, es su límite.

4.3 Estabilidad entre semillas

Para disponer de una escala con la que juzgar el tamaño de cualquier diferencia reportada, la configuración de producción de `EfficientNet-Lite0` se reentrenó con tres semillas distintas sobre la **misma partición materializada**, de modo que la única fuente de variación es la inicialización y el barajado (Tabla 6).

Tabla 6: Variabilidad del Macro F_1 en prueba retenida entre semillas de entrenamiento

Semilla	Macro F_1 en prueba	Épocas	Mejor época
42 (modelo desplegado)	0.9468	43	35
1	0.9448	60	53
2	0.9375	32	24
Media	0.9430 ± 0.0122	—	—
<i>Desviación estándar</i>	$\sigma = 0.0049$	—	—

El valor esperado de esta configuración es **0.9430** con un intervalo de confianza al 95% de ± 0.0122 ; el **0.9468** del modelo desplegado es la más alta de las tres corridas.




Figura 7: Impacto de las decisiones medido en múltiplos de desviación estándar (σ).

Como ilustra la Figura 7, la decisión de partición representa un impacto de **más de 66σ** , mientras que el ensamble y el ajuste de hiperparámetros se mueven entre 1.2σ y 2.5σ respecto al ruido natural entre semillas.

5 Análisis de Sesgos y Ética

El despliegue de tecnologías de aprendizaje automático en la agricultura familiar demanda una rigurosa evaluación de equidad (*Fairness*) para garantizar que la herramienta no perjudique a productores con condiciones fotográficas rústicas.

5.1 Equidad entre entornos: Laboratorio vs. Campo Real

Se auditó el desempeño de `EfficientNet-Lite0` desglosando el conjunto de prueba entre fotos en condiciones controladas de laboratorio ($N = 532$) y fotos en condiciones auténticas de campo ($N = 4\,483$).

Tabla 7: Métricas de equidad desagregadas por entorno fotográfico

Subgrupo	Muestras	Accuracy	Macro F_1 (evaluable)	Disparidad (DIR)
Campo Real (<code>real</code>)	1 121	97.77%	0.9050	
Laboratorio (<code>lab</code>)	532	96.80%	0.9423	
<i>Disparate Impact Ratio</i>	—	$DIR_{Acc} = 0.9901$	$DIR_{F_1} = 0.9604$	

Sobre esa base comparable, la disparidad en exactitud es de **0.97 puntos porcentuales** y ambos *Disparate Impact Ratio*, 0.9901 en exactitud y 0.9604 en Macro F_1 , superan con holgura el umbral regulatorio del 80% (Figura 8). El sentido de la disparidad se invierte según la métrica: campo real acierta más en conjunto, y laboratorio reparte mejor el acierto entre las tres clases.




Figura 8: Equidad por entorno sobre las tres clases comparables.




Figura 9: Matrices de confusión en campo real y laboratorio.

Al examinar las matrices de confusión (Figura 9), el panel izquierdo (azul) corresponde al entorno de laboratorio, donde los repositorios públicos históricos únicamente registran tres clases (*roya*, *mancha gris* y *tizón*), razón por la cual las seis clases restantes presentan soporte nulo (filas en blanco/cero). En contraposición, el panel derecho (verde) evalúa el comportamiento en campo real cubriendo las nueve clases completas. Se constata que en laboratorio el modelo no genera falsos positivos hacia categorías ausentes, y en campo real preserva una diagonal sólida, localizándose las confusiones menores entre síntomas visualmente convergentes (como roya frente a tizón, o la clorosis recíproca entre deficiencias nutricionales).

La desagregación por clase dentro de cada entorno descubre una asimetría (Tabla 8). La **roya común** es prácticamente infalible en laboratorio (1 fallo sobre 322 imágenes) y **falla en casi un tercio de los casos en campo real** (5 fallos sobre 16). Es el reflejo directo de la composición del corpus: el 95% de las imágenes de roya del conjunto de prueba proceden de repositorios de laboratorio, de modo que el modelo aprendió la patología bajo fondo controlado y no la reconoce con fiabilidad sobre vegetación. La **mancha gris** tiene el patrón inverso y más favorable.

Tabla 8: Tasa de falsos negativos por clase y entorno en las tres clases compartidas

Clase	<i>FNR laboratorio</i>	<i>N</i>	<i>FNR campo real</i>	<i>N</i>
Roya Común	0.31%	322	31.25%	16
Mancha Gris (GLS)	15.58%	77	5.16%	213
Tizón Foliar (NCLB)	3.01%	133	1.01%	892

5.2 Prueba de oclusión espacial (Clever Hans Check)

Para verificar si la red atiende a la patología o al entorno, se realizó una auditoría de oclusión geométrica sobre las 5 015 imágenes de prueba, contrastando el resultado contra un predictor nulo constante (Tabla 9). La máscara es un rectángulo fijo que abarca del 20% al 80% de cada eje, al ocluir el centro se tapa el 36.3% del área y queda visible un anillo periférico del 63.7%, al ocluir la periferia se tapa ese 63.7% y queda visible la caja central del 36.3%. Es una máscara geométrica, no anatómica, es decir que no aísla la lesión ni la lámina foliar, sino regiones de la escena.

Tabla 9: Auditoría de ablación espacial con control nulo en el conjunto de prueba

Condición de Inferencia	Región Visible	Área visible	Accuracy	Exceso s/Nulo	Conf. Retenida
Imagen completa original	Toda la escena	100.0%	97.91%	+71.77 pp	100.0%
Oclusión central	Anillo periférico	63.7%	79.46%	+53.32 pp	69.16%
Oclusión periférica	Caja central	36.3%	42.25%	+16.11 pp	42.66%
Control nulo (sin imagen)	Clase mayoritaria	0.0%	26.14%	0.0 pp	—




Figura 10: Exactitud del modelo según la región visible frente a la línea de azar nulo.

Responder siempre *healthy*, la clase más frecuente con 1 311 de las 5 015 imágenes, ya acierta el **26.14%** sin mirar un píxel. Ese predictor constante es el control nulo y la columna de exceso mide lo que cada condición añade sobre él.

Al tapar el centro, donde el encuadre habitual del corpus sitúa la lámina foliar, el modelo conserva el **79.46%**, esto es **+53.32 puntos sobre el nulo**.

Queda establecido que **la región exterior porta por sí sola una fracción sustancial de la información de clase**, pero no que el fondo pese más que la hoja: las dos condiciones no están igualadas en área, ya que el anillo muestra 1.75 veces más píxeles que la caja central. La comparación rigurosa es la de cada condición contra el nulo, y ambas lo superan, la caída de 18.45 puntos al tapar el centro demuestra que este aporta señal propia.

Cada repositorio se fotografió con su propio suelo, luz y sensor, y cuatro de las catorce fuentes contienen una sola clase: **la periferia no predice la enfermedad, predice el repositorio, y el repositorio acota la enfermedad**. Es lo mismo que arroja desde otro ángulo la Tabla 5, donde el Macro F_1 cae a 0.6026 al evaluar fuentes nunca vistas.

Con esto se puede concluir que en una parcela salvadoreña el suelo y la luz no se parecen a los del corpus, de modo que esa evidencia deja de ayudar y puede confundir.

Recortar el fondo mediante un segmentador automático a negro degradó el Macro F_1 a 0.7191,

esta caída mezcla dos efectos: la pérdida del atajo de procedencia, y los errores de la propia segmentación, que sobre clases de fondo poco contrastado rechaza o recorta tejido legítimo.

5.3 Auditoría visual con Grad-CAM y SHAP

Para auditar cualitativamente la atención, se generaron mapas de activación con Grad-CAM y valores de importancia con SHAP (Figuras 11 y 12).




Figura 11: Mapas de activación Grad-CAM en muestras de campo real y laboratorio.




Figura 12: Panel comparado de interpretabilidad con segmentación SLIC: LIME, SHAP y Grad-CAM.

En tomas de campo bien encuadradas, los paneles sitúan los gradientes principales sobre las lesiones necróticas y las pústulas fúngicas. Pero esa lectura visual no basta como evidencia, ya que la lámina foliar ocupa el centro y la mayor parte del cuadro en prácticamente todo el corpus, de modo que una atribución repartida al azar también recaería mayoritariamente sobre la hoja. Para separar ambos efectos se midió el **exceso de atribución**: la fracción de atribución positiva que cae sobre el tejido foliar menos la cobertura de la máscara de hoja, que es el nivel de azar correspondiente a cada imagen.

Tabla 10: Exceso de atribución sobre el tejido foliar frente a su nivel de azar

Clase	<i>N</i>	Atribución en hoja	Cobertura (azar)	Exceso
Roya Común	29	0.897	0.703	+0.193
Deficiencia de Fósforo	28	0.474	0.378	+0.096
Deficiencia de Nitrógeno	23	0.352	0.302	+0.051
Tizón Foliar (NCLB)	30	0.575	0.584	−0.009
Planta Sana	30	0.538	0.578	−0.040
Mancha Gris (GLS)	26	0.570	0.639	−0.069
Media de las seis clases	—	—	—	+0.037

El perfil se calculó sobre 270 imágenes (30 por clase), empleando como máscara de hoja la segmentación producida por el modelo del repositorio `maize-doctor-segmenter`. Las tres clases restantes —*gusano cogollero*, *necrosis letal* y *deficiencia de potasio*— quedan fuera de la tabla porque su máscara (debido a los límites del segmentador entrenado) alcanza coberturas de entre 0.54 y 0.86 y el control de calidad rechaza entre el 37% y el 57% de sus imágenes, de modo

que su ratio no es interpretable.

El resultado es que **el exceso medio es de +0.037 y su signo se reparte: tres clases por encima del azar y tres por debajo**. La atribución sobre la hoja no supera de forma consistente la que produciría una atención repartida en proporción al área. Únicamente la roya común exhibe una concentración foliar netamente superior a su nivel de azar.

Este resultado no contradice la prueba de oclusión, porque ambas técnicas responden a preguntas distintas. Grad-CAM y SHAP son métodos de atribución *local*: miden la contribución de cada región **mientras el resto de la imagen sigue presente**, y premian la evidencia concentrada y de alto contraste, como es una lesión. La ablación mide la *suficiencia*: cuánto acierto sobrevive cuando todo lo demás se elimina. La firma de procedencia de un repositorio, como la paleta cromática, iluminación, ruido de sensor, textura del suelo, es un estadístico de baja frecuencia repartido sobre decenas de miles de píxeles: cada píxel aporta poco, por lo que nunca aparece como un punto caliente en un mapa de atribución, pero el agregado carga información de clase suficiente para sostener el 79.46% de acierto de la Tabla 9.

6 Prototipo Funcional y Despliegado

El objetivo último de este proyecto no es acumular checkpoints en la nube, sino poner una herramienta operativa en las manos de campesinos y promotores agrícolas. Se construyó la aplicación móvil nativa **DoctorMaiz**, desarrollada en React Native y TypeScript sobre Expo, con motor de inferencia completamente desconectado (*offline*).

6.1 Optimización para el borde: Cuantización Int8 a 3.56 MB

Para cumplir con las restricciones de hardware rural (dispositivos de gama media/baja con procesadores Snapdragon serie 6xx o MediaTek), el checkpoint de `EfficientNet-Lite0` fue exportado a TensorFlow Lite cuantizado simétricamente a enteros de 8 bits (**Int8**):

- **Reducción de tamaño:** El archivo pasó de 12.92 MB (FP32) a apenas **3.56 MB** (Int8), logrando una compresión del 72% sin pérdida detectable de exactitud.
- **Consumo de memoria RAM:** Inferior a 85 MB en tiempo de ejecución, garantizando compatibilidad con teléfonos de 3 GB y 4 GB de RAM.
- **Operación 100% offline:** Todo el grafo, los pesos y el cálculo de softmax se resuelven en la CPU local mediante C++ (`react-native-fast-tflite`), sin enviar ninguna foto a internet.

6.2 Pruebas de latencia en hardware real (Motorola edge 40 neo)

El prototipo final fue instalado y medido en un dispositivo físico auténtico: un smartphone **Motorola edge 40 neo** (procesador MediaTek Dimensity 7030, 8 núcleos a 2.5 GHz, pantalla 1080×2400 px, Android 15).

Las mediciones instrumentadas mediante `adb logcat` arrojaron tiempos sobresalientes (Tabla 11):

Tabla 11: Tiempos de ejecución por etapa medidos en el dispositivo móvil físico

Etapa del Flujo	Mediana	Promedio	Mínimo	Máximo	Descripción Operativa
Preprocesado	41 ms	157 ms	19 ms	675 ms	Decodificación JPEG, orientación EXIF y escalado bilineal.
Inferencia TFLite	60 ms	68 ms	34 ms	141 ms	Cálculo del modelo Int8 en CPU móvil.
Pipeline Total	473 ms	548 ms	336 ms	977 ms	Captura, persistencia SQLite local y renderizado de UI.

La inferencia toma apenas **60 milisegundos**, cumpliendo con holgura extrema la meta técnica de ≤ 300 ms. La experiencia de usuario se percibe instantánea.

6.3 Interfaz y soluciones de Experiencia de Usuario (UX)

La aplicación incorpora cuatro innovaciones clave adaptadas al campo salvadoreño, cada una respondiendo a una limitación concreta detectada en el análisis del modelo:




Figura 13: Pantalla de inicio. Figura 14: Cámara con marco guía. Figura 15: Resultado diagnóstico.

1. **Cámara con marco guía (Figura 14):** Para neutralizar el atajo del fondo descubierto en el análisis de sesgos, el visor superpone la silueta de una hoja e instruye: «Acérquese a 20–30 cm y llene el marco». La app recorta automáticamente el 24% central de la foto (3.02 MP a partir del sensor de 12.6 MP), descartando tres cuartas partes del fondo engañoso antes de inferir.
2. **Detector OOD por distancia de Mahalanobis (Figura 16):** Para evitar diagnósticos falsos frente a manos, tierra o malezas ajenas, el modelo extrae el vector de características (1 280 dimensiones) y calcula la distancia relativa de Mahalanobis (RMD) reducida por

PCA a 186 componentes. Si la distancia supera el percentil 95 calibrado (31.47), la pantalla muestra prudentemente: «**Imagen no reconocida**» en lugar de inventar una enfermedad.

3. **Módulo de contribución comunitaria (Figura 17):** Permite al agricultor guardar fotos y etiquetas para subirlas al backend cuando haya señal, resolviendo la brecha de datos con fotos genuinas de El Salvador.
4. **Guía de severidad en lenguaje natural (Figura 18):** El clasificador dice qué tiene la hoja, pero no cuánto. Una hoja con tres pústulas sueltas y otra con la lámina entera destruida salen de la red con la misma etiqueta y una confianza prácticamente igual, porque el modelo nunca aprendió a medir área foliar afectada. Y no lo aprendió por una razón sencilla, que es que las imágenes del corpus vienen etiquetadas por clase y nada más. Añadirles un grado de daño no sería cuestión de limpiar datos sino de sentar a un fitopatólogo a calificar imagen por imagen con la escala que corresponda a cada patógeno, que son distintas entre sí (la Cobb modificada para roya, la de Vieira *et al.* para tizón del norte, la de Brito *et al.* para mancha gris, la ordinal del CIMMYT para necrosis letal, la de Davis *et al.* para cogollero). Aun con ese trabajo hecho, repartir en tres grados unas clases que apenas rondan las 300 imágenes dejaría celdas de dos dígitos, demasiado pequeñas para entrenar.

La app cubre ese hueco haciendo que debajo del diagnóstico aparezcan los niveles de severidad de la enfermedad detectada, reescritos en lenguaje natural, y el agricultor compara su hoja con ellos y decide. Cada nivel indica cuánta hoja suele comprometer, qué se ve a simple vista y qué hacer al respecto según manejo integrado de plagas. Los textos provienen del catálogo de escalas homologadas por CIMMYT, Embrapa, Iowa State University Extension e IPNI, se conservaron los umbrales y los nombres de los bioinsumos, que es lo que el productor va a pedir en la agroservicio, y se quitaron la nomenclatura binomial y las siglas patométricas.




Figura 16: Rechazo seguro por el detector OOD.



Figura 17: Pantalla de aporte de datos.




Figura 18: Guía de severidad bajo el resultado de inferencia, con el segundo nivel desplegado.

7 Análisis de Impacto Social y Recomendaciones de Política Pública

La viabilidad de una solución de inteligencia artificial en el sector agropecuario no se mide únicamente por su puntuación de F1, sino por su capacidad para transformar las condiciones de vida de los sectores más vulnerables y encajar en las políticas públicas del país.

7.1 Recomendaciones de política pública aplicables

Para traducir los avances técnicos de este proyecto en acciones, se proponen cinco medidas de política pública dirigidas al Ministerio de Agricultura y Ganadería (MAG) y al CENTA:

7.1.1 1. Adopción a futuro de DoctorMaiz como herramienta oficial de extensión

El MAG puede homologar la aplicación móvil como herramienta de apoyo digital de bolsillo para los más de 300 extensionistas y promotores agrícolas comunitarios del CENTA. Su funcionamiento offline permite que el técnico emita diagnósticos estandarizados en caseríos remotos de Cabañas o Morazán sin consumir datos móviles, complementando el juicio agronómico presencial y reduciendo el tiempo de atención.

7.1.2 2. Red Nacional de Alerta Fitosanitaria Temprana

Aprovechando el módulo de sincronización de la app, cada escaneo realizado por productores o extensionistas puede almacenar de forma anónima las coordenadas GPS aproximadas y la fecha del diagnóstico. Cuando el dispositivo detecte conexión, esos registros alimentarían un **Tablero Epidemiológico Nacional** en el MAG, detectando en tiempo real la dispersión geográfica de plagas cuarentenarias (como la necrosis letal o rebrotes de roya) para activar cordones fitosanitarios semanas antes de que se conviertan en desastres nacionales.

7.1.3 3. Creación del Banco Nacional Participativo de Datos Agrícolas

La auditoría de procedencia de este proyecto demostró que entrenar con fotos de África o India limita la generalización en El Salvador. El Estado puede financiar brigadas de captura fotográfica participativa, articuladas con estudiantes de la Universidad de El Salvador (UES) y escuelas agrícolas, para nutrir un repositorio soberano de imágenes de variedades locales (como el híbrido H-59 y maíces criollos), recalibrando periódicamente los modelos para cerrar la brecha de dominio que ha sido el principal hallazgo y limitación de la Etapa 2.

7.1.4 4. Campañas comunitarias de alfabetización digital agropecuaria

El despliegue de la aplicación debe acompañarse de talleres prácticos en cooperativas agrícolas y ADESCOs, enseñando a los productores el uso correcto del marco guía de la cámara y la interpretación del detector OOD. La tecnología debe presentarse como un «*asistente de apoyo*» y no como un reemplazo del saber campesino, fomentando la confianza y evitando la exclusión de adultos mayores o mujeres productoras.

7.1.5 5. Soberanía tecnológica y protección de datos campesinos

El código fuente, las arquitecturas y los pesos cuantizados de DoctorMaiz deben mantenerse bajo licencias de código abierto (*Open Source*, Apache 2.0 o MIT). El Estado no debe ceder la propiedad de los modelos agronómicos a corporaciones transnacionales de semillas o agroquímicos, garantizando que el patrimonio de datos del maíz pertenezca a la sociedad salvadoreña y protegiendo la privacidad de los productores frente a cualquier explotación comercial de su información.

8 Conclusiones y Trabajo Futuro

La Etapa 2 de este proyecto de investigación consolida la transición desde la prueba de concepto preliminar hacia un sistema integral, riguroso y desplegado operativamente en dispositivos móviles.

8.1 Conclusiones principales

1. **Superación de metas de desempeño:** El ensamble heterogéneo por voto suave alcanzó un Macro F_1 de **0.9567** y una exactitud de **98.29%**, superando con holgura el umbral de viabilidad del proyecto ($F_1 \geq 0.85$).
2. **Resolución del cuello de botella de potasio:** La incorporación de nuevos datasets dirigidos y la función de pérdida `sqrt_inverse` permitieron elevar el F_1 de `potassium_deficiency` desde 0.49 (Etapa 1) hasta **0.8475**, mitigando el sesgo hacia las clases mayoritarias.
3. **Descubrimiento crítico sobre la brecha de dominio:** La validación cruzada agrupada por procedencia demostró que evaluar fuera de fuente reduce el F1 a **0.6026**, evidenciando que las redes convolucionales son vulnerables a memorizar el fondo y la cámara de los repositorios públicos recopilados en este proyecto. Las intervenciones algorítmicas alcanzaron un techo, dando como conclusión que la solución definitiva es la captura de datos locales.
4. **Prototipo móvil de alta eficiencia:** Se logró compilar `EfficientNet-Lite0` a Int8 ocupando apenas **3.56 MB**, con una latencia de inferencia de **60 ms** en un teléfono físico Motorola edge 40 neo. El encuadre se resolvió con un marco guía foliar y la salida quedó protegida por un detector de anomalías OOD. Como el corpus no trae anotaciones de nivel de daño, la interfaz acompaña cada etiqueta con una guía de severidad escrita en lenguaje natural, que le devuelve al agricultor el juicio que el modelo no puede emitir.

8.2 Trabajo futuro y transición a campo

- **Piloto de validación en cooperativas salvadoreñas:** Desplegar la aplicación en campo con agricultores evaluando la adopción y usabilidad real del marco guía en condiciones de luz solar intensa.
- **Alimentación del Banco de Datos Nacional:** Integrar las primeras 1 000 fotografías capturadas en parcelas locales mediante el módulo de contribución para realizar un *fine-tuning* regional de los pesos del modelo.
- **Anotación de severidad para predecir el grado de daño:** Calificar un subconjunto del corpus con las escalas diagramáticas homologadas, de la mano de fitopatólogos del CENTA, abriría la puerta a una cabeza de regresión ordinal capaz de estimar el nivel además de la clase.
- **Modelos en cascada con segmentación liviana en servidor:** Evaluar en el backend en la nube la incorporación de un detector ligero (YOLOv8-Nano) que aísle la hoja antes del ensamble cuando se reciban imágenes con encuadres lejanos, para intentar mejorar la robustez frente a fotos de campo con mucho fondo.

9 Referencias

- Ahmad, A., El Gamal, A., & Saraswat, D. (2023a). Toward generalization of deep learning-based plant disease identification under controlled and field conditions. *IEEE Access*, 11, 9042–9057.
- Ahmad, A., El Gamal, A., & Saraswat, D. (2023b). Towards generalization of deep learning-based plant disease identification under controlled and field conditions. Purdue e-Pubs. <https://docs.lib.purdue.edu/fund/58/>
- Baya, J. et al. (2024). A mobile-based system for maize leaf disease detection and classification using machine learning algorithms and deep learning: A case study of ZeaWatch. Preprint.
- Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 248–255). Miami, FL, USA.
- Gulrajani, I., & Lopez-Paz, D. (2021). In search of lost domain generalization. En *International Conference on Learning Representations (ICLR)*.
- Howard, A. G., et al. (2017). MobileNets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*.
- Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 7132–7141). Salt Lake City, UT, USA.
- Lee, K., Lee, K., Lee, H., & Shin, J. (2018). A simple unified framework for detecting out-of-distribution samples and adversarial attacks. En *Advances in Neural Information Processing Systems (NeurIPS)*, 31.

- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 4765–4774. Long Beach, CA, USA.
- Ma, N., Zhang, X., Zheng, H.-T., & Sun, J. (2018). ShuffleNet V2: Practical guidelines for efficient CNN architecture design. En *Proceedings of the European Conference on Computer Vision (ECCV)* (pp. 116–131). Munich, Germany.
- Molnar, C. (2022). *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable* (2nd ed.). <https://christophm.github.io/interpretable-ml-book/>
- Ren, J., Fort, S., Liu, J., Roy, A. G., Padhy, S., & Lakshminarayanan, B. (2021). A simple fix to Mahalanobis distance for improving near-OOD detection. *arXiv preprint arXiv:2106.09022*.
- Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). “Why should I trust you?”: Explaining the predictions of any classifier. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)* (pp. 1135–1144). San Francisco, CA, USA.
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 618–626). Venice, Italy.
- Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. En *Proceedings of the 36th International Conference on Machine Learning (ICML)* (pp. 6105–6114). Long Beach, CA, USA.