UNIVERSIDAD DE EL SALVADOR

FACULTAD DE INGENIERÍA Y ARQUITECTURA

ESCUELA DE INGENIERÍA DE SISTEMAS INFORMÁTICOS

CURSO DE ESPECIALIZACIÓN EN MACHINE LEARNING

DISEÑO E IMPLEMENTACIÓN DE DOCTOR MAÍZ: SISTEMA MÓVIL BASADO EN REDES NEURONALES CONVOLUCIONALES PARA LA IDENTIFICACIÓN FITOSANITARIA EN HOJAS DE MAÍZ Y CONTRIBUCIÓN A UN CONJUNTO DE DATOS NACIONAL

PRESENTADO POR:

JOSÍAS ABNER RIVAS FUENTES

DAVID ALEJANDRO DERAS CERROS

ELMER EDENILSON ROSALES MOLINA

PARA OPTAR AL TÍTULO DE:

INGENIERO(A) DE SISTEMAS INFORMÁTICOS

CIUDAD UNIVERSITARIA, 24 DE NOVIEMBRE DE 2026

UNIVERSIDAD DE EL SALVADOR

RECTOR:

MSC. JUAN ROSA QUINTANILLA

SECRETARIO GENERAL:

LCDO. PEDRO ROSALIO ESCOBAR CASTANEDA

FACULTAD DE INGENIERÍA Y ARQUITECTURA

DECANO:

MSC. LUIS SALVADOR BARRERA MANCÍA

SECRETARIO:

ARQ. RAÚL ALEXANDER FABIÁN ORELLANA

ESCUELA DE INGENIERIA DE SISTEMAS INFORMÁTICOS

DIRECTOR:

MSC. CESAR AUGUSTO GONZÁLEZ RODRÍGUEZ

UNIVERSIDAD DE EL SALVADOR

FACULTAD DE INGENIERIA Y ARQUITECTURA

ESCUELA DE INGENIERIA DE SISTEMAS INFORMÁTICOS

Trabajo de Graduación previo a la opción al Grado de:

INGENIERO (A) DE SISTEMAS INFORMÁTICOS

Título:

“DISEÑO E IMPLEMENTACIÓN DE DOCTOR MAÍZ: SISTEMA MÓVIL BASADO EN REDES NEURONALES CONVOLUCIONALES PARA LA IDENTIFICACIÓN FITOSANITARIA EN HOJAS DE MAÍZ Y CONTRIBUCIÓN A UN CONJUNTO DE DATOS NACIONAL”

Presentado por:

JOSÍAS ABNER RIVAS FUENTES

DAVID ALEJANDRO DERAS CERROS

ELMER EDENILSON ROSALES MOLINA

Trabajo de Graduación Aprobado por:

Docentes Asesores:

ING. BLADIMIR DIAZ CAMPOS

ING. KAREN ELVIRA PEÑATE AVILES

ING. RODRIGO ERNESTO VASQUEZ ESCALANTE

SAN SALVADOR, 24 DE NOVIEMBRE DE 2026

Trabajo de Graduación Aprobado por:

Docentes Asesores:

ING. BLADIMIR DIAZ CAMPOS

ING. KAREN ELVIRA PEÑATE AVILES

ING. RODRIGO ERNESTO VASQUEZ ESCALANTE

Agradecimientos

A Dios todopoderoso, por haberme concedido la perseverancia, la sabiduría y la fortaleza necesaria para afrontar cada desafío académico y culminar con éxito esta etapa de mi formación profesional.
A mi familia, cuyo respaldo incondicional, sacrificios silenciosos y constante motivación fueron el cimiento sobre el cual pude edificar cada meta. Gracias por creer en mí en todo instante.
A mis compañeros de tesis y amigos entrañables, David y Elmer, por las incontables jornadas de discusión técnica, investigación y programación. Su compromiso y esfuerzo conjunto hicieron posible que esta investigación trascendiera el aula para convertirse en un aporte tangible al agro salvadoreño.
A la Universidad de El Salvador y a cada docente de la Escuela de Ingeniería de Sistemas Informáticos, por transmitirme con rigor y vocación los principios científicos que hoy me capacitan como profesional al servicio de la sociedad.

Josias Abner Rivas Fuentes

Agradecimientos

A Dios, por darme salud, fortaleza y la oportunidad de llegar hasta este momento.
A mis padres y hermanos, por su apoyo, paciencia y confianza durante todo este proceso. Gracias por acompañarme y motivarme a seguir adelante, incluso en los momentos difíciles.
A mis compañeros de equipo, Josias y Elmer, por el esfuerzo, la dedicación y el compromiso que compartimos durante el desarrollo de este proyecto. Gracias por el trabajo en equipo, las experiencias y todo lo aprendido en el camino.
A nuestros profesores y asesores, por compartir sus conocimientos, orientarnos y brindarnos su apoyo durante nuestra formación académica y el desarrollo de este trabajo.

David Alejandro Deras Cerros

Agradecimientos

Agradezco profundamente al Todopoderoso, por su gracia inmerecida, sabiduría que me concedió y fortaleza para superar cada desafío a lo largo de este proceso de formación. A él atribuyo la gloria de haber culminado con éxito esta etapa de mi vida académica y profesional.

Además, expreso mi sincero agradecimiento a mis padres, por el apoyo incondicional que me han demostrado en pequeños y grandes detalles. Su motivación constante y su confianza en mis capacidades fueron actos de amor que me ayudaron a vencer el cansancio y me hicierón recordar mis objetivos.

A mis compañeros de graduación, Josias y David, por su amistad. El trabajo en equipo se volvió una experiencia enriquecedora, y el entusiasmo inagotable con el que enfrentamos este reto nos dejó un gran aprendizaje. Reconozco el talento y dedicación que mostraron, que hicieron de cada desafío una oportunidad de crecimiento.

A la gloriosa Universidad de El Salvador, alma mater de generaciones, por abrirme sus puertas y formarme con sentido crítico y compromiso social. A todo el cuerpo docente, por su dedicación y entrega en la formación de profesionales competentes y comprometidos con la sociedad.

Elmer Edenilson Rosales Molina

Resumen Ejecutivo

El maíz es la base de la alimentación de las familias campesinas de El Salvador, y la mayoría de los productores trabaja parcelas pequeñas con poca asistencia técnica. Las enfermedades foliares, las plagas y las deficiencias nutricionales reducen el rendimiento si no se detectan a tiempo. Las herramientas de diagnóstico por visión artificial suelen exigir conexión a internet o teléfonos potentes, o fallan con fotografías distintas a las del entrenamiento.

Esta investigación presenta **Doctor Maíz**, una aplicación móvil que clasifica nueve condiciones de la hoja de maíz (enfermedades, una plaga y deficiencias nutricionales) con una red convolucional que se ejecuta en el propio teléfono, sin conexión. Incluye un marco guía para la captura, un detector de imágenes fuera de distribución (*Out-of-Distribution*, OOD) y un módulo opcional para aportar fotografías a un conjunto de datos nacional.

Se reunió un corpus de **33 429 imágenes** de 11 repositorios internacionales, con control de integridad, revisión de duplicados y registro de la procedencia. El modelo oficial es un modelo EfficientNet-Lite0, que obtuvo un Macro F_1 de **0.9480** y una exactitud de 97.81 % en 5 015 imágenes de prueba ($0{,}9435 \pm 0{,}0052$ con tres semillas). La búsqueda de hiperparámetros con Optuna quedó como experimento complementario al no superar ese resultado en prueba, y un ensamble de tres redes (0.9567) se conservó como referencia.

La principal limitación es la generalización. En fotografías de campo ajenas al corpus el modelo acertó 41 (42 %) y el detector rechazó 49. La validación agrupada por fuente dio un Macro F_1 de $0{,}6026 \pm 0{,}1240$, frente a $0{,}9311 \pm 0{,}0099$ en la partición estratificada. La ablación espacial indica que el modelo se apoya en la periferia de la imagen: la exactitud fue de 79.46 % al ocluir el centro y de 42.25 % al ocluir la periferia.

El modelo se cuantizó a enteros de 8 bits (Int8) y pesa **3.74 MB**, 72.9 % menos que en coma flotante, con un Macro F_1 de 0.9489 en la prueba completa. En un Motorola edge 40 neo con Android 15, las medianas fueron de 98 ms de preprocesado y 23 ms de inferencia. Solo la sincronización de aportes requiere conexión. Se proponen cinco recomendaciones al Ministerio de Agricultura y Ganadería (MAG) y al CENTA: validación en campo, un banco nacional de datos, una red de alerta fitosanitaria, capacitación comunitaria y software abierto.

Índice general

1 Especificación del Proyecto **1**

1.1 Situación Actual . . . 1

1.1.1 Antecedentes . . . 1

1.1.2 Descripción del problema . . . 2

1.1.3 Planteamiento del problema . . . 2

1.2 Objetivos . . . 3

1.2.1 Objetivo General . . . 3

1.2.2 Objetivos Específicos . . . 3

1.3 Alcance y Límites del Proyecto . . . 4

1.3.1 Alcance del Proyecto . . . 4

1.3.2 Límites del Proyecto . . . 5

1.4 Hipótesis . . . 6

1.4.1 Hipótesis General . . . 6

1.4.2 Criterios de Éxito Específicos . . . 6

1.5 Justificación . . . 6

1.5.1 Justificación Técnica y Metodológica . . . 6

1.5.2 Justificación Económica . . . 7

1.5.3 Justificación Social y Ambiental . . . 7

1.5.4 Justificación Académica e Institucional . . . 7

1.6 Cronograma de Actividades . . . 7

1.7 Presupuesto Global Estimado . . . 9

2 Análisis y Diseño de la Solución **11**

2.1 Trazabilidad de los Datos . . . 11

2.2 Condiciones Agronómicas Objetivo . . . 11

2.3 Recopilación, Depuración y Auditoría de Datos . . . 14

2.3.1 Análisis Exploratorio . . . 14

2.3.2 Auditoría de Duplicados y Partición . . . 16

2.4 Arquitecturas y Búsqueda de Hiperparámetros . . . 16

2.4.1 Familias Convolucionales Seleccionadas . . . 16

2.4.2 Espacio de Búsqueda y Poda Temprana 16
2.4.3 Ensamble Multimodelo por Soft Voting 17
2.5 Despliegue en Dispositivo Móvil 17
2.5.1 Cuantización a Enteros de 8 Bits (Int8) 17
2.5.2 Detector de Anomalías Fuera de Distribución (OOD) 17
2.5.3 Mitigación en la Interfaz 18
2.6 Sincronización y Aportes al Conjunto de Datos 18
2.7 Arquitectura General del Sistema 19

3 Estrategia de Implementación y Análisis de Resultados 21
3.1 Estrategia y Entorno de Implementación 21
3.1.1 Infraestructura de Cómputo y Entrenamiento en la Nube 21
3.2 Resultados 22
3.2.1 Búsqueda Bayesiana de Hiperparámetros 22
3.2.2 Generalización entre Fuentes 23
3.2.3 Fotografías de Campo Externas 26
3.2.4 Equidad entre Laboratorio y Campo 26
3.2.5 Dependencia del Fondo 28
3.2.6 Desempeño en el Teléfono 30
3.2.7 Ensamble 32

Conclusiones y Recomendaciones 35

Bibliografía 38

Glosario de Términos 40

Anexos 41

Índice de tablas

1.1 Criterios de éxito del proyecto 6
1.2 Cronograma de actividades por fase (CRISP-DM), con horas por integrante 8
1.3 Presupuesto del proyecto (USD) 9

2.1 Taxonomía agronómica de las nueve clases integradas en DoctorMaiz 12
2.2 Fuentes de datos recopiladas, licencia declarada y distribución de muestras 14
2.3 Espacio de búsqueda de hiperparámetros explorado con Optuna 17
2.4 Tecnologías principales por proyecto 19

3.1 Estado de los criterios de éxito 22
3.2 Configuración inicial frente a la mejor configuración de Optuna 23
3.3 Validación cruzada de 5 pliegues con partición estratificada y agrupada por fuente 24
3.4 Macro F_1 y exactitud en la fuente retenida, evaluación LOSO con tres semillas 24
3.5 Aciertos del modelo oficial en fotografías de campo externas, por clase 26
3.6 Tasa de falsos negativos (FNR) por clase y entorno. 28
3.7 Exactitud al ocultar regiones de la imagen. 28
3.8 Latencias medianas en el Motorola edge 40 neo 30
3.9 Ensamble frente a modelos individuales en la prueba (5 015 imágenes) 32
3.10 F_1 por clase de los modelos individuales y del ensamble 34

Índice de figuras

1.1 Modelo conceptual de caja negra para el diagnóstico fitosanitario móvil. 3
1.2 Diagrama de Gantt del cronograma planificado (Metodología CRISP-DM) 8

2.1 Catálogo fotográfico de las nueve clases agronómicas presentes en el corpus. 13
2.2 Distribución del corpus por clase y por entorno de captura. 15
2.3 Distribución de imágenes por clase y fuente de origen. 15
2.4 Flujo de sincronización de un aporte. 19
2.5 Arquitectura del sistema DoctorMaiz. 20

3.1 Macro F_1 de validación y pérdida por época de las tres arquitecturas con la configuración inicial. 21
3.2 Resultados de la búsqueda con Optuna. 23
3.3 Efecto de la partición frente al ajuste de hiperparámetros. 25
3.4 Desempeño por entorno de captura. 27
3.5 Exactitud según la región visible de la imagen. 29
3.6 Mapas de activación Grad-CAM en imágenes de campo y de laboratorio. 29
3.7 Explicaciones locales de LIME, SHAP y Grad-CAM para la roya común. 30
3.8 Flujo principal de la aplicación DoctorMaiz. 31
3.9 Rechazo de imágenes, aportes y guía de severidad. 32
3.10 Desempeño del ensamble frente a los modelos individuales. 33
3.11 Matriz de confusión normalizada del ensamble sobre 5 015 imágenes de prueba. 33

CAPÍTULO 1

ESPECIFICACIÓN DEL PROYECTO

1.1. Situación Actual

1.1.1. Antecedentes

La agricultura representa el 5.6 % del Producto Interno Bruto (PIB) de El Salvador [2] y sostiene de forma directa a más de dos millones de personas en el sector rural. Para las familias campesinas salvadoreñas, el maíz (*Zea mays L.*) constituye la base diaria de la alimentación familiar, con un consumo promedio reportado que supera los 115 kilogramos por persona al año [3]. De acuerdo con registros oficiales del Ministerio de Agricultura y Ganadería [16], el 82.1 % de los productores nacionales trabajan pequeñas parcelas familiares menores a dos manzanas (1.4 hectáreas), bajo un régimen de agricultura de subsistencia dependiente casi por completo del régimen de lluvias estacionales.

En los últimos años esta producción ha quedado más expuesta a anomalías climáticas y a problemas fitosanitarios [16]. En una milpa con estrés hídrico o térmico también aparecen enfermedades foliares y plagas, y si una infección o un ataque no se atiende a tiempo, reduce el llenado del grano y el rendimiento de la cosecha [3]. Para un hogar que vive de su parcela, esa pérdida afecta directamente su alimentación.

Pese a esa importancia, el efecto de los problemas fitosanitarios sobre la producción nacional no está cuantificado, la información pública disponible no permite estimar cuánto maíz pierde El Salvador por enfermedades foliares, plagas o deficiencias nutricionales. Las pérdidas recientes mejor documentadas son de origen climático: en el ciclo 2023-2024 se reportaron unos 1.46 millones de quintales perdidos, el 9.8 % de los 14.9 millones producidos, con más de 24 % en cada departamento del oriente [8], y en el ciclo 2024-2025 la cosecha fue de 10.9 millones de quintales frente a 18.8 millones requeridos [6]. En el frente fitosanitario solo se dispone de evidencias puntuales: en un ensayo de híbridos del CENTA, los tres sitios con presión de mancha de asfalto rindieron cerca de 51 % menos que los sitios sin la enfermedad [5], y en un ensayo de 2017 en La Libertad el control optimizado de plagas y enfermedades elevó el rendimiento 15 % pero redujo la utilidad neta en US$395 por hectárea [7].

Esa falta de cifras es parte del problema y también afectó a este proyecto, porque sin un registro de diagnósticos nadie puede decir qué enfermedades predominan en cada zona ni cuánto cuestan, y el productor decide sin referencia. El ensayo de La Libertad muestra que tratar no siempre compensa el gasto. Con los datos para entrenar un modelo ocurre lo mismo. El corpus reúne 33 429 imágenes de 11 repositorios internacionales y ninguna fotografía salvadoreña etiquetada. La misma carencia impidió estimar el ahorro económico que el diagnóstico podría producir. Por eso la aplicación incluye un módulo de aportes voluntarios con el que podría formarse, con el tiempo, el registro que hoy falta.

1.1.2. Descripción del problema

En las parcelas rurales salvadoreñas no hay laboratorios cercanos, y el diagnóstico se hace a simple vista, el agricultor observa las manchas o el marchitamiento de la hoja e intenta reconocer la causa. Los casos más difíciles son el tizón foliar, la mancha gris, la roya común, el gusano cogollero, la necrosis letal del maíz y las deficiencias de nitrógeno, fósforo y potasio (Tabla 2.1), cuyos síntomas se confunden entre sí y con los de otros hongos o virus.

La asistencia técnica pública no alcanza para cubrir esa necesidad, hay pocos extensionistas para el número de productores dispersos en la zona rural, y una visita agronómica puede tardar semanas o no llegar mientras la infección avanza [3].

Ante el riesgo de perder la siembra, el agricultor suele acudir a un agroservicio, y sin un diagnóstico de por medio, la recomendación tiende a ser un agroquímico de amplio espectro, aun cuando los síntomas se deben a una deficiencia nutricional del suelo, entonces el productor paga por un producto que no resuelve el problema, se aplican químicos de más y el tratamiento adecuado se retrasa [3].

1.1.3. Planteamiento del problema

La extensión agronómica no alcanza a cubrir a los pequeños productores de maíz, y las herramientas digitales disponibles se diseñaron para condiciones distintas a las del campo salvadoreño. Las aplicaciones de diagnóstico por visión artificial suelen tener estas limitaciones:

1. **Dependen de la conexión.** La mayoría envía la fotografía a un servidor para procesarla. En muchas zonas rurales la cobertura celular es inestable o nula y los agricultores no tienen un plan de datos, de modo que la herramienta no funciona en la parcela.

2. **Exigen teléfonos potentes.** Los modelos de aprendizaje profundo convencionales necesitan más memoria y cómputo de los que ofrecen los teléfonos de gama de entrada que usan las familias campesinas. El resultado son bloqueos, esperas largas y un consumo alto de batería.

3. **Fallan con fotografías de campo.** Se entrenaron sobre todo con imágenes de laboratorio, con fondo neutro y luz pareja. En la milpa aparecen suelo, sombras, maleza y contraluz, y el modelo se equivoca con frecuencia y con una confianza alta [1].

De ahí surge la pregunta de investigación:

> *¿En qué medida puede una aplicación móvil que funciona sin conexión, en teléfonos de gama baja o media, identificar problemas fitosanitarios en fotografías de hojas de maíz tomadas en campo, abstenerse cuando la imagen no es confiable y orientar al agricultor salvadoreño sobre el manejo de su cultivo?*

Modelo conceptual de caja negra del sistema

Para delimitar el problema el sistema se representa como una caja negra (Figura 1.1). Las entradas son las condiciones y restricciones del entorno, las salidas son los resultados que el sistema debe producir, y el proceso intermedio es el objeto de estudio de esta investigación.

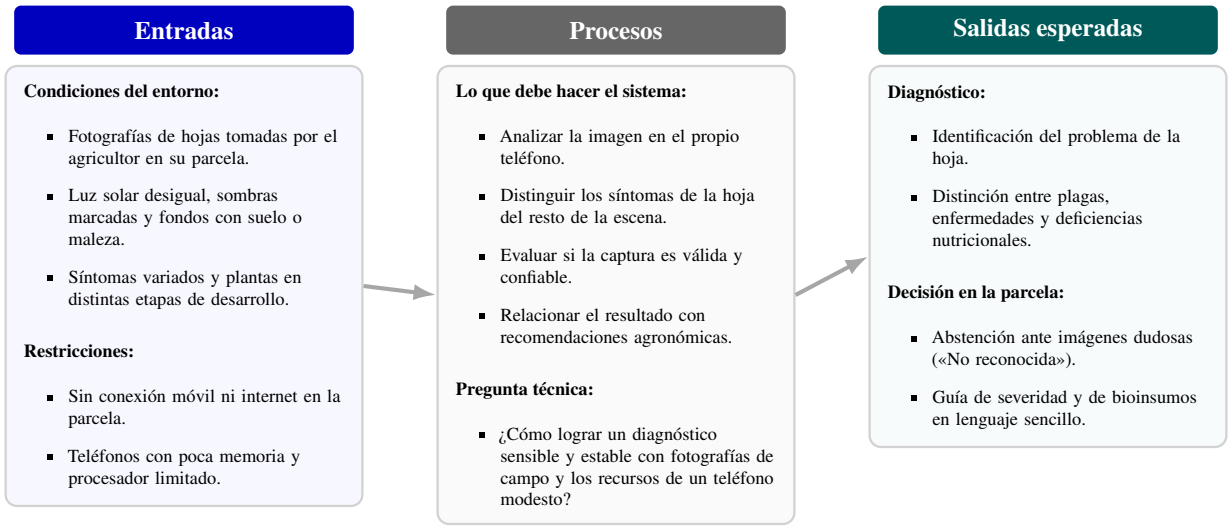


Figura 1.1: Modelo conceptual de caja negra para el diagnóstico fitosanitario móvil.

1.2. Objetivos

1.2.1. Objetivo General

Desarrollar y evaluar un sistema de visión artificial para el diagnóstico fitosanitario de la hoja de maíz en El Salvador, integrado en una aplicación móvil que funcione sin conexión (*Edge AI*) en teléfonos de gama baja o media, con alta sensibilidad y baja latencia.

1.2.2. Objetivos Específicos

1. Reunir y depurar un corpus de imágenes de la hoja de maíz en nueve condiciones agronómicas a partir de repositorios públicos, con controles verificables que descarten duplicados y eviten que una misma imagen aparezca en más de una partición.

2. Ajustar arquitecturas convolucionales ligeras preentrenadas mediante búsqueda bayesiana de hiperparámetros (Optuna) con poda temprana, y comprobar si mejoran el Macro F_1 de la configuración inicial sin un gasto excesivo de GPU.

3. Evaluar un ensamble por votación suave (*Soft Voting*) de modelos con arquitecturas distintas, para

medir si aumenta la sensibilidad en las enfermedades más graves y en las clases con menos imágenes.

4. Evaluar el sistema con una validación que separe las fuentes de entrenamiento y de evaluación, medir la diferencia de desempeño entre imágenes de laboratorio y de campo, y analizar en qué regiones de la imagen se apoya el modelo mediante explicabilidad y ablación espacial.
5. Cuantizar el modelo a enteros de 8 bits (Int8), integrarlo en una aplicación móvil con ayudas para la captura y un mecanismo de rechazo de imágenes no válidas, y medir su exactitud y su latencia en teléfonos de gama baja o media.
6. Formular recomendaciones al Ministerio de Agricultura y Ganadería (MAG) y al CENTA sobre las condiciones para incorporar la herramienta al acompañamiento técnico de los pequeños productores de maíz.

1.3. Alcance y Límites del Proyecto

1.3.1. Alcance del Proyecto

El proyecto abarca el diseño, el desarrollo y la evaluación de una herramienta de diagnóstico fitosanitario para los pequeños productores de maíz en El Salvador. Tiene dos componentes: la aplicación móvil que usa el agricultor y el modelo de visión artificial que se ejecuta dentro de ella.

Alcance de la Aplicación Móvil (DoctorMaiz)

La aplicación incluye:

- **Diagnóstico sin conexión.** El modelo cuantizado se ejecuta en el procesador del teléfono, sin internet ni datos móviles.
- **Captura con marco guía.** La cámara muestra un marco con la silueta de la hoja para que el agricultor la encuadre y deje fuera la mayor parte del suelo, las sombras y la maleza.
- **Rechazo de imágenes dudosas.** Si la captura no parece una hoja de maíz o el modelo no está seguro, la aplicación muestra «No reconocida» en lugar de un diagnóstico.
- **Resultado y guía de severidad.** El resultado se presenta en lenguaje sencillo, con una guía visual de tres niveles (baja, moderada y crítica) que el productor compara con su hoja, la aplicación no mide el daño.
- **Recomendaciones de manejo.** Para cada diagnóstico se ofrecen alternativas de bioinsumos y de manejo cultural de bajo costo.

- **Historial.** Cada evaluación se guarda en el teléfono con fecha, diagnóstico, severidad y ubicación GPS, para que el agricultor siga la evolución de su parcela durante el ciclo.
- **Aportes voluntarios.** El usuario puede guardar fotografías en el teléfono y enviarlas cuando tenga conexión, con fines de monitoreo fitosanitario colectivo.

Alcance del Componente de Inteligencia Artificial

El componente de inteligencia artificial abarca:

- **Nueve clases.** Tres enfermedades causadas por hongos (tizón foliar, mancha gris y roya común), una virosis (necrosis letal del maíz), una plaga (gusano cogollero), tres deficiencias nutricionales (nitrógeno, fósforo y potasio) y la hoja sana.
- **Entrenamiento y exportación.** Búsqueda de hiperparámetros con Optuna y poda temprana, un ensamble por votación suave (*Soft Voting*) y cuantización a 8 bits en formato TensorFlow Lite con litert-torch, con una meta de 300 ms o menos para preprocesado e inferencia en el teléfono.
- **Evaluación de sesgos.** Validación cruzada agrupada por procedencia (*SourceGroupedKFold*) y ablación espacial, para detectar si el modelo se apoya en atajos visuales del fondo (efecto *Clever Hans*).

1.3.2. Límites del Proyecto

El proyecto tiene los siguientes límites:

- **Solo la hoja.** El sistema analiza síntomas visibles en la lámina de la hoja. No cubre enfermedades de la raíz, daños internos del tallo sin síntomas en la hoja ni plagas del suelo.
- **Solo Android.** La aplicación requiere Android 7.0 (API 24) o superior, procesador ARM (v7 o v8), cámara trasera con enfoque automático y al menos 4 GB de RAM. Las pruebas en dispositivo se hicieron en Android 15. No hay versión para iOS ni para teléfonos que no sean inteligentes.
- **Sin dependencia de la nube.** El diagnóstico no usa servicios en la nube, y no hay sincronización en tiempo real entre varios teléfonos.
- **Herramienta de orientación.** La aplicación orienta al productor, pero no reemplaza los análisis de laboratorio, ni los dictámenes oficiales de cuarentena o certificación fitosanitaria del MAG.
- **Clases y evidencia de campo.** El corpus procede de 11 repositorios públicos internacionales.

1.4. Hipótesis

1.4.1. Hipótesis General

Un modelo convolucional ligero, cuantizado a enteros de 8 bits y ejecutado sin conexión en un teléfono de gama baja o media, puede clasificar nueve condiciones de la hoja de maíz con un Macro F_1 de al menos 0.85 en una partición de prueba retenida, con 300 ms o menos de preprocesado e inferencia y con un desempeño comparable entre imágenes de laboratorio y de campo. La hipótesis se considera aceptada si se cumplen los criterios de la Tabla 1.1.

1.4.2. Criterios de Éxito Específicos

Tabla 1.1: Criterios de éxito del proyecto

Tema	**Criterio y umbral**	**Métrica**
Rendimiento del modelo	Alcanzar Macro $F_1 \geq 0{,}85$ en la partición de prueba retenida.	Macro F_1
Capacidades del diagnóstico	Mantener un *Disparate Impact Ratio* $\geq 0{,}80$ entre laboratorio y campo real.	DIR
Confiabilidad de la evaluación	Ninguna imagen del conjunto de prueba aparece en entrenamiento ni validación, por hash de archivo y por píxeles.	Solapamiento por SHA-256 y por píxeles
Solución integral	Modelo Int8 de 20 MB o menos, preprocesado e inferencia de 300 ms o menos en un teléfono de gama media o baja y funcionamiento sin conexión.	Tamaño, latencia

1.5. Justificación

1.5.1. Justificación Técnica y Metodológica

La mayoría de los sistemas de diagnóstico foliar por visión artificial procesan la imagen en un servidor, lo que exige conexión en el momento de usarlos. Este proyecto ejecuta el modelo en el propio teléfono (*Edge AI*), con arquitecturas convolucionales diseñadas para dispositivos móviles [9, 22] y cuantización a enteros de 8 bits, que reduce el tamaño del modelo y el costo de cada inferencia [11].

En la visión por computadora aplicada a la agricultura, muchos modelos se evalúan con particiones aleatorias de un mismo repositorio. Con ese esquema, imágenes muy parecidas o tomadas en las mismas condiciones quedan a ambos lados de la partición, y el modelo puede apoyarse en el fondo o en la cámara en lugar de la lesión [1]. Por eso el proyecto incorpora una auditoría de duplicados, una validación que separa las fuentes de entrenamiento y de evaluación, mapas de activación para revisar en qué regiones se

apoya el modelo [21] y un detector que evita diagnosticar imágenes que no corresponden a una hoja de maíz [12].

1.5.2. Justificación Económica

La mayoría de los productores de maíz trabaja parcelas pequeñas con márgenes estrechos [16], de modo que un gasto mal dirigido pesa en la economía del hogar. Un diagnóstico equivocado puede llevar a comprar un agroquímico que no corresponde, por ejemplo un fungicida para lo que en realidad es una deficiencia nutricional, y el ensayo de La Libertad muestra que incluso un control de plagas y enfermedades bien aplicado puede reducir la utilidad neta [7]. Una aplicación gratuita que funciona en el teléfono del agricultor orienta esa decisión antes de la compra y ayuda a actuar a tiempo contra plagas como el gusano cogollero (*Spodoptera frugiperda*) [3].

1.5.3. Justificación Social y Ambiental

Muchas comunidades rurales tienen poco acceso a apoyo agronómico presencial [3]. Una herramienta que funciona sin conexión en un teléfono de gama baja o media pone información técnica al alcance del productor en su parcela, en un lenguaje que puede entender sin formación especializada. En lo ambiental, un diagnóstico más preciso favorece un mejor manejo de plagas y puede reducir la aplicación de pesticidas cuando no hacen falta.

1.5.4. Justificación Académica e Institucional

Para la Escuela de Ingeniería de Sistemas Informáticos de la Universidad de El Salvador, el proyecto aplica el aprendizaje profundo embebido a un problema del agro nacional y deja disponibles el código, el corpus consolidado y los modelos. Además, documenta un procedimiento de evaluación (auditoría de duplicados, validación por fuente y análisis de la dependencia del fondo) que puede reutilizarse en otros sistemas de visión artificial con poca capacidad de cómputo y conectividad limitada.

1.6. Cronograma de Actividades

El proyecto se organizó según las fases de *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*), con una fase adicional para el desarrollo de la aplicación móvil. Abarca 32 semanas, del 14 de abril al 24 de noviembre de 2026. La Figura 1.2 muestra el diagrama de Gantt y la Tabla 1.2 detalla la duración, las horas y el entregable de cada fase.

Figura 1.2: Diagrama de Gantt del cronograma planificado (Metodología CRISP-DM)

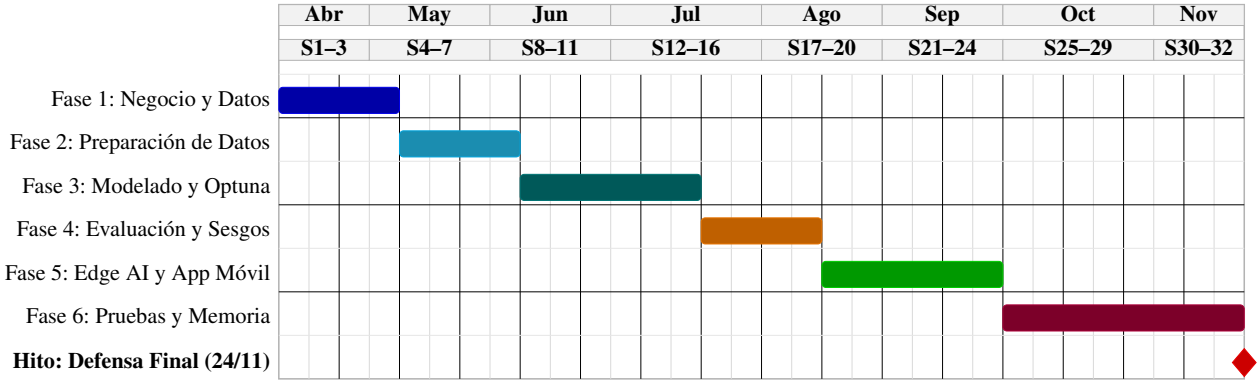


Tabla 1.2: Cronograma de actividades por fase (CRISP-DM), con horas por integrante

Fase	Inicio	Fin	Semanas	Horas	Entregable principal
Fase 1: Comprensión del negocio y de los datos	14/04/26	12/05/26	4	40 h	Requisitos fitosanitarios y selección de repositorios públicos.
Fase 2: Preparación de datos	12/05/26	09/06/26	4	40 h	Corpus consolidado, auditoría de duplicados, balanceo y aumento de datos.
Fase 3: Modelado	09/06/26	21/07/26	6	60 h	Modelos ligeros con transferencia de aprendizaje y búsqueda de hiperparámetros.
Fase 4: Evaluación	21/07/26	18/08/26	4	40 h	Comparación de modelos, evaluación por fuente y en campo, y análisis de explicabilidad.
Fase 5: Despliegue y aplicación móvil	18/08/26	29/09/26	6	60 h	Modelo cuantizado a Int8 y aplicación móvil con inferencia local.
Fase 6: Pruebas finales y memoria	29/09/26	24/11/26	8	80 h	Pruebas en dispositivo físico, memoria técnica y defensa.
Defensa del proyecto	**24 de noviembre de 2026**		**32**	**320 h**	**Sistema DoctorMaiz y memoria final**

1.7. Presupuesto Global Estimado

El presupuesto se organiza en cuatro rubros: el recurso humano, el entrenamiento de los modelos, la inferencia y el despliegue (Tabla 1.3).

Tabla 1.3: Presupuesto del proyecto (USD)

Rubro	**Detalle**	**Costo**
Recurso humano		
Ingeniero de Datos / MLOps	320 h	$3,380.77
Investigador de Deep Learning	320 h	$3,056.53
Desarrollador Móvil Edge AI	320 h	$2,840.39
Entrenamiento		
GPU NVIDIA A10G en Modal	Modelos de referencia, entrenamiento principal, búsqueda de hiperparámetros y experimentos de validación	$250.00
Inferencia		
Inferencia en el teléfono	Sin servidor de inferencia	$0.00
Dispositivo de prueba	Motorola edge 40 neo, aportado por un integrante	$0.00
Despliegue (agosto a noviembre de 2026)		
Servidor Hetzner	API, base de datos y sitio web ($6.00 al mes durante 4 meses)	$24.00
Volumen Hetzner de 100 GB	Fotografías aportadas y respaldos ($7.67 al mes durante 4 meses)	$30.68
Dominio	Registro anual	$12.00
Distribución	APK en GitHub Releases, dataset en Hugging Face	$0.00
Total		**$9,594.37**

Recurso humano

Los salarios mensuales de referencia ($1,500, $1,350 y $1,250) son el punto medio de la escala del sector público salvadoreño para perfiles equivalentes. Se estimó una dedicación de 2 horas diarias de lunes a viernes por integrante (10 horas semanales), que suman 320 horas en las 32 semanas del cronograma (Tabla 1.2). Eso equivale a 1.85 meses de jornada completa, y el salario se prorrateó en esa proporción. Los montos incluyen las prestaciones de ley.

Entrenamiento

Todo el entrenamiento se ejecutó en GPU NVIDIA A10G de la plataforma Modal, con un presupuesto de $250 en créditos. Ese monto cubrió los modelos de referencia iniciales, el entrenamiento del modelo oficial, la búsqueda de hiperparámetros con Optuna (12.65 horas de GPU, $13.92) y los experimentos de validación por fuente, con varias semillas y de explicabilidad. El entrenamiento es un costo de una sola vez: una vez exportado, el modelo no requiere más GPU.

Inferencia

El modelo se ejecuta en el procesador del teléfono, de modo que cada diagnóstico no tiene costo de servidor ni consume datos móviles. El costo de inferencia no crece con el número de usuarios, lo que hace viable distribuir la aplicación de forma gratuita. Las pruebas en dispositivo se hicieron con un teléfono de gama media propiedad de un integrante del equipo.

Despliegue y operación

La API de sincronización, su base de datos y el sitio web del proyecto comparten un servidor en Hetzner, con un volumen adicional de 100 GB para las fotografías aportadas por los usuarios. El APK se compila y publica en GitHub Releases mediante GitHub Actions, y el corpus consolidado se distribuye en Hugging Face, ambos sin costo. Mantener el sistema en operación cuesta $176.04 al año ($72.00 de servidor, $92.04 de volumen y $12.00 de dominio).

CAPÍTULO 2

ANÁLISIS Y DISEÑO DE LA SOLUCIÓN

2.1. Trazabilidad de los Datos

Cada imagen del corpus tiene un registro con un identificador único, la huella SHA-256 del archivo, la fuente de la que proviene y el entorno de captura (laboratorio o campo). El identificador se calcula a partir de la ruta de la imagen, de modo que una misma imagen conserva su identidad en cualquier ejecución. La huella permite detectar si un archivo cambió entre versiones del corpus, y la fuente y el entorno permiten formar las particiones agrupadas del Capítulo 3.

Las listas de entrenamiento, validación y prueba se guardaron con su propia huella, de modo que cada experimento puede comprobar que usa exactamente la misma partición. La ausencia de solapamientos entre particiones se verificó en la auditoría descrita más abajo.

2.2. Condiciones Agronómicas Objetivo

El sistema clasifica la hoja de maíz en nueve categorías mutuamente excluyentes (Tabla 2.1): tres enfermedades causadas por hongos, un complejo viral, una plaga, tres deficiencias nutricionales y la hoja sana.

Tabla 2.1: Taxonomía agronómica de las nueve clases integradas en DoctorMaiz

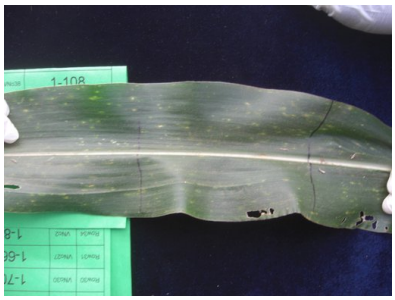
Clase Agronómica	**Agente Causal / Tipo**	**Síntoma Primario**	**Consecuencia en el cultivo**
Roya Común	*Puccinia sorghi* (Hongo)	Pústulas pulverulentas castaño-rojizas en ambas caras.	Reducción del área foliar activa.
Tizón Foliar (NCLB)	*Exserohilum turcicum* (Hongo)	Lesiones alargadas en forma de cigarro o huso (grises).	Necrosis de la lámina, con mayor daño si aparece antes de la floración.
Mancha Gris (GLS)	*Cercospora zeae-maydis* (Hongo)	Manchas rectangulares delimitadas por venas secundarias.	Destrucción del follaje y menor llenado del grano.
Necrosis Letal (MLN)	Complejo viral sinérgico (MCMV + Potyvirus)	Clorosis severa, moteado, necrosis marginal y secado total.	Secado prematuro de la planta y pérdida severa del rendimiento [15].
Gusano Cogollero	*Spodoptera frugiperda* (Plaga/Insecto)	Perforaciones irregulares y excrementos en el cogollo.	Daño al cogollo y al punto de crecimiento.
Deficiencia de Nitrógeno	Desbalance nutricional abiótico	Clorosis en “V” invertida desde la punta hacia la base.	Reducción de porte, espigas pequeñas y bajo llenado.
Deficiencia de Fósforo	Desbalance nutricional abiótico	Coloración púrpura o rojiza en bordes de hojas jóvenes.	Retraso radicular y esterilidad parcial de la mazorca.
Deficiencia de Potasio	Desbalance nutricional abiótico	Clorosis y necrosis marginal desde el ápice foliar.	Acame o volcamiento del tallo y grano liviano.
Planta Sana (Healthy)	Control agronómico	Lámina foliar verde homogénea sin lesiones ni plagas.	Crecimiento óptimo según potencial genético del cultivar.



a) Roya Común



b) Tizón Foliar



c) Mancha Gris



d) Necrosis Letal



e) Gusano Cogollero



f) Deficiencia N



g) Deficiencia P



h) Deficiencia K



i) Planta Sana

Figura 2.1: Catálogo fotográfico de las nueve clases agronómicas presentes en el corpus.

2.3. Recopilación, Depuración y Auditoría de Datos

El corpus final reúne **33 429 imágenes** de 11 fuentes públicas (Tabla 2.2).

Tabla 2.2: Fuentes de datos recopiladas, licencia declarada y distribución de muestras

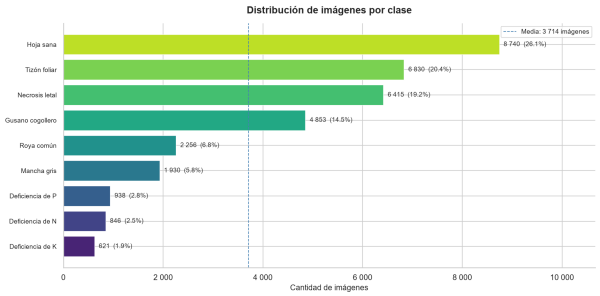
Identificador de Fuente (`source_id`)	**Licencia declarada**	**Muestras**	**Entorno**	**Clases aportadas**
`maize-beans-tomatoes-africa`	Apache 2.0 y CC	12 136	Campo real	4 clases.
`maize-diseases`	CC BY-NC-SA 4.0	6 989	Mixto	3 clases.
`multicrop-disease-maiz`	CC BY 4.0	5 816	Mixto	3 clases.
`corn-leaf-roboflow`	CC BY 4.0	2 919	Campo real	6 clases.
`cropdg-unified-multidomain`	CC BY-NC-SA 4.0	2 562	Mixto	3 clases.
`maize-in-field-dataset`	CC BY-NC-SA 4.0	852	Campo real	3 clases.
`maize-2-roboflow`	CC BY 4.0	846	Campo real	3 clases.
`corn-leaf-diseases-classification-roboflow`	CC BY 4.0	480	Mixto	1 clase.
`maize-nutrient-deficiency`	CC BY 4.0	340	Campo real	4 clases.
`maize-leaf-roboflow`	CC BY 4.0	331	Campo real	1 clase.
`maize-deficiency-scanner-roboflow`	CC BY 4.0	158	Campo real	3 clases de deficiencia.
Total	—	**33 429**	—	**9 clases agronómicas**

La licencia es la declarada por cada repositorio de origen.

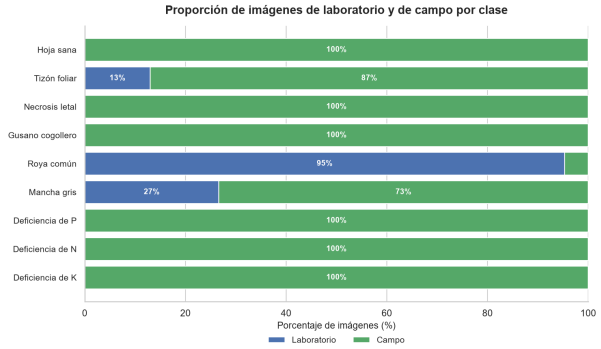
2.3.1. Análisis Exploratorio

El corpus está desbalanceado. La clase sana tiene cerca de 8 700 imágenes y el tizón foliar cerca de 6 800, mientras que la deficiencia de potasio tiene 621, una relación de 14.1:1 que antes de ampliar el corpus era de 32.9:1 (Figura 2.2). Las resoluciones también varían mucho y se agrupan en tres rangos: alrededor de 256 píxeles en las imágenes de laboratorio, alrededor de 640 en las de Roboflow y las deficiencias nutricionales, y entre 3 000 y 5 000 en varias fuentes de campo. Todas se reducen a 224×224 antes de entrar al modelo, de modo que las fotografías grandes pierden parte del detalle fino de las lesiones.
Solo tres clases tienen imágenes de laboratorio, tomadas sobre un fondo controlado: la roya común (95 % de sus imágenes, 2 150 de 2 256), la mancha gris (27 %) y el tizón foliar (13 %). Las otras seis clases son por completo de campo. En conjunto, el laboratorio aporta 3 551 imágenes, el 10.6 % del corpus. Esta composición condiciona la evaluación del Capítulo 3: la comparación entre laboratorio y campo solo

puede hacerse en esas tres clases, y la roya, con apenas 106 imágenes de campo, es la clase con más riesgo de fallar en campo.



a) Imágenes por clase.



b) Laboratorio y campo por clase.

Figura 2.2: Distribución del corpus por clase y por entorno de captura.

Además, la procedencia y la etiqueta están asociadas: varias fuentes aportan una sola clase, y una sola fuente, `maize-beans-tomatoes-africa`, aporta 12 136 imágenes, el 36.3 % del corpus (Figura 2.3). Con esa asociación, un modelo puede aprender rasgos propios de cada fuente, como el fondo o la cámara, además de la lesión.

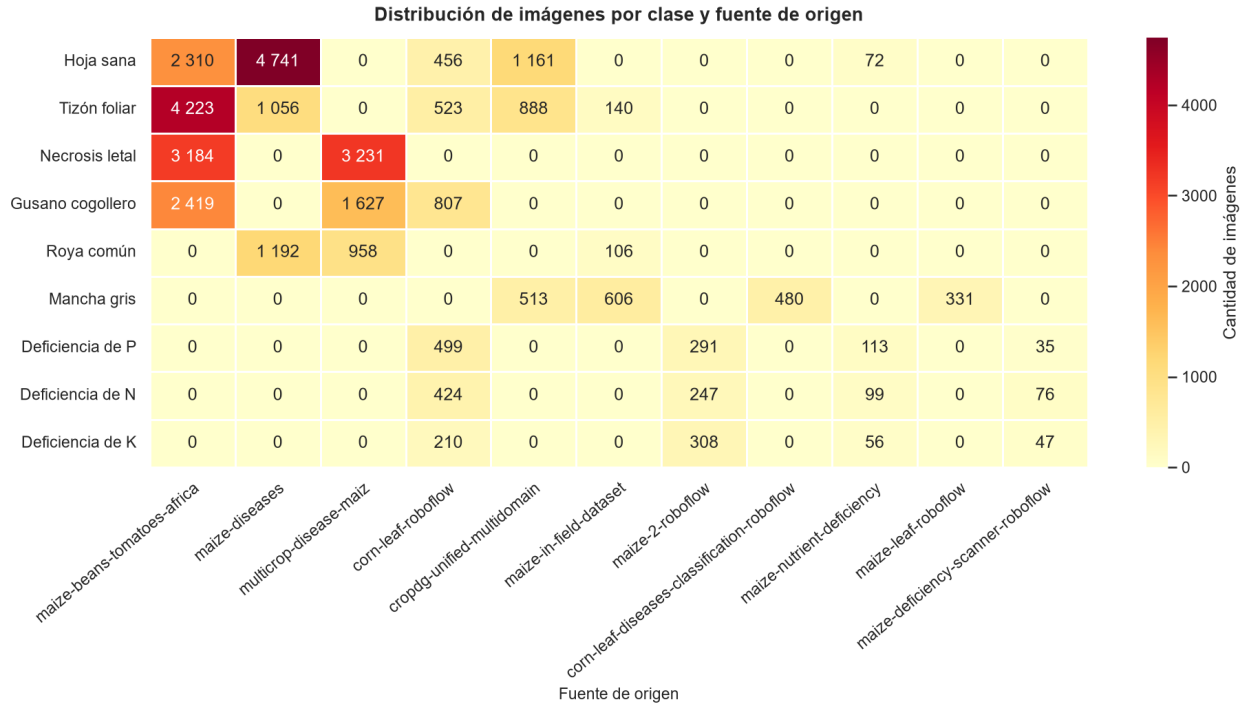


Figura 2.3: Distribución de imágenes por clase y fuente de origen.

2.3.2. Auditoría de Duplicados y Partición

Cada imagen se comparó con el resto mediante dos hashes SHA-256, uno del archivo y otro de los píxeles decodificados. No se encontraron duplicados, salvo cuatro pares de imágenes con etiquetas contradictorias que se excluyeron del corpus.
La partición oficial reparte las 33 429 imágenes en 70/15/15, estratificada por clase y entorno: 23 400 de entrenamiento, 5 014 de validación y 5 015 de prueba. Como las mismas fuentes aparecen en los tres conjuntos, el Capítulo 3 la complementa con una validación agrupada por fuente.

2.4. Arquitecturas y Búsqueda de Hiperparámetros

2.4.1. Familias Convolucionales Seleccionadas

Se compararon tres redes convolucionales ligeras, preentrenadas en ImageNet [4], con diseños distintos:

1. **EfficientNet-Lite0**, es la variante de EfficientNet para móviles: sustituye la activación *swish* por ReLU6 y elimina los bloques *Squeeze-and-Excitation* (SE) [10], lo que facilita la cuantización a enteros. Tiene 3.38 millones de parámetros [22].

2. **EfficientNet-B0**, la versión original, con escalado compuesto y bloques SE. Con 4.02 millones de parámetros.

3. **ShuffleNet-V2-x1.0**, que divide y baraja los canales (*channel split* y *channel shuffle*) para reducir los accesos a memoria. Es la más pequeña, con 1.26 millones de parámetros [14].

2.4.2. Espacio de Búsqueda y Poda Temprana

La búsqueda de hiperparámetros se hizo con Optuna [17], usando el estimador de árbol de Parzen multivariado (TPE), con el objetivo de maximizar el Macro F_1 de validación. Para no gastar GPU en configuraciones poco prometedoras se usó *MedianPruner*: tras cinco ensayos iniciales y a partir de la época 8, un ensayo se detiene si su Macro F_1 queda por debajo de la mediana de los ensayos anteriores en la misma época. La Tabla 2.3 muestra los seis hiperparámetros explorados.

Tabla 2.3: Espacio de búsqueda de hiperparámetros explorado con Optuna

Hiperparámetro	**Rango / Opciones**
`learning_rate`	Log-uniforme: $[10^{-5}, 3 \times 10^{-3}]$
`batch_size`	Categórico: $\{16, 32, 64\}$
`weight_decay`	Log-uniforme: $[10^{-7}, 10^{-2}]$
`class_weights`	Categórico: $\{$none, inverse, sqrt_inverse$\}$
`label_smoothing`	Categórico: $\{0, 0{,}025, \ldots, 0{,}15\}$ en pasos de 0.025
`warmup_epochs`	Entero: $[1, 5]$

2.4.3. Ensamble Multimodelo por Soft Voting

El ensamble promedia las probabilidades de las tres redes, entrenadas por separado, para que los errores de una arquitectura se compensen con las otras:

$$P_{\text{ens}}(y = c \mid x) = \frac{1}{M} \sum_{m=1}^{M} P_m(y = c \mid x) \tag{2.1}$$

donde $M = 3$ es el número de redes y $c \in \{1, \ldots, 9\}$. La clase predicha es la de mayor probabilidad promedio: $\hat{y} = \arg\max_c P_{\text{ens}}(y = c \mid x)$.

2.5. Despliegue en Dispositivo Móvil

2.5.1. Cuantización a Enteros de 8 Bits (Int8)

Para que EfficientNet-Lite0 funcione en teléfonos de forma eficiente, se cuantizó a enteros de 8 bits después del entrenamiento (*Post-Training Quantization*, PTQ) [11] y se exportó a TensorFlow Lite con litert-torch. Los pesos $W_{f,c,i}$ de cada canal de salida c se escalan por separado:

$$S_c = \frac{\max_i |W_{f,c,i}|}{127}, \qquad q_{c,i} = \text{clip}\left(\left\lfloor \frac{W_{f,c,i}}{S_c} \right\rceil, \; -127, \; 127 \right) \tag{2.2}$$

2.5.2. Detector de Anomalías Fuera de Distribución (OOD)

El modelo siempre responde con alguna de las clases que aprendió, aunque la fotografía no tenga relación con el maíz. Si se le muestra suelo o un zapato, elegirá de todos modos una enfermedad, a veces con mucha seguridad, porque solo puede repartir su confianza entre las etiquetas que conoce [12]. Por eso, antes de mostrar un diagnóstico, la aplicación comprueba si la imagen se parece a las que el modelo vio durante el entrenamiento.

Para hacerlo aprovecha la descripción numérica que la red construye de cada imagen justo antes de clasificarla, una especie de huella de su contenido. Durante el entrenamiento se registra en qué zona se agrupan las huellas de cada clase. Cuando llega una fotografía nueva, se mide qué tan lejos queda su huella del grupo más cercano con la distancia de Mahalanobis, que considera cuánto varían normalmente las imágenes de ese grupo [18]. A esa medida se le resta la distancia al conjunto completo de entrenamiento, para no castigar rasgos que comparte cualquier fotografía, como la iluminación o el encuadre [19].
El límite de aceptación se fijó de modo que el 95 % de las imágenes del conjunto de validación quede por debajo de él. Además, el diagnóstico se descarta cuando el modelo duda: si la enfermedad más probable no alcanza el 60 % de confianza o aventaja a la segunda por menos de 15 puntos. En cualquiera de estos casos la aplicación muestra **«Imagen no reconocida»** y no emite diagnóstico.

2.5.3. Mitigación en la Interfaz

La interfaz incorpora dos elementos que complementan al modelo:

1. **Marco guía.** La cámara muestra la silueta de una hoja (*Acérquese a 20–30 cm y llene el marco*) y la imagen se recorta a esa región, con un margen de 15 %, antes de pasar al modelo.

2. **Guía de severidad.** Debajo del diagnóstico se muestra una escala de tres niveles (baja, moderada y crítica), basada en escalas del CIMMYT y de Iowa State University Extension, que el productor compara con su hoja, junto con bioinsumos disponibles en el agroservicio.

2.6. Sincronización y Aportes al Conjunto de Datos

La aplicación no necesita un servidor para diagnosticar. El servidor solo interviene cuando el productor decide compartir información, y para eso debe crear una cuenta. Puede enviar una corrección, si considera que el diagnóstico fue equivocado, o una fotografía con la etiqueta que él mismo le asigna, que pasa a formar parte del conjunto de datos colaborativo. Con la fotografía solo viajan la etiqueta, una nota opcional y la fecha.
Como en la parcela puede no haber señal, cada aporte se guarda primero en el teléfono y se envía después, cuando vuelve la conexión o cuando el usuario lo pide (Figura 2.4). El registro se marca como enviado solo cuando el servidor confirma que lo recibió, y si algo falla se intenta de nuevo más tarde. En el servidor, la API (FastAPI con MySQL 8.4) rechaza los envíos repetidos y acepta como máximo 30 solicitudes por minuto.

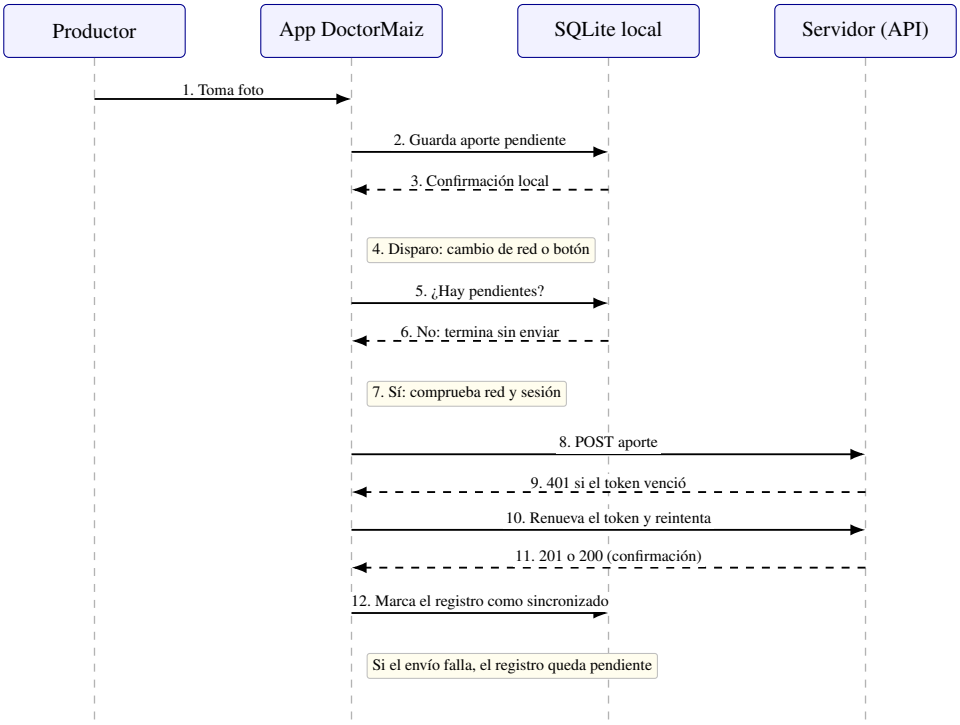


Figura 2.4: Flujo de sincronización de un aporte.

2.7. Arquitectura General del Sistema

El sistema se compone de tres repositorios independientes (Tabla 2.4).

Tabla 2.4: Tecnologías principales por proyecto

Proyecto	**Función**	**Tecnologías**
Pipeline del modelo	Entrenamiento, exportación y explicabilidad	PyTorch, timm, Optuna, litert-torch y ONNX Runtime para exportación, Modal (GPU A10G) para entrenamiento en la nube, SHAP y LIME.
Aplicación móvil	Captura, inferencia local y sincronización	Expo, React Native, TypeScript, `react-native-fast-tflite` para inferencia, WatermelonDB con SQLite local y NativeWind.
API de sincronización	Versión de la app y aportes al dataset colaborativo	FastAPI, SQLAlchemy, Alembic, MySQL en Docker Compose, JWT y bcrypt para autenticación y slowapi para límites de tasa.

La aplicación no tiene dependencia con el entorno de entrenamiento, solo empaqueta el modelo `.tflite`, las etiquetas y los parámetros del detector OOD, y se comunica con la API por HTTP. La Figura 2.5 resume el flujo completo.

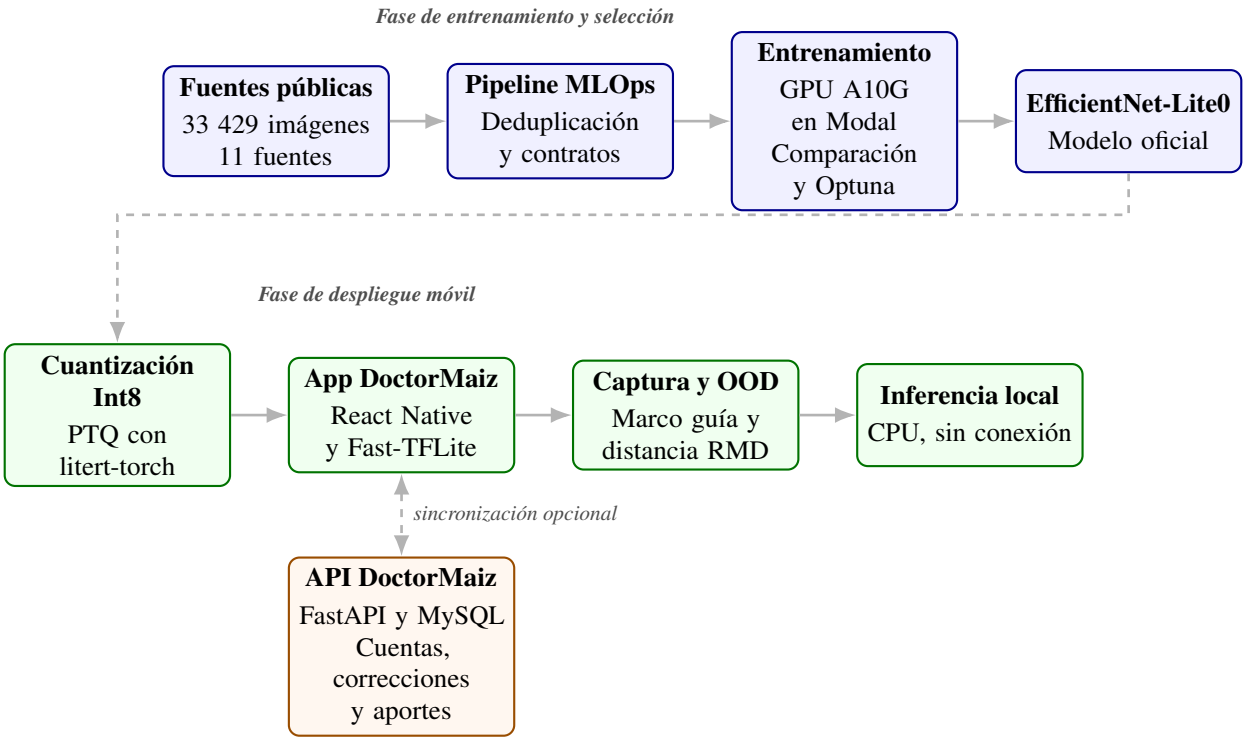


Figura 2.5: Arquitectura del sistema DoctorMaiz.

CAPÍTULO 3

ESTRATEGIA DE IMPLEMENTACIÓN Y ANÁLISIS DE RESULTADOS

3.1. Estrategia y Entorno de Implementación

3.1.1. Infraestructura de Cómputo y Entrenamiento en la Nube

El entrenamiento se realizó en la plataforma Modal, sobre GPU NVIDIA A10G de 24 GB de VRAM, con CUDA 12.6 y PyTorch 2.12.1.

En todos los entrenamientos se utilizó un calendario de tasa de aprendizaje de tipo coseno, precedido por tres épocas de calentamiento lineal. Este calentamiento evita que los primeros pasos de optimización alteren en exceso los pesos preentrenados en ImageNet [4] mientras la red se adapta a las nuevas clases. El entrenamiento se detenía cuando el Macro F_1 de validación no mejoraba durante 8 épocas consecutivas. Como muestra la Figura 3.1, las tres arquitecturas alcanzan un Macro F_1 cercano a 0.90 en torno a la décima época, y a partir de ese punto las mejoras son graduales.

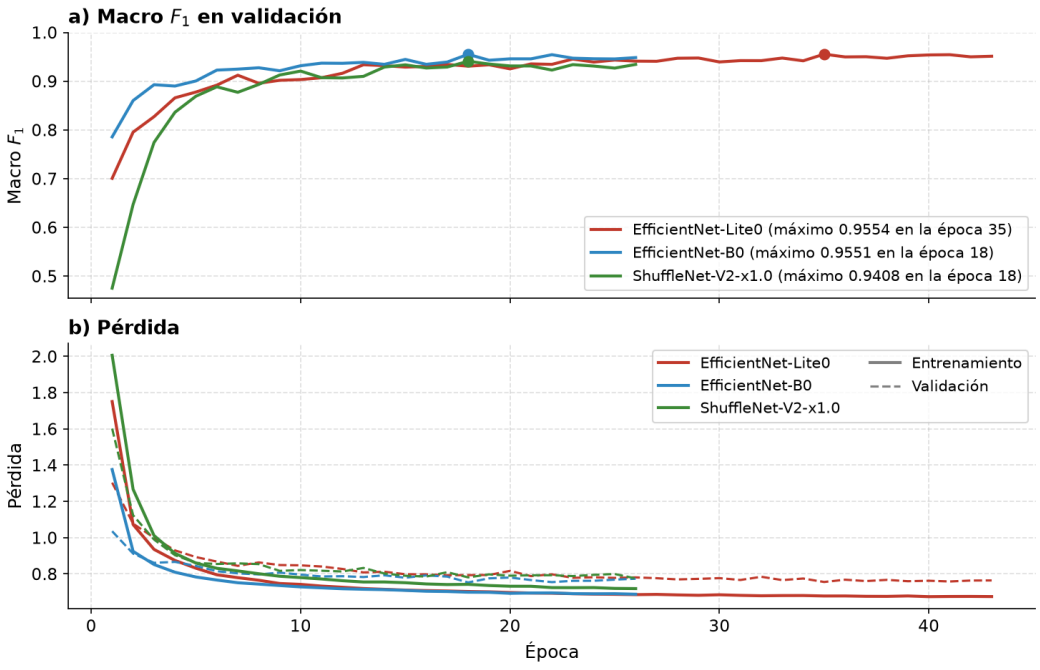


Figura 3.1: Macro F_1 de validación y pérdida por época de las tres arquitecturas con la configuración inicial.

3.2. Resultados

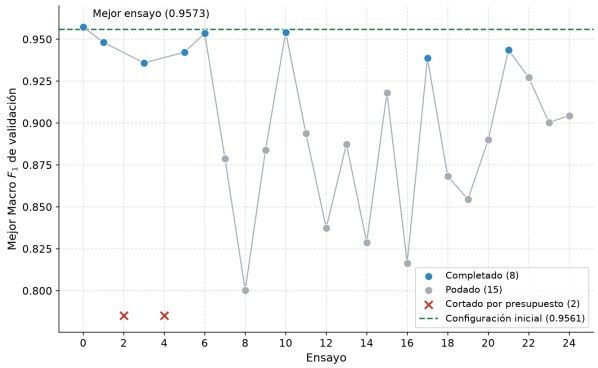
El sistema cumple los seis criterios de éxito (Tabla 3.1). Estos criterios se midieron sobre una partición que mezcla las fuentes, así que el desempeño en campo se analiza aparte, con la validación por fuente y las fotografías externas (Secciones 3.2.2 y 3.2.3).
El modelo oficial elegido es EfficientNet-Lite0 y es el que se usa en la aplicación.

Tabla 3.1: Estado de los criterios de éxito

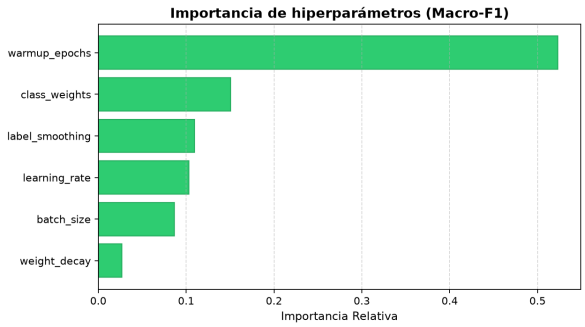
Criterio	**Resultado medido**	**Estado**
Macro $F_1 \geq 0{,}85$ en prueba	0.9480 con una semilla y $0{,}9435 \pm 0{,}0052$ con tres semillas.	Cumple
DIR $\geq 0{,}80$ entre laboratorio y campo	0.9636 en Macro F_1 y 0.9956 en exactitud, sobre las tres clases con imágenes de laboratorio.	Cumple
Solapamiento cero entre particiones	Ninguna de las 5 015 imágenes de prueba aparece en entrenamiento ni en validación.	Cumple
Modelo Int8 de 20 MB o menos	3.74 MB.	Cumple
Preprocesado e inferencia ≤ 300 ms	Medianas de 98 ms de preprocesado y 23 ms de inferencia en un Motorola edge 40 neo.	Cumple
Funcionamiento sin conexión	Clasificación local en el teléfono.	Cumple

3.2.1. Búsqueda Bayesiana de Hiperparámetros

La búsqueda de hiperparámetros con Optuna evaluó 25 configuraciones de EfficientNet-Lite0, cada una con un máximo de 60 épocas. De ellas, 8 completaron el entrenamiento, 15 fueron detenidas por la poda al quedar por debajo de la mediana y 2 quedaron sin terminar porque se alcanzaron los límites de créditos de cómputo. La búsqueda consumió en total 12.65 horas de GPU, y la configuración con mejor Macro F_1 de validación fue la del ensayo 0. Como muestra la Figura 3.2, solo ese ensayo superó, por poco, a la configuración inicial, y los ensayos podados quedaron claramente por debajo.



a) Mejor Macro F_1 de validación de cada ensayo.



b) Importancia de los hiperparámetros.

Figura 3.2: Resultados de la búsqueda con Optuna.

El análisis de importancia (Figura 3.2) indica que el número de épocas de calentamiento es el hiperparámetro que más influye en el resultado, con un peso de 0.52, muy por encima de la ponderación de la pérdida (0.15), el suavizado de etiquetas (0.11), la tasa de aprendizaje (0.10) y el tamaño de lote (0.09). La Tabla 3.2 compara la mejor configuración encontrada con la utilizada inicialmente.

Tabla 3.2: Configuración inicial frente a la mejor configuración de Optuna

Métrica o hiperparámetro	**Inicial**	**Optuna**	**Diferencia**
Macro F_1 en validación	0.9561	0.9573	+0.12 pp
Macro F_1 en prueba	0.9480	0.9431	$-0{,}49$ pp
Tasa de aprendizaje	$1{,}00 \times 10^{-4}$	$8{,}47 \times 10^{-5}$	—
Tamaño de lote	32	16	—
Épocas de calentamiento	3	1	—
Decaimiento de pesos	$1{,}00 \times 10^{-4}$	$5{,}67 \times 10^{-3}$	—
Ponderación de la pérdida	`sqrt_inverse`	`none`	—
Suavizado de etiquetas	0.10	0.075	—

La configuración encontrada por Optuna mejoró en 0.12 puntos porcentuales el Macro F_1 de validación, pero en el conjunto de prueba obtuvo 0.49 puntos menos que la configuración inicial. Una mejora tan pequeña, que además no se traslada a la prueba, es compatible con un ajuste a las particularidades del conjunto de validación. Por ese motivo se conservó la configuración inicial (tasa de aprendizaje de 10^{-4}, lote de 32, ponderación `sqrt_inverse` y suavizado de 0.1), con la que el modelo oficial alcanzó en prueba un Macro F_1 de **0.9480** y una exactitud de 97.81 %.

3.2.2. Generalización entre Fuentes

Con el fin de medir cuánto depende el desempeño de las fuentes vistas durante el entrenamiento, se repitió la validación cruzada de 5 pliegues con dos esquemas de partición. El primero es la partición estratificada

que se usa normalmente. El segundo agrupa las imágenes por fuente, de modo que ningún repositorio aparece a la vez en entrenamiento y en evaluación. Cada esquema se probó con la configuración inicial y con una configuración ajustada (Tabla 3.3 y Figura 3.3).

Tabla 3.3: Validación cruzada de 5 pliegues con partición estratificada y agrupada por fuente

Configuración	**Estratificada (media ± IC95)**	**Agrupada por fuente (media ± IC95)**	**Diferencia**
Hiperparámetros iniciales	$0{,}9311 \pm 0{,}0099$	$\mathbf{0{,}6026 \pm 0{,}1240}$	$\mathbf{-0{,}3286}$
Hiperparámetros ajustados	$0{,}9463 \pm 0{,}0052$	$0{,}6499 \pm 0{,}1508$	$-0{,}2964$

La forma de partir los datos pesó mucho más que los hiperparámetros. Con la partición estratificada el Macro F_1 fue de 0.9311, y al evaluar con fuentes que el modelo no vio durante el entrenamiento bajó a 0.6026 (0.4359 sobre las nueve clases). Ajustar los hiperparámetros apenas lo movió, de 0.9311 a 0.9463. El intervalo de confianza también creció, de $\pm 0{,}0099$ a $\pm 0{,}1240$, porque el resultado cambia bastante según qué fuente quede fuera.

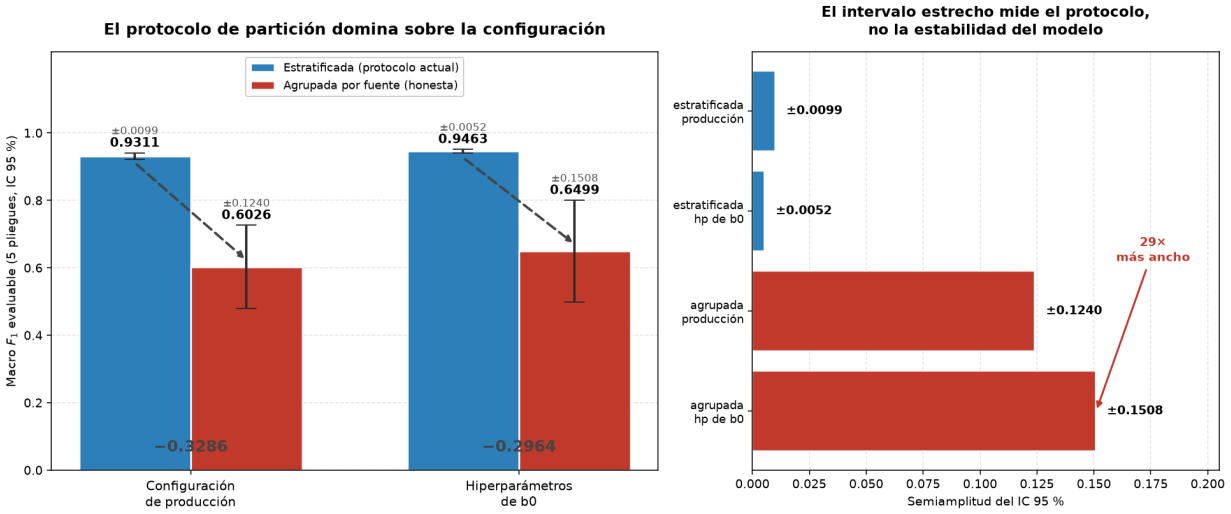
Una caída de 0.33 no se explica por el azar del entrenamiento, entre tres semillas, el Macro F_1 varió con una desviación estándar de 0.0052, y entre pliegues estratificados, de 0.0080 (Figura 3.3). Lo más probable es que el modelo, además de los síntomas, haya aprendido rasgos de cada repositorio, como el fondo, la luz o la cámara, algo que ya se ha observado en otros trabajos con imágenes de cultivos [1].

En la evaluación LOSO (*leave-one-source-out*), el modelo se entrenó sin una fuente completa y se probó solo con las imágenes de esa fuente, con tres semillas (Tabla 3.4). Sin `maize-diseases`, el Macro F_1 quedó en 0.9933, casi igual que si esa fuente se hubiera visto. Con `multicrop-disease-maiz` el resultado fue otro, y la exactitud bajó a 80.38 %.

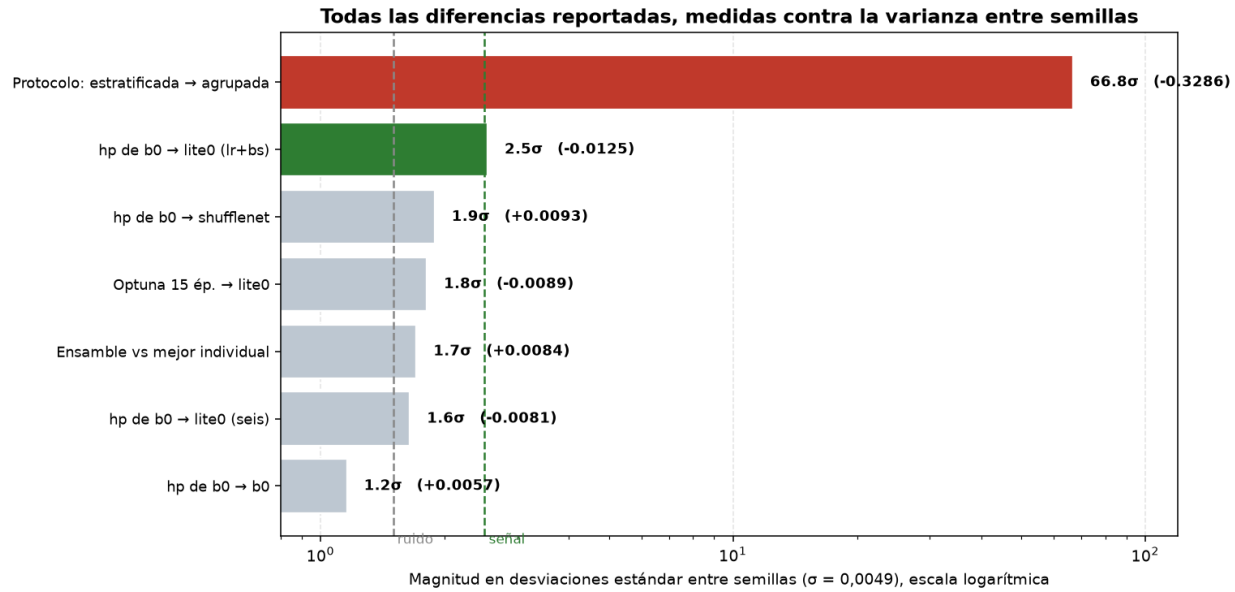
Tabla 3.4: Macro F_1 y exactitud en la fuente retenida, evaluación LOSO con tres semillas

Fuente retenida	**Macro F_1 (media ± DE)**	**Exactitud (media ± DE)**	**Semillas**
`maize-diseases`	0.9933 ± 0.0006	$99.37\,\% \pm 0.07$ pp	3
`multicrop-disease-maiz`	0.9019 ± 0.0044	$80.38\,\% \pm 0.32$ pp	3

Los resultados casi no cambian entre las tres semillas, así que la caída al retirar `multicrop-disease-maiz` no es solo casualidad, la caída depende de qué fuente se deja fuera.



a) Macro F_1 e intervalo de confianza según la partición.



b) Magnitud de cada efecto en desviaciones estándar.

Figura 3.3: Efecto de la partición frente al ajuste de hiperparámetros.

3.2.3. Fotografías de Campo Externas

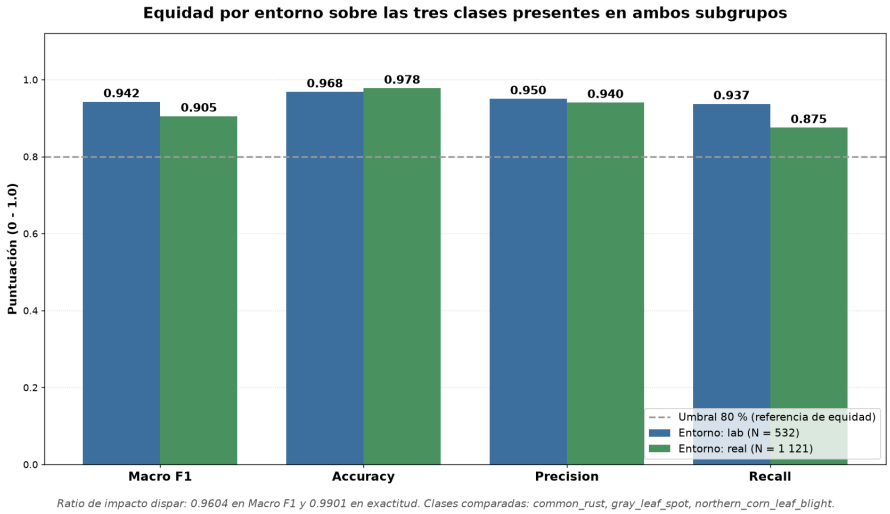
La prueba más cercana al uso real consistió en evaluar el modelo oficial con 97 fotografías de campo ajenas al corpus, organizadas por clase. El modelo acertó 41 de ellas (42 %) y el detector OOD rechazó 49 (Tabla 3.5). Esta cifra concuerda con la caída observada en la validación por fuente y constituye la principal limitación del sistema. El desempeño, además, es muy desigual entre clases. La mancha gris y el gusano cogollero se reconocieron en las 10 fotografías de cada una, mientras que ninguna de las 10 de necrosis letal se clasificó correctamente.

Tabla 3.5: Aciertos del modelo oficial en fotografías de campo externas, por clase

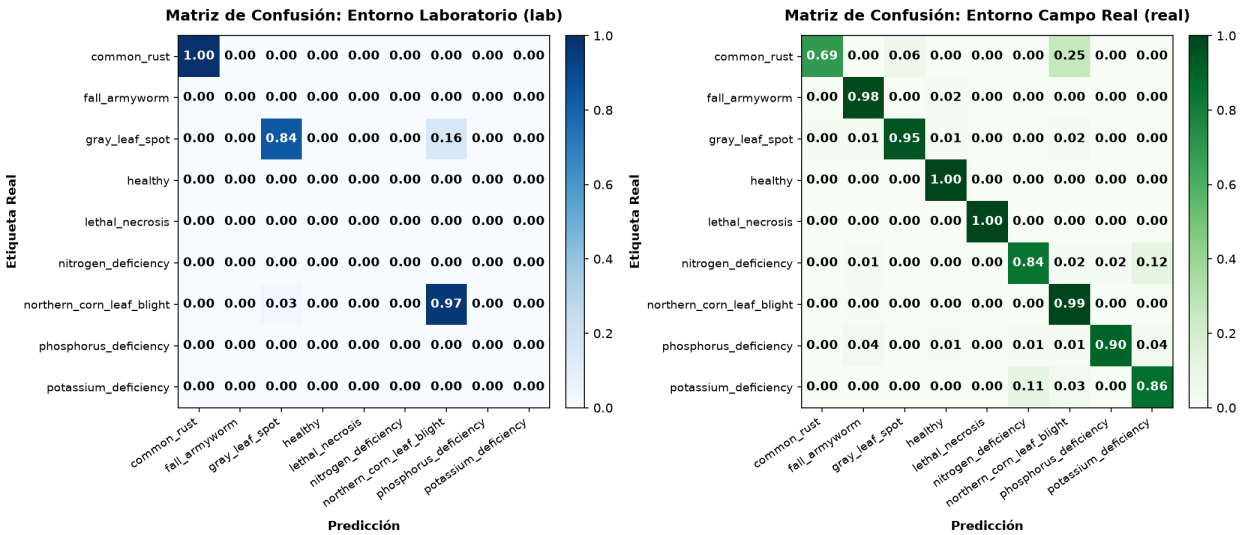
Clase	**Fotografías**	**Aciertos**
Roya común	18	2
Deficiencia de fósforo	10	2
Mancha gris	10	10
Deficiencia de nitrógeno	10	6
Deficiencia de potasio	9	4
Tizón foliar	10	5
Gusano cogollero	10	10
Necrosis letal	10	0
Hoja sana	10	2
Total	**97**	**41**

3.2.4. Equidad entre Laboratorio y Campo

Para comparar el desempeño entre imágenes de laboratorio y de campo se utilizó el *Disparate Impact Ratio* (DIR), que divide el desempeño del entorno con peor resultado entre el del mejor. Según la regla de los cuatro quintos, un valor igual o superior a 0.80 se considera aceptable. Dado que solo la roya, la mancha gris y el tizón cuentan con imágenes de laboratorio, el cálculo se restringió a esas tres clases. Con el modelo oficial, evaluado sobre 533 imágenes de laboratorio y 1 120 de campo, el Macro F_1 fue de 0.9383 y 0.9041, respectivamente, lo que da un DIR de 0.9636 (0.9956 si se calcula sobre la exactitud). Sin embargo, un DIR cercano a uno no implica que todas las clases se comporten igual en ambos entornos. El desglose de falsos negativos (Tabla 3.6) revela diferencias importantes. La roya común apenas falla en laboratorio (1 de 322 casos), pero falla en 5 de los 16 casos de campo (31.25 %), lo que es coherente con que el 95 % de sus imágenes procedan del laboratorio. Esta diferencia se mantiene con el modelo oficial, cuyo F_1 para la roya es de 0.998 en laboratorio y de 0.77 en campo. La mancha gris presenta el patrón contrario, con un 15.58 % de falsos negativos en laboratorio y un 5.16 % en campo.



a) Disparidad por entorno.



b) Matrices de confusión por entorno.

Figura 3.4: Desempeño por entorno de captura.

Tabla 3.6: Tasa de falsos negativos (FNR) por clase y entorno.

Clase	FNR **laboratorio**	**Imágenes**	FNR **campo**	**Imágenes**
Roya común	0.31 %	322	**31.25 %**	16
Mancha gris	15.58 %	77	5.16 %	213
Tizón foliar	3.01 %	133	1.01 %	892

3.2.5. Dependencia del Fondo

Para determinar en qué medida el modelo se apoya en la hoja o en el entorno, se ocultaron distintas regiones de las 5 015 imágenes de prueba y se midió la exactitud con lo que quedaba visible (Tabla 3.7 y Figura 3.5). Como referencia se usó un predictor nulo, que no mira la imagen y lo que hace es responder siempre con la clase más frecuente de la prueba, la hoja sana. Ese predictor acierta el 26.14 % de las veces, así que cualquier exactitud por encima de ese valor indica que la región visible todavía contiene información sobre la clase. La columna «Sobre el nulo» de la tabla muestra esa diferencia.

Tabla 3.7: Exactitud al ocultar regiones de la imagen.

Condición	**Región visible**	**Área**	**Exactitud**	**Sobre el nulo**	**Confianza retenida**
Imagen completa	Toda la escena	100.0 %	97.91 %	+71.77 pp	100.0 %
Centro oculto	**Borde**	**63.7 %**	**79.46 %**	**+53.32 pp**	**69.16 %**
Periferia oculta	Centro	36.3 %	42.25 %	+16.11 pp	42.66 %
Predictor nulo	Ninguna	0.0 %	26.14 %	0.0 pp	—

Cuando se oculta el centro de la imagen, el modelo conserva un **79.46 % de exactitud** a partir del borde, mientras que al ocultar la periferia la exactitud desciende a 42.25 %. Las dos condiciones no dejan visible la misma superficie (63.7 % y 36.3 %), pero la diferencia es lo bastante amplia para sugerir que el fondo aporta información sobre la clase. Este resultado motivó que la aplicación recorte la captura al marco guía antes de clasificarla.

Los mapas de Grad-CAM [21], LIME [20] y SHAP [13] coinciden, en los ejemplos analizados, con las lesiones visibles (Figuras 3.6 y 3.7), pero, al cuantificar cuánta atribución recae sobre la hoja más allá de lo esperado por su área, el exceso medio en seis clases (270 imágenes con máscara de la hoja) fue de apenas +0.037, con tres clases por encima de lo esperado y tres por debajo. Una explicación posible es que la señal del fondo esté repartida en muchos píxeles y, por ello, no destaque en los mapas locales.

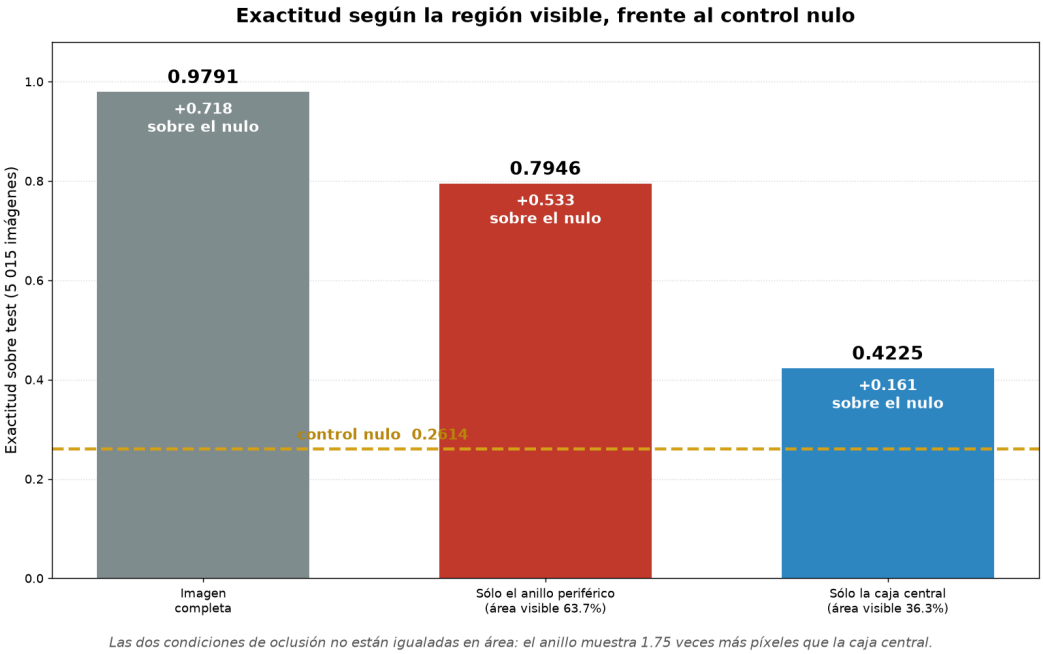
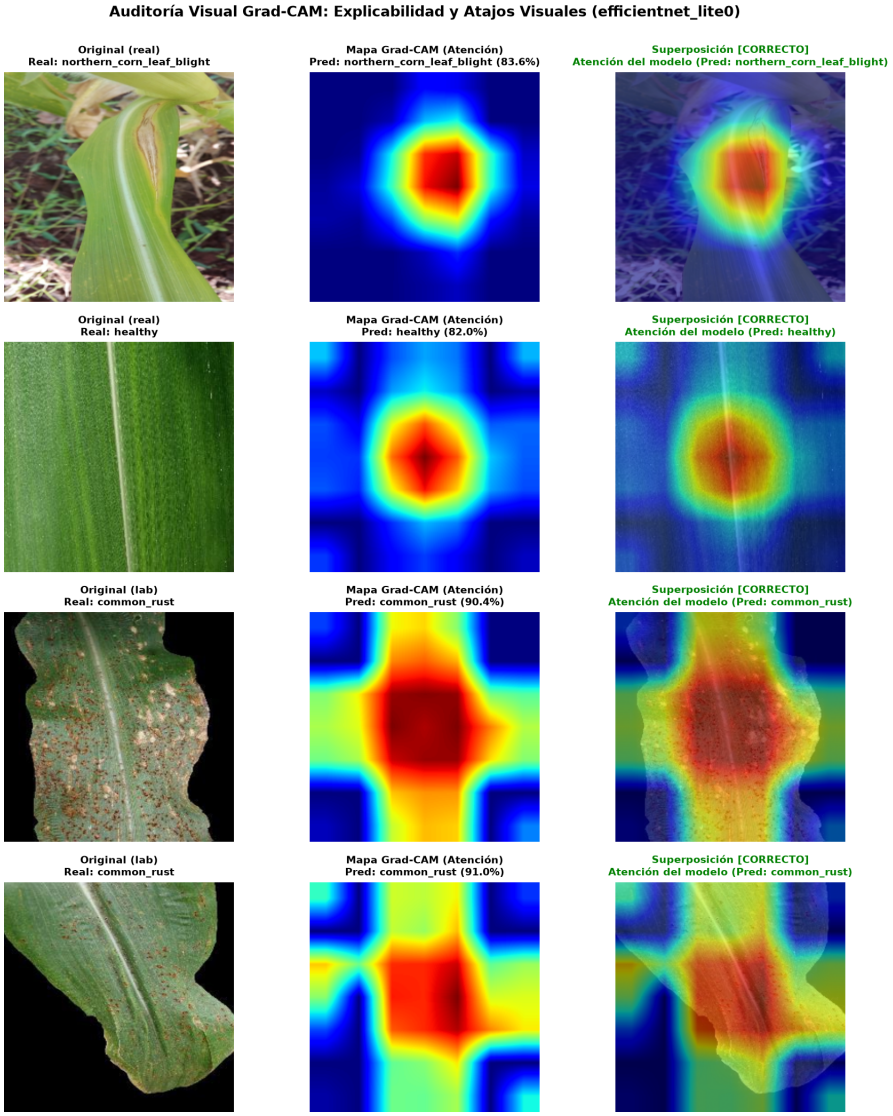


Figura 3.5: Exactitud según la región visible de la imagen.



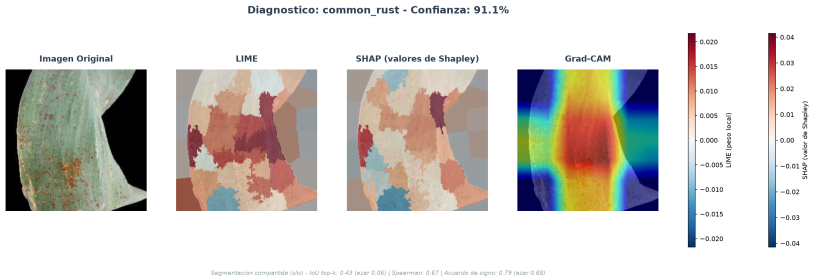


Figura 3.7: Explicaciones locales de LIME, SHAP y Grad-CAM para la roya común.

3.2.6. Desempeño en el Teléfono

Cuantizado a Int8, el modelo oficial pesa **3.74 MB**, un 72.9 % menos que la versión en coma flotante (13.79 MB). Esa reducción no le costó precisión. En las 5 015 imágenes de prueba, el modelo Int8 obtuvo un Macro F_1 de 0.9489 y una exactitud de 97.87 %, prácticamente lo mismo que el original (0.9480 y 97.81 %), y coincidió con él en el 99.74 % de las predicciones.

Las pruebas en el teléfono se hicieron en un Motorola edge 40 neo (MediaTek Dimensity 7030, 8 GB de RAM, Android 15), un equipo de gama media. Preparar la imagen tomó una mediana de **98 ms** (p95 de 279 ms) y la inferencia, **23 ms** (Tabla 3.8), ambos por debajo de la meta de 300 ms. Lo que más tarda, entonces, no es el modelo sino el preprocesado, que se lleva cuatro veces más tiempo que la inferencia. El flujo completo, desde la captura hasta que aparece el resultado, tomó 473 ms.

Tabla 3.8: Latencias medianas en el Motorola edge 40 neo

Fase	Modelo	Mediana
Preprocesado	Oficial (Int8)	98 ms
Inferencia	Oficial (Int8)	23 ms
Flujo completo	Versión anterior	473 ms

Para verificar que la aplicación produce las mismas predicciones que el modelo evaluado en las secciones anteriores, se procesaron en el teléfono 143 imágenes, 95 fotografías de campo y 48 del corpus. Las predicciones coincidieron con las del modelo Int8 en las 143 imágenes. El teléfono acertó 45 de las 48 imágenes del corpus (93.8 %) y 38 de las 95 fotografías de campo (40.0 %), cifras similares a las obtenidas en las pruebas de las secciones anteriores.

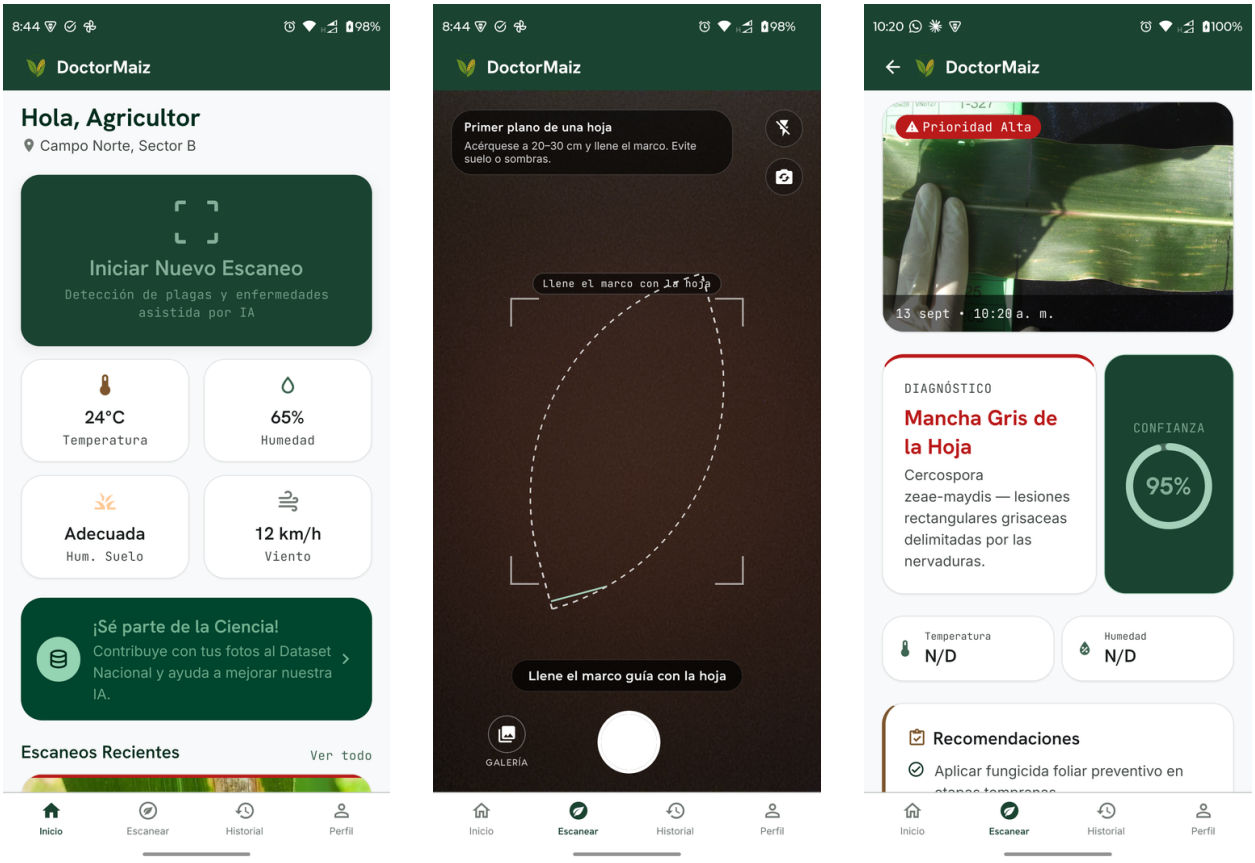
Por último, la interfaz incorpora los elementos descritos en el Capítulo 2 (Figuras 3.8 y 3.9):

1. **Marco guía.** La aplicación recorta la captura al marco con un margen de 15 %. En el teléfono de prueba, la imagen pasa de 12.6 a 3.02 megapíxeles.

2. **Detector OOD.** Cuando la puntuación supera el umbral de 106.37, la aplicación muestra **«Imagen no reconocida»**. El detector rechazó las cinco imágenes sintéticas de prueba (negro, blanco, gris, ruido y azul) y, por error, el 3.8 % de 500 imágenes de prueba válidas.

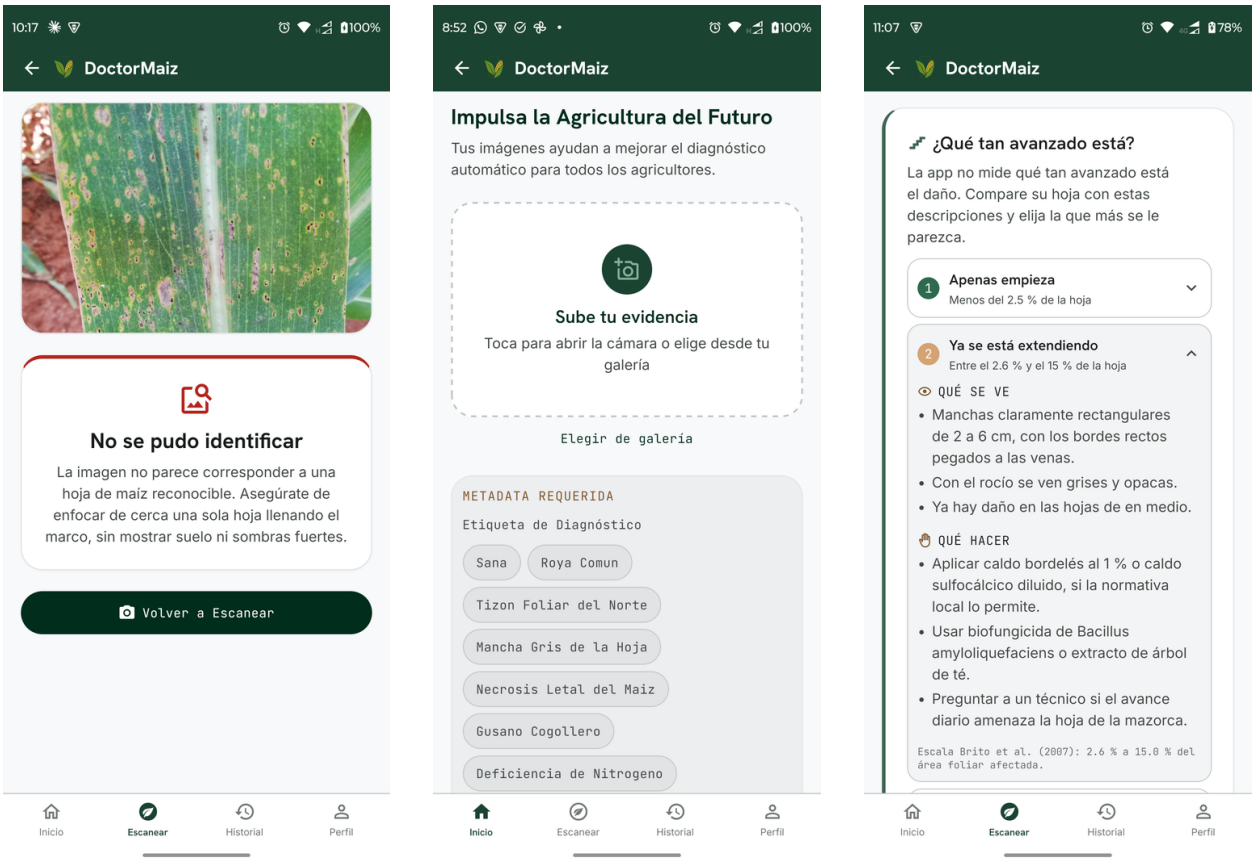
3. **Aportes.** El productor puede guardar fotografías de su milpa para enviarlas cuando haya conexión.

4. **Guía de severidad.** Muestra una escala de tres niveles que el productor compara con su hoja, con pautas de bioinsumos.



a) Pantalla de inicio. b) Marco guía. c) Diagnóstico.

Figura 3.8: Flujo principal de la aplicación DoctorMaiz.



a) Imagen no reconocida. b) Aporte de fotografías. c) Guía de severidad.

Figura 3.9: Rechazo de imágenes, aportes y guía de severidad.

3.2.7. Ensamble

También se evaluó un ensamble por votación suave de las tres arquitecturas, que superó a cada una por separado en la partición estratificada (Tabla 3.9 y Figura 3.10). Para el ensamble se usaron entrenamientos históricos de cada arquitectura, hechos específicamente para esta comparación.

Tabla 3.9: Ensamble frente a modelos individuales en la prueba (5 015 imágenes)

Modelo	**Exactitud**	**Macro F_1**	**Precisión**	**Recall**
ShuffleNet-V2-x1.0	97.31 %	0.9330	0.9388	0.9298
EfficientNet-Lite0	97.91 %	0.9468	0.9533	0.9413
EfficientNet-B0	97.97 %	0.9483	0.9589	0.9400
Ensamble (votación suave)	**98.29 %**	**0.9567**	**0.9642**	**0.9506**
Ganancia frente al mejor individual	*+0.32 pp*	*+0.83 pp*	*+0.52 pp*	*+0.93 pp*

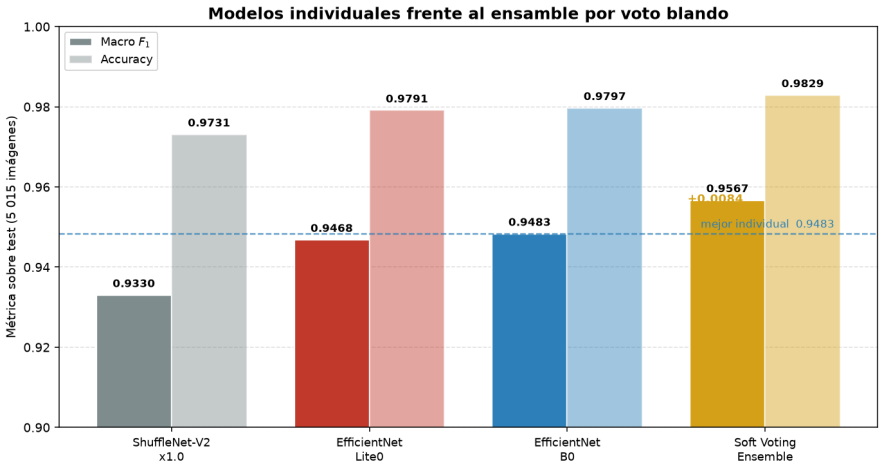


Figura 3.10: Desempeño del ensamble frente a los modelos individuales.

En un sistema de diagnóstico el recall tiene cierta mayor importancia, porque cada falso negativo deja sin atención una infección. El ensamble alcanzó un recall macro de **95.06 %**, y su matriz de confusión (Figura 3.11) muestra que detectó los 963 casos de necrosis letal de la prueba y más del 98 % de los de roya y tizón. Con fuentes no vistas, en cambio, el recall de necrosis letal se redujo a valores entre 0.72 y 0.81 en la evaluación LOSO.

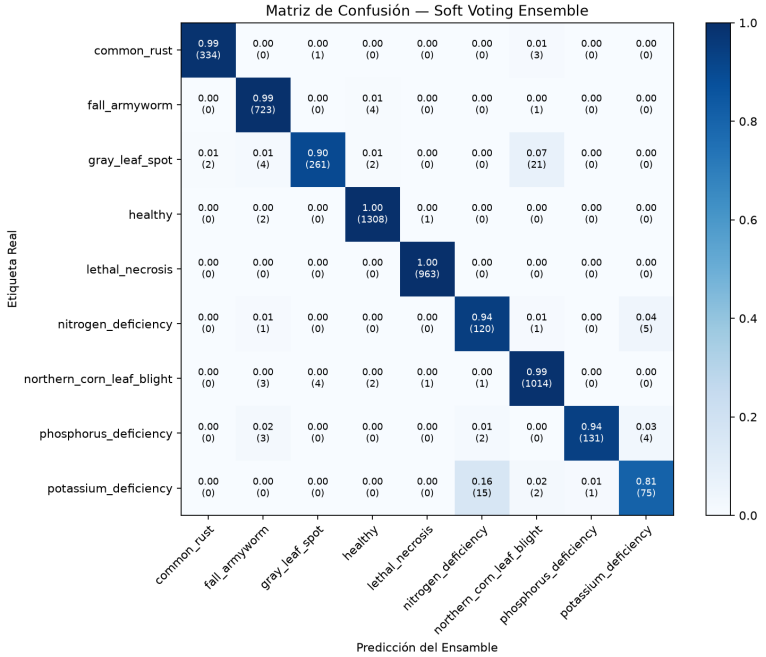


Figura 3.11: Matriz de confusión normalizada del ensamble sobre 5 015 imágenes de prueba.

El caso de la deficiencia de potasio nos muestra el efecto de ampliar el corpus de entrenamiento, ya que esta clase, que en los primeros entrenamientos tenía un F_1 de 0.49, alcanzó **0.8475** en el ensamble y 0.8242

en el modelo oficial (Tabla 3.10). La mejora coincide precisamente con la incorporación de nuevos repositorios de deficiencias nutricionales y con el uso de la ponderación `sqrt_inverse` en la función de pérdida.

Tabla 3.10: F_1 por clase de los modelos individuales y del ensamble

Clase	**Imágenes**	**Lite0**	**B0**	**ShuffleNet**	**Ensamble**
Necrosis letal	963	**0.9990**	0.9984	0.9974	**0.9990**
Hoja sana	1 311	0.9936	0.9954	0.9901	**0.9958**
Roya común	338	0.9866	0.9896	0.9867	**0.9911**
Gusano cogollero	728	0.9814	**0.9877**	0.9815	**0.9877**
Tizón foliar	1 025	0.9797	0.9769	0.9728	**0.9811**
Mancha gris	290	**0.9451**	0.9194	0.9120	0.9388
Deficiencia de fósforo	140	0.9403	0.9527	0.9275	**0.9632**
Deficiencia de nitrógeno	127	0.8664	0.8939	0.8613	**0.9057**
Deficiencia de potasio	93	0.8290	0.8208	0.7674	**0.8475**
Promedio macro	**5 015**	0.9468	0.9483	0.9330	**0.9567**

CONCLUSIONES Y RECOMENDACIONES

Conclusiones

La presente investigación pasa de una prueba de concepto a un sistema de diagnóstico foliar de maíz que se ejecuta sin conexión en un teléfono. Por objetivo específico del Capítulo 1, se obtuvo lo siguiente:

- **Corpus:** 33 429 imágenes de 11 fuentes, con cero solapamiento por hash y por píxeles entre particiones.
- **Optimización:** 25 ensayos de Optuna con poda temprana (15 podados, 12.65 horas de GPU). El ganador rindió 0.49 pp menos en prueba y se conservó la configuración inicial.
- **Ensamble:** Macro F_1 de 0.9567 con votación suave.
- **Evaluación:** Macro F_1 de 0.6026 en validación agrupada por fuente frente a 0.9311 en la estratificada; la ablación dejó 79.46 % de exactitud al ocluir el centro y 42.25 % al ocluir la periferia.
- **Despliegue móvil:** Modelo Int8 de 3.74 MB, con 98 ms de preprocesado y 23 ms de inferencia en un teléfono de gama media.
- **Propuesta institucional:** Cinco recomendaciones para el MAG y el CENTA, al final de este capítulo.

Las conclusiones se detallan a continuación.

1. **Modelo oficial y su exportación móvil:** El modelo oficial (EfficientNet-Lite0, run `20260921_204608`) obtuvo un Macro F_1 de **0.9480** y una exactitud de 97.81 % sobre 5 015 imágenes de prueba, y 0.9435 $\pm$ 0.0052 con tres semillas. Su versión Int8 pesa **3.74 MB** (72.9 % menos que el punto de control FP32) y obtuvo un Macro F_1 de 0.9489, con 99.74 % de acuerdo con PyTorch. En el Motorola edge 40 neo la mediana fue de 98 ms de preprocesado y 23 ms de inferencia, y el teléfono reproduce las predicciones del Int8 del servidor en 143 de 143 imágenes.
2. **Generalización entre fuentes, limitación principal:** En 97 fotografías de campo externas el modelo acertó 41 (42 %) y el detector OOD rechazó 49. Una versión anterior del modelo acertó 39, así que la brecha no se explica por el cambio de modelo. Coincide con la validación agrupada por fuente, donde el Macro F_1 baja de 0.9311 $\pm$ 0.0099 a 0.6026 $\pm$ 0.1240, y con LOSO: 0.9933 $\pm$ 0.0006 sin `maize-diseases` y 0.9019 $\pm$ 0.0044 sin `multicrop-disease-maiz`, fuentes que contienen solo tres clases cada una.

3. **Dependencia del fondo:** El *Disparate Impact Ratio* entre laboratorio y campo, calculado sobre las tres clases presentes en ambos entornos, es 0.9636 con el modelo oficial y supera el umbral de 0.80, pero no refleja la roya de campo, que con 16 imágenes obtiene $F_1 = 0{,}77$ frente a 0.998 en laboratorio. La ablación espacial dejó 79.46 % de exactitud al ocluir el centro y 42.25 % al ocluir la periferia. Es compatible con sensibilidad a la región periférica, pero las áreas visibles difieren y el experimento no separa el fondo de la hoja.

4. **Mitigación en la interfaz:** La aplicación incorporó un marco guía de captura y un detector OOD basado en distancia de Mahalanobis relativa, con umbral 106.37 (percentil 95 de validación). El detector rechazó las 5 imágenes sintéticas de prueba y 3.8 % de 500 imágenes válidas.

5. **Ensamble:** El ensamble de EfficientNet-Lite0, EfficientNet-B0 y ShuffleNet-V2 alcanzó un Macro F_1 de 0.9567 en una partición que mezcla fuentes y con una sola semilla; no está desplegado. Bajo LOSO el recall de MLN baja a 0.79–0.81 en el ensamble y a 0.72–0.74 en Lite0.

Limitaciones

1. **Generalización:** Fuera de las fuentes de entrenamiento el desempeño cae, de modo que las cifras de la partición estratificada no describen el uso en campo. Además, ciertas fuentes aportan una sola patología y no se midió la similitud perceptual entre particiones.

2. **Cobertura y evidencia de campo:** La taxonomía no incluye la mancha de asfalto y no hay reportes locales de necrosis letal. Se desconocen el lugar, la fecha y el criterio de etiquetado de las 97 fotografías externas, y el sistema no se evaluó con productores.

3. **Dispositivo:** Las mediciones en teléfono provienen de un solo dispositivo de gama media.

4. **Alcance del diagnóstico:** El sistema indica la clase y no mide la severidad; la guía de tres niveles la compara el productor con su hoja.

5. **Búsqueda de hiperparámetros:** Se redujo a 25 ensayos y no se comparó con una búsqueda sin poda, de modo que el ahorro de la poda no se midió.

6. **Beneficio económico:** Al no existir una cuantificación nacional de pérdidas, el ahorro que el diagnóstico podría producir no se estimó.

7. **Licencias:** Tres fuentes (31.1 % del corpus) tienen licencia CC BY-NC-SA 4.0, por lo que el uso comercial y la redistribución requieren una revisión legal.

Trabajo futuro

- Reunir y etiquetar fotografías salvadoreñas con apoyo técnico del CENTA o del MAG, incluida la mancha de asfalto, documentando su procedencia, y reentrenar evaluando con fuentes completas retenidas.
- Medir cobertura y exactitud con distintos umbrales de rechazo y auditar la similitud perceptual entre particiones.
- Probar la aplicación con productores y asesores, y en teléfonos de gama baja.
- Reducir el tiempo de preprocesado en el teléfono.

Recomendaciones

Con base en los resultados, se proponen cinco recomendaciones dirigidas al Ministerio de Agricultura y Ganadería (MAG) y al Centro Nacional de Tecnología Agropecuaria y Forestal (CENTA), que responden a las limitaciones anteriores:

1. **Validación en campo antes de la adopción institucional:** Evaluar la aplicación con promotores del CENTA sobre fotografías propias de cada zona productora, dado que la exactitud en fotografías de campo externas fue de 42 % (Sección 3.2.3).
2. **Banco nacional participativo de datos agrícolas:** Financiar brigadas fotográficas junto a la Universidad de El Salvador para capturar variedades y condiciones locales, con el fin de reducir la brecha de dominio detectada.
3. **Red de alerta fitosanitaria temprana:** Evaluar el uso de los aportes voluntarios sincronizados para un tablero epidemiológico centralizado en el MAG, sujeto a una política explícita de tratamiento de metadatos y ubicación.
4. **Capacitación comunitaria:** Enseñar a cooperativas y ADESCOs el uso del marco guía de captura, posicionando la herramienta como apoyo al criterio del productor.
5. **Software abierto y protección de datos:** Conservar el software bajo licencias de código abierto y definir las condiciones de uso de los datos aportados por los productores.

BIBLIOGRAFÍA

[1] Ahmad, A., El Gamal, A., & Saraswat, D. (2023). Toward generalization of deep learning-based plant disease identification under controlled and field conditions. *IEEE Access*, 11, 9042–9057.

[2] Banco Central de Reserva de El Salvador (BCR). (2023). *Revista Económica: Aporte Agropecuario al Producto Interno Bruto 2022-2023*. San Salvador: BCR.

[3] Centro Nacional de Tecnología Agropecuaria y Forestal "Enrique Álvarez Córdova" (CENTA). (2022). *Guía técnica del cultivo de maíz en El Salvador*. San Salvador: CENTA / Gerencia de Investigación y Transferencia.

[4] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 248–255).

[5] Deras F., H. R., Flor de Serrano, R., Mejía, C., & Moreno, W. (2015). Evaluación de híbridos trilineales de maíz (*Zea mays* L.), por su reacción al Complejo Mancha de asfalto causada por los patógenos (*Phyllachora maydis*, *Monographella maydis* y *Coniothyrium phyllacorae*). *Producción Agropecuaria y Desarrollo Sostenible*, 3, 77–88. https://camjol.info/index.php/PAyDS/article/view/3973

[6] Diario El Mundo. (2025, 7 de febrero). El déficit de granos básicos supera los 9.9 millones de quintales en 2025. https://diario.elmundo.sv/economia/el-deficit-de-granos-basicos-supera-los-9-9-millones-de-quintales-en-2025

[7] Eash, L., Fonte, S. J., Sonder, K., Honsdorf, N., Schmidt, A., Govaerts, B., & Verhulst, N. (2019). Factors contributing to maize and bean yield gaps in Central America vary with site and agroecological conditions. *The Journal of Agricultural Science*, 157(4). https://doi.org/10.1017/S0021859619000571

[8] El Diario de Hoy. (2024, 4 de abril). Las altas temperaturas en El Salvador tendrán efecto en el ciclo agrícola 2024-2025. https://www.elsalvador.com/?p=1134038

[9] Howard, A. G., et al. (2017). MobileNets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*.

[10] Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 7132–7141).

[11] Jacob, B., Kligys, S., Chen, B., Zhu, M., Tang, M., Howard, A., Adam, H., & Kalenichenko, D. (2018). Quantization and training of neural networks for efficient integer-arithmetic-only inference. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 2704–2713).

[12] Lee, K., Lee, K., Lee, H., & Shin, J. (2018). A simple unified framework for detecting out-of-distribution samples and adversarial attacks. En *Advances in Neural Information Processing Systems (NeurIPS)*, 31.

[13] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 4765–4774.

[14] Ma, N., Zhang, X., Zheng, H.-T., & Sun, J. (2018). ShuffleNet V2: Practical guidelines for efficient CNN architecture design. En *Proceedings of the European Conference on Computer Vision (ECCV)* (pp. 116–131).

[15] Mahuku, G., Lockhart, B. E., Wanjala, B., Jones, M. W., Kimunye, J. N., Stewart, L. R., … & Redinbaugh, M. G. (2015). Maize lethal necrosis (MLN), an emerging threat to maize-based food security in sub-Saharan Africa. *Phytopathology*, 105(7), 956–965. https://doi.org/10.1094/PHYTO-12-14-0367-FI

[16] Ministerio de Agricultura y Ganadería (MAG). (2023). *Anuario de Estadísticas Agropecuarias y Seguridad Alimentaria en El Salvador 2022-2023*. San Salvador: MAG / Dirección General de Economía Agropecuaria.

[17] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)* (pp. 2623–2631).

[18] Mueller, M., & Hein, M. (2025). Mahalanobis++: Improving OOD detection via feature normalization. *arXiv preprint arXiv:2505.18032*.

[19] Ren, J., Fort, S., Liu, J., Roy, A. G., Padhy, S., & Lakshminarayanan, B. (2021). A simple fix to Mahalanobis distance for improving near-OOD detection. *arXiv preprint arXiv:2106.09022*.

[20] Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. En *ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)* (pp. 1135–1144).

[21] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 618–626).

[22] Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. En *International Conference on Machine Learning (ICML)* (pp. 6105–6114).

GLOSARIO DE TÉRMINOS

Clever Hans Effect: Fenómeno en el cual un modelo de aprendizaje automático alcanza una aparente alta precisión apoyándose en correlaciones espurias o atajos del entorno (fondos, sensores, marcas de agua) en lugar de las características intrínsecas de la clase.

Disparate Impact Ratio (DIR): Métrica de equidad que cuantifica el cociente entre el desempeño del grupo con peor resultado y el del mejor, aquí medido con Macro F_1 o exactitud. Un valor inferior a 0.80 se toma como indicio de trato dispar.

Macro F_1-Score: Media aritmética no ponderada del valor F_1 calculado independientemente para cada clase. Asigna el mismo peso relativo a clases minoritarias y mayoritarias, siendo la métrica estándar ante conjuntos desbalanceados.

Necrosis Letal del Maíz (MLN): Complejo viral provocado por la coinfección sinérgica del virus del moteado clorótico del maíz (MCMV) y un potyvirus (como SCMV), con pérdidas de rendimiento de hasta 90 % documentadas en Kenia en 2012.

Out-of-Distribution (OOD): Condición que presentan aquellas muestras alimentadas a un clasificador cuyas características estadísticas provienen de una distribución ajena a la utilizada durante el entrenamiento (ej. fotografiar una piedra o una mano frente a un modelo de hojas).

ANEXOS

Anexo A: Registro de Enlaces y Repositorios Abiertos del Proyecto

Los repositorios y recursos de **DoctorMaiz** son los siguientes:

- **Clasificador (*pipeline* de entrenamiento, evaluación y exportación):**

  `https://github.com/daiv05/maize-doctor-classifier`

- **Aplicación móvil DoctorMaiz (React Native, inferencia *offline*):**

  `https://github.com/Edenilson-Molina/maize-doctor-app`

- **API (cuenta de usuario, sincronización opcional y avisos de actualización):**

  `https://github.com/daiv05/maize-doctor-api`

- **Sitio web y documentación técnica:**

  `https://doctor-maiz.deras.dev/es`

- **Dataset consolidado en Hugging Face:**

  `https://huggingface.co/datasets/daiv05/corn-leaf-diseases-pests-and-deficiencies`

  Cada fuente conserva su licencia original (Tabla 2.2).

- **Artefactos de evaluación y modelos exportados:**

  `https://drive.google.com/drive/folders/1OeZdWggfp7nVkaYHW_oOuCma5xbwhns6?usp=drive_link`

Anexo B: Inventario Criptográfico de Checkpoints Respaldados

La tabla siguiente lista los hashes SHA-256 de los modelos que sustentan la reproducibilidad de la tesina.

Hashes SHA-256 de los pesos físicos de los modelos respaldados

Modelo / Protocolo	**Tamaño**	**Hash SHA-256 del Checkpoint (`best.pth`)**
EfficientNet-Lite0 Base (42, oficial)	13.79 MB	`860180f33bf1749ffee9f3cccb9569a47afd9ca0fcef52713e18f99f82a57859`
EfficientNet-Lite0 Int8 (Móvil, `model_int8.tflite`)	3.74 MB	`bb31467a58c11cd474159bd5739a7a57b1f1edfda6b5dbfae8fa91337f3c56b1`
EfficientNet-B0 Referencia	16.36 MB	`0e367a5318c068c9bcc90a6bec0d17a0b029251ca5f98400034bd09de7524fdb`