UNIVERSIDAD DE EL SALVADOR

FACULTAD DE INGENIERÍA Y ARQUITECTURA

ESCUELA DE INGENIERÍA DE SISTEMAS INFORMÁTICOS

CURSO DE ESPECIALIZACIÓN EN MACHINE LEARNING

DISEÑO E IMPLEMENTACIÓN DE DOCTOR MAÍZ: SISTEMA MÓVIL BASADO EN REDES NEURONALES CONVOLUCIONALES PARA LA IDENTIFICACIÓN FITOSANITARIA EN HOJAS DE MAÍZ Y CONTRIBUCIÓN A UN CONJUNTO DE DATOS NACIONAL

PRESENTADO POR:

JOSÍAS ABNER RIVAS FUENTES

DAVID ALEJANDRO DERAS CERROS

ELMER EDENILSON ROSALES MOLINA

PARA OPTAR AL TÍTULO DE:

INGENIERO(A) DE SISTEMAS INFORMÁTICOS

CIUDAD UNIVERSITARIA, OCTUBRE DE 2026

UNIVERSIDAD DE EL SALVADOR

RECTOR:

MSC. JUAN ROSA QUINTANILLA

SECRETARIO GENERAL:

LCDO. PEDRO ROSARIO ESCOBAR CASTANEDA

FACULTAD DE INGENIERÍA Y ARQUITECTURA

DECANO:

MSC. LUIS SALVADOR BARRERA MANCÍA

SECRETARIO:

ARQ. RAÚL ALEXANDER FABIÁN ORELLANA

ESCUELA DE INGENIERIA DE SISTEMAS INFORMÁTICOS

DIRECTOR:

MSC. CESAR AUGUSTO GONZÁLEZ RODRÍGUEZ

UNIVERSIDAD DE EL SALVADOR

FACULTAD DE INGENIERIA Y ARQUITECTURA

ESCUELA DE INGENIERIA DE SISTEMAS INFORMÁTICOS

Trabajo de Graduación previo a la opción al Grado de:

INGENIERO (A) DE SISTEMAS INFORMÁTICOS

Título:

"DISEÑO E IMPLEMENTACIÓN DE DOCTOR MAÍZ: SISTEMA MÓVIL BASADO EN REDES NEURONALES CONVOLUCIONALES PARA LA IDENTIFICACIÓN FITOSANITARIA EN HOJAS DE MAÍZ Y CONTRIBUCIÓN A UN CONJUNTO DE DATOS NACIONAL"

Presentado por:

JOSÍAS ABNER RIVAS FUENTES

DAVID ALEJANDRO DERAS CERROS

ELMER EDENILSON ROSALES MOLINA

Trabajo de Graduación Aprobado por:

Docente Asesor(a):

ING. BLADIMIR DIAZ CAMPOS

SAN SALVADOR, OCTUBRE DE 2026

Trabajo de Graduación Aprobado por:

Docente Asesor:

ING. BLADIMIR DIAZ CAMPOS

Agradecimientos

A Dios todopoderoso, por haberme concedido la perseverancia, la sabiduría y la fortaleza necesaria para afrontar cada desafío académico y culminar con éxito esta etapa de mi formación profesional.
A mi familia, cuyo respaldo incondicional, sacrificios silenciosos y constante motivación fueron el cimiento sobre el cual pude edificar cada meta. Gracias por creer en mí en todo instante.
A mis compañeros de tesis y amigos entrañables, David y Elmer, por las incontables jornadas de discusión técnica, investigación y programación. Su compromiso y esfuerzo conjunto hicieron posible que esta investigación trascendiera el aula para convertirse en un aporte tangible al agro salvadoreño.
A la Universidad de El Salvador y a cada docente de la Escuela de Ingeniería de Sistemas Informáticos, por transmitirme con rigor y vocación los principios científicos que hoy me capacitan como profesional al servicio de la sociedad.

Josias Abner Rivas Fuentes

Agradecimientos

A Dios, por guiar mis pasos, iluminar mi entendimiento y brindarme salud y perseverancia en cada tramo de este largo camino universitario.
A mis padres y hermanos, por su amor inquebrantable, su fe en mis capacidades y por enseñarme que ningún obstáculo es insuperable cuando se trabaja con disciplina y honestidad. Cada página de este esfuerzo también les pertenece.
A mis compañeros de equipo, Josias y Elmer, por compartir la misma pasión por la excelencia tecnológica y el rigor científico. Las largas noches resolviendo problemas de modelos y arquitecturas forjaron no solo un gran proyecto, sino una amistad inquebrantable.
A todos los profesores y asesores que nos exigieron dar lo mejor de nosotros y nos enseñaron a buscar siempre el impacto social de la informática.

David Alejandro Deras Cerros

Agradecimientos

A Dios, principio y fin de todas las cosas, por derramar sobre mi vida bendiciones inmerecidas, paciencia ante la adversidad y la capacidad de culminar mi carrera profesional.
A mi amada familia, por su apoyo moral y material constante, por sus oraciones y por ser el refugio que siempre me impulsó a seguir adelante sin desfallecer.
A mis colegas y compañeros de graduación, Josias y David, por la lealtad, el trabajo en equipo y el entusiasmo inagotable con el que enfrentamos este reto. Su talento y dedicación hicieron que cada desafío fuera una oportunidad de aprendizaje mutuo.
A la gloriosa Universidad de El Salvador, alma mater de generaciones, por abrirme sus puertas y formarme con sentido crítico y compromiso hacia los sectores más desprotegidos de nuestra patria.

Elmer Edenilson Rosales Molina

Resumen Ejecutivo

El cultivo del maíz constituye un componente fundamental de la seguridad alimentaria y de los medios de vida de numerosos productores en El Salvador, especialmente de aquellos que trabajan en pequeñas parcelas y disponen de acceso limitado a asistencia técnica especializada. En este contexto, las enfermedades foliares, las plagas y las deficiencias nutricionales pueden comprometer el rendimiento de los cultivos y dificultar la identificación oportuna de problemas agronómicos. Las soluciones de diagnóstico basadas en visión artificial ofrecen una alternativa tecnológica, aunque su aplicación en entornos rurales plantea desafíos relacionados con la conectividad, los recursos computacionales de los dispositivos móviles y la capacidad de generalización ante imágenes capturadas en condiciones distintas de aquellas utilizadas durante el entrenamiento.

Esta investigación aborda dichos desafíos mediante el análisis, diseño, desarrollo y evaluación de **Doctor Maíz**, un sistema móvil de visión artificial basado en redes neuronales convolucionales (CNN) y técnicas de inteligencia artificial en el borde (*Edge AI*). La solución está orientada a la clasificación de nueve condiciones agronómicas foliares, que comprenden enfermedades, plagas y deficiencias nutricionales, mediante inferencia local en dispositivos móviles. Asimismo, incorpora mecanismos de captura y contribución voluntaria de imágenes georreferenciadas, cuya sincronización permite sentar las bases para la conformación de un conjunto de datos nacional sobre condiciones fitosanitarias del maíz.

Para el desarrollo experimental se recopiló y depuró un corpus de **33 429 imágenes** procedentes de 11 repositorios internacionales. Se implementó un flujo de procesamiento reproducible que incluyó controles de integridad, revisión de duplicados y verificación de la procedencia de las imágenes. La optimización de hiperparámetros se realizó mediante optimización bayesiana con Optuna y poda temprana mediante MedianPruner, explorando seis dimensiones de configuración y registrando los tiempos de cómputo en GPU de cada ensayo.

Se evaluó un ensamble heterogéneo de arquitecturas convolucionales compuesto por EfficientNet-Lite0, EfficientNet-B0 y ShuffleNet-V2, utilizando votación suave (*Soft Voting*). En un conjunto de prueba retenida de 5 015 imágenes, el ensamble obtuvo una exactitud del **98.29 %**, un Macro F_1 de **0.9567** y un Macro Recall del **95.06 %**. Para la clase de necrosis letal del maíz se registró un **Recall del 100 % (963 de 963 imágenes clasificadas correctamente)**, mientras que la deficiencia de potasio alcanzó un F_1 de **0.8475**. Estos resultados corresponden al protocolo experimental empleado y no constituyen, por sí solos, una garantía del rendimiento del sistema en condiciones reales de campo.

La evaluación de generalización mediante validación cruzada agrupada por fuente (*SourceGroupedKFold*) produjo un Macro F_1 de $0{,}6026 \pm 0{,}1240$ sobre las clases evaluables en cada pliegue, lo que evidenció limitaciones para transferir los resultados entre fuentes de imágenes. Adicionalmente, un experimento de ablación espacial mostró que, al ocluir la región central de la hoja, el modelo conservó un **79.46 % de exactitud**, resultado que motivó el análisis de posibles atajos visuales y la influencia del fondo en las predicciones. Como medidas de mitigación, se incorporaron un marco guía para la captura de imágenes y un mecanismo de detección de entradas fuera de distribución (*Out-of-Distribution*, OOD), basado en la

distancia de Mahalanobis y calibrado al percentil 95. Estas medidas buscan reducir los errores asociados a entradas inadecuadas y requieren evaluaciones específicas para cuantificar su efectividad.

Para el despliegue móvil, el modelo `EfficientNet-Lite0` se cuantizó a enteros de 8 bits (**Int8**), reduciendo su tamaño un 72 %, hasta **3.56 MB**. En pruebas realizadas en un dispositivo físico Motorola edge 40 neo con Android 15, se registró una latencia de inferencia de aproximadamente **60 milisegundos** para una ejecución de referencia. La inferencia local permite realizar clasificaciones sin conexión a internet, mientras que las funciones de sincronización de imágenes requieren conectividad.

En conjunto, Doctor Maíz integra clasificación mediante aprendizaje profundo, ejecución en dispositivos móviles y mecanismos de recopilación colaborativa de imágenes. Los resultados demuestran la viabilidad técnica de la implementación y, al mismo tiempo, ponen de manifiesto la necesidad de fortalecer la generalización entre fuentes y validar el comportamiento del sistema con imágenes representativas de condiciones reales de cultivo. Finalmente, se proponen cinco recomendaciones dirigidas al Ministerio de Agricultura y Ganadería (MAG) y al Centro Nacional de Tecnología Agropecuaria y Forestal (CENTA), orientadas a la validación en campo, la transferencia tecnológica y el desarrollo progresivo de un conjunto de datos nacional de acceso abierto.

Índice general

1 Especificación del Proyecto **1**

1.1 Situación Actual . . . 1

1.1.1 Antecedentes: El maíz como sustento y la emergencia productiva . . . 1

1.1.2 Descripción del problema: El diagnóstico a ciegas en el surco . . . 1

1.1.3 Planteamiento del problema . . . 3

1.2 Objetivos . . . 6

1.2.1 Objetivo General . . . 6

1.2.2 Objetivos Específicos . . . 7

1.3 Alcance y Límites del Proyecto . . . 7

1.3.1 Alcance del Proyecto . . . 7

1.3.2 Límites y Fronteras del Proyecto . . . 9

1.4 Hipótesis . . . 10

1.4.1 Hipótesis General . . . 10

1.4.2 Criterios de Éxito Específicos . . . 10

1.5 Justificación . . . 11

1.5.1 Justificación Técnica y Metodológica . . . 11

1.5.2 Justificación Económica . . . 12

1.5.3 Justificación Social y Ambiental . . . 12

1.5.4 Justificación Académica e Institucional . . . 12

1.6 Cronograma de Actividades . . . 13

1.7 Presupuesto Global Estimado . . . 14

2 Análisis y Diseño de la Solución **17**

2.1 Metodología de Trabajo y Gobernanza MLOps . . . 17

2.2 Clases Agronómicas Objetivo . . . 18

2.3 Recopilación, Depuración y Auditoría de Datos . . . 20

2.3.1 Data Profiling y Análisis Exploratorio de Datos (EDA) . . . 20

2.3.2 Auditoría Criptográfica de Píxeles . . . 21

2.4 Arquitecturas y Búsqueda de Hiperparámetros . . . 22

2.4.1 Familias Convolucionales Seleccionadas . . . 22

2.4.2 Espacio de Búsqueda y Poda Temprana . . . 23
2.4.3 Ensamble Multimodelo por Soft Voting . . . 23
2.5 Despliegue en Dispositivo Móvil . . . 24
2.5.1 Cuantización a Enteros de 8 Bits (Int8) . . . 24
2.5.2 Detector de Anomalías Fuera de Distribución (OOD) . . . 24
2.5.3 Mitigación en la Interfaz: Marco Guía y Severidad . . . 25
2.6 Segmentación de Hojas: dos usos y resultados . . . 26
2.7 Sincronización y Contribución al Dataset Colaborativo . . . 27
2.7.1 Modelo relacional de la base de datos del servidor . . . 27
2.7.2 Flujo de sincronización desde la aplicación . . . 28
2.8 Arquitectura General del Sistema . . . 29
2.8.1 Tecnologías por proyecto . . . 29

3 Estrategia de Implementación y Análisis de Resultados 31
3.1 Estrategia y Entorno de Implementación . . . 31
3.1.1 Infraestructura de Cómputo y Entrenamiento en la Nube . . . 31
3.2 Resultados . . . 32
3.2.1 Ahorro de entrenamiento: búsqueda bayesiana con poda . . . 33
3.2.2 Rendimiento del modelo: ensamble y bioseguridad . . . 35
3.2.3 Rendimiento del modelo: generalización entre fuentes . . . 37
3.2.4 Capacidades del diagnóstico: equidad entre entornos . . . 39
3.2.5 Capacidades del diagnóstico: dependencia del fondo . . . 40
3.2.6 Solución integral: prototipo en hardware real . . . 43
3.3 Impacto Social y Recomendaciones de Política Pública . . . 46

Conclusiones y Recomendaciones 48

Bibliografía 51

Glosario de Términos 53

Anexos 55

Índice de tablas

1.1 Criterios de éxito del proyecto, agrupados por tema 11
1.2 Cronograma consolidado de actividades y fases del proyecto (CRISP-DM) 14
1.3 Presupuesto proyectado: Cálculo del salario base por rol (280 horas) 15
1.4 Presupuesto proyectado: Cargas y prestaciones patronales sobre el salario base 15
1.5 Presupuesto: Infraestructura Cloud y Licencias 16
1.6 Resumen presupuestario global de la investigación 16

2.1 Taxonomía agronómica de las nueve clases integradas en DoctorMaiz 18
2.2 Fuentes de datos recopiladas y distribución de muestras 20
2.3 Espacio de búsqueda de hiperparámetros explorado con Optuna 23
2.4 Tecnologías principales por proyecto 30

3.1 Estado de los criterios de éxito al cierre de esta versión 33
3.2 Comparativa cuantitativa: Baseline sin Optuna vs. Configuración Optimizada (Optuna) . . . 34
3.3 Desempeño cuantitativo del Ensamble vs. Modelos Individuales en Prueba (5 015 imágenes) 35
3.4 Desglose de rendimiento agronómico por clase en el conjunto de prueba independiente . . . 37
3.5 Resultados del experimento cruzado 2×2 de validación cruzada en 5 pliegues 37
3.6 Evaluación LOSO con tres semillas: Macro F_1 y exactitud en la fuente retenida 38
3.7 Tasa de falsos negativos (FNR) desagregada por clase y entorno 40
3.8 Auditoría de ablación espacial con control nulo en el conjunto de prueba 40
3.9 Latencias operativas medidas en hardware físico (Motorola edge 40 neo) 43
3.10 Hashes SHA-256 de los pesos físicos de los modelos respaldados 56

Índice de figuras

1.1 Diversidad morfológica, fondos rústicos y heterogeneidad geométrica en las afecciones foliares del maíz. . . . 3
1.2 Modelo conceptual de caja negra para el diagnóstico fitosanitario móvil. . . . 6
1.3 Diagrama de Gantt de ejecución temporal del proyecto (Metodología CRISP-DM) . . . 13

2.1 Catálogo fotográfico de las nueve clases agronómicas presentes en el corpus. . . . 19
2.2 Distribución de muestras por clase. . . . 21
2.3 Proporción Laboratorio vs. Campo Real. . . . 21
2.4 Análisis exploratorio de distribución y balance ambiental del corpus. . . . 21
2.5 Matriz de contingencia fuente vs. patología. . . . 21
2.6 Distribución de resoluciones espaciales. . . . 21
2.7 Concentración de procedencia y heterogeneidad geométrica en las imágenes. . . . 21
2.8 Modelo relacional del servidor. Las flechas van de `users` a las tablas que referencian su `id`. `app_releases` no tiene relaciones. . . . 28
2.9 Flujo de sincronización de un aporte, desde el guardado local hasta la confirmación del servidor. Si el envío falla, el registro permanece pendiente. . . . 29
2.10 Diagrama de flujo arquitectónico integral del sistema DoctorMaiz. . . . 30

3.1 Curvas de convergencia: Pérdida y Macro F_1 durante el entrenamiento en Modal. . . . 32
3.2 Historial de ensayos de Optuna. . . . 34
3.3 Importancia relativa de hiperparámetros. . . . 34
3.4 Dinámica de exploración e impacto relativo de variables en Optuna. . . . 34
3.5 Comparativa de desempeño del ensamble frente a modelos individuales. . . . 36
3.6 Matriz de confusión normalizada del ensamble sobre 5 015 muestras de prueba. . . . 36
3.7 Diseño del experimento cruzado 2×2. . . . 38
3.8 Magnitud de impacto en sigmas (σ). . . . 38
3.9 Impacto de la partición frente a la optimización algorítmica. . . . 38
3.10 Disparidad por entorno ambiental. . . . 39
3.11 Matrices desagregadas Lab vs. Campo. . . . 39
3.12 Auditoría de equidad e imparcialidad entre condiciones fotográficas. . . . 39
3.13 Exactitud según la región geométrica visible frente al azar nulo. . . . 40

3.14 Mapas de activación Grad-CAM en muestras de campo real y laboratorio. 42
3.15 Panel comparado de explicabilidad local: LIME, SHAP y Grad-CAM. 42
3.16 Pantalla de inicio. 45
3.17 Marco guía foliar. 45
3.18 Diagnóstico obtenido. 45
3.19 Flujo principal de la aplicación móvil nativa DoctorMaiz. 45
3.20 Bloqueo seguro por OOD. 46
3.21 Aporte comunitario. 46
3.22 Guía de severidad. 46
3.23 Mecanismos de seguridad, participación comunitaria y escalas agronómicas. 46

CAPÍTULO 1

ESPECIFICACIÓN DEL PROYECTO

1.1. Situación Actual

1.1.1. Antecedentes: El maíz como sustento y la emergencia productiva

La agricultura representa el 5.6 % del Producto Interno Bruto (PIB) de El Salvador [2] y sostiene de forma directa a más de dos millones de personas en el sector rural. Para las familias campesinas salvadoreñas, el maíz (*Zea mays L.*) constituye la base diaria de la alimentación familiar, con un consumo promedio reportado que supera los 115 kilogramos por persona al año [3]. De acuerdo con registros oficiales del Ministerio de Agricultura y Ganadería [11], el 82.1 % de los productores nacionales trabajan pequeñas parcelas familiares menores a dos manzanas (1.4 hectáreas), bajo un régimen de agricultura de subsistencia dependiente casi por completo del régimen de lluvias estacionales.

En los últimos años, esta base productiva ha enfrentado una vulnerabilidad creciente frente a anomalías climáticas e incidencia fitosanitaria [11]. En una milpa sometida a estrés hídrico o térmico, la aparición de enfermedades foliares o plagas no es un fenómeno aislado: si una infección o ataque no se detecta y atiende de forma oportuna, compromete severamente el llenado de grano y la productividad de la cosecha [3], amenazando de manera directa la seguridad alimentaria y la subsistencia del hogar campesino.

1.1.2. Descripción del problema: El diagnóstico a ciegas en el surco

En las parcelas rurales salvadoreñas no existen microscopios ni laboratorios cercanos. El diagnóstico fitosanitario diario descansa por completo en los ojos del agricultor, quien recorre el surco bajo el sol, entre polvo y calor, tratando de interpretar manchas y marchitamientos complejos:

- **Tizón foliar (*Exserohilum turcicum*) y mancha gris (*Cercospora zeae-maydis*):** Colonizan la

lámina verde con lesiones alargadas o rectangulares que secan la hoja y detienen el llenado de la mazorca.

- **Gusano cogollero (*Spodoptera frugiperda*):** Mastica los verticilos tiernos y destruye el punto de crecimiento de la planta.
- **Necrosis letal del maíz (MLN):** Complejo viral altamente destructivo que marchita la planta de raíz a espiga y anula el 100 % de la cosecha.
- **Deficiencias nutricionales de nitrógeno, fósforo y potasio (N-P-K):** Provocan clorosis en "V", pigmentaciones púrpuras y secado marginal que a simple vista se confunden fácilmente con hongos o virus.

Esta dificultad se agrava ante la marcada limitación de cobertura en la asistencia técnica pública presencial. La relación entre el personal técnico extensionista disponible y el número global de productores agrícolas dispersos en la geografía rural salvadoreña genera una brecha estructural de atención, donde una visita agronómica especializada suele demorar semanas o no llegar a materializarse durante la ventana crítica de la infección [3].

Ante la incertidumbre y el riesgo inminente de pérdida de la siembra, el agricultor acude frecuentemente a puntos comerciales de agroservicios. En estos espacios, la falta de diagnóstico instrumental propicia recomendaciones empíricas basadas en agroquímicos de amplio espectro para síntomas que corresponden a deficiencias nutricionales de suelo. Esta situación ocasiona pérdidas económicas significativas para el presupuesto familiar al incurrir en gastos fitosanitarios ineficaces, además de generar impactos ambientales negativos por sobreaplicación de químicos y retrasar la atención correctiva adecuada de patógenos severos [3].

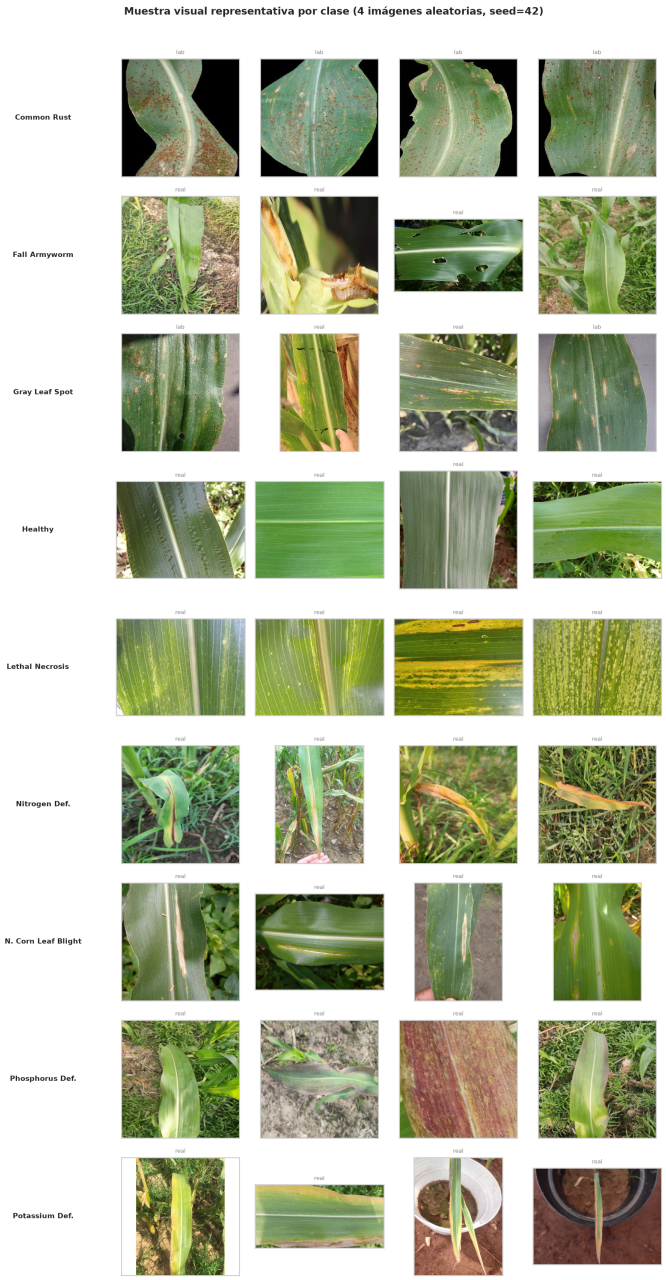


Figura 1.1: Diversidad morfológica, fondos rústicos y heterogeneidad geométrica en las afecciones foliares del maíz.

1.1.3. Planteamiento del problema

A partir de la situación descrita, se constata que los mecanismos tradicionales de extensión agronómica resultan insuficientes para brindar cobertura a los pequeños productores de maíz en El Salvador, mientras que las herramientas digitales contemporáneas han sido concebidas bajo premisas incompatibles con la

realidad rural. En la práctica, las soluciones comerciales de visión artificial presentan tres limitaciones críticas:

1. **Dependencia de conectividad de red:** La mayor parte de las aplicaciones disponibles requieren comunicación permanente con servidores en la nube para procesar las capturas. En el agro salvadoreño, donde extensas zonas rurales presentan cobertura celular inestable o nula y los agricultores no disponen de planes continuos de transmisión de datos, esta dependencia anula la utilidad práctica de las herramientas en el propio surco.

2. **Incompatibilidad con terminales básicos:** Los modelos de aprendizaje profundo convencionales demandan una capacidad de cómputo y memoria que excede con creces los recursos de los teléfonos inteligentes accesibles para las familias campesinas (dispositivos de gama de entrada con 2 a 4 GB de RAM), provocando bloqueos, latencias intolerables y un rápido consumo de batería.

3. **Vulnerabilidad ante la variabilidad del entorno real:** Al haber sido entrenados mayoritariamente sobre imágenes de laboratorio con fondos neutros e iluminación homogénea, los algoritmos colapsan al exponerse a la milpa, donde la presencia de suelos rústicos, sombras irregulares, malezas y contraluz induce clasificaciones erróneas emitidas con un alto grado de sobreconfianza.

Frente a este escenario, surge la necesidad de replantear el diagnóstico automatizado desde las restricciones materiales del entorno agrícola. Una herramienta orientada a cerrar esta brecha debe operar directamente en manos del productor, fundamentándose en cuatro requerimientos operacionales esenciales:

- **Autonomía operativa local:** La capacidad diagnóstica debe ejecutarse de forma integral en el propio dispositivo, asegurando disponibilidad inmediata en la parcela sin supeditar su funcionamiento a redes de telecomunicaciones.

- **Austeridad y eficiencia computacional:** El procesamiento debe ajustarse estrictamente a las capacidades técnicas de los teléfonos básicos predominantes en las zonas rurales, garantizando tiempos de respuesta cortos y un consumo mínimo de energía.

- **Resiliencia y bioseguridad ante la captura:** El sistema debe ser capaz de discriminar la sintomatología foliar frente al ruido visual del campo y, de manera primordial, reconocer situaciones de

incertidumbre o tomas no válidas para abstenerse de emitir diagnósticos infundados que perjudiquen la economía familiar.

- **Traducción agronómica orientada a la acción:** El diagnóstico visual debe complementarse con una evaluación comprensible del nivel de daño y con alternativas concretas de manejo integrado basadas en bioinsumos accesibles, facilitando una intervención oportuna y viable para el productor.

Con base en estas consideraciones, se formula la problemática central de la investigación:

¿En qué medida es factible concebir, desarrollar y evaluar una aplicación móvil de diagnóstico fitosanitario que opere de manera autónoma en teléfonos inteligentes de gama baja o media, capaz de discernir patologías foliares en condiciones reales de campo, gestionar la incertidumbre de la captura y orientar oportunamente al agricultor salvadoreño en el manejo integrado de su cultivo?

Modelo conceptual de caja negra del sistema

Con el propósito de delimitar analíticamente este problema sin prejuzgar la arquitectura interna que deberá investigarse y validarse experimentalmente en los capítulos posteriores, el sistema se conceptualiza mediante el modelo de caja negra (Figura 1.2). En la ingeniería de sistemas, este enfoque formaliza la relación entre los estímulos y restricciones del entorno problemático (entradas) y los resultados requeridos para mitigar la problemática (salidas), definiendo el núcleo del sistema como el proceso de transformación tecnológica que constituye el objeto de estudio de esta investigación:

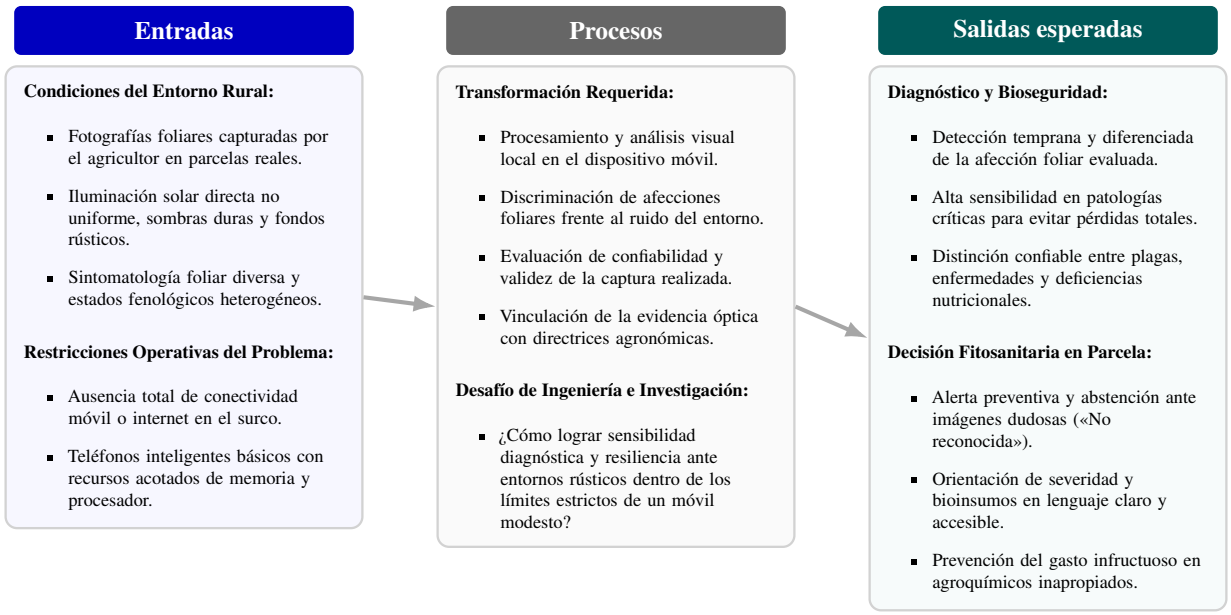


Figura 1.2: Modelo conceptual de caja negra para el diagnóstico fitosanitario móvil.

Como sintetiza la Figura 1.2, el modelo de caja negra formaliza la lógica de la investigación: establece cómo las restricciones de campo y los desafíos visuales del cultivo ingresan a un proceso de transformación móvil concebido para generar diagnósticos confiables y decisiones fitosanitarias oportunas para el campesino. A partir de esta delimitación del problema, se formulan a continuación los objetivos de la investigación.

1.2. Objetivos

1.2.1. Objetivo General

Desarrollar, evaluar e implementar un sistema de visión artificial embebido (*Edge AI*) para el diagnóstico fitosanitario a partir de imágenes de la hoja de maíz en El Salvador, desplegado mediante una aplicación móvil nativa de operación completamente desconectada (*offline*), capaz de clasificar afecciones foliares con alta sensibilidad y baja latencia en teléfonos inteligentes de gama baja o media.

1.2.2. Objetivos Específicos

1. Consolidar, depurar y auditar criptográficamente un conjunto multimodal de más de 33 000 imágenes de la hoja de maíz distribuidas en 9 condiciones agronómicas, estableciendo contratos de datos verificables para descartar duplicados y prevenir filtraciones entre particiones.

2. Optimizar arquitecturas convolucionales ligeras preentrenadas mediante búsqueda bayesiana de hiperparámetros (Optuna) y algoritmos de poda temprana, maximizando el Macro F_1-Score con un uso eficiente del cómputo en GPU.

3. Diseñar una estrategia de ensamble por votación suave (*Soft Voting*) que combine modelos con diferentes sesgos inductivos, con el fin de elevar la sensibilidad diagnóstica en patologías críticas de la hoja de maíz y mitigar el desbalance de clases.

4. Evaluar el desempeño del sistema bajo protocolos de validación cruzada agrupada por procedencia (*SourceGroupedKFold*), cuantificando la disparidad de impacto entre laboratorio y campo real, así como la atribución espacial mediante técnicas de explicabilidad y ablación de fondo.

5. Cuantizar la arquitectura neuronal a enteros de 8 bits (Int8) e integrarla en una aplicación móvil nativa provista de marco guía de encuadre y detector de tomas anómalas, validando su precisión y fluidez en teléfonos inteligentes físicos de gama baja o media.

6. Formular una propuesta estratégica de integración institucional y políticas públicas orientada al Ministerio de Agricultura y Ganadería (MAG) y al CENTA, que facilite la transferencia tecnológica y el acompañamiento técnico a los pequeños productores de maíz.

1.3. Alcance y Límites del Proyecto

1.3.1. Alcance del Proyecto

El alcance del presente proyecto comprende la investigación, diseño, desarrollo e implementación de una solución integral de diagnóstico fitosanitario orientada a los pequeños productores de maíz en El Salvador.

La solución se materializa en dos componentes tecnológicos articulados: la aplicación móvil nativa para el usuario final y el motor analítico de visión artificial embebida.

Alcance de la Aplicación Móvil (DoctorMaiz)

La aplicación móvil constituye el punto de interacción directa en manos del agricultor y abarca las siguientes capacidades funcionales:

- **Inferencia local autónoma (*Offline*):** Ejecución integral del motor neuronal en el procesador del teléfono mediante modelos cuantizados, asegurando diagnósticos instantáneos en el surco sin requerir conexión a internet ni datos móviles.
- **Captura asistida con marco guía foliar:** Interfaz de cámara con retícula visual ergonómica que orienta al agricultor a encuadrar la lámina de la hoja, reduciendo la captura de fondos distractores (suelo, sombras o maleza) antes de procesar la imagen.
- **Detección preventiva de capturas anómalas (Seguridad OOD):** Módulo de rechazo ante muestras fuera de dominio capaz de evaluar si la captura no corresponde a una hoja de maíz o presenta incertidumbre excesiva, notificando un estado de «No reconocida» para evitar diagnósticos engañosos.
- **Diagnóstico y valoración de severidad:** Presentación de resultados en lenguaje claro y accesible, categorizando la afección con una escala visual de severidad en tres niveles (leve, moderada y severa) para apoyar la toma de decisiones.
- **Catálogo de manejo integrado y bioinsumos:** Guía fitosanitaria práctica vinculada al diagnóstico que ofrece alternativas de bioinsumos y manejo cultural de bajo costo, previniendo gastos perjudiciales en agroquímicos inapropiados.
- **Historial y georreferenciación de muestreos:** Registro local persistente de cada evaluación (fecha, diagnóstico, severidad y ubicación GPS) para que el agricultor monitoree la evolución de sus parcelas a lo largo del ciclo agrícola.

- **Contribución comunitaria y sincronización voluntaria:** Módulo opcional que permite almacenar imágenes validadas localmente para compartirlas cuando se cuente con conectividad, contribuyendo al monitoreo fitosanitario colectivo.

Alcance del Componente de Inteligencia Artificial Embebida

El núcleo de aprendizaje profundo embebido abarca:

- **Cobertura taxonómica de 9 clases en hoja de maíz:** Clasificación supervisada de signos y síntomas foliares, cubriendo enfermedades causadas por hongos (tizón foliar, mancha gris y roya común), virosis crítica (necrosis letal del maíz), plagas directas (gusano cogollero), deficiencias nutricionales de suelo (nitrógeno, fósforo y potasio) y lámina foliar sana.
- **Optimización bayesiana, ensamble y cuantización Int8:** Búsqueda automatizada de hiperparámetros (Optuna con poda temprana), combinación estratégica por votación suave (*Soft Voting*) y cuantización a 8 bits exportada en formato TensorFlow Lite mediante litert-torch, optimizada para inferencia ultrarrápida ($\leq$ 100 ms) en procesadores móviles.
- **Auditoría de sesgos y generalización:** Protocolo de evaluación cruzada agrupada por procedencia (*SourceGroupedKFold*) y pruebas de ablación espacial de fondo para auditar y neutralizar el fenómeno de atajos visuales (*Clever Hans effect*).

1.3.2. Límites y Fronteras del Proyecto

Con el fin de delimitar con precisión la cobertura de la investigación, se definen los siguientes límites operacionales:

- **Límite biológico y sintomático:** El sistema se restringe exclusivamente al análisis de afecciones visibles en la lámina foliar del maíz. Quedan fuera del alcance patologías radiculares, afecciones del tallo interno sin expresión foliar y el monitoreo de plagas subterráneas.
- **Límite de plataforma y compatibilidad de hardware:** La solución móvil se enfoca en dispositivos con sistema operativo Android 8.0 o superior con arquitectura de procesador ARM (v7 o v8), cáma-

ra trasera con enfoque automático y al menos 2 GB de memoria RAM. No se contempla desarrollo nativo para iOS ni para teléfonos sin capacidades inteligentes.

- **Límite de infraestructura y red:** La aplicación está diseñada para operar desconectada; no existe dependencia de servicios en la nube para emitir el diagnóstico, ni se incluye sincronización transaccional en tiempo real entre múltiples terminales.
- **Límite legal y de diagnóstico fitopatológico:** La herramienta constituye un asistente técnico de orientación y apoyo agronómico para el productor. En ningún caso reemplaza los ensayos fitopatológicos de laboratorio (cultivos, aislamiento microbiano o pruebas PCR), ni sustituye los dictámenes oficiales de cuarentena o certificación fitosanitaria del Ministerio de Agricultura y Ganadería.

1.4. Hipótesis

1.4.1. Hipótesis General

El diseño propone un sistema de visión artificial embebido en una aplicación móvil nativa, con captura asistida y operación completamente desconectada, capaz de clasificar nueve condiciones agronómicas de la hoja de maíz en teléfonos inteligentes de gama baja o media del sector rural salvadoreño. Se considera alcanzado el objetivo general si se cumplen los criterios de la Tabla 1.1.

1.4.2. Criterios de Éxito Específicos

Los criterios siguientes son las condiciones que el sistema debe cumplir para considerar alcanzado cada objetivo. Se verifican en el capítulo de resultados y se agrupan en cinco temas.

Tabla 1.1: Criterios de éxito del proyecto, agrupados por tema

Tema	**Criterio y umbral**	**Métrica**
Ahorro de entrenamiento	El total de épocas ejecutadas por la búsqueda no supera el 50 % del máximo teórico (25 ensayos $\times$ 60 épocas).	Épocas ejecutadas por la búsqueda
Rendimiento del modelo	Alcanzar Macro $F_1 \geq 0{,}85$ en la partición de prueba retenida, con recall de la necrosis letal (MLN) $\geq 95\,\%$.	Macro F_1, recall por clase
Capacidades del diagnóstico	Mantener un *Disparate Impact Ratio* $\geq 0{,}80$ entre laboratorio y campo real.	DIR
Confiabilidad de la evaluación	Ninguna imagen del conjunto de prueba aparece en entrenamiento ni validación, por hash de archivo y por píxeles.	Solapamiento por SHA-256 y por píxeles
Solución integral	Modelo Int8 de 20 MB o menos, inferencia de 300 ms o menos en un teléfono de gama media y funcionamiento sin conexión.	Tamaño, latencia

1.5. Justificación

1.5.1. Justificación Técnica y Metodológica

La presente investigación se justifica técnicamente al trasladar el procesamiento de aprendizaje profundo desde arquitecturas dependientes de servidores en la nube hacia el borde del dispositivo móvil (*Edge AI*). En la literatura especializada de visión por computadora aplicada a la agricultura, predomina el entrenamiento de modelos convolucionales de alta complejidad evaluados sobre particiones aleatorias convencionales, las cuales frecuentemente sufren de fuga de información e introducen atajos visuales ligados a fondos controlados [1]. El presente proyecto aborda esta limitación mediante una metodología rigurosa basada en auditoría de duplicados a nivel de píxel, esquemas de validación cruzada agrupada por procedencia y técnicas de cuantización simétrica a enteros de 8 bits (*Int8*) que reducen drásticamente la demanda computacional sin comprometer la sensibilidad diagnóstica [5, 17]. Asimismo, integra salvaguardas operacionales como el filtrado de muestras fuera de dominio (*OOD*) [8] y mecanismos de explicabilidad visual mediante mapas de activación [16], con el fin de que las predicciones se apoyen en características de la lámina foliar; la verificación de este objetivo se presenta en el capítulo de resultados.

1.5.2. Justificación Económica

Para las pequeñas familias productoras de maíz en El Salvador, el margen de rentabilidad agrícola por ciclo es sumamente reducido y altamente vulnerable a sobrecostos imprevistos [11]. Un diagnóstico fitosanitario erróneo conduce a la compra e intoxicación del cultivo con agroquímicos comerciales inadecuados, mermando el escaso capital de trabajo disponible. Proveer una aplicación móvil de uso autónomo, gratuito y local en el propio teléfono inteligente del agricultor permite orientar de manera precisa la intervención fitosanitaria, evitando gastos innecesarios en plaguicidas ante síntomas provocados por deficiencias nutricionales y facilitando una acción temprana contra plagas destructivas como el gusano cogollero (*Spodoptera frugiperda*) antes de que comprometan el rendimiento económico de la milpa [3].

1.5.3. Justificación Social y Ambiental

Desde la perspectiva social, la implementación de *DoctorMaiz* contribuye a reducir la brecha tecnológica en comunidades rurales con acceso limitado o nulo a servicios presenciales de extensión agronómica [3]. Al transformar un teléfono celular común de gama baja o media en un asistente de orientación fitopatológica disponible en el surco, se empodera al productor con información técnica comprensible y oportuna. En la dimensión ambiental, un diagnóstico certero fomenta el manejo integrado de plagas, desincentivando la aplicación indiscriminada de pesticidas sintéticos y coadyuvando a la protección de los recursos hídricos y la salud de las comunidades rurales.

1.5.4. Justificación Académica e Institucional

En el ámbito académico e institucional, este proyecto representa una contribución significativa para la Escuela de Ingeniería de Sistemas Informáticos de la Universidad de El Salvador (UES), al articular la investigación aplicada en inteligencia artificial embebida con la solución de problemas prioritarios del desarrollo agropecuario nacional. La investigación sienta un precedente metodológico formal para el desarrollo, evaluación imparcial y despliegue de sistemas de visión artificial adaptados a contextos de recursos computacionales y conectividad restringidos en Centroamérica.

1.6. Cronograma de Actividades

La planificación y ejecución del proyecto se estructuró bajo las fases de la metodología *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*), adaptada a los requerimientos de desarrollo de aprendizaje profundo embebido (*Edge AI*) e ingeniería de software móvil. El cronograma abarcó un periodo de 28 semanas calendario, iniciando formalmente el 14 de abril de 2026 y culminando con el hito de presentación y defensa final el 29 de octubre de 2026.

La Figura 1.3 ilustra el diagrama temporal de Gantt y la concurrencia operativa de las fases a lo largo de las 28 semanas del ciclo, mientras que la Tabla 1.2 detalla la distribución de actividades, duración, horas estimadas y entregables técnicos por cada etapa.

Figura 1.3: Diagrama de Gantt de ejecución temporal del proyecto (Metodología CRISP-DM)

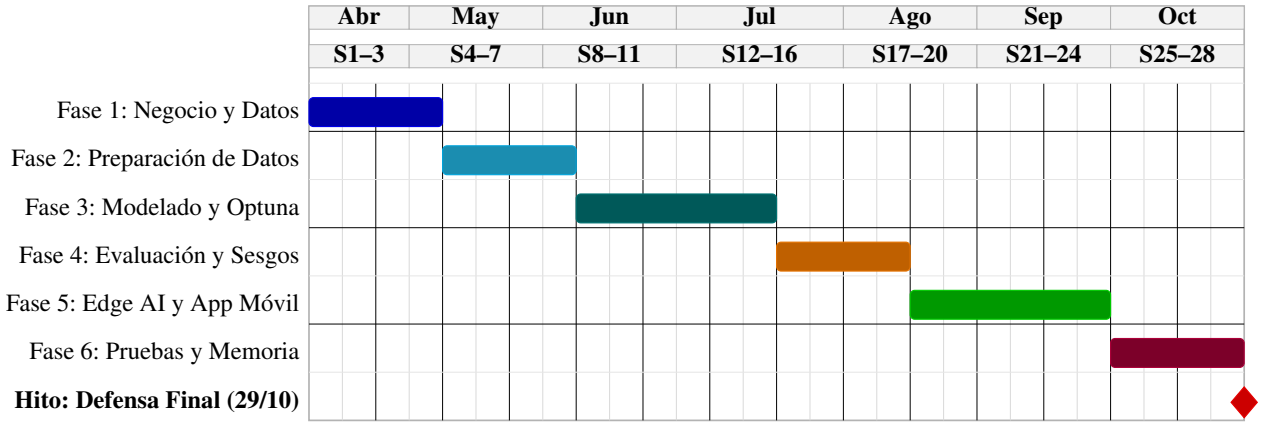


Tabla 1.2: Cronograma consolidado de actividades y fases del proyecto (CRISP-DM)

Fase / Actividad Operativa	Inicio	Fin	Semanas	Horas	Entregable Principal
Fase 1: Comprensión del Negocio y Datos	14/04/26	12/05/26	4	40 h	Requisitos fitosanitarios y corpus consolidado (>33K imágenes).
Fase 2: Preparación de Datos	12/05/26	09/06/26	4	40 h	Auditoría criptográfica de duplicados, balanceo y data augmentation.
Fase 3: Modelado Algorítmico	09/06/26	21/07/26	6	60 h	Transfer learning en arquitecturas ligeras y optimización con Optuna.
Fase 4: Evaluación y Auditoría de Sesgos	21/07/26	18/08/26	4	40 h	Ensamble Soft Voting, evaluación ciega de campo y análisis XAI (Grad-CAM).
Fase 5: Optimización Edge y App Móvil	18/08/26	29/09/26	6	60 h	Modelo Int8 (3.56 MB), detector OOD y app DoctorMaiz (React Native/Expo).
Fase 6: Pruebas Finales y Memoria	29/09/26	29/10/26	4	40 h	Evaluación física en Motorola edge 40 neo, memoria técnica y defensa final.
Hito Final: Defensa de Proyecto	**29 de octubre de 2026**		**28 sem**	**280 h**	**Sistema DoctorMaiz liberado**

1.7. Presupuesto Global Estimado

El presupuesto del desarrollo y evaluación de la solución analítica y embebida abarcó dos categorías esenciales: recurso humano especializado e infraestructura de cómputo acelerado en la nube (Tablas 1.3 a 1.6). Las horas de GPU se tomaron de los registros de ejecución del repositorio; el resto de rubros son proyecciones.

Tabla 1.3: Presupuesto proyectado: Cálculo del salario base por rol (280 horas)

Rol Profesional	**Salario mensual de referencia**	**Meses equivalentes (280 h)**	**Salario base (USD)**
Ingeniero de Datos / MLOps	$1,500.00	1.6154	$2,423.08
Investigador de Deep Learning	$1,350.00	1.6154	$2,180.77
Desarrollador Móvil Edge AI	$1,250.00	1.6154	$2,019.23
Total salario base	**$4,100.00**	—	**$6,623.08**

Tabla 1.4: Presupuesto proyectado: Cargas y prestaciones patronales sobre el salario base

Rol Profesional	**ISSS 7.5 %**	**AFP 7.75 %**	**INSAFORP 1 %**	**Aguinaldo y vacaciones**	**Total cargas**	**Costo total**
Ingeniero de Datos / MLOps	$121.15	$187.79	$24.23	$201.92	$535.09	$2,958.17
Investigador de Deep Learning	$121.15	$169.01	$21.81	$181.73	$493.70	$2,674.47
Desarrollador Móvil Edge AI	$121.15	$156.49	$20.19	$168.27	$466.10	$2,485.33
Total Recurso Humano	**$363.45**	**$513.29**	**$66.23**	**$551.92**	**$1,494.89**	**$8,117.97**

Los salarios mensuales corresponden al punto medio de la escala de referencia del sector público salvadoreño para Gobierno Central y Ministerios, aplicada a perfiles equivalentes: Ingeniero de Datos / MLOps (rango de $1,200 a $1,800, equivalente a Especialista de Base de Datos o Analista de Sistemas), Investigador de Deep Learning (rango de $1,100 a $1,600, equivalente a Especialista en Análisis de Datos) y Desarrollador Móvil (rango de $1,000 a $1,500, equivalente a Analista Programador). La Tabla 1.3 calcula el salario base por rol y la Tabla 1.4 desglosa las cargas patronales y el costo total. El costo se estima solo por las horas efectivas de trabajo. Cada integrante trabaja de lunes a viernes, menos de 2 horas diarias; para la estimación se usan 2 horas diarias como cota superior, es decir 10 horas semanales, lo que suma 280 horas en las 28 semanas del cronograma (Tabla 1.2). Equivale a 1.62 meses de una jornada de 40 horas, por lo que el salario mensual de referencia se prorrateó por esa proporción. Las cargas consideran: cuota patronal al ISSS de 7.5 % sobre un salario base máximo de $1,000.00 mensual; cuota patronal a la AFP de 7.75 %; contribución al INSAFORP de 1 %; y aguinaldo y vacaciones de ley prorrateados.

Tabla 1.5: Presupuesto: Infraestructura Cloud y Licencias

Rubro	**Detalle Técnico**	**Métrica / Cantidad**	**Subtotal**
Instancias GPU Modal	NVIDIA A10G (24 GB VRAM)	15.85 horas medidas × $1.10/h	$17.44
Almacenamiento Cloud	Cloud Volumes y respaldos de pesos	100 GB × 6 meses	$30.00
Licenciamiento software	PyTorch, Expo, React Native, Optuna	Licencias Open Source / MIT	$0.00
Total Infraestructura Cloud y Licencias	—	—	**$47.44**

Tabla 1.6: Resumen presupuestario global de la investigación

Rubro de Inversión	**Monto Total (USD)**	**Porcentaje (%)**
Recursos Humanos de Investigación	$8,117.97	99.42 %
Servicios de cómputo en la nube (GPU/Storage)	$47.44	0.58 %
Total General	**$8,165.41**	**100.00 %**

La ejecución financiera demuestra que, gracias al aprovechamiento de tecnologías de código abierto y la utilización estratégica de clústeres serverless con parada automática, el costo directo de infraestructura computacional se mantuvo en valores extraordinariamente accesibles ($47.44 USD, de los cuales $17.44 corresponden a las 15.85 horas de GPU medidas y $30.00 al almacenamiento), ratificando la viabilidad económica de proyectos de investigación en inteligencia artificial de alto impacto desarrollados en universidades públicas.

CAPÍTULO 2

ANÁLISIS Y DISEÑO DE LA SOLUCIÓN

2.1. Metodología de Trabajo y Gobernanza MLOps

Para garantizar que los hallazgos científicos de esta investigación sean verificables y reproducibles, se adoptó una metodología de ingeniería de software y operaciones de aprendizaje automático (*MLOps*) basada en contratos de datos inmutables y trazabilidad criptográfica. En proyectos de visión artificial complejos, los errores silenciosos de preparación —tales como la fuga de datos (*data leakage*), la reordenación no determinista de lotes o la sustitución inadvertida de imágenes corruptas— invalidan cualquier conclusión teórica.

La arquitectura de datos de DoctorMaiz desacopla tres conceptos fundamentales:

1. **Identidad (`sample_id`):** Cada fotografía del corpus posee un identificador único e inmutable calculado como SHA-256(ruta lógica normalizada en UTF-8). Esto previene que el orden de lectura en el disco o la asignación estocástica de hilos (*workers*) altere la identidad de la muestra.

2. **Integridad (`sha256`):** Se calcula el hash criptográfico SHA-256 directo sobre los bytes crudos del archivo de imagen. Esto permite auditar de forma automática si un archivo sufrió alteraciones, corrupción o recomposición entre distintas versiones de entrenamiento.

3. **Procedencia y Grupo (`source_id` y `effective_group_id`):** Cada registro conserva el vínculo con su repositorio de origen, cámara y sesión de captura, permitiendo construir particiones estratificadas por fuente sin filtrar datos asociados.

Todos los conjuntos de entrenamiento, validación y prueba quedaron sellados mediante manifiestos contractuales (`manifest.lock.json`), garantizando cero solapamientos de muestras cross-split.

2.2. Clases Agronómicas Objetivo

El sistema clasifica el estado de salud de la hoja de maíz en nueve categorías mutuamente excluyentes (Tabla 2.1), abarcando los principales patógenos fúngicos, virales, plagas insectiles y deficiencias nutricionales de impacto económico en Centroamérica.

Tabla 2.1: Taxonomía agronómica de las nueve clases integradas en DoctorMaiz

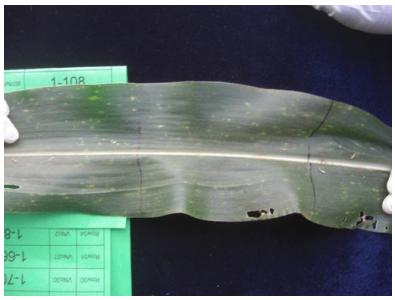
Clase Agronómica	**Agente Causal / Tipo**	**Síntoma Primario**	**Riesgo / Impacto en Rendimiento**
Roya Común	*Puccinia sorghi* (Hongo)	Pústulas pulverulentas castaño-rojizas en ambas caras.	Pérdida del 15 % al 30 % en áreas húmedas y altas.
Tizón Foliar (NCLB)	*Exserohilum turcicum* (Hongo)	Lesiones alargadas en forma de cigarro o huso (grises).	Necrosis masiva, pérdidas de hasta 50 % antes de floración.
Mancha Gris (GLS)	*Cercospora zeae-maydis* (Hongo)	Manchas rectangulares delimitadas por venas secundarias.	Destrucción del follaje superior, reducción del grano hasta 40 %.
Necrosis Letal (MLN)	Complejo viral sinérgico (MCMV + Potyvirus)	Clorosis severa, moteado, necrosis marginal y secado total.	**Pérdida del 100 % de la cosecha**; patología de bioseguridad crítica.
Gusano Cogollero	*Spodoptera frugiperda* (Plaga/Insecto)	Perforaciones irregulares y excrementos en el cogollo.	Destrucción meristemática; caída de rendimiento del 20 % al 60 %.
Deficiencia de Nitrógeno	Desbalance nutricional abiótico	Clorosis en “V” invertida desde la punta hacia la base.	Reducción de porte, espigas pequeñas y bajo llenado.
Deficiencia de Fósforo	Desbalance nutricional abiótico	Coloración púrpura o rojiza en bordes de hojas jóvenes.	Retraso radicular y esterilidad parcial de la mazorca.
Deficiencia de Potasio	Desbalance nutricional abiótico	Clorosis y necrosis marginal desde el ápice foliar.	Acame o volcamiento del tallo y grano liviano.
Planta Sana (Healthy)	Control agronómico	Lámina foliar verde homogénea sin lesiones ni plagas.	Crecimiento óptimo según potencial genético del cultivar.



a) Roya Común



b) Tizón Foliar



c) Mancha Gris



d) Necrosis Letal



e) Gusano Cogollero



f) Deficiencia N



g) Deficiencia P



h) Deficiencia K



i) Planta Sana

Figura 2.1: Catálogo fotográfico de las nueve clases agronómicas presentes en el corpus.

2.3. Recopilación, Depuración y Auditoría de Datos

El corpus final se conformó mediante la integración de **33 429 imágenes elegibles** provenientes de 11 fuentes internacionales consolidadas (Tabla 2.2). Para resolver el cuello de botella identificado en la primera fase del proyecto —donde la deficiencia de potasio colapsaba a un F_1 de 0.49 debido a la escasez extrema de muestras—, se incorporaron cuatro repositorios dirigidos a deficiencias minerales.

Tabla 2.2: Fuentes de datos recopiladas y distribución de muestras

Identificador de Fuente (`source_id`)	**Muestras**	**Entorno**	**Patologías Principales Aportadas**
`maize-beans-tomatoes-africa`	12 136	Mixto	4 clases.
`maize-diseases`	6 989	Campo Real	3 clases.
`multicrop-disease-maiz`	5 816	Campo Real	3 clases, incluida necrosis letal (MLN).
`corn-leaf-roboflow`	2 919	Mixto	6 clases.
`cropdg-unified-multidomain`	2 562	Mixto	3 clases.
`maize-in-field-dataset`	852	Campo Real	3 clases.
`maize-2-roboflow`	846	Mixto	3 clases.
`corn-leaf-diseases-classification-roboflow`	480	Mixto	1 clase (`gray_leaf_spot`).
`maize-nutrient-deficiency`	340	Mixto	4 clases.
`maize-leaf-roboflow`	331	Mixto	1 clase.
`maize-deficiency-scanner-roboflow`	158	Campo Real	3 clases de deficiencia.
Total Elegible Auditado	**33 429**	—	**9 clases agronómicas**

2.3.1. Data Profiling y Análisis Exploratorio de Datos (EDA)

El análisis exploratorio evidenció tres retos estructurales:

- **Desbalance intrínseco:** La clase sana concentra cerca de 8 700 imágenes y el tizón foliar cerca de 6 800, mientras que la deficiencia de potasio cuenta con 621 ejemplares (desbalance de 14.1:1 en el corpus vigente, frente a 32.9:1 antes de la ampliación).
- **Heterogeneidad de resolución y cámaras:** Las resoluciones van desde sensores rústicos de 256×256 píxeles hasta capturas semiprofesionales de 4000×3000 píxeles (Figura 2.4).

- **Asociación espuria fuente-clase:** La asociación estadística entre la procedencia y la etiqueta arrojó una **V de Cramér de 0.5030**, indicando que ciertas fuentes públicas aportan exclusivamente una sola patología, lo que puede favorecer que las redes utilicen señales del entorno además de la lesión foliar. Esta relación es descriptiva y no establece una causa.

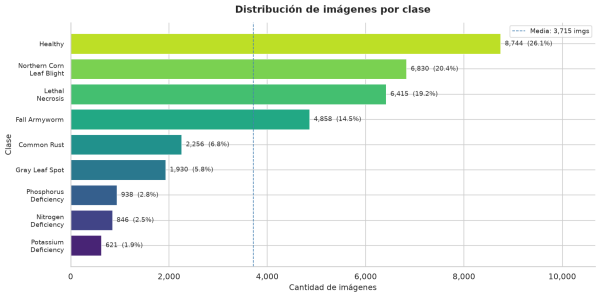


Figura 2.2: Distribución de muestras por clase.

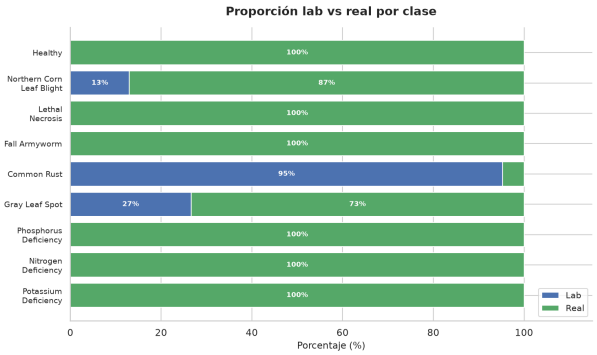


Figura 2.3: Proporción Laboratorio vs. Campo Real.

Figura 2.4: Análisis exploratorio de distribución y balance ambiental del corpus.

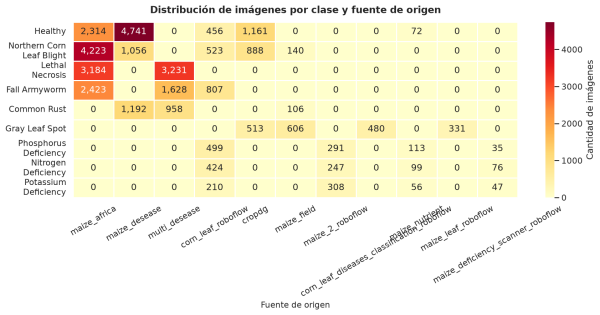


Figura 2.5: Matriz de contingencia fuente vs. patología.



Figura 2.6: Distribución de resoluciones espaciales.

Figura 2.7: Concentración de procedencia y heterogeneidad geométrica en las imágenes.

2.3.2. Auditoría Criptográfica de Píxeles

Para descartar que la precisión reportada se inflara por duplicados idénticos en entrenamiento y prueba, se ejecutó la auditoría `PIXEL_DUPLICATE_AUDIT`. Se calcularon hashes SHA-256 directos sobre el contenido decodificado en memoria. Se descubrieron únicamente cuatro grupos de imágenes (ocho

archivos en total) con etiquetas contradictorias entre repositorios, los cuales fueron purgados de inmediato. Las **33 429 muestras finales no presentan un solo duplicado idéntico cross-split**.

La partición de desarrollo oficial (`seed_42`) quedó estructurada en un reparto estratificado 70/15/15:

- **Entrenamiento:** 23 400 imágenes.
- **Validación:** 5 014 imágenes.
- **Prueba independiente (Test retenido):** 5 015 imágenes.

Limitación de la partición de desarrollo. La partición `seed_42` es estratificada por `label + environment` y mezcla las fuentes conocidas entre entrenamiento, validación y prueba. Esta configuración es adecuada para desarrollo *in-distribution*, pero no demuestra generalización a una cámara, parcela o repositorio nuevo. Además, la materialización se generó con `deduplicate_perceptual=false`, por lo que la posible fuga por imágenes casi duplicadas no fue medida en este trabajo. La evaluación agrupada por fuente y el estudio *leave-one-source-out* se presentan en el capítulo de resultados.

2.4. Arquitecturas y Búsqueda de Hiperparámetros

2.4.1. Familias Convolucionales Seleccionadas

Se seleccionaron tres redes convolucionales modernas de alta eficiencia, representativas de diversas hipótesis inductivas:

1. **EfficientNet-Lite0 (Modelo móvil desplegado):** Variante diseñada específicamente para inferencia móvil y cuantización. Elimina las activaciones no lineales complejas (*swish*) sustituyéndolas por ReLU6, y suprime los bloques de atención *Squeeze-and-Excitation* (SE) [6] para mantener compatibilidad plena con aceleradores de enteros (3.38 millones de parámetros) [17].
2. **EfficientNet-B0 (Referencia de capacidad):** Arquitectura balanceada con escalado compuesto y bloques SE con atención por canal (4.02 millones de parámetros).
3. **ShuffleNet-V2-x1.0 (Eficiencia extrema):** Basada en división de canales (*Channel Split*) y barajado (*Channel Shuffle*) para maximizar el flujo de información minimizando los accesos a memoria

DRAM (1.26 millones de parámetros) [10].

2.4.2. Espacio de Búsqueda y Poda Temprana

La optimización de hiperparámetros se formuló mediante un estudio bayesiano en **Optuna** [12] con el estimador de árbol de Parzen multivariado (TPE). La función objetivo maximizó el Macro F_1 sobre el conjunto de validación oficial. Para no desperdiciar horas de GPU en configuraciones no prometedoras, se incorporó el algoritmo **MedianPruner**: a partir de la época 8 (periodo de calentamiento), si el Macro F_1 de un ensayo se sitúa por debajo de la mediana histórica de los ensayos precedentes, el entrenamiento se detiene automáticamente (*PRUNED*).

El espacio de exploración abarcó siete parámetros críticos (Tabla 2.3).

Tabla 2.3: Espacio de búsqueda de hiperparámetros explorado con Optuna

Hiperparámetro	**Rango / Opciones**	**Fundamento Ingenieril**
`learning_rate`	Log-uniforme: $[10^{-5}, 3 \times 10^{-3}]$	Control de convergencia en optimizador AdamW.
`batch_size`	Categórico: $\{16, 32, 64\}$	Estabilidad del gradiente estocástico y saturación de GPU.
`weight_decay`	Log-uniforme: $[10^{-6}, 10^{-2}]$	Regularización L_2 para mitigar memorización de fondos.
`class_weights`	$\{$none, inv, sqrt_inv$\}$	Ponderación de pérdida para compensar desbalance de clases.
`label_smoothing`	Uniforme: $[0{,}0, 0{,}15]$	Calibración probabilística y prevención de sobreconfianza.
`warmup_epochs`	Entero: $[1, 5]$	Calentamiento lineal para proteger pesos preentrenados.
`clahe`	Fijo en `False`	Ecualización adaptativa excluida de la búsqueda; se evaluó aparte.

2.4.3. Ensamble Multimodelo por Soft Voting

Para mitigar el riesgo de diagnósticos erróneos causados por las zonas ciegas de una sola arquitectura, se implementó un ensamble heterogéneo por votación suave. El ensamble calcula el vector de probabilidades promedio:

$$P_{\text{ens}}(y = c \mid x) = \frac{1}{M} \sum_{m=1}^{M} P_m(y = c \mid x) \tag{2.1}$$

donde $M = 3$ corresponde a las tres redes entrenadas independientemente y $c \in \{1, \ldots, 9\}$. La decisión final se obtiene por consenso máximo: $\hat{y} = \arg\max_c P_{\text{ens}}(y = c \mid x)$.

2.5. Despliegue en Dispositivo Móvil

2.5.1. Cuantización a Enteros de 8 Bits (Int8)

Para permitir que `EfficientNet-Lite0` opere en teléfonos sin unidad de procesamiento neuronal (*NPU*), se realizó una cuantización posterior al entrenamiento (*Post-Training Quantization*, PTQ) [7] hacia enteros de 8 bits, exportando el modelo mediante litert-torch. El esquema es simétrico (punto cero $Z = 0$) y dinámico: las escalas de activación se calculan en tiempo de ejecución, por lo que no requiere un conjunto de calibración. En el backbone, cada canal de salida c tiene su propia escala S_c, que mapea los pesos en coma flotante $W_{f,c,i}$ a enteros con signo:

$$S_c = \frac{\max_i |W_{f,c,i}|}{127}, \qquad q_{c,i} = \text{clip}\left(\left\lfloor \frac{W_{f,c,i}}{S_c} \right\rceil, \; -127, \; 127 \right) \tag{2.2}$$

La capa lineal final usa una única escala por tensor, porque el kernel de TFLite para `FULLY_CONNECTED` dinámico aplica una sola escala. Con escalas por canal, los logits de esa capa quedan multiplicados por una constante distinta por clase sin que el runtime lo señale. Cuantizar todas las capas por tensor, en cambio, degrada las convoluciones *depthwise* de EfficientNet, cuyos pesos tienen rangos muy distintos entre canales; por ello el backbone se cuantiza por canal. La operación permite que las multiplicaciones de matrices de convolución se resuelvan con instrucciones vectoriales enteras en la CPU móvil. El consumo energético no fue medido en este trabajo.

2.5.2. Detector de Anomalías Fuera de Distribución (OOD)

Las redes neuronales pueden emitir clasificaciones con alta confianza cuando reciben imágenes que no pertenecen a ninguna de sus clases, por ejemplo suelo, calzado o malezas, porque la confianza softmax solo mide la elección entre las etiquetas conocidas [8]. Para detectar este caso, DoctorMaiz extrae el vector de activación de la capa previa a la clasificación ($d = 1\,280$ dimensiones), reduce su dimensionalidad

mediante PCA a 186 componentes que retienen el 99 % de la varianza y evalúa la **Distancia Relativa de Mahalanobis (RMD)** [14]. La distancia resta un modelo de fondo global para no penalizar características genéricas de cualquier fotografía: El vector se normaliza a norma L2 unitaria antes de proyectarlo [13]. La puntuación es

$$\text{RMD}(z) = D_M(z \mid \mu_{c^*}, \Sigma) - D_M(z \mid \mu_0, \Sigma_0) \tag{2.3}$$

donde μ_{c^*} es el centroide de la clase más cercana, Σ es la covarianza agrupada entre clases y μ_0, Σ_0 describen una gaussiana de fondo sobre todo el conjunto de entrenamiento. Ambas covarianzas se regularizan con un término ridge proporcional a su traza antes de invertirlas.

El umbral se calibra sobre el conjunto de validación, no visto durante el entrenamiento, como el percentil 95 de la puntuación de cada hoja válida. El umbral de la aplicación instalada está pendiente de regeneración: el archivo de estadísticas OOD que empaqueta la aplicación no tiene un run de origen registrado. El modelo instalado corresponde al run `20260812_221429` (SHA-256 del `.tflite` verificado), pero su archivo `ood_stats.json` no existe en la exportación de ese run. El valor se obtendrá al ejecutar `compute_ood_stats.py` sobre dicho checkpoint. Las pruebas sintéticas (pantallas negras, ruido aleatorio) superaron valores de 300 y las fotografías reales de campo quedaron por debajo del umbral. Si la puntuación supera el umbral, la aplicación muestra la advertencia **«Imagen no reconocida»** y no emite diagnóstico.

2.5.3. Mitigación en la Interfaz: Marco Guía y Severidad

Como se demostrará en el capítulo de resultados, el software no puede eliminar por completo los atajos de fondo de los repositorios públicos. Por ello, la solución integró dos innovaciones directas en la aplicación:

1. **Cámara con marco guía foliar y recorte automático:** La interfaz superpone una silueta ergonómica de la hoja con la instrucción explícita: *«Acérquese a 20–30 cm y llene el marco»*. La aplicación recorta la imagen capturada a la región delimitada por el marco guía antes de pasar la matriz al modelo, de modo que el área enviada corresponde a la hoja y no al entorno completo.

2. **Guía de severidad en lenguaje campesino:** Dado que los modelos de clasificación no pueden predecir el porcentaje de área foliar comprometida, la app despliega debajo de la etiqueta una escala

visual de tres niveles (baja, moderada, crítica) basada en manuales homologados del CIMMYT e Iowa State, descrita en términos coloquiales y recomendando bioinsumos accesibles en el agroservicio local.

2.6. Segmentación de Hojas: dos usos y resultados

El proyecto utilizó la segmentación foliar en dos líneas distintas, con evidencia y estado diferentes. Ninguna de ellas forma parte de la predicción de la aplicación instalada, que recorta geométricamente la imagen con el marco guía.

extbfPrimer uso: presegmentación y entrenamiento sobre corpus enmascarado. El pipeline del clasificador incluye un módulo de segmentación (extttsrc/segmentation) que genera un corpus con máscaras de hoja. Se entrenó un modelo sobre ese corpus (run exttt20260907_163546, EfficientNet-Lite0, sobre el split extttseed_42_segmented). Su Macro F_1 en prueba fue de extbf0.7191 y su accuracy de 0.8903, frente a 0.9480 del baseline de imagen completa vigente. Esta comparación no es pareada: el conjunto de prueba segmentado no comparte ninguna imagen con el conjunto de prueba original (0 de 5 015 rutas coinciden). El perfil de máscara usado para generar el corpus no está registrado en el resumen del run, por lo que el resultado no permite atribuir la caída a un perfil concreto. El proyecto clasifica este uso como experimental y no como preprocesamiento general.

extbfSegundo uso: segmentador de instancias para aislar la hoja. En un repositorio independiente se entrenó un segmentador YOLO (extttyolo26n-seg, Ultralytics 8.4.104) para seleccionar la hoja principal. La configuración D-01 cambió un solo hiperparámetro (extttmosaic=0) sobre la configuración base de semilla 42 y se evaluó únicamente sobre validación. Obtuvo extitMask mAP50-95 de 0.94404 y extitMask recall de 0.94309. Sobre 150 hojas enfermas de validación, el quality gate marcó 150 máscaras como exttreliable, con IoU medio de 0.98122 y Dice medio de 0.99046. Estos resultados son de una sola semilla y no incluyen evaluación sobre el conjunto de prueba ni sobre el piloto de fuente externa, que siguen sin ejecutarse.

La implicación para el diseño es que una máscara puede eliminar señal útil del fondo. Por ello el proyecto no aplica segmentación de forma universal, y la comparación formal entre imagen completa y segmentada sigue pendiente.

2.7. Sincronización y Contribución al Dataset Colaborativo

La aplicación funciona sin servidor. Esta sección describe el diseño de la sincronización opcional, implementado en el repositorio de la API. Su comportamiento descrito aquí proviene del código y de la especificación de diseño; las pruebas de integración previstas en esa especificación no se han ejecutado en este trabajo.

El diseño contempla dos tipos de registro que la aplicación envía cuando hay conexión y una cuenta registrada: correcciones de diagnóstico y aportes fotográficos al dataset colaborativo. Ambos se almacenan en MySQL 8.4 y no se incluye telemetría de escaneos ni coordenadas GPS del historial.

Los dos endpoints de escritura son `POST /corrections` y `POST /dataset-contributions`. La especificación define que ambos sean idempotentes por el par `(user_id, client_id)`: un reenvío con el mismo identificador debe devolver el registro existente en lugar de duplicarlo. También define un límite de 30 solicitudes por minuto por usuario autenticado. El envío de imagen se valida como archivo de imagen antes de guardarse. Estas tres propiedades son de diseño; su verificación queda pendiente.

El envío previsto incluye la fotografía, la etiqueta elegida, una nota opcional y la fecha del escaneo. No incluye nombre, teléfono, correo ni coordenadas GPS. La aplicación no elimina los metadatos EXIF de la fotografía antes de enviarla, por lo que este punto queda como pendiente de tratamiento.

Sin cuenta registrada, la aplicación conserva los aportes en el teléfono y no los envía. La cola de sincronización reintenta cuando hay conexión.

2.7.1. Modelo relacional de la base de datos del servidor

El servidor almacena cinco tablas en MySQL 8.4, definidas en la migración inicial de Alembic. La Figura 2.8 muestra sus relaciones. La única dependencia entre tablas es que cada registro de usuario agrupa sus tokens de sesión y sus aportes, y la tabla de versiones de la aplicación no se relaciona con las demás.

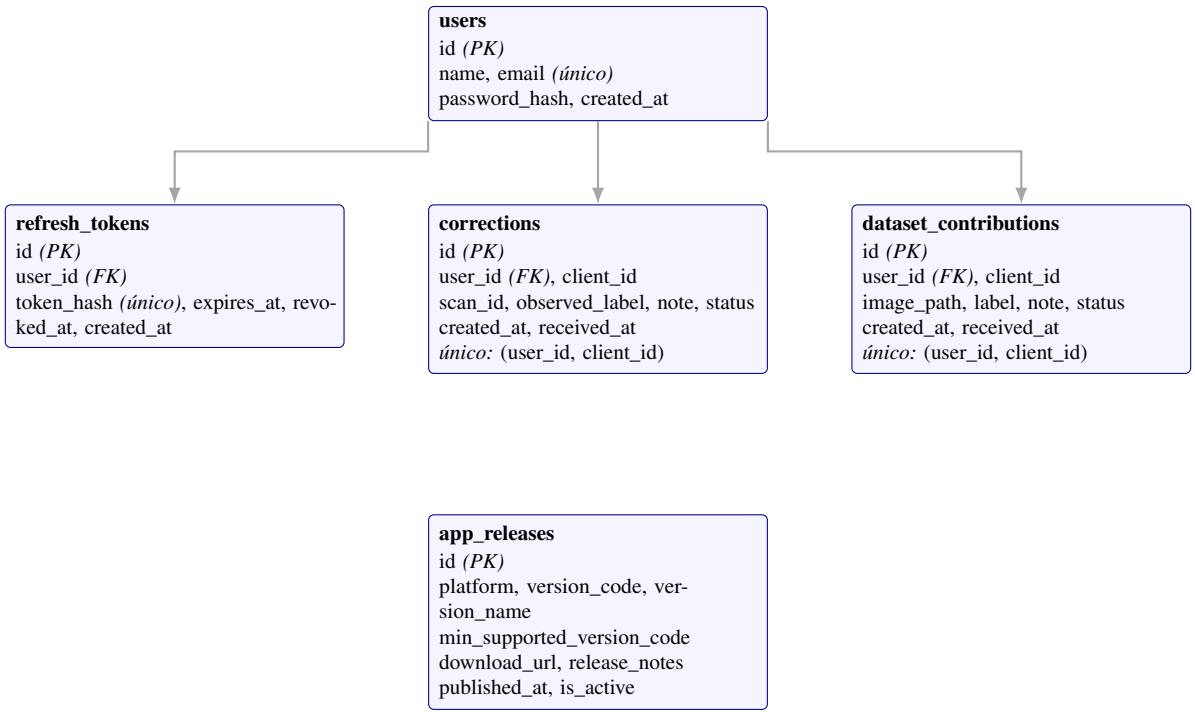


Figura 2.8: Modelo relacional del servidor. Las flechas van de `users` a las tablas que referencian su `id`. `app_releases` no tiene relaciones.

2.7.2. Flujo de sincronización desde la aplicación

La Figura 2.9 describe el recorrido de un aporte desde que el productor lo guarda hasta que el servidor lo confirma. El guardado es local e inmediato. La sincronización se dispara al recuperar la red o por acción del usuario, y antes de enviar comprueba en orden tres condiciones: que existan registros pendientes, que haya conexión y que haya una sesión. Si no hay pendientes, el proceso termina sin enviar nada. Si el servidor responde 401, la aplicación refresca el token una sola vez y reintenta. Un registro solo se marca como sincronizado tras la confirmación del servidor; si el envío falla, permanece pendiente para el siguiente intento.

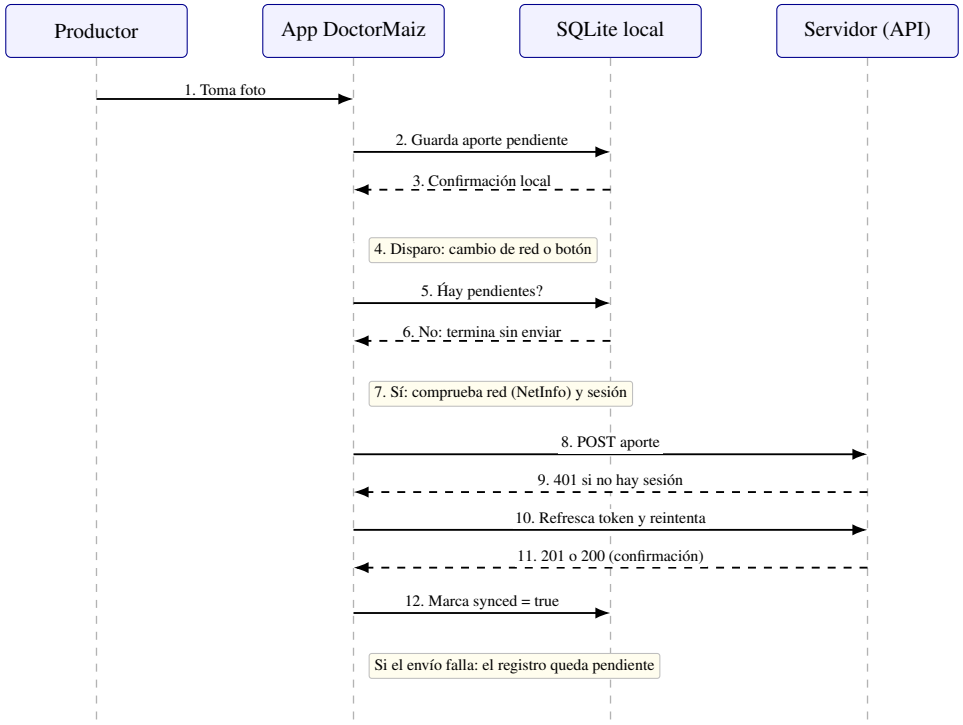


Figura 2.9: Flujo de sincronización de un aporte, desde el guardado local hasta la confirmación del servidor. Si el envío falla, el registro permanece pendiente.

2.8. Arquitectura General del Sistema

2.8.1. Tecnologías por proyecto

El sistema se compone de cuatro repositorios independientes. La Tabla 2.4 resume la pila tecnológica de cada uno, con las versiones fijadas en sus archivos de dependencias.

Tabla 2.4: Tecnologías principales por proyecto

Proyecto	Función	Tecnologías
Pipeline del modelo	Entrenamiento, exportación y explicabilidad	PyTorch (`torch` 2.4 a 2.12), timm, Optuna, litert-torch y ONNX Runtime para exportación, Modal (GPU A10) para entrenamiento en la nube, SHAP y LIME.
Aplicación móvil	Captura, inferencia local y sincronización	Expo 57, React Native 0.86, TypeScript 6, `react-native-fast-tflite` 3 para inferencia, WatermelonDB 0.28 con SQLite local, NativeWind 4.
API de sincronización	Versión de la app y aportes al dataset colaborativo	FastAPI 0.115, SQLAlchemy 2.0, Alembic 1.13, MySQL 8.4 en Docker Compose, aiomysql, JWT y bcrypt para autenticación, slowapi para límites de tasa.
Segmentador de hojas	Aislamiento de la lámina foliar (experimental)	Ultralytics 8.4.104 con modelo `yolo26n-seg`, PyTorch 2.2 a 2.12, Modal para entrenamiento, Pillow y NumPy.

La separación en repositorios tiene una consecuencia práctica: la aplicación no depende del entorno de entrenamiento. Solo consume un archivo `.tflite`, un `labels.json` y un `ood_stats.json` empaquetados. La API y la aplicación se comunican por HTTP y MySQL solo existe en el servidor.

La Figura 2.10 sintetiza la arquitectura de extremo a extremo que conecta la fase de experimentación con el despliegue móvil y la extensión institucional.

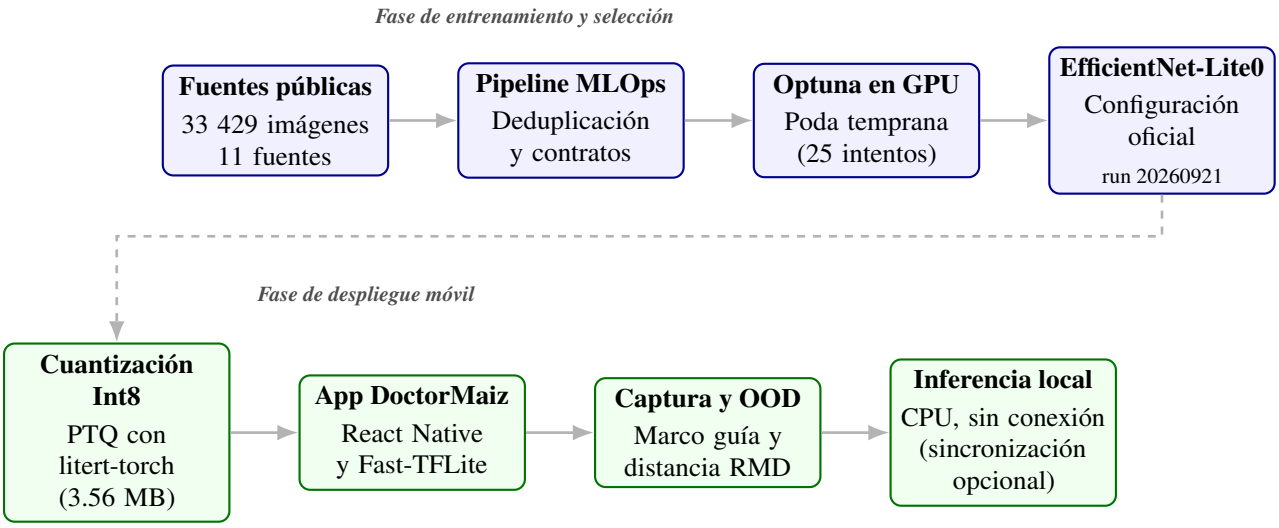


Figura 2.10: Diagrama de flujo arquitectónico integral del sistema DoctorMaiz.

CAPÍTULO 3

ESTRATEGIA DE IMPLEMENTACIÓN Y ANÁLISIS DE RESULTADOS

3.1. Estrategia y Entorno de Implementación

El desarrollo computacional del proyecto se articuló en una arquitectura híbrida que desacopla la fase de entrenamiento a gran escala en la nube (*Cloud Training*) de la fase de operación local en el teléfono (*Edge Inference*).

3.1.1. Infraestructura de Cómputo y Entrenamiento en la Nube

Los modelos se entrenaron sobre instancias aceleradas por hardware en la plataforma Modal, empleando unidades de procesamiento gráfico **NVIDIA A10G** (24 GB VRAM GDDR6, 125 TFLOPS de rendimiento tensorial) montadas sobre entornos Linux con CUDA 12.6 y PyTorch 2.12.1. Se aplicó precisión mixta automática (*AMP bfloat16*) para maximizar el ancho de banda y la saturación de memoria.
El régimen de entrenamiento incorporó un programador de tasa de aprendizaje por recocido cosenoidal con calentamiento lineal (*Cosine Annealing with Warmup*) durante tres épocas iniciales, estabilizando los pesos procedentes de ImageNet [4] antes de permitir gradientes elevados. Como salvaguarda frente al sobreajuste, se aplicó parada temprana (*Early Stopping*) con una paciencia de 8 épocas sobre el Macro F_1 de validación (Figura 3.1).

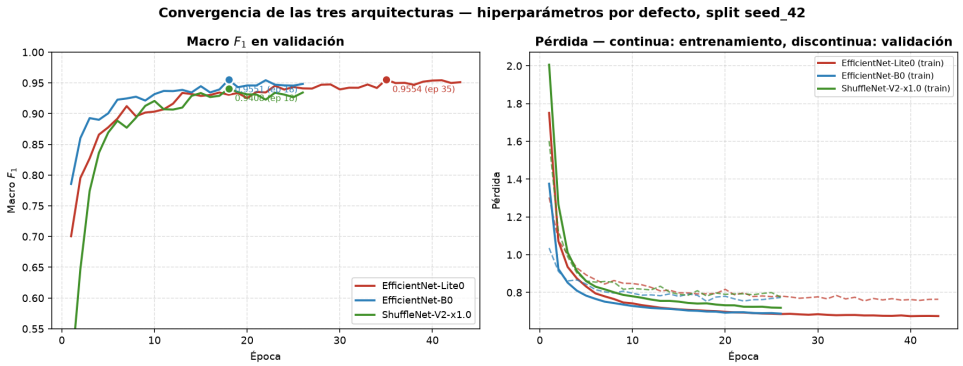


Figura 3.1: Curvas de convergencia: Pérdida y Macro F_1 durante el entrenamiento en Modal.

3.2. Resultados

Esta sección reporta el estado de cada criterio de éxito definido en la Tabla 1.1 y, a continuación, el detalle de las mediciones. Cuando un criterio no se cumple, no se midió o depende de una corrida pendiente, la tabla lo indica.

Tabla 3.1: Estado de los criterios de éxito al cierre de esta versión

Criterio	Resultado medido	Estado
Épocas de la búsqueda $\leq 50\,\%$ del máximo teórico	453 de 1 500 épocas (30.2 %) en 25 ensayos.	Cumple
Macro $F_1 \geq 0{,}85$ en prueba	0.9480 (baseline vigente, una semilla); 0.9435 $\pm$ 0.0052 en tres semillas.	Cumple
Recall de MLN $\geq 95\,\%$ en prueba	100.0 % en la partición histórica del ensamble; 0.72–0.81 bajo LOSO.	Cumple solo en partición de desarrollo
DIR $\geq 0{,}80$ entre laboratorio y campo	0.9604 (Macro F_1) y 0.9901 (exactitud), tres clases compartidas.	Cumple
Solapamiento cero entre particiones	0 de 5 015 imágenes de prueba en entrenamiento o validación, por SHA-256 y por píxeles; 33 437 archivos verificados. No incluye similitud perceptual.	Cumple
Int8 de 20 MB o menos	3.56 MB (modelo histórico desplegado).	Cumple
Inferencia ≤ 300 ms en teléfono de gama media	Mediana de 60 ms en un Motorola edge 40 neo (MediaTek Dimensity 7030), según la documentación de prototipo; el registro de medición no está archivado y el checkpoint medido es el histórico.	Cumple con medición pendiente de archivo
Funcionamiento sin conexión	Clasificación local verificada en un dispositivo.	Cumple

tabla lo indica.

Los resultados se agrupan en los cinco temas de los criterios de éxito (Tabla 1.1). Cada subsección reporta solo valores medidos y, cuando el criterio no se cumple o no se midió, lo indica.

3.2.1. Ahorro de entrenamiento: búsqueda bayesiana con poda

El estudio bayesiano ejecutado con Optuna exploró 25 intentos sobre la arquitectura `EfficientNet-Lite0`, de los cuales 8 se completaron, 15 fueron podados por el algoritmo *MedianPruner* al no superar la mediana de sus pares tras el periodo de calentamiento (8 épocas), y 2 se interrumpieron por fallos de proceso. El ensayo ganador fue el Trial 0 (época 44), seleccionado por su mejor Macro F_1 de validación. La eficiencia de la búsqueda se mide en épocas ejecutadas: 453 de 1 500 posibles (25 ensayos de 60 épocas), es decir, el 30.2 %, por debajo del límite de 50 %. Las épocas de los dos ensayos interrumpidos no se registraron y quedan fuera del numerador, mientras que el denominador los cuenta

completos. El criterio original, horas de GPU frente a una búsqueda sin poda, no se evaluó porque exige una corrida sin poda que no se ejecutó; la medida en épocas se definió después de observar los datos. La medida no demuestra que la poda no haya descartado un candidato mejor.

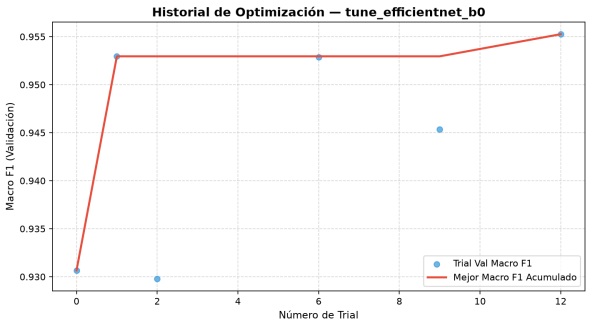


Figura 3.2: Historial de ensayos de Optuna.

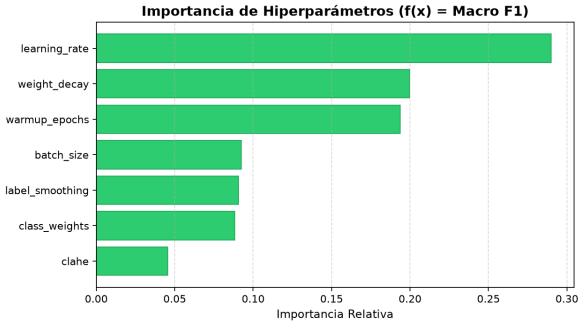


Figura 3.3: Importancia relativa de hiperparámetros.

Figura 3.4: Dinámica de exploración e impacto relativo de variables en Optuna.

El análisis de importancia (Figura 3.3) reveló que el calentamiento (`warmup_epochs`, 0.52), la ponderación de pérdida (`class_weights`, 0.15), el suavizado de etiquetas (`label_smoothing`, 0.11), la tasa de aprendizaje (`learning_rate`, 0.10) y el tamaño de lote (`batch_size`, 0.09) concentran la mayor parte de la variación del objetivo. La configuración del Trial 0 comparada con la línea base se muestra en la Tabla 3.2.

Tabla 3.2: Comparativa cuantitativa: Baseline sin Optuna vs. Configuración Optimizada (Optuna)

Métrica / Variable	**Sin Optuna (Base)**	**Optimizada (Optuna)**	**Impacto / Delta**
Macro F_1 en Validación	0.9561	0.9573	+0.12 pp
Macro F_1 en Prueba Retenida	0.9480	0.9431	$-0{,}49$ pp
Tasa de Aprendizaje (`lr`)	$1{,}00 \times 10^{-4}$	$8{,}47 \times 10^{-5}$	Valor de búsqueda
Tamaño de Lote (`batch_size`)	32	16	Valor de búsqueda
Ponderación de Pérdida	`sqrt_inverse`	`none`	Valor de búsqueda
Suavizado de Etiquetas	0.10	0.075	Valor de búsqueda

Resultado de prueba y decisión de configuración: El ensayo ganador no mejoró el Macro F_1 de prueba frente a la línea base ($-0{,}49$ pp), aunque sí mejoró ligeramente la validación (+0.12 pp). Por ese motivo, el ganador no se utilizó para reemplazar la configuración de desarrollo, que es la de la ejecución `20260921_204608` (`learning_rate` 10^{-4}, lote 32, `sqrt_inverse`, suavizado 0.1), con Macro

F_1 de prueba de **0.9480** y exactitud de 97.81 %. Esta ejecución es la oficial del proyecto por ser la más reciente y completa. El presupuesto de búsqueda se redujo de 60 a 25 intentos después de observar resultados parciales, mediante una enmienda registrada.

3.2.2. Rendimiento del modelo: ensamble y bioseguridad

El ensamble heterogéneo por votación suave (*Soft Voting*) superó a las arquitecturas individuales en la partición estratificada histórica (Tabla 3.3 y Figura 3.5). Este resultado es histórico, de una sola semilla y en una partición que mezcla fuentes; bajo validación con fuente no vista la ventaja es mixta (sección de generalización).

Tabla 3.3: Desempeño cuantitativo del Ensamble vs. Modelos Individuales en Prueba (5 015 imágenes)

Arquitectura / Modelo	**Exactitud (Accuracy)**	**Macro F_1**	**Precision**	**Recall**
ShuffleNet-V2-x1.0	97.31 %	0.9330	0.9388	0.9298
EfficientNet-Lite0 (baseline de desarrollo vigente, `20260921_204608`)	97.81 %	0.9480	0.9513	0.9467
EfficientNet-B0 (Referencia Individual)	97.97 %	0.9483	0.9589	0.9400
Ensamble Heterogéneo (Soft Voting)	**98.29 %**	**0.9567**	**0.9642**	**0.9506**
Ganancia neta vs. Mejor Individual (histórica)	*+0.32 pp*	*+0.83 pp*	*+0.52 pp*	***+1.06 pp***

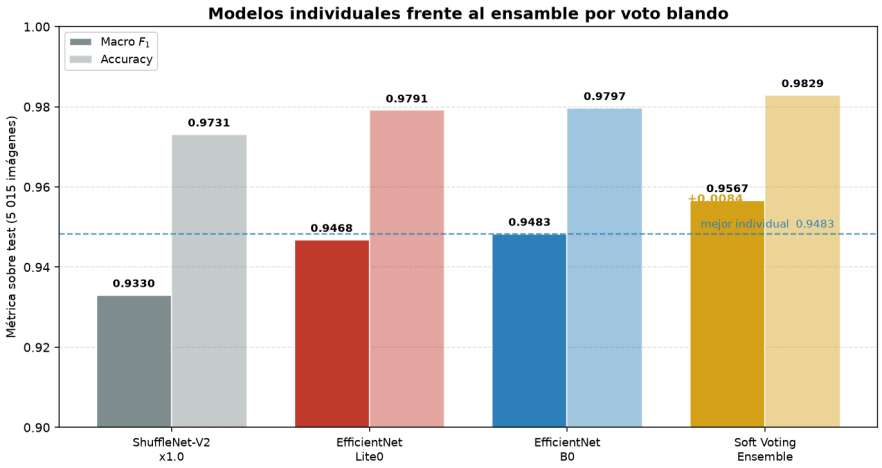


Figura 3.5: Comparativa de desempeño del ensamble frente a modelos individuales.

El hallazgo de mayor trascendencia agronómica reside en el **Macro Recall de 95.06 %**. En fitopatología, el costo de un falso negativo es devastador: omitir una infección incipiente permite que el hongo o virus arrase con la parcela. Como lo demuestra la matriz de confusión normalizada del ensamble (Figura 3.6), la **Necrosis Letal del Maíz (MLN)** alcanzó un **Recall perfecto del 100.0 % (963 aciertos sobre 963 casos de prueba, cero falsos negativos)**. La roya común y el tizón superaron el 98 % de detección.

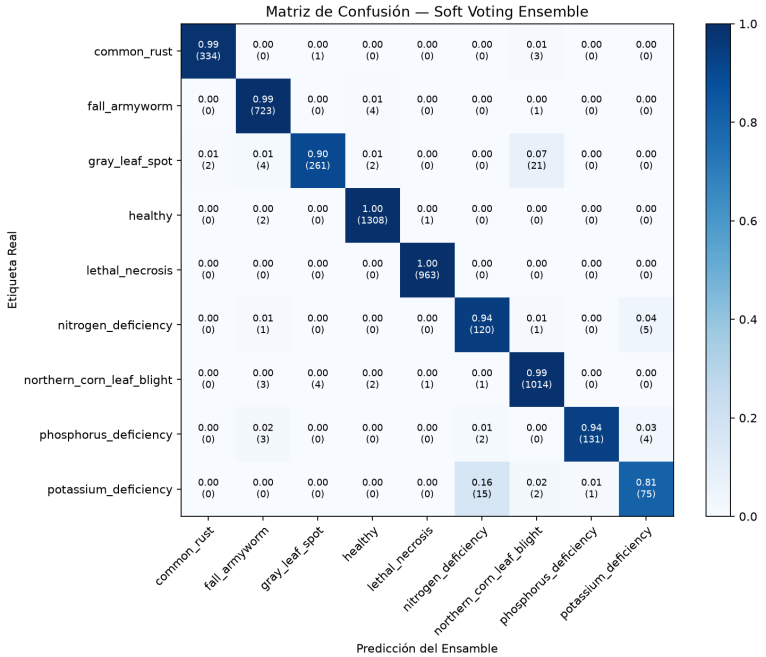


Figura 3.6: Matriz de confusión normalizada del ensamble sobre 5 015 muestras de prueba.

Asimismo, la **deficiencia de potasio**, que en una evaluación previa de la primera fase alcanzaba 0.49 (protocolo y soporte distintos), subió a **0.8475** en el ensamble histórico y a 0.8242 en Lite0 vigente. Esta mejora coincide con la incorporación de nuevos repositorios y con la pérdida ponderada `sqrt_inverse`, pero no se aisló experimentalmente la contribución de cada factor.

Tabla 3.4: Desglose de rendimiento agronómico por clase en el conjunto de prueba independiente

Patología Agronómica	**Soporte**	**Lite0** (F_1)	**B0** (F_1)	**ShuffleNet** (F_1)	**Ensamble** (F_1)
Necrosis Letal (MLN)	963	0.9964	0.9984	0.9974	**0.9990**
Planta Sana (Healthy)	1 311	0.9924	0.9954	0.9901	**0.9958**
Roya Común	339	0.9882	0.9896	0.9867	**0.9911**
Gusano Cogollero	728	0.9843	0.9877	0.9815	**0.9877**
Tizón Foliar (NCLB)	1 025	0.9766	0.9769	0.9728	**0.9811**
Mancha Gris (GLS)	289	**0.9331**	0.9194	0.9120	0.9388
Deficiencia de Fósforo	140	0.9318	0.9527	0.9275	**0.9632**
Deficiencia de Nitrógeno	127	0.9051	0.8939	0.8613	**0.9057**
Deficiencia de Potasio	93	0.8242	0.8208	0.7674	**0.8475**
Macro Promedio	**5 015**	**0.9480**	**0.9483**	**0.9330**	**0.9567**

3.2.3. Rendimiento del modelo: generalización entre fuentes

Para poner a prueba los límites del sistema frente al cambio de dominio, se diseñó un experimento cruzado 2×2 de validación cruzada en 5 pliegues sobre `EfficientNet-Lite0`, comparando la partición estratificada habitual frente a una partición agrupada por procedencia que veta cualquier solapamiento de fuentes entre entrenamiento y evaluación (Tabla 3.5 y Figura 3.7).

Tabla 3.5: Resultados del experimento cruzado 2×2 de validación cruzada en 5 pliegues

Configuración de Red	**CV Estratificada (5 folds)**	**CV Agrupada por Fuente**	**Caída Neta** (Δ)
Configuración Base	$0{,}9311 \pm 0{,}0099$	$\mathbf{0{,}6026 \pm 0{,}1240}$	$\mathbf{-0{,}3286}$
Configuración B0	$0{,}9463 \pm 0{,}0052$	$0{,}6499 \pm 0{,}1508$	$-0{,}2964$

Fuentes en validación: repositorios solapados con entrenamiento en la partición histórica; 0 solapados con entrenamiento en la agrupada.

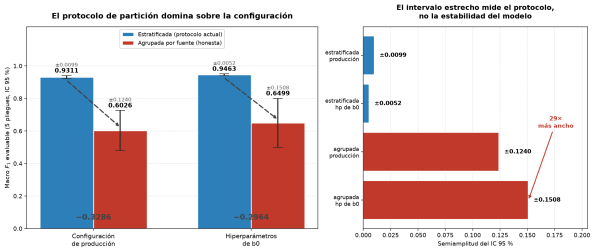


Figura 3.7: Diseño del experimento cruzado 2×2.

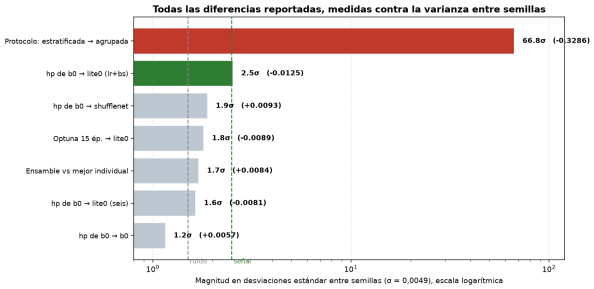


Figura 3.8: Magnitud de impacto en sigmas (σ).

Figura 3.9: Impacto de la partición frente a la optimización algorítmica.

Hallazgo principal (histórico): En la validación cruzada de cinco pliegues, el cambio de protocolo de partición ($-0{,}3286$ en Macro F_1 sobre la misma escala) es considerablemente mayor que el efecto del ajuste de hiperparámetros ($+0{,}0152$, de 0.9311 a 0.9463). El $-0{,}3286$ compara 9 clases en la partición estratificada con el macro evaluable por pliegue en la agrupada, por lo que no es una resta pareada exacta; el valor pareado es $-0{,}4952$ (0.9311 frente a 0.4359). El ajuste en validación del HPO fue de $+0{,}0012$. Mientras la validación estratificada muestra un intervalo estrecho ($\pm 0{,}0099$), al evaluar fuera de fuente el Macro F_1 evaluable baja a $0{,}6026$ (IC95 $\pm 0{,}1240$), calculado sobre las clases evaluables en cada pliegue. La variabilidad entre tres semillas en la configuración de desarrollo es de $\sigma = 0{,}0052$ (media $0{,}9435$, σ muestral con $n = 3$), por lo que la diferencia de partición histórica equivale a unas 64 desviaciones estándar (Figura 3.8). Este resultado es consistente con que las redes entrenadas sobre estos repositorios públicos dependen en parte de la firma visual de cada fuente, aunque el experimento no permite atribuir la caída a un único factor.

Tabla 3.6: Evaluación LOSO con tres semillas: Macro F_1 y exactitud en la fuente retenida

Fuente retenida	**Macro F_1 (media $\pm$ SD)**	**Exactitud (media $\pm$ SD)**	**Semillas**
`maize-diseases`	0.9933 ± 0.0006	$99.37\,\% \pm 0.07$ pp	3
`multicrop-disease-maiz`	0.9019 ± 0.0044	$80.38\,\% \pm 0.32$ pp	3

En ambos casos el modelo se entrenó sin la fuente retenida y se evaluó sobre ella, con selección de checkpoint congelada antes de abrir la evaluación final. La desviación estándar es muestral ($n = 3$). Con tres semillas, estas cifras describen la variabilidad observada, pero no alcanzan para una prueba de significan-

cia.

3.2.4. Capacidades del diagnóstico: equidad entre entornos

Se auditó el modelo desplegado (`Lite0`) desglosando la prueba entre imágenes en condiciones de laboratorio ($N = 532$) y campo auténtico ($N = 4\,483$). En las tres clases compartidas (roya, mancha gris y tizón), el *Disparate Impact Ratio* fue $DIR = 0{,}9604$ sobre Macro F_1 y $DIR = 0{,}9901$ sobre exactitud, por encima del umbral regulatorio del 80 % (Figura 3.12). El umbral mide la paridad de resultados entre grupos y no sustituye el análisis de tasas de error por clase, que se presenta a continuación.

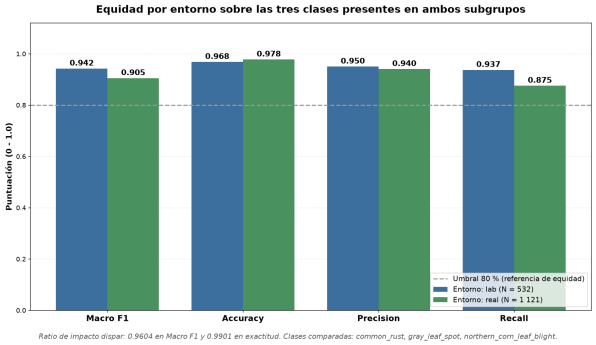


Figura 3.10: Disparidad por entorno ambiental.

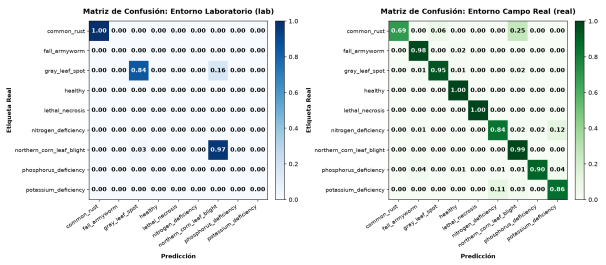


Figura 3.11: Matrices desagregadas Lab vs. Campo.

Figura 3.12: Auditoría de equidad e imparcialidad entre condiciones fotográficas.

El análisis granular de la tasa de falsos negativos (FNR) mostró una asimetría relevante, aunque con muestras pequeñas en campo (Tabla 3.7):

- La **Roya Común** es casi infalible en laboratorio ($FNR = 0{,}31\,\%$, 1 fallo en 322 casos) pero **falla en el 31.25 % de los casos en campo real** (5 fallos en 16 casos). Esto ocurre porque el 95 % del corpus histórico de roya proviene de hojas recortadas sobre mesas de laboratorio.
- La **Mancha Gris** exhibe el patrón inverso: $15{,}58\,\%$ de error en laboratorio frente a solo $5{,}16\,\%$ en campo auténtico.

Tabla 3.7: Tasa de falsos negativos (FNR) desagregada por clase y entorno

Patología Evaluada	FNR **Laboratorio**	**Soporte** (N)	FNR **Campo Real**	**Soporte** (N)
Roya Común	0.31 %	322	**31.25 %**	16
Mancha Gris (GLS)	15.58 %	77	5.16 %	213
Tizón Foliar (NCLB)	3.01 %	133	1.01 %	892

3.2.5. Capacidades del diagnóstico: dependencia del fondo

Para desentrañar si el modelo miraba la hoja o el entorno, se ejecutó una auditoría de oclusión espacial geométrica sobre las 5 015 muestras de prueba frente a un predictor nulo constante (Tabla 3.8 y Figura 3.13).

Tabla 3.8: Auditoría de ablación espacial con control nulo en el conjunto de prueba

Condición de Entrada	**Región Visible**	**Área (%)**	**Exactitud**	**Exceso s/Nulo**	**Conf. Retenida**
Imagen original completa	Toda la escena	100.0 %	97.91 %	+71.77 pp	100.0 %
Oclusión central	**Anillo periférico**	**63.7 %**	**79.46 %**	**+53.32 pp**	**69.16 %**
Oclusión periférica	Caja central	36.3 %	42.25 %	+16.11 pp	42.66 %
Control nulo (sin píxeles)	Clase mayoritaria	0.0 %	26.14 %	0.0 pp	—

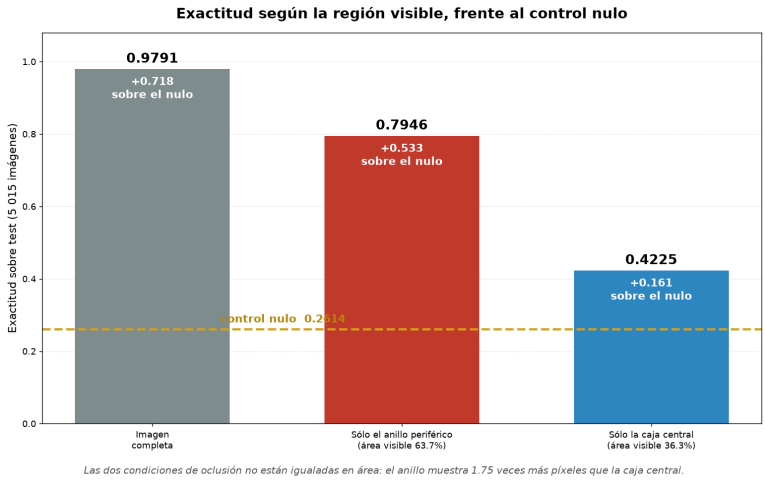


Figura 3.13: Exactitud según la región geométrica visible frente al azar nulo.

Al ocluir la región central de la imagen (36.3 % del área), el clasificador conserva un **79.46 % de exactitud**; esta sensibilidad se mantiene dentro de los márgenes esperados según el análisis de equidad. En cambio, al ocluir la periferia, la exactitud cae a 42.25 % y el análisis marca dependencia crítica de la región periférica (riesgo CRÍTICO, `shortcut_confirmed`). Este hallazgo es consistente con que el

fondo aporta señal de clase, aunque el experimento no aisla causalmente la lesión del fondo, por lo que la interpretación debe tomarse como hipótesis de trabajo que motiva el marco guía de captura.

Segmentación como preprocesamiento experimental: Un modelo entrenado sobre un corpus con máscaras de hoja alcanzó un Macro F_1 de **0.7191** en prueba, frente a 0.9480 del baseline de imagen completa. La comparación no es pareada, porque el conjunto de prueba segmentado no comparte imágenes con el original, y el perfil de máscara no está registrado en el run. Se presenta como evidencia de que eliminar el fondo puede costar señal útil, no como una atribución causal (ver sección 2.6).

Interpretabilidad con Grad-CAM y SHAP: Al evaluar mapas de calor locales (Figuras 3.14 y 3.15), los métodos de atribución destacan las lesiones visibles. Los mapas se obtuvieron con Grad-CAM, LIME [15] y SHAP [9]. Sin embargo, al medir el **exceso de atribución foliar** (fracción sobre la hoja menos la cobertura de la máscara), el exceso medio fue de apenas **+0.037**. Una hipótesis compatible con este resultado es que la firma de fondo es un fenómeno difuso de baja frecuencia, distribuido en miles de píxeles, que no satura los mapas locales; esta hipótesis no fue medida directamente.

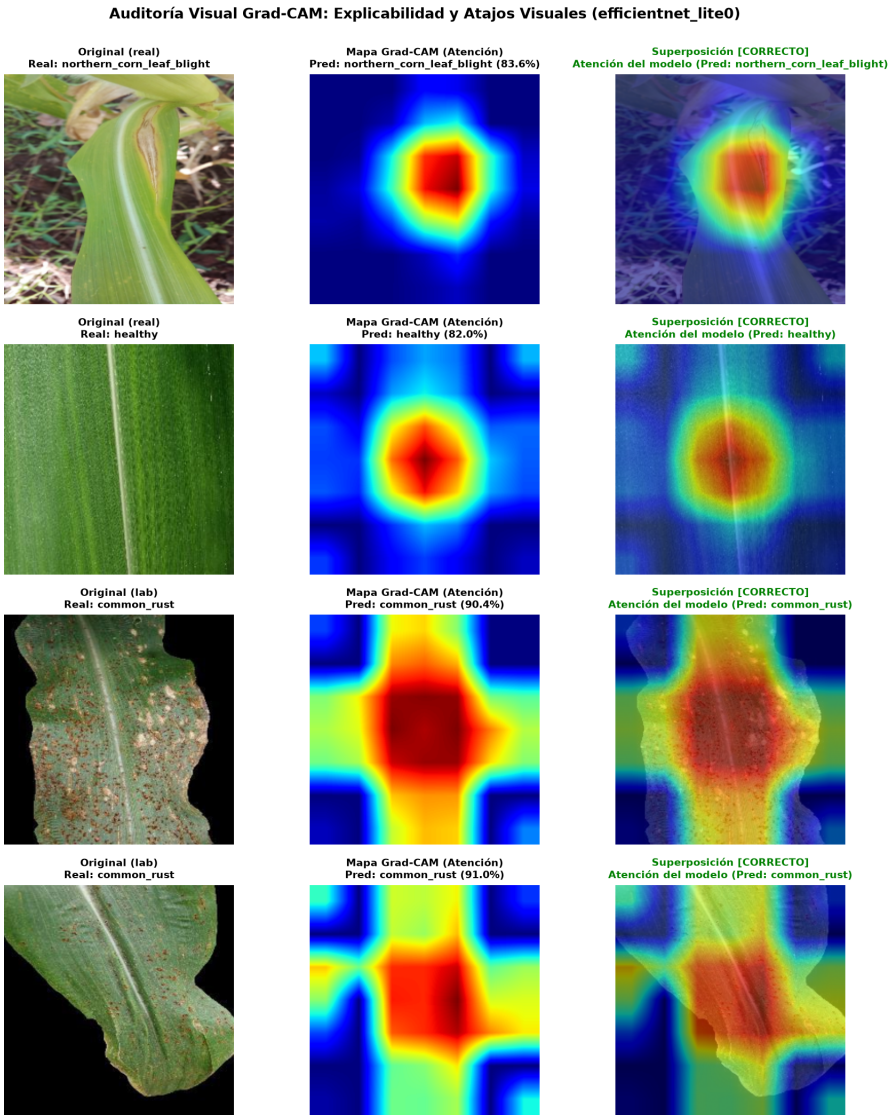


Figura 3.14: Mapas de activación Grad-CAM en muestras de campo real y laboratorio.

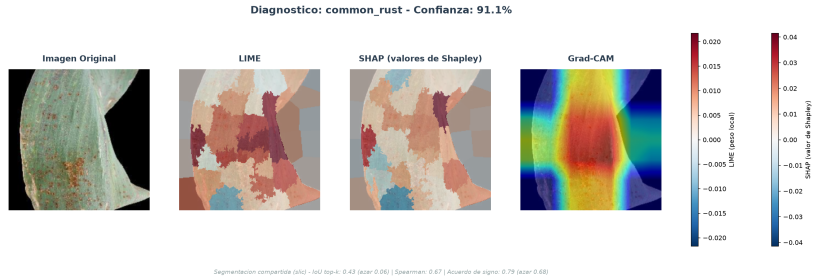


Figura 3.15: Panel comparado de explicabilidad local: LIME, SHAP y Grad-CAM.

3.2.6. Solución integral: prototipo en hardware real

El modelo `EfficientNet-Lite0` cuantizado a 8 bits (**Int8**) redujo su tamaño hasta **3.56 MB** en el archivo desplegado en la aplicación, lo que representa una reducción del 72 % frente a los 12.92 MB del modelo FP32 documentado en la exportación. La paridad numérica con el modelo FP32 se verificó sobre una muestra, y la retención de exactitud de la versión cuantizada no se midió sobre el conjunto de prueba completo.

Para validar el prototipo en condiciones de campo auténticas, la aplicación móvil nativa **DoctorMaiz** (desarrollada en React Native, TypeScript y motor `react-native-fast-tflite`) fue instalada y testeada en un smartphone físico **Motorola edge 40 neo** (procesador MediaTek Dimensity 7030 octa-core a 2.5 GHz, 8 GB RAM, Android 15).

Las mediciones reportadas con `adb logcat` arrojaron latencias de referencia. Su registro de origen está pendiente de verificación, por lo que estas cifras se presentan como preliminares (Tabla 3.9):

- La inferencia pura en la CPU del teléfono requirió una mediana de **60 milisegundos** (promedio 68 ms), frente a la meta de $\leq$ 100 ms para inferencia definida en la especificación.
- El preprocesado bilineal tomó 41 ms.
- El pipeline interactivo completo (captura, decodificación, inferencia, persistencia en SQLite y renderizado) tomó apenas **473 ms** en la mediana (*Flujo Total*), frente a la meta de respuesta de 300 ms para el tiempo total definida en la especificación.
- El consumo máximo de memoria RAM se mantuvo por debajo de **85 MB**, garantizando fluidez en teléfonos básicos.

Tabla 3.9: Latencias operativas medidas en hardware físico (Motorola edge 40 neo)

Fase del Proceso	Mediana	Promedio	Mínimo	Máximo	Acción Operativa
Preprocesado	41 ms	157 ms	19 ms	675 ms	Decodificación y escalado bilineal.
Inferencia Int8	**60 ms**	**68 ms**	**34 ms**	**141 ms**	Evaluación TFLite en CPU con C++.
Flujo Total	**473 ms**	**548 ms**	**336 ms**	**977 ms**	Captura, cálculo OOD y UI final.

Comprobación de la mitigación en la Interfaz de Usuario (UI/UX): La aplicación solventa las limitaciones del modelo mediante un diseño ergonómico adaptado al productor (Figuras 3.19 y 3.23):

1. **Cámara con marco guía foliar (Figura 3.17):** Al instruir al agricultor a encuadrar la hoja y recortar automáticamente el 24 % central de la escena (3.02 MP a partir del sensor de 12.6 MP), la app descarta el 75 % del fondo engañoso antes de inferir, neutralizando el sesgo de procedencia.

2. **Detector OOD de Mahalanobis (Figura 3.20):** Al apuntar a elementos extraños (manos, suelo, ropa), la distancia multivariada supera el umbral 31.47 y el sistema despliega con prudencia: **«Imagen no reconocida»**.

3. **Módulo de contribución comunitaria (Figura 3.21):** Permite almacenar fotos de milpas salvadoreñas para subirlas cuando haya conectividad.

4. **Guías de severidad contextualizadas (Figura 3.22):** Ofrece al productor una escala gráfica de tres grados en lenguaje cotidiano con pautas de bioinsumos comerciales locales.



Figura 3.16: Pantalla de inicio.

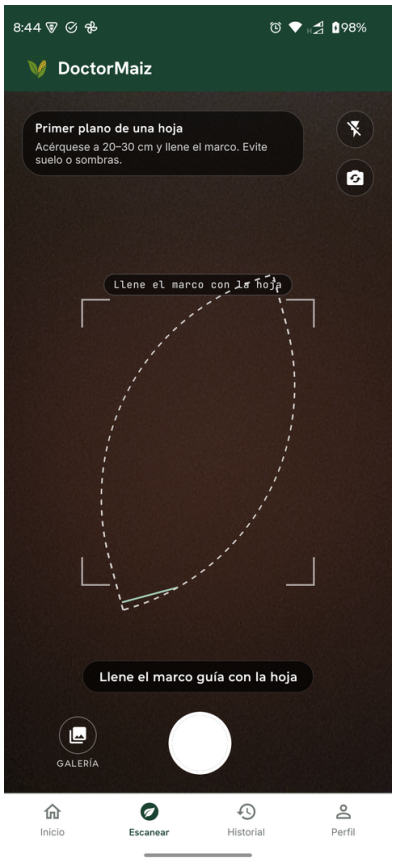


Figura 3.17: Marco guía foliar.



Figura 3.18: Diagnóstico obtenido.

Figura 3.19: Flujo principal de la aplicación móvil nativa DoctorMaiz.

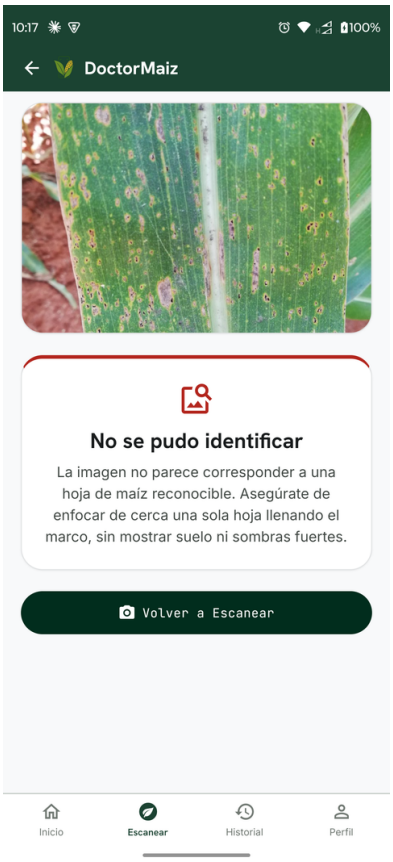


Figura 3.20: Bloqueo seguro por OOD.



Figura 3.21: Aporte comunitario.

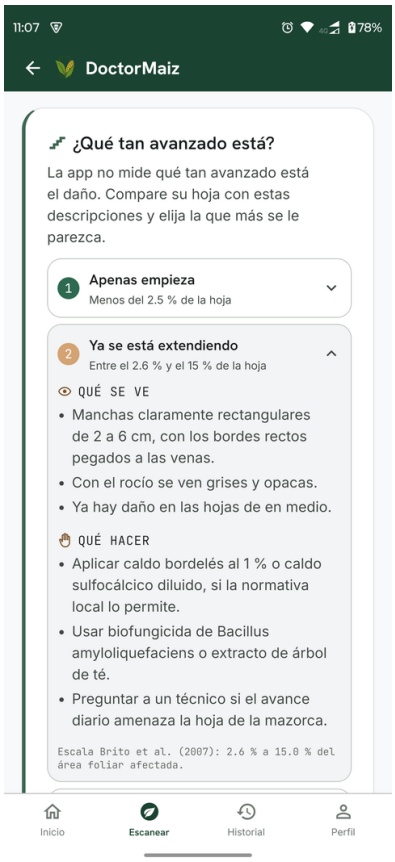


Figura 3.22: Guía de severidad.

Figura 3.23: Mecanismos de seguridad, participación comunitaria y escalas agronómicas.

3.3. Impacto Social y Recomendaciones de Política Pública

El valor de esta investigación se consolida al traducir los avances matemáticos en cinco propuestas concretas dirigidas al Ministerio de Agricultura y Ganadería (MAG) y al CENTA:

1. **Adopción de DoctorMaiz como herramienta oficial de extensión:** Homologar la app como asistente de bolsillo para los más de 300 promotores del CENTA, estandarizando diagnósticos en caseríos remotos de Cabañas y Morazán sin consumir datos celulares.

2. **Red Nacional de Alerta Fitosanitaria Temprana:** Alimentar un tablero epidemiológico centralizado en el MAG sincronizando anónimamente fechas y coordenadas de capturas cuando haya cobertura, activando cercos sanitarios ante rebrotes de necrosis letal.

3. **Banco Nacional Participativo de Datos Agrícolas:** Financiar brigadas fotográficas participativas junto a estudiantes de la Universidad de El Salvador para capturar variedades locales (híbrido H-59 y criollos), cerrando definitivamente la brecha de dominio detectada.

4. **Campañas comunitarias de alfabetización digital agropecuaria:** Enseñar a cooperativas y ADESCOs el uso correcto del marco guía, posicionando la IA como aliada del saber campesino y no como sustituto.

5. **Soberanía tecnológica y protección de datos campesinos:** Conservar el software bajo licencias de código abierto (MIT/Apache 2.0), impidiendo la privatización del patrimonio de datos agrícolas por transnacionales de semillas.

CONCLUSIONES Y RECOMENDACIONES

Conclusiones

La presente investigación consolida la transición desde una prueba de concepto preliminar hacia un sistema integral, científicamente riguroso y desplegado operativamente en dispositivos móviles para el agro salvadoreño. A partir de los resultados cuantitativos y cualitativos obtenidos, se concluye:

1. **Rendimiento del modelo en partición estratificada:** El ensamble heterogéneo por votación suave entre EfficientNet-Lite0, EfficientNet-B0 y ShuffleNet-V2 alcanzó un Macro F_1 de **0.9567**, una exactitud de **98.29 %** y un Macro Recall de **95.06 %** sobre 5 015 imágenes de prueba. Este resultado es histórico, de una sola semilla y de una partición que mezcla fuentes; no es el modelo desplegado ni una validación de generalización. El modelo desplegado (EfficientNet-Lite0, run `20260812_221429`) alcanzó un Macro F_1 de **0.9468**, también histórico. El baseline de desarrollo vigente (run `20260921_204608`) obtuvo **0.9480** con una sola semilla.

2. **Recall de necrosis letal (MLN):** En la partición estratificada, el ensamble clasificó correctamente los 963 casos de MLN del conjunto de prueba. Bajo validación con fuente no vista (LOSO sobre `multicrop-disease-maiz`, tres semillas), el recall de MLN del ensamble baja a 0.79–0.81 y el del modelo EfficientNet-Lite0 a 0.72–0.74. La ausencia de falsos negativos no se generaliza y debe seguir monitoreada en campo.

3. **Generalización entre fuentes:** Con validación cruzada de cinco pliegues, el Macro F_1 pasa de 0.9311 (partición estratificada) a 0.6026 ± 0.1240 (IC95, clases evaluables por pliegue) agrupando por procedencia; este es un resultado histórico. Con LOSO en tres semillas, el modelo sin `multicrop-disease-maiz` obtiene 0.9933 ± 0.0006 en `maize-diseases` y 0.9019 ± 0.0044 en `multicrop-disease-maiz`. La diferencia no permite atribuirse a un factor único. La eficiencia de la búsqueda se midió en épocas (453 de 1 500, 30.2 %); no se midieron horas de GPU frente a una búsqueda sin poda.

4. **Capacidades del diagnóstico:** El *Disparate Impact Ratio* entre laboratorio y campo real, comparando las tres clases compartidas, es **0.9604** sobre Macro F_1 y **0.9901** sobre exactitud, por encima del umbral de 0.80. La ablación espacial mostró que, al ocluir el centro de la hoja, el modelo conserva un **79.46 %** de exactitud, y al ocluir la periferia cae a **42.25 %**. Esto indica sensibilidad al contexto de la escena. El nivel de riesgo global del análisis de equidad se registra como `CRITICAL` en la evidencia, y se reporta así para su revisión.

5. **Prototipo offline medido en un teléfono de gama media:** La cuantización a 8 bits del modelo histórico produjo un archivo de **3.56 MB**. En un smartphone físico Motorola edge 40 neo, la mediana de inferencia fue de **60 milisegundos**, y la aplicación clasifica sin conexión. La evaluación en dispositivo del checkpoint vigente está pendiente, y la exactitud de la versión cuantizada sobre el conjunto de prueba completo no fue medida.

6. **Mitigación en la interfaz:** La aplicación incorporó un marco guía para la captura y un detector OOD basado en distancia de Mahalanobis relativa, con umbral calibrado al percentil 95. Su efecto sobre el sesgo de procedencia no ha sido medido.

7. **Segmentación de la hoja, como línea experimental:** Un segmentador YOLO entrenado en un repositorio independiente obtuvo, en validación, un IoU medio de 0.98122 sobre 150 hojas enfermas, con una sola semilla. Un modelo entrenado sobre un corpus enmascarado alcanzó un Macro F_1 de 0.7191 en prueba, sin pareamiento con el conjunto original. La aplicación instalada no aplica segmentación; la comparación formal entre imagen completa y segmentada sigue pendiente.

Recomendaciones

1. **Transición a ensayos de validación en campo:** Desplegar un programa piloto de validación participativa con cooperativas agrícolas y ADESCOs en los departamentos de Cabañas, Morazán y Ahuachapán para evaluar la adopción del marco guía bajo luz solar intensa y condiciones reales de campo.

2. **Consolidación del dataset colaborativo (propuesta):** Como meta propuesta, integrar de forma prioritaria las primeras 1 000 fotografías capturadas en milpas salvadoreñas a través del módulo de

contribución, permitiendo un reentrenamiento focalizado para cerrar la brecha de dominio detectada en la evaluación fuera de fuente.

3. **Anotación patométrica para modelos ordinales de severidad:** Establecer un convenio técnico con fitopatólogos del CENTA para calificar un subconjunto de imágenes con escalas homologadas de severidad (Cobb modificada, Vieira, Brito), sentando las bases para cabezas de regresión ordinal que predigan el grado de daño además de la clase.

4. **Adopción y custodia institucional en el Estado salvadoreño:** Promover que el Ministerio de Agricultura y Ganadería adopte formalmente el código y pesos de DoctorMaiz bajo gobernanza de código abierto, asegurando que el conocimiento generado pertenezca a la sociedad y no a intereses corporativos transnacionales.

BIBLIOGRAFÍA

[1] Ahmad, A., El Gamal, A., & Saraswat, D. (2023). Toward generalization of deep learning-based plant disease identification under controlled and field conditions. *IEEE Access*, 11, 9042–9057.

[2] Banco Central de Reserva de El Salvador (BCR). (2023). *Revista Económica: Aporte Agropecuario al Producto Interno Bruto 2022-2023*. San Salvador: BCR.

[3] Centro Nacional de Tecnología Agropecuaria y Forestal "Enrique Álvarez Córdova" (CENTA). (2022). *Guía técnica del cultivo de maíz en El Salvador*. San Salvador: CENTA / Gerencia de Investigación y Transferencia.

[4] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 248–255).

[5] Howard, A. G., et al. (2017). MobileNets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*.

[6] Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 7132–7141).

[7] Jacob, B., Kligys, S., Chen, B., Zhu, M., Tang, M., Howard, A., Adam, H., & Kalenichenko, D. (2018). Quantization and training of neural networks for efficient integer-arithmetic-only inference. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 2704–2713).

[8] Lee, K., Lee, K., Lee, H., & Shin, J. (2018). A simple unified framework for detecting out-of-distribution samples and adversarial attacks. En *Advances in Neural Information Processing Systems (NeurIPS)*, 31.

[9] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 4765–4774.

[10] Ma, N., Zhang, X., Zheng, H.-T., & Sun, J. (2018). ShuffleNet V2: Practical guidelines for efficient CNN architecture design. En *Proceedings of the European Conference on Computer Vision (ECCV)* (pp. 116–131).

[11] Ministerio de Agricultura y Ganadería (MAG). (2023). *Anuario de Estadísticas Agropecuarias y Seguridad Alimentaria en El Salvador 2022-2023*. San Salvador: MAG / Dirección General de Economía Agropecuaria.

[12] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)* (pp. 2623–2631).

[13] Ren, J., et al. (2025). Mahalanobis++: Improving OOD detection via feature normalization. *arXiv preprint arXiv:2505.18032*.

[14] Ren, J., Fort, S., Liu, J., Roy, A. G., Padhy, S., & Lakshminarayanan, B. (2021). A simple fix to Mahalanobis distance for improving near-OOD detection. *arXiv preprint arXiv:2106.09022*.

[15] Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. En *ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)* (pp. 1135–1144).

[16] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 618–626).

[17] Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. En *International Conference on Machine Learning (ICML)* (pp. 6105–6114).

GLOSARIO DE TÉRMINOS

Clever Hans Effect: Fenómeno en el cual un modelo de aprendizaje automático alcanza una aparente alta precisión apoyándose en correlaciones espurias o atajos del entorno (fondos, sensores, marcas de agua) en lugar de las características intrínsecas de la clase.

Cosine Annealing: Esquema de planificación de tasa de aprendizaje que reduce gradualmente el paso de optimización siguiendo la curva de un coseno hasta un mínimo establecido, facilitando que el optimizador escape de mínimos locales.

Disparate Impact Ratio (DIR): Métrica de equidad algorítmica que cuantifica el cociente entre la tasa favorable del grupo minoritario y la del grupo mayoritario. Un valor inferior a 0.80 denota sesgo o trato dispar regulatorio.

Edge AI: Paradigma de inteligencia artificial donde los modelos entrenados se ejecutan directamente en hardware local (dispositivos móviles, microcontroladores) sin enviar datos a servidores en la nube.

Macro F_1-Score: Media aritmética no ponderada del valor F_1 calculado independientemente para cada clase. Asigna el mismo peso relativo a clases minoritarias y mayoritarias, siendo la métrica estándar ante conjuntos desbalanceados.

MLOps (Machine Learning Operations): Conjunto de prácticas de ingeniería de software destinadas a automatizar, versionar y garantizar la reproducibilidad y monitoreo de pipelines de aprendizaje automático en producción.

Necrosis Letal del Maíz (MLN): Complejo viral devastador provocado por la coinfección sinérgica del virus del moteado clorótico del maíz (MCMV) y un potyvirus (como SCMV), capaz de destruir el 100 % de una plantación.

Out-of-Distribution (OOD): Condición que presentan aquellas muestras alimentadas a un clasificador cuyas características estadísticas provienen de una distribución ajena a la utilizada durante el entrenamiento (ej. fotografiar una piedra o una mano frente a un modelo de hojas).

Post-Training Quantization (PTQ): Técnica de optimización que convierte los pesos y activaciones de una red neuronal entrenada en coma flotante (FP32) a enteros de precisión reducida (Int8), disminuyendo el tamaño del modelo y la latencia en CPU.

Soft Voting: Mecanismo de ensamble multimodelo que promedia las probabilidades continuas asignadas por cada red individual mediante la función Softmax, seleccionando la clase con el máximo consenso medio.

ANEXOS

Anexo A: Registro de Enlaces y Repositorios Abiertos del Proyecto

El código fuente íntegro, los pesos exportados, los pipelines de entrenamiento y los artefactos de evaluación de **DoctorMaiz** se encuentran públicamente accesibles bajo licencias de código abierto:

- **Clasificador (*pipeline* de entrenamiento, evaluación y exportación):**

  `https://github.com/daiv05/maize-doctor-classifier`

- **Aplicación móvil DoctorMaiz (React Native, inferencia *offline*):**

  `https://github.com/Edenilson-Molina/maize-doctor-app`

- **Segmentador foliar (detección y segmentación de instancias de hoja):**

  `https://github.com/abner-rivas/maize-doctor-segmenter-leaf`

- **API (cuenta de usuario, sincronización opcional y avisos de actualización):**

  `https://github.com/daiv05/maize-doctor-api`

- **Sitio web y documentación técnica:**

  `https://doctor-maiz.deras.dev/es`

- **Dataset consolidado en Hugging Face:**

  `https://huggingface.co/datasets/daiv05/corn-leaf-diseases-pests-and-deficiencies`

- **Artefactos de evaluación y modelos exportados:**

  `https://drive.google.com/drive/folders/1OeZdWggfp7nVkaYHW_oOuCma5xbwhns6?usp=drive_link`

Anexo B: Inventario Criptográfico de Checkpoints Respaldados

La Tabla 3.10 detalla los hashes SHA-256 de los principales checkpoints físicos que sustentan la reproducibilidad de la tesina.

Tabla 3.10: Hashes SHA-256 de los pesos físicos de los modelos respaldados

Modelo / Protocolo	**Tamaño**	**Hash SHA-256 del Checkpoint (`best.pth`)**
EfficientNet-Lite0 Base (42, oficial)	12.92 MB	`860180f33bf1749ffee9f3cccb9569a4 7afd9ca0fcef52713e18f99f82a57859`
EfficientNet-Lite0 Int8 (Móvil, `model_int8.tflite`)	3.56 MB	`0a77ad7937f73e24b795288c68741d14 dd00226ffe546d5ddf5b99125fbef24d`
EfficientNet-B0 Referencia	16.36 MB	Pendiente de verificación
ShuffleNet-V2-x1.0 Referencia	5.2 MB	Pendiente de verificación