UNIVERSIDAD DE EL SALVADOR

FACULTAD DE INGENIERÍA Y ARQUITECTURA

ESCUELA DE INGENIERÍA DE SISTEMAS INFORMÁTICOS

CURSO DE ESPECIALIZACIÓN EN MACHINE LEARNING

DISEÑO E IMPLEMENTACIÓN DE DOCTOR MAÍZ: SISTEMA MÓVIL BASADO EN REDES NEURONALES CONVOLUCIONALES PARA LA IDENTIFICACIÓN FITOSANITARIA EN HOJAS DE MAÍZ Y CONTRIBUCIÓN A UN CONJUNTO DE DATOS NACIONAL

PRESENTADO POR:

JOSÍAS ABNER RIVAS FUENTES

DAVID ALEJANDRO DERAS CERROS

ELMER EDENILSON ROSALES MOLINA

PARA OPTAR AL TÍTULO DE:

INGENIERO(A) DE SISTEMAS INFORMÁTICOS

CIUDAD UNIVERSITARIA, 24 DE NOVIEMBRE DE 2026

UNIVERSIDAD DE EL SALVADOR

RECTOR:

MSC. JUAN ROSA QUINTANILLA

SECRETARIO GENERAL:

LCDO. PEDRO ROSALIO ESCOBAR CASTANEDA

FACULTAD DE INGENIERÍA Y ARQUITECTURA

DECANO:

MSC. LUIS SALVADOR BARRERA MANCÍA

SECRETARIO:

ARQ. RAÚL ALEXANDER FABIÁN ORELLANA

ESCUELA DE INGENIERIA DE SISTEMAS INFORMÁTICOS

DIRECTOR:

MSC. CESAR AUGUSTO GONZÁLEZ RODRÍGUEZ

UNIVERSIDAD DE EL SALVADOR

FACULTAD DE INGENIERIA Y ARQUITECTURA

ESCUELA DE INGENIERIA DE SISTEMAS INFORMÁTICOS

Trabajo de Graduación previo a la opción al Grado de:

INGENIERO (A) DE SISTEMAS INFORMÁTICOS

Título:

“DISEÑO E IMPLEMENTACIÓN DE DOCTOR MAÍZ: SISTEMA MÓVIL BASADO EN REDES NEURONALES CONVOLUCIONALES PARA LA IDENTIFICACIÓN FITOSANITARIA EN HOJAS DE MAÍZ Y CONTRIBUCIÓN A UN CONJUNTO DE DATOS NACIONAL”

Presentado por:

JOSÍAS ABNER RIVAS FUENTES

DAVID ALEJANDRO DERAS CERROS

ELMER EDENILSON ROSALES MOLINA

Trabajo de Graduación Aprobado por:

Docentes Asesores:

ING. BLADIMIR DIAZ CAMPOS

ING. KAREN ELVIRA PEÑATE AVILES

ING. RODRIGO ERNESTO VASQUEZ ESCALANTE

SAN SALVADOR, 24 DE NOVIEMBRE DE 2026

Trabajo de Graduación Aprobado por:

Docentes Asesores:

ING. BLADIMIR DIAZ CAMPOS

ING. KAREN ELVIRA PEÑATE AVILES

ING. RODRIGO ERNESTO VASQUEZ ESCALANTE

Agradecimientos

A Dios todopoderoso, por haberme concedido la perseverancia, la sabiduría y la fortaleza necesaria para afrontar cada desafío académico y culminar con éxito esta etapa de mi formación profesional.
A mi familia, cuyo respaldo incondicional, sacrificios silenciosos y constante motivación fueron el cimiento sobre el cual pude edificar cada meta. Gracias por creer en mí en todo instante.
A mis compañeros de tesis y amigos entrañables, David y Elmer, por las incontables jornadas de discusión técnica, investigación y programación. Su compromiso y esfuerzo conjunto hicieron posible que esta investigación trascendiera el aula para convertirse en un aporte tangible al agro salvadoreño.
A la Universidad de El Salvador y a cada docente de la Escuela de Ingeniería de Sistemas Informáticos, por transmitirme con rigor y vocación los principios científicos que hoy me capacitan como profesional al servicio de la sociedad.

Josias Abner Rivas Fuentes

Agradecimientos

A Dios, por darme salud, fortaleza y la oportunidad de llegar hasta este momento.
A mis padres y hermanos, por su apoyo, paciencia y confianza durante todo este proceso. Gracias por acompañarme y motivarme a seguir adelante, incluso en los momentos difíciles.
A mis compañeros de equipo, Josias y Elmer, por el esfuerzo, la dedicación y el compromiso que compartimos durante el desarrollo de este proyecto. Gracias por el trabajo en equipo, las experiencias y todo lo aprendido en el camino.
A nuestros profesores y asesores, por compartir sus conocimientos, orientarnos y brindarnos su apoyo durante nuestra formación académica y el desarrollo de este trabajo.

David Alejandro Deras Cerros

Agradecimientos

Agradezco profundamente al Todopoderoso, por su gracia inmerecida, sabiduría que me concedió y fortaleza para superar cada desafío a lo largo de este proceso de formación. A él atribuyo la gloria de haber culminado con éxito esta etapa de mi vida académica y profesional.

Además, expreso mi sincero agradecimiento a mis padres, por el apoyo incondicional que me han demostrado en pequeños y grandes detalles. Su motivación constante y su confianza en mis capacidades fueron actos de amor que me ayudaron a vencer el cansancio y me hicierón recordar mis objetivos.

A mis compañeros de graduación, Josias y David, por su amistad. El trabajo en equipo se volvió una experiencia enriquecedora, y el entusiasmo inagotable con el que enfrentamos este reto nos dejó un gran aprendizaje. Reconozco el talento y dedicación que mostraron, que hicieron de cada desafío una oportunidad de crecimiento.

A la gloriosa Universidad de El Salvador, alma mater de generaciones, por abrirme sus puertas y formarme con sentido crítico y compromiso social. A todo el cuerpo docente, por su dedicación y entrega en la formación de profesionales competentes y comprometidos con la sociedad.

Elmer Edenilson Rosales Molina

Resumen Ejecutivo

El maíz es la base de la alimentación de las familias campesinas de El Salvador, y la mayoría de los productores trabaja parcelas pequeñas con poca asistencia técnica. Las enfermedades foliares, las plagas y las deficiencias nutricionales reducen el rendimiento si no se detectan a tiempo. Las herramientas de diagnóstico por visión artificial suelen exigir conexión a internet o teléfonos potentes, o fallan con fotografías distintas a las del entrenamiento.

Esta investigación presenta **Doctor Maíz**, una aplicación móvil que clasifica nueve condiciones de la hoja de maíz (enfermedades, una plaga y deficiencias nutricionales) con una red convolucional que se ejecuta en el propio teléfono, sin conexión. Incluye un marco guía para la captura, un detector de imágenes fuera de distribución (*Out-of-Distribution*, OOD) y un módulo opcional para aportar fotografías a un conjunto de datos nacional.

Se reunió un corpus de **33 429 imágenes** de 11 repositorios internacionales, con control de integridad, revisión de duplicados y registro de la procedencia. El modelo oficial es un modelo EfficientNet-Lite0, que obtuvo un Macro F_1 de **0.9480** y una exactitud de 97.81 % en 5 015 imágenes de prueba ($0{,}9435 \pm 0{,}0052$ con tres semillas). La búsqueda de hiperparámetros con Optuna quedó como experimento complementario al no superar ese resultado en prueba, y un ensamble de tres redes (0.9567) se conservó como referencia.

La principal limitación es la generalización. En fotografías de campo ajenas al corpus el modelo acertó 41 (42 %) y el detector rechazó 49. La validación agrupada por fuente dio un Macro F_1 de $0{,}6026 \pm 0{,}1240$, frente a $0{,}9311 \pm 0{,}0099$ en la partición estratificada. La ablación espacial indica que el modelo se apoya en la periferia de la imagen: la exactitud fue de 79.46 % al ocluir el centro y de 42.25 % al ocluir la periferia.

El modelo se cuantizó a enteros de 8 bits (Int8) y pesa **3.74 MB**, 72.9 % menos que en coma flotante, con un Macro F_1 de 0.9489 en la prueba completa. En un Motorola edge 40 neo con Android 15, las medianas fueron de 98 ms de preprocesado y 23 ms de inferencia. Solo la sincronización de aportes requiere conexión. Se proponen cinco recomendaciones al Ministerio de Agricultura y Ganadería (MAG) y al CENTA: validación en campo, un banco nacional de datos, una red de alerta fitosanitaria, capacitación comunitaria y software abierto.

Índice general

1 Especificación del Proyecto **1**

1.1 Situación Actual . . . 1

1.1.1 Antecedentes . . . 1

1.1.2 Descripción del problema . . . 2

1.1.3 Planteamiento del problema . . . 2

1.2 Objetivos . . . 3

1.2.1 Objetivo General . . . 3

1.2.2 Objetivos Específicos . . . 3

1.3 Alcance y Límites del Proyecto . . . 4

1.3.1 Alcance del Proyecto . . . 4

1.3.2 Límites del Proyecto . . . 5

1.4 Hipótesis . . . 6

1.4.1 Hipótesis General . . . 6

1.4.2 Criterios de Éxito Específicos . . . 6

1.5 Justificación . . . 6

1.5.1 Justificación Técnica y Metodológica . . . 6

1.5.2 Justificación Económica . . . 7

1.5.3 Justificación Social y Ambiental . . . 7

1.5.4 Justificación Académica e Institucional . . . 7

1.6 Cronograma de Actividades . . . 7

1.7 Presupuesto Global Estimado . . . 9

2 Análisis y Diseño de la Solución **11**

2.1 Trazabilidad de los Datos . . . 11

2.2 Condiciones Agronómicas Objetivo . . . 11

2.3 Recopilación, Depuración y Auditoría de Datos . . . 14

2.3.1 Análisis Exploratorio . . . 14

2.3.2 Auditoría de Duplicados y Partición . . . 16

2.4 Arquitecturas y Búsqueda de Hiperparámetros . . . 16

2.4.1 Familias Convolucionales Seleccionadas . . . 16

2.4.2 Espacio de Búsqueda y Poda Temprana 16
2.4.3 Ensamble Multimodelo por Soft Voting 17
2.5 Despliegue en Dispositivo Móvil 17
2.5.1 Cuantización a Enteros de 8 Bits (Int8) 17
2.5.2 Detector de Anomalías Fuera de Distribución (OOD) 17
2.5.3 Mitigación en la Interfaz 18
2.6 Sincronización y Aportes al Conjunto de Datos 18
2.7 Arquitectura General del Sistema 19

3 Estrategia de Implementación y Análisis de Resultados 21
3.1 Estrategia y Entorno de Implementación 21
3.1.1 Infraestructura de Cómputo y Entrenamiento en la Nube 21
3.2 Resultados 22
3.2.1 Búsqueda bayesiana de hiperparámetros con poda 22
3.2.2 Rendimiento del modelo: generalización entre fuentes 24
3.2.3 Rendimiento del modelo: fotografías de campo externas 25
3.2.4 Capacidades del diagnóstico: equidad entre entornos 26
3.2.5 Capacidades del diagnóstico: dependencia del fondo 27
3.2.6 Solución integral: prototipo en hardware real 29
3.2.7 Resultado exploratorio: ensamble de la etapa 2 (no desplegado) 32

Conclusiones y Recomendaciones 35

Bibliografía 38

Glosario de Términos 40

Anexos 41

Índice de tablas

1.1 Criterios de éxito del proyecto 6
1.2 Cronograma de actividades por fase (CRISP-DM), con horas por integrante 8
1.3 Presupuesto del proyecto (USD) 9

2.1 Taxonomía agronómica de las nueve clases integradas en DoctorMaiz 12
2.2 Fuentes de datos recopiladas, licencia declarada y distribución de muestras 14
2.3 Espacio de búsqueda de hiperparámetros explorado con Optuna 17
2.4 Tecnologías principales por proyecto 19

3.1 Estado de los criterios de éxito al cierre de esta versión 22
3.2 Comparativa cuantitativa: Baseline sin Optuna vs. Configuración Optimizada (Optuna) . . . 23
3.3 Resultados del experimento cruzado 2×2 de validación cruzada en 5 pliegues 24
3.4 Evaluación LOSO con tres semillas: Macro F_1 y exactitud en la fuente retenida 25
3.5 Aciertos del modelo oficial en fotografías de campo externas, por clase 25
3.6 Tasa de falsos negativos (FNR) desagregada por clase y entorno, checkpoint de la etapa 2 . 27
3.7 Auditoría de ablación espacial con control nulo en el conjunto de prueba, checkpoint de la etapa 2 27
3.8 Latencias medianas en hardware físico (Motorola edge 40 neo) 29
3.9 Desempeño del ensamble frente a modelos individuales en la prueba de la etapa 2 (corpus de 33 433 imágenes, 5 015 de prueba) 33
3.10 Desglose de F_1 por clase en la prueba de la etapa 2 (corpus de 33 433 imágenes; Lite0 `20260812_221429`) 34

Índice de figuras

1.1 Modelo conceptual de caja negra para el diagnóstico fitosanitario móvil. 3
1.2 Diagrama de Gantt del cronograma planificado (Metodología CRISP-DM) 8

2.1 Catálogo fotográfico de las nueve clases agronómicas presentes en el corpus. 13
2.2 Distribución del corpus por clase y por entorno de captura. 15
2.3 Distribución de imágenes por clase y fuente de origen. 15
2.4 Flujo de sincronización de un aporte. 19
2.5 Arquitectura del sistema DoctorMaiz. 20

3.1 Curvas de convergencia: Pérdida y Macro F_1 durante el entrenamiento en Modal. 21
3.2 Dinámica de exploración e impacto relativo de variables en Optuna. 23
3.3 Impacto de la partición frente a la optimización algorítmica. 24
3.4 Auditoría de equidad e imparcialidad entre condiciones fotográficas. 26
3.5 Exactitud según la región geométrica visible frente al azar nulo. 27
3.6 Mapas de activación Grad-CAM en muestras de campo real y laboratorio. 28
3.7 Panel comparado de explicabilidad local: LIME, SHAP y Grad-CAM. 29
3.8 Flujo principal de la aplicación móvil nativa DoctorMaiz. 31
3.9 Mecanismos de seguridad, participación comunitaria y escalas agronómicas. 32
3.10 Comparativa de desempeño del ensamble frente a modelos individuales. 33
3.11 Matriz de confusión normalizada del ensamble sobre 5 015 muestras de prueba. 34

CAPÍTULO 1

ESPECIFICACIÓN DEL PROYECTO

1.1. Situación Actual

1.1.1. Antecedentes

La agricultura representa el 5.6 % del Producto Interno Bruto (PIB) de El Salvador [2] y sostiene de forma directa a más de dos millones de personas en el sector rural. Para las familias campesinas salvadoreñas, el maíz (*Zea mays L.*) constituye la base diaria de la alimentación familiar, con un consumo promedio reportado que supera los 115 kilogramos por persona al año [3]. De acuerdo con registros oficiales del Ministerio de Agricultura y Ganadería [16], el 82.1 % de los productores nacionales trabajan pequeñas parcelas familiares menores a dos manzanas (1.4 hectáreas), bajo un régimen de agricultura de subsistencia dependiente casi por completo del régimen de lluvias estacionales.

En los últimos años esta producción ha quedado más expuesta a anomalías climáticas y a problemas fitosanitarios [16]. En una milpa con estrés hídrico o térmico también aparecen enfermedades foliares y plagas, y si una infección o un ataque no se atiende a tiempo, reduce el llenado del grano y el rendimiento de la cosecha [3]. Para un hogar que vive de su parcela, esa pérdida afecta directamente su alimentación.

Pese a esa importancia, el efecto de los problemas fitosanitarios sobre la producción nacional no está cuantificado, la información pública disponible no permite estimar cuánto maíz pierde El Salvador por enfermedades foliares, plagas o deficiencias nutricionales. Las pérdidas recientes mejor documentadas son de origen climático: en el ciclo 2023-2024 se reportaron unos 1.46 millones de quintales perdidos, el 9.8 % de los 14.9 millones producidos, con más de 24 % en cada departamento del oriente [8], y en el ciclo 2024-2025 la cosecha fue de 10.9 millones de quintales frente a 18.8 millones requeridos [6]. En el frente fitosanitario solo se dispone de evidencias puntuales: en un ensayo de híbridos del CENTA, los tres sitios con presión de mancha de asfalto rindieron cerca de 51 % menos que los sitios sin la enfermedad [5], y en un ensayo de 2017 en La Libertad el control optimizado de plagas y enfermedades elevó el rendimiento 15 % pero redujo la utilidad neta en US$395 por hectárea [7].

Esa falta de cifras es parte del problema y también afectó a este proyecto, porque sin un registro de diagnósticos nadie puede decir qué enfermedades predominan en cada zona ni cuánto cuestan, y el productor decide sin referencia; el ensayo de La Libertad muestra que tratar no siempre compensa el gasto. Con los datos para entrenar un modelo ocurre lo mismo. El corpus reúne 33 429 imágenes de 11 repositorios internacionales y ninguna fotografía salvadoreña etiquetada. La misma carencia impidió estimar el ahorro económico que el diagnóstico podría producir. Por eso la aplicación incluye un módulo de aportes voluntarios con el que podría formarse, con el tiempo, el registro que hoy falta.

1.1.2. Descripción del problema

En las parcelas rurales salvadoreñas no hay laboratorios cercanos, y el diagnóstico se hace a simple vista, el agricultor observa las manchas o el marchitamiento de la hoja e intenta reconocer la causa. Los casos más difíciles son el tizón foliar, la mancha gris, la roya común, el gusano cogollero, la necrosis letal del maíz y las deficiencias de nitrógeno, fósforo y potasio (Tabla 2.1), cuyos síntomas se confunden entre sí y con los de otros hongos o virus.

La asistencia técnica pública no alcanza para cubrir esa necesidad, hay pocos extensionistas para el número de productores dispersos en la zona rural, y una visita agronómica puede tardar semanas o no llegar mientras la infección avanza [3].

Ante el riesgo de perder la siembra, el agricultor suele acudir a un agroservicio, y sin un diagnóstico de por medio, la recomendación tiende a ser un agroquímico de amplio espectro, aun cuando los síntomas se deben a una deficiencia nutricional del suelo, entonces el productor paga por un producto que no resuelve el problema, se aplican químicos de más y el tratamiento adecuado se retrasa [3].

1.1.3. Planteamiento del problema

La extensión agronómica no alcanza a cubrir a los pequeños productores de maíz, y las herramientas digitales disponibles se diseñaron para condiciones distintas a las del campo salvadoreño. Las aplicaciones de diagnóstico por visión artificial suelen tener estas limitaciones:

1. **Dependen de la conexión.** La mayoría envía la fotografía a un servidor para procesarla. En muchas zonas rurales la cobertura celular es inestable o nula y los agricultores no tienen un plan de datos, de modo que la herramienta no funciona en la parcela.

2. **Exigen teléfonos potentes.** Los modelos de aprendizaje profundo convencionales necesitan más memoria y cómputo de los que ofrecen los teléfonos de gama de entrada que usan las familias campesinas. El resultado son bloqueos, esperas largas y un consumo alto de batería.

3. **Fallan con fotografías de campo.** Se entrenaron sobre todo con imágenes de laboratorio, con fondo neutro y luz pareja. En la milpa aparecen suelo, sombras, maleza y contraluz, y el modelo se equivoca con frecuencia y con una confianza alta [1].

De ahí surge la pregunta de investigación:

> *¿En qué medida puede una aplicación móvil que funciona sin conexión, en teléfonos de gama baja o media, identificar problemas fitosanitarios en fotografías de hojas de maíz tomadas en campo, abstenerse cuando la imagen no es confiable y orientar al agricultor salvadoreño sobre el manejo de su cultivo?*

Modelo conceptual de caja negra del sistema

Para delimitar el problema el sistema se representa como una caja negra (Figura 1.1). Las entradas son las condiciones y restricciones del entorno, las salidas son los resultados que el sistema debe producir, y el proceso intermedio es el objeto de estudio de esta investigación.

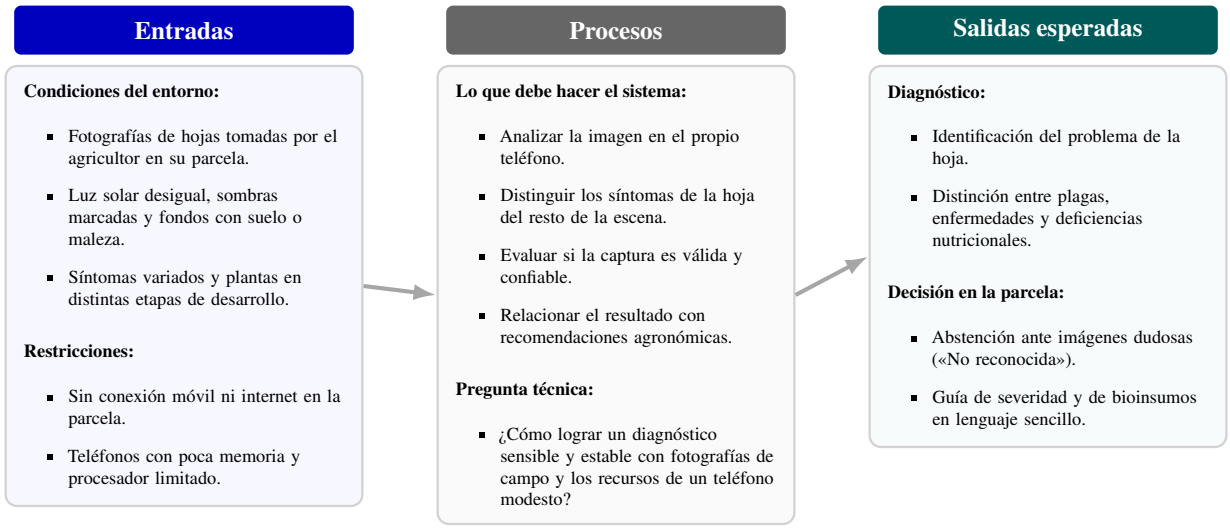


Figura 1.1: Modelo conceptual de caja negra para el diagnóstico fitosanitario móvil.

1.2. Objetivos

1.2.1. Objetivo General

Desarrollar y evaluar un sistema de visión artificial para el diagnóstico fitosanitario de la hoja de maíz en El Salvador, integrado en una aplicación móvil que funcione sin conexión (*Edge AI*) en teléfonos de gama baja o media, con alta sensibilidad y baja latencia.

1.2.2. Objetivos Específicos

1. Reunir y depurar un corpus de imágenes de la hoja de maíz en nueve condiciones agronómicas a partir de repositorios públicos, con controles verificables que descarten duplicados y eviten que una misma imagen aparezca en más de una partición.

2. Ajustar arquitecturas convolucionales ligeras preentrenadas mediante búsqueda bayesiana de hiperparámetros (Optuna) con poda temprana, y comprobar si mejoran el Macro F_1 de la configuración inicial sin un gasto excesivo de GPU.

3. Evaluar un ensamble por votación suave (*Soft Voting*) de modelos con arquitecturas distintas, para

medir si aumenta la sensibilidad en las enfermedades más graves y en las clases con menos imágenes.

4. Evaluar el sistema con una validación que separe las fuentes de entrenamiento y de evaluación, medir la diferencia de desempeño entre imágenes de laboratorio y de campo, y analizar en qué regiones de la imagen se apoya el modelo mediante explicabilidad y ablación espacial.
5. Cuantizar el modelo a enteros de 8 bits (Int8), integrarlo en una aplicación móvil con ayudas para la captura y un mecanismo de rechazo de imágenes no válidas, y medir su exactitud y su latencia en teléfonos de gama baja o media.
6. Formular recomendaciones al Ministerio de Agricultura y Ganadería (MAG) y al CENTA sobre las condiciones para incorporar la herramienta al acompañamiento técnico de los pequeños productores de maíz.

1.3. Alcance y Límites del Proyecto

1.3.1. Alcance del Proyecto

El proyecto abarca el diseño, el desarrollo y la evaluación de una herramienta de diagnóstico fitosanitario para los pequeños productores de maíz en El Salvador. Tiene dos componentes: la aplicación móvil que usa el agricultor y el modelo de visión artificial que se ejecuta dentro de ella.

Alcance de la Aplicación Móvil (DoctorMaiz)

La aplicación incluye:

- **Diagnóstico sin conexión.** El modelo cuantizado se ejecuta en el procesador del teléfono, sin internet ni datos móviles.
- **Captura con marco guía.** La cámara muestra un marco con la silueta de la hoja para que el agricultor la encuadre y deje fuera la mayor parte del suelo, las sombras y la maleza.
- **Rechazo de imágenes dudosas.** Si la captura no parece una hoja de maíz o el modelo no está seguro, la aplicación muestra «No reconocida» en lugar de un diagnóstico.
- **Resultado y guía de severidad.** El resultado se presenta en lenguaje sencillo, con una guía visual de tres niveles (baja, moderada y crítica) que el productor compara con su hoja, la aplicación no mide el daño.
- **Recomendaciones de manejo.** Para cada diagnóstico se ofrecen alternativas de bioinsumos y de manejo cultural de bajo costo.

- **Historial.** Cada evaluación se guarda en el teléfono con fecha, diagnóstico, severidad y ubicación GPS, para que el agricultor siga la evolución de su parcela durante el ciclo.
- **Aportes voluntarios.** El usuario puede guardar fotografías en el teléfono y enviarlas cuando tenga conexión, con fines de monitoreo fitosanitario colectivo.

Alcance del Componente de Inteligencia Artificial

El componente de inteligencia artificial abarca:

- **Nueve clases.** Tres enfermedades causadas por hongos (tizón foliar, mancha gris y roya común), una virosis (necrosis letal del maíz), una plaga (gusano cogollero), tres deficiencias nutricionales (nitrógeno, fósforo y potasio) y la hoja sana.
- **Entrenamiento y exportación.** Búsqueda de hiperparámetros con Optuna y poda temprana, un ensamble por votación suave (*Soft Voting*) y cuantización a 8 bits en formato TensorFlow Lite con litert-torch, con una meta de 300 ms o menos para preprocesado e inferencia en el teléfono.
- **Evaluación de sesgos.** Validación cruzada agrupada por procedencia (*SourceGroupedKFold*) y ablación espacial, para detectar si el modelo se apoya en atajos visuales del fondo (efecto *Clever Hans*).

1.3.2. Límites del Proyecto

El proyecto tiene los siguientes límites:

- **Solo la hoja.** El sistema analiza síntomas visibles en la lámina de la hoja. No cubre enfermedades de la raíz, daños internos del tallo sin síntomas en la hoja ni plagas del suelo.
- **Solo Android.** La aplicación requiere Android 7.0 (API 24) o superior, procesador ARM (v7 o v8), cámara trasera con enfoque automático y al menos 4 GB de RAM. Las pruebas en dispositivo se hicieron en Android 15. No hay versión para iOS ni para teléfonos que no sean inteligentes.
- **Sin dependencia de la nube.** El diagnóstico no usa servicios en la nube, y no hay sincronización en tiempo real entre varios teléfonos.
- **Herramienta de orientación.** La aplicación orienta al productor, pero no reemplaza los análisis de laboratorio, ni los dictámenes oficiales de cuarentena o certificación fitosanitaria del MAG.
- **Clases y evidencia de campo.** El corpus procede de 11 repositorios públicos internacionales.

1.4. Hipótesis

1.4.1. Hipótesis General

Un modelo convolucional ligero, cuantizado a enteros de 8 bits y ejecutado sin conexión en un teléfono de gama baja o media, puede clasificar nueve condiciones de la hoja de maíz con un Macro F_1 de al menos 0.85 en una partición de prueba retenida, con 300 ms o menos de preprocesado e inferencia y con un desempeño comparable entre imágenes de laboratorio y de campo. La hipótesis se considera aceptada si se cumplen los criterios de la Tabla 1.1.

1.4.2. Criterios de Éxito Específicos

Tabla 1.1: Criterios de éxito del proyecto

Tema	**Criterio y umbral**	**Métrica**
Rendimiento del modelo	Alcanzar Macro $F_1 \geq 0{,}85$ en la partición de prueba retenida.	Macro F_1
Capacidades del diagnóstico	Mantener un *Disparate Impact Ratio* $\geq 0{,}80$ entre laboratorio y campo real.	DIR
Confiabilidad de la evaluación	Ninguna imagen del conjunto de prueba aparece en entrenamiento ni validación, por hash de archivo y por píxeles.	Solapamiento por SHA-256 y por píxeles
Solución integral	Modelo Int8 de 20 MB o menos, preprocesado e inferencia de 300 ms o menos en un teléfono de gama media o baja y funcionamiento sin conexión.	Tamaño, latencia

1.5. Justificación

1.5.1. Justificación Técnica y Metodológica

La mayoría de los sistemas de diagnóstico foliar por visión artificial procesan la imagen en un servidor, lo que exige conexión en el momento de usarlos. Este proyecto ejecuta el modelo en el propio teléfono (*Edge AI*), con arquitecturas convolucionales diseñadas para dispositivos móviles [9, 22] y cuantización a enteros de 8 bits, que reduce el tamaño del modelo y el costo de cada inferencia [11].

En la visión por computadora aplicada a la agricultura, muchos modelos se evalúan con particiones aleatorias de un mismo repositorio. Con ese esquema, imágenes muy parecidas o tomadas en las mismas condiciones quedan a ambos lados de la partición, y el modelo puede apoyarse en el fondo o en la cámara en lugar de la lesión [1]. Por eso el proyecto incorpora una auditoría de duplicados, una validación que separa las fuentes de entrenamiento y de evaluación, mapas de activación para revisar en qué regiones se

apoya el modelo [21] y un detector que evita diagnosticar imágenes que no corresponden a una hoja de maíz [12].

1.5.2. Justificación Económica

La mayoría de los productores de maíz trabaja parcelas pequeñas con márgenes estrechos [16], de modo que un gasto mal dirigido pesa en la economía del hogar. Un diagnóstico equivocado puede llevar a comprar un agroquímico que no corresponde, por ejemplo un fungicida para lo que en realidad es una deficiencia nutricional, y el ensayo de La Libertad muestra que incluso un control de plagas y enfermedades bien aplicado puede reducir la utilidad neta [7]. Una aplicación gratuita que funciona en el teléfono del agricultor orienta esa decisión antes de la compra y ayuda a actuar a tiempo contra plagas como el gusano cogollero (*Spodoptera frugiperda*) [3].

1.5.3. Justificación Social y Ambiental

Muchas comunidades rurales tienen poco acceso a apoyo agronómico presencial [3]. Una herramienta que funciona sin conexión en un teléfono de gama baja o media pone información técnica al alcance del productor en su parcela, en un lenguaje que puede entender sin formación especializada. En lo ambiental, un diagnóstico más preciso favorece un mejor manejo de plagas y puede reducir la aplicación de pesticidas cuando no hacen falta.

1.5.4. Justificación Académica e Institucional

Para la Escuela de Ingeniería de Sistemas Informáticos de la Universidad de El Salvador, el proyecto aplica el aprendizaje profundo embebido a un problema del agro nacional y deja disponibles el código, el corpus consolidado y los modelos. Además, documenta un procedimiento de evaluación (auditoría de duplicados, validación por fuente y análisis de la dependencia del fondo) que puede reutilizarse en otros sistemas de visión artificial con poca capacidad de cómputo y conectividad limitada.

1.6. Cronograma de Actividades

El proyecto se organizó según las fases de *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*), con una fase adicional para el desarrollo de la aplicación móvil. Abarca 32 semanas, del 14 de abril al 24 de noviembre de 2026. La Figura 1.2 muestra el diagrama de Gantt y la Tabla 1.2 detalla la duración, las horas y el entregable de cada fase.

Figura 1.2: Diagrama de Gantt del cronograma planificado (Metodología CRISP-DM)

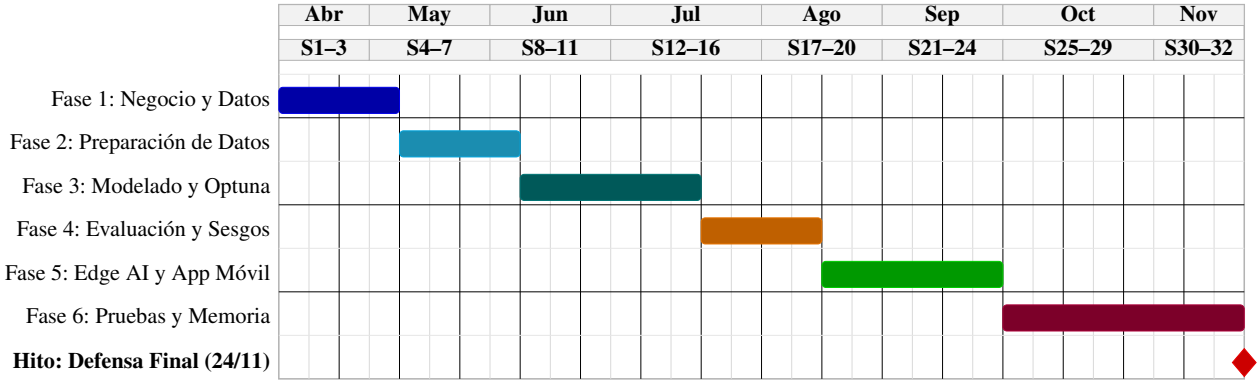


Tabla 1.2: Cronograma de actividades por fase (CRISP-DM), con horas por integrante

Fase	Inicio	Fin	Semanas	Horas	Entregable principal
Fase 1: Comprensión del negocio y de los datos	14/04/26	12/05/26	4	40 h	Requisitos fitosanitarios y selección de repositorios públicos.
Fase 2: Preparación de datos	12/05/26	09/06/26	4	40 h	Corpus consolidado, auditoría de duplicados, balanceo y aumento de datos.
Fase 3: Modelado	09/06/26	21/07/26	6	60 h	Modelos ligeros con transferencia de aprendizaje y búsqueda de hiperparámetros.
Fase 4: Evaluación	21/07/26	18/08/26	4	40 h	Comparación de modelos, evaluación por fuente y en campo, y análisis de explicabilidad.
Fase 5: Despliegue y aplicación móvil	18/08/26	29/09/26	6	60 h	Modelo cuantizado a Int8 y aplicación móvil con inferencia local.
Fase 6: Pruebas finales y memoria	29/09/26	24/11/26	8	80 h	Pruebas en dispositivo físico, memoria técnica y defensa.
Defensa del proyecto	**24 de noviembre de 2026**		**32**	**320 h**	**Sistema DoctorMaiz y memoria final**

1.7. Presupuesto Global Estimado

El presupuesto se organiza en cuatro rubros: el recurso humano, el entrenamiento de los modelos, la inferencia y el despliegue (Tabla 1.3).

Tabla 1.3: Presupuesto del proyecto (USD)

Rubro	**Detalle**	**Costo**
Recurso humano		
Ingeniero de Datos / MLOps	320 h	$3,380.77
Investigador de Deep Learning	320 h	$3,056.53
Desarrollador Móvil Edge AI	320 h	$2,840.39
Entrenamiento		
GPU NVIDIA A10G en Modal	Modelos de referencia, entrenamiento principal, búsqueda de hiperparámetros y experimentos de validación	$250.00
Inferencia		
Inferencia en el teléfono	Sin servidor de inferencia	$0.00
Dispositivo de prueba	Motorola edge 40 neo, aportado por un integrante	$0.00
Despliegue (agosto a noviembre de 2026)		
Servidor Hetzner	API, base de datos y sitio web; $6.00 al mes durante 4 meses	$24.00
Volumen Hetzner de 100 GB	Fotografías aportadas y respaldos; $7.67 al mes durante 4 meses	$30.68
Dominio	Registro anual	$12.00
Distribución	APK en GitHub Releases, dataset en Hugging Face	$0.00
Total		**$9,594.37**

Recurso humano

Los salarios mensuales de referencia ($1,500, $1,350 y $1,250) son el punto medio de la escala del sector público salvadoreño para perfiles equivalentes. Se estimó una dedicación de 2 horas diarias de lunes a viernes por integrante (10 horas semanales), que suman 320 horas en las 32 semanas del cronograma (Tabla 1.2). Eso equivale a 1.85 meses de jornada completa, y el salario se prorrateó en esa proporción. Los montos incluyen las prestaciones de ley.

Entrenamiento

Todo el entrenamiento se ejecutó en GPU NVIDIA A10G de la plataforma Modal, con un presupuesto de $250 en créditos. Ese monto cubrió los modelos de referencia de la primera etapa, el entrenamiento del modelo oficial, la búsqueda de hiperparámetros con Optuna (12.65 horas de GPU, $13.92) y los experimentos de validación por fuente, con varias semillas y de explicabilidad. El entrenamiento es un costo de una sola vez: una vez exportado, el modelo no requiere más GPU.

Inferencia

El modelo se ejecuta en el procesador del teléfono, de modo que cada diagnóstico no tiene costo de servidor ni consume datos móviles. El costo de inferencia no crece con el número de usuarios, lo que hace viable distribuir la aplicación de forma gratuita. Las pruebas en dispositivo se hicieron con un teléfono de gama media propiedad de un integrante del equipo.

Despliegue y operación

La API de sincronización, su base de datos y el sitio web del proyecto comparten un servidor en Hetzner, con un volumen adicional de 100 GB para las fotografías aportadas por los usuarios. El APK se compila y publica en GitHub Releases mediante GitHub Actions, y el corpus consolidado se distribuye en Hugging Face, ambos sin costo. Mantener el sistema en operación cuesta $176.04 al año ($72.00 de servidor, $92.04 de volumen y $12.00 de dominio).

CAPÍTULO 2

ANÁLISIS Y DISEÑO DE LA SOLUCIÓN

2.1. Trazabilidad de los Datos

Cada imagen del corpus tiene un registro con un identificador único, la huella SHA-256 del archivo, la fuente de la que proviene y el entorno de captura (laboratorio o campo). El identificador se calcula a partir de la ruta de la imagen, de modo que una misma imagen conserva su identidad en cualquier ejecución. La huella permite detectar si un archivo cambió entre versiones del corpus, y la fuente y el entorno permiten formar las particiones agrupadas del Capítulo 3.

Las listas de entrenamiento, validación y prueba se guardaron con su propia huella, de modo que cada experimento puede comprobar que usa exactamente la misma partición. La ausencia de solapamientos entre particiones se verificó en la auditoría descrita más abajo.

2.2. Condiciones Agronómicas Objetivo

El sistema clasifica la hoja de maíz en nueve categorías mutuamente excluyentes (Tabla 2.1): tres enfermedades causadas por hongos, un complejo viral, una plaga, tres deficiencias nutricionales y la hoja sana.

Tabla 2.1: Taxonomía agronómica de las nueve clases integradas en DoctorMaiz

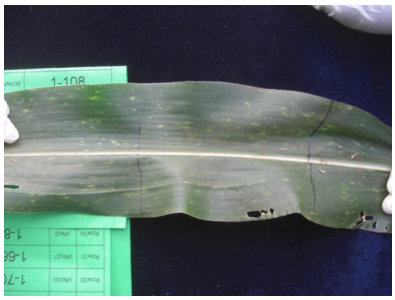
Clase Agronómica	**Agente Causal / Tipo**	**Síntoma Primario**	**Consecuencia en el cultivo**
Roya Común	*Puccinia sorghi* (Hongo)	Pústulas pulverulentas castaño-rojizas en ambas caras.	Reducción del área foliar activa.
Tizón Foliar (NCLB)	*Exserohilum turcicum* (Hongo)	Lesiones alargadas en forma de cigarro o huso (grises).	Necrosis de la lámina, con mayor daño si aparece antes de la floración.
Mancha Gris (GLS)	*Cercospora zeae-maydis* (Hongo)	Manchas rectangulares delimitadas por venas secundarias.	Destrucción del follaje y menor llenado del grano.
Necrosis Letal (MLN)	Complejo viral sinérgico (MCMV + Potyvirus)	Clorosis severa, moteado, necrosis marginal y secado total.	Secado prematuro de la planta y pérdida severa del rendimiento [15].
Gusano Cogollero	*Spodoptera frugiperda* (Plaga/Insecto)	Perforaciones irregulares y excrementos en el cogollo.	Daño al cogollo y al punto de crecimiento.
Deficiencia de Nitrógeno	Desbalance nutricional abiótico	Clorosis en “V” invertida desde la punta hacia la base.	Reducción de porte, espigas pequeñas y bajo llenado.
Deficiencia de Fósforo	Desbalance nutricional abiótico	Coloración púrpura o rojiza en bordes de hojas jóvenes.	Retraso radicular y esterilidad parcial de la mazorca.
Deficiencia de Potasio	Desbalance nutricional abiótico	Clorosis y necrosis marginal desde el ápice foliar.	Acame o volcamiento del tallo y grano liviano.
Planta Sana (Healthy)	Control agronómico	Lámina foliar verde homogénea sin lesiones ni plagas.	Crecimiento óptimo según potencial genético del cultivar.



a) Roya Común



b) Tizón Foliar



c) Mancha Gris



d) Necrosis Letal



e) Gusano Cogollero



f) Deficiencia N



g) Deficiencia P



h) Deficiencia K



i) Planta Sana

Figura 2.1: Catálogo fotográfico de las nueve clases agronómicas presentes en el corpus.

2.3. Recopilación, Depuración y Auditoría de Datos

El corpus final reúne **33 429 imágenes** de 11 fuentes públicas (Tabla 2.2).

Tabla 2.2: Fuentes de datos recopiladas, licencia declarada y distribución de muestras

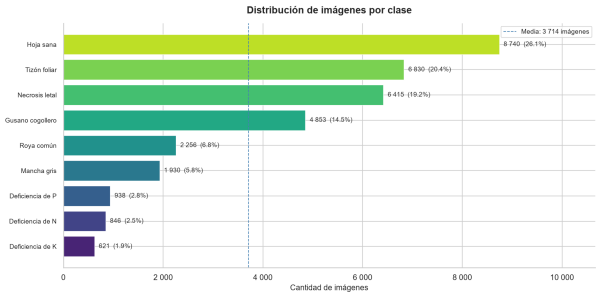
Identificador de Fuente (`source_id`)	**Licencia declarada**	**Muestras**	**Entorno**	**Clases aportadas**
`maize-beans-tomatoes-africa`	Apache 2.0 y CC	12 136	Campo real	4 clases.
`maize-diseases`	CC BY-NC-SA 4.0	6 989	Mixto	3 clases.
`multicrop-disease-maiz`	CC BY 4.0	5 816	Mixto	3 clases.
`corn-leaf-roboflow`	CC BY 4.0	2 919	Campo real	6 clases.
`cropdg-unified-multidomain`	CC BY-NC-SA 4.0	2 562	Mixto	3 clases.
`maize-in-field-dataset`	CC BY-NC-SA 4.0	852	Campo real	3 clases.
`maize-2-roboflow`	CC BY 4.0	846	Campo real	3 clases.
`corn-leaf-diseases-classification-roboflow`	CC BY 4.0	480	Mixto	1 clase.
`maize-nutrient-deficiency`	CC BY 4.0	340	Campo real	4 clases.
`maize-leaf-roboflow`	CC BY 4.0	331	Campo real	1 clase.
`maize-deficiency-scanner-roboflow`	CC BY 4.0	158	Campo real	3 clases de deficiencia.
Total	—	**33 429**	—	**9 clases agronómicas**

La licencia es la declarada por cada repositorio de origen.

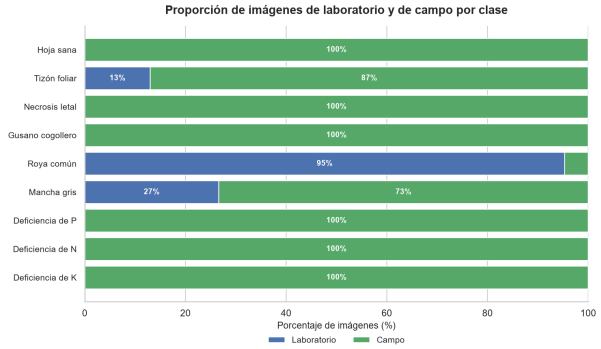
2.3.1. Análisis Exploratorio

El corpus está desbalanceado. La clase sana tiene cerca de 8 700 imágenes y el tizón foliar cerca de 6 800, mientras que la deficiencia de potasio tiene 621, una relación de 14.1:1 que antes de ampliar el corpus era de 32.9:1 (Figura 2.2). Las resoluciones también varían mucho y se agrupan en tres rangos: alrededor de 256 píxeles en las imágenes de laboratorio, alrededor de 640 en las de Roboflow y las deficiencias nutricionales, y entre 3 000 y 5 000 en varias fuentes de campo. Todas se reducen a 224×224 antes de entrar al modelo, de modo que las fotografías grandes pierden parte del detalle fino de las lesiones.
Solo tres clases tienen imágenes de laboratorio, tomadas sobre un fondo controlado: la roya común (95 % de sus imágenes, 2 150 de 2 256), la mancha gris (27 %) y el tizón foliar (13 %). Las otras seis clases son por completo de campo. En conjunto, el laboratorio aporta 3 551 imágenes, el 10.6 % del corpus. Esta composición condiciona la evaluación del Capítulo 3: la comparación entre laboratorio y campo solo

puede hacerse en esas tres clases, y la roya, con apenas 106 imágenes de campo, es la clase con más riesgo de fallar en campo.



a) Imágenes por clase.



b) Laboratorio y campo por clase.

Figura 2.2: Distribución del corpus por clase y por entorno de captura.

Además, la procedencia y la etiqueta están asociadas: varias fuentes aportan una sola clase, y una sola fuente, `maize-beans-tomatoes-africa`, aporta 12 136 imágenes, el 36.3 % del corpus (Figura 2.3). Con esa asociación, un modelo puede aprender rasgos propios de cada fuente, como el fondo o la cámara, además de la lesión.

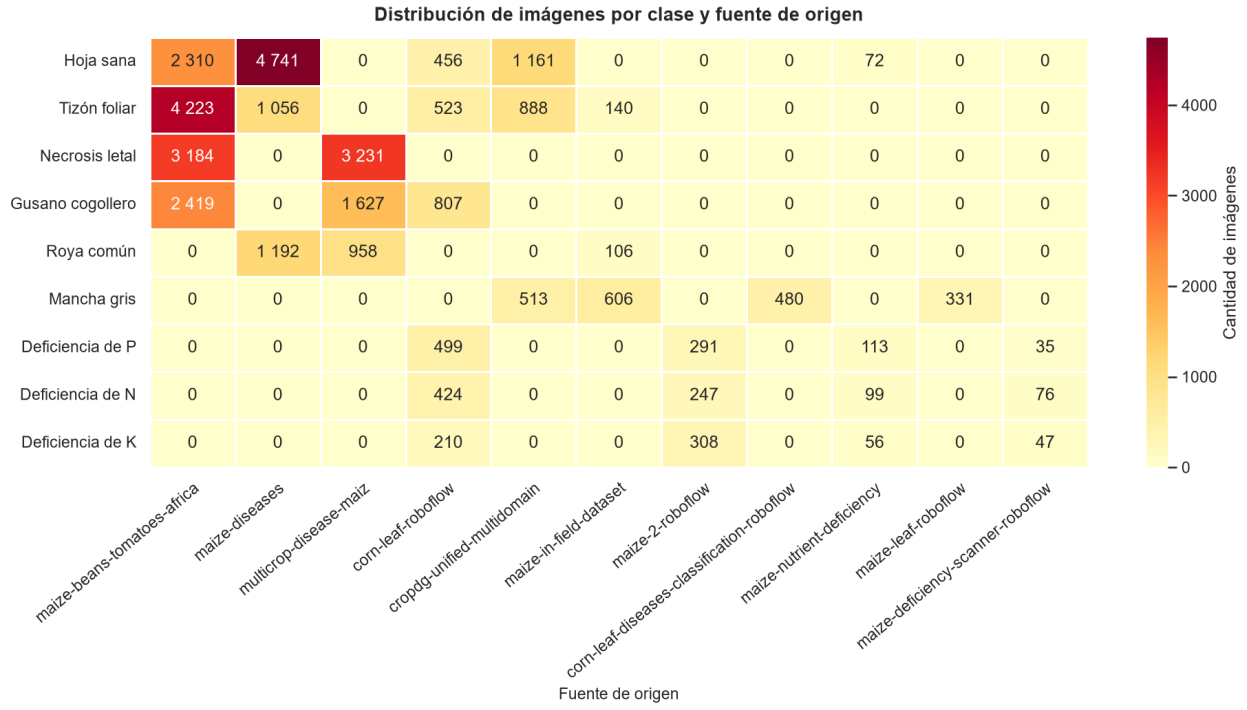


Figura 2.3: Distribución de imágenes por clase y fuente de origen.

2.3.2. Auditoría de Duplicados y Partición

Cada imagen se comparó con el resto mediante dos hashes SHA-256, uno del archivo y otro de los píxeles decodificados. No se encontraron duplicados; solo cuatro pares de imágenes con etiquetas contradictorias, que se excluyeron del corpus.
La partición oficial reparte las 33 429 imágenes en 70/15/15, estratificada por clase y entorno: 23 400 de entrenamiento, 5 014 de validación y 5 015 de prueba. Como las mismas fuentes aparecen en los tres conjuntos, el Capítulo 3 la complementa con una validación agrupada por fuente.

2.4. Arquitecturas y Búsqueda de Hiperparámetros

2.4.1. Familias Convolucionales Seleccionadas

Se compararon tres redes convolucionales ligeras, preentrenadas en ImageNet [4], con diseños distintos:

1. **EfficientNet-Lite0**, es la variante de EfficientNet para móviles: sustituye la activación *swish* por ReLU6 y elimina los bloques *Squeeze-and-Excitation* (SE) [10], lo que facilita la cuantización a enteros. Tiene 3.38 millones de parámetros [22].

2. **EfficientNet-B0**, la versión original, con escalado compuesto y bloques SE. Con 4.02 millones de parámetros.

3. **ShuffleNet-V2-x1.0**, que divide y baraja los canales (*channel split* y *channel shuffle*) para reducir los accesos a memoria. Es la más pequeña, con 1.26 millones de parámetros [14].

2.4.2. Espacio de Búsqueda y Poda Temprana

La búsqueda de hiperparámetros se hizo con Optuna [17], usando el estimador de árbol de Parzen multivariado (TPE), con el objetivo de maximizar el Macro F_1 de validación. Para no gastar GPU en configuraciones poco prometedoras se usó *MedianPruner*: tras cinco ensayos iniciales y a partir de la época 8, un ensayo se detiene si su Macro F_1 queda por debajo de la mediana de los ensayos anteriores en la misma época. La Tabla 2.3 muestra los seis hiperparámetros explorados.

Tabla 2.3: Espacio de búsqueda de hiperparámetros explorado con Optuna

Hiperparámetro	**Rango / Opciones**
`learning_rate`	Log-uniforme: $[10^{-5}, 3 \times 10^{-3}]$
`batch_size`	Categórico: $\{16, 32, 64\}$
`weight_decay`	Log-uniforme: $[10^{-7}, 10^{-2}]$
`class_weights`	Categórico: $\{$none, inverse, sqrt_inverse$\}$
`label_smoothing`	Categórico: $\{0, 0{,}025, \ldots, 0{,}15\}$ en pasos de 0.025
`warmup_epochs`	Entero: $[1, 5]$

2.4.3. Ensamble Multimodelo por Soft Voting

El ensamble promedia las probabilidades de las tres redes, entrenadas por separado, para que los errores de una arquitectura se compensen con las otras:

$$P_{\text{ens}}(y = c \mid x) = \frac{1}{M} \sum_{m=1}^{M} P_m(y = c \mid x) \tag{2.1}$$

donde $M = 3$ es el número de redes y $c \in \{1, \ldots, 9\}$. La clase predicha es la de mayor probabilidad promedio: $\hat{y} = \arg\max_c P_{\text{ens}}(y = c \mid x)$.

2.5. Despliegue en Dispositivo Móvil

2.5.1. Cuantización a Enteros de 8 Bits (Int8)

Para que EfficientNet-Lite0 funcione en teléfonos de forma eficiente, se cuantizó a enteros de 8 bits después del entrenamiento (*Post-Training Quantization*, PTQ) [11] y se exportó a TensorFlow Lite con litert-torch. Los pesos $W_{f,c,i}$ de cada canal de salida c se escalan por separado:

$$S_c = \frac{\max_i |W_{f,c,i}|}{127}, \qquad q_{c,i} = \text{clip}\left(\left\lfloor \frac{W_{f,c,i}}{S_c} \right\rceil, \; -127, \; 127 \right) \tag{2.2}$$

2.5.2. Detector de Anomalías Fuera de Distribución (OOD)

El modelo siempre responde con alguna de las clases que aprendió, aunque la fotografía no tenga relación con el maíz. Si se le muestra suelo o un zapato, elegirá de todos modos una enfermedad, a veces con mucha seguridad, porque solo puede repartir su confianza entre las etiquetas que conoce [12]. Por eso, antes de mostrar un diagnóstico, la aplicación comprueba si la imagen se parece a las que el modelo vio durante el entrenamiento.

Para hacerlo aprovecha la descripción numérica que la red construye de cada imagen justo antes de clasificarla, una especie de huella de su contenido. Durante el entrenamiento se registra en qué zona se agrupan las huellas de cada clase. Cuando llega una fotografía nueva, se mide qué tan lejos queda su huella del grupo más cercano con la distancia de Mahalanobis, que considera cuánto varían normalmente las imágenes de ese grupo [18]. A esa medida se le resta la distancia al conjunto completo de entrenamiento, para no castigar rasgos que comparte cualquier fotografía, como la iluminación o el encuadre [19].
El límite de aceptación se fijó de modo que el 95 % de las imágenes del conjunto de validación quede por debajo de él. Además, el diagnóstico se descarta cuando el modelo duda: si la enfermedad más probable no alcanza el 60 % de confianza o aventaja a la segunda por menos de 15 puntos. En cualquiera de estos casos la aplicación muestra **«Imagen no reconocida»** y no emite diagnóstico.

2.5.3. Mitigación en la Interfaz

La interfaz incorpora dos elementos que complementan al modelo:

1. **Marco guía.** La cámara muestra la silueta de una hoja (*Acérquese a 20–30 cm y llene el marco*) y la imagen se recorta a esa región, con un margen de 15 %, antes de pasar al modelo.

2. **Guía de severidad.** Debajo del diagnóstico se muestra una escala de tres niveles (baja, moderada y crítica), basada en escalas del CIMMYT y de Iowa State University Extension, que el productor compara con su hoja, junto con bioinsumos disponibles en el agroservicio.

2.6. Sincronización y Aportes al Conjunto de Datos

La aplicación no necesita un servidor para diagnosticar. El servidor solo interviene cuando el productor decide compartir información, y para eso debe crear una cuenta. Puede enviar una corrección, si considera que el diagnóstico fue equivocado, o una fotografía con la etiqueta que él mismo le asigna, que pasa a formar parte del conjunto de datos colaborativo. Con la fotografía solo viajan la etiqueta, una nota opcional y la fecha.
Como en la parcela puede no haber señal, cada aporte se guarda primero en el teléfono y se envía después, cuando vuelve la conexión o cuando el usuario lo pide (Figura 2.4). El registro se marca como enviado solo cuando el servidor confirma que lo recibió, y si algo falla se intenta de nuevo más tarde. En el servidor, la API (FastAPI con MySQL 8.4) rechaza los envíos repetidos y acepta como máximo 30 solicitudes por minuto.

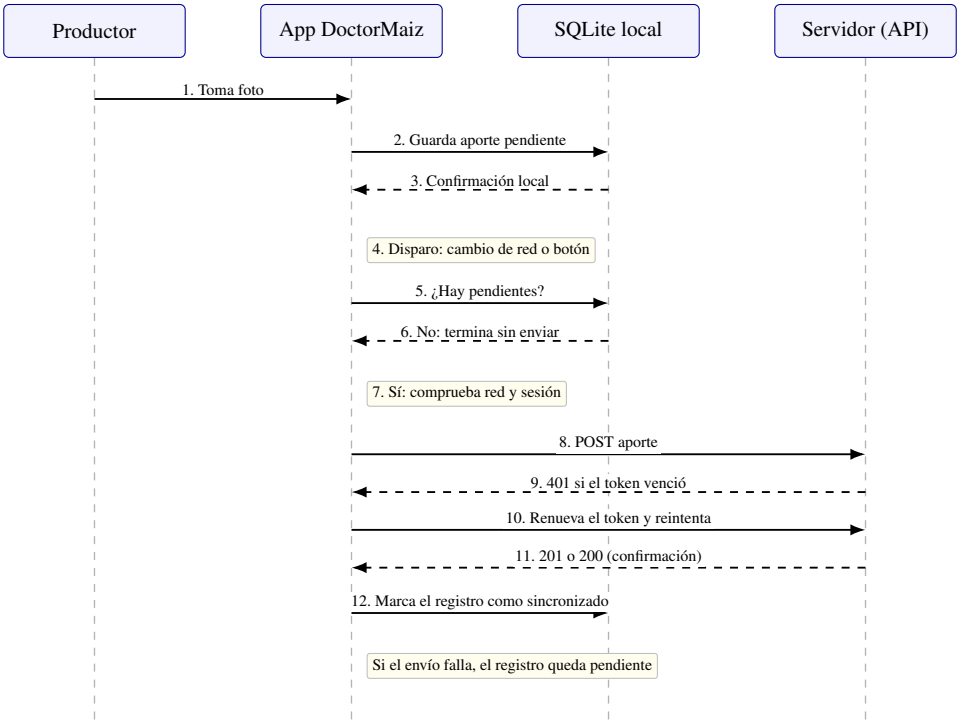


Figura 2.4: Flujo de sincronización de un aporte.

2.7. Arquitectura General del Sistema

El sistema se compone de tres repositorios independientes (Tabla 2.4).

Tabla 2.4: Tecnologías principales por proyecto

Proyecto	**Función**	**Tecnologías**
Pipeline del modelo	Entrenamiento, exportación y explicabilidad	PyTorch, timm, Optuna, litert-torch y ONNX Runtime para exportación, Modal (GPU A10G) para entrenamiento en la nube, SHAP y LIME.
Aplicación móvil	Captura, inferencia local y sincronización	Expo, React Native, TypeScript, `react-native-fast-tflite` para inferencia, WatermelonDB con SQLite local y NativeWind.
API de sincronización	Versión de la app y aportes al dataset colaborativo	FastAPI, SQLAlchemy, Alembic, MySQL en Docker Compose, JWT y bcrypt para autenticación y slowapi para límites de tasa.

La aplicación no tiene dependencia con el entorno de entrenamiento, solo empaqueta el modelo `.tflite`, las etiquetas y los parámetros del detector OOD, y se comunica con la API por HTTP. La Figura 2.5 resume el flujo completo.

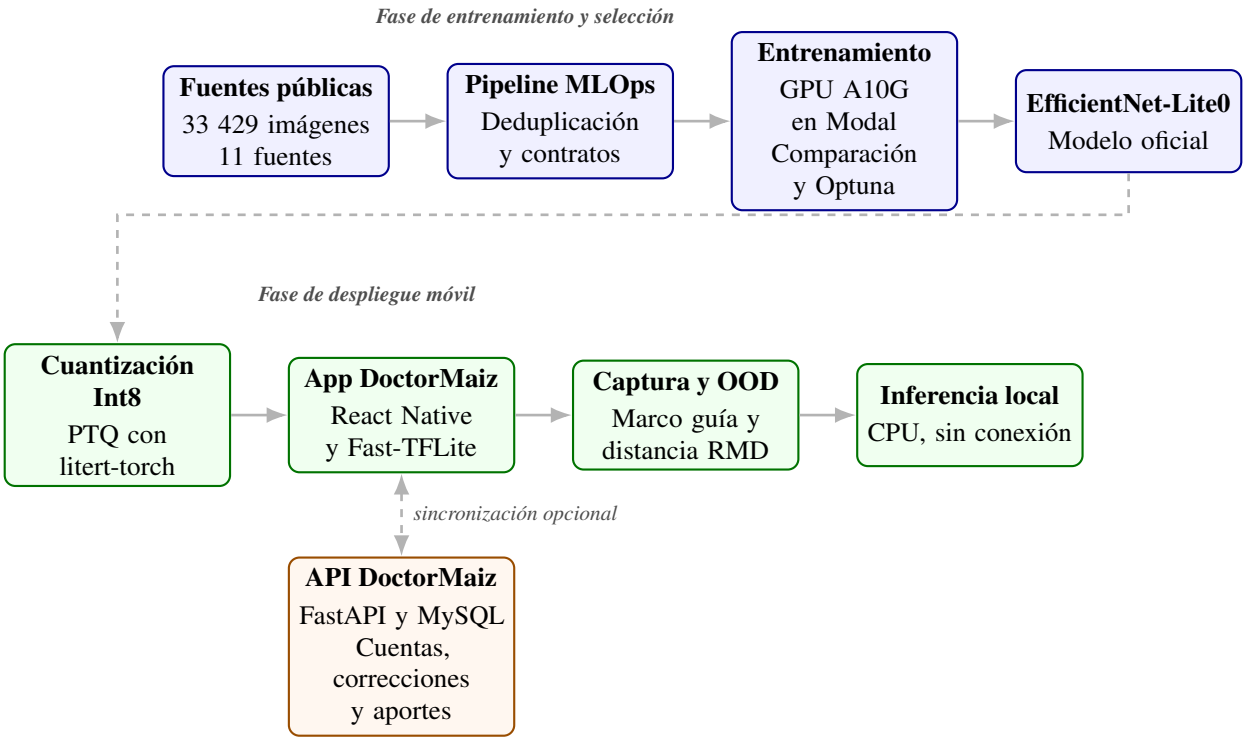


Figura 2.5: Arquitectura del sistema DoctorMaiz.

CAPÍTULO 3

ESTRATEGIA DE IMPLEMENTACIÓN Y ANÁLISIS DE RESULTADOS

3.1. Estrategia y Entorno de Implementación

El desarrollo computacional del proyecto se articuló en una arquitectura híbrida que desacopla la fase de entrenamiento a gran escala en la nube (*Cloud Training*) de la fase de operación local en el teléfono (*Edge Inference*).

3.1.1. Infraestructura de Cómputo y Entrenamiento en la Nube

Los modelos se entrenaron sobre instancias aceleradas por hardware en la plataforma Modal, empleando unidades de procesamiento gráfico **NVIDIA A10G** (24 GB de VRAM) montadas sobre entornos Linux con CUDA 12.6 y PyTorch 2.12.1.
El régimen de entrenamiento incorporó un programador de tasa de aprendizaje por recocido cosenoidal con calentamiento lineal (*Cosine Annealing with Warmup*) durante tres épocas iniciales, estabilizando los pesos procedentes de ImageNet [4] antes de permitir gradientes elevados. Como salvaguarda frente al sobreajuste, se aplicó parada temprana (*Early Stopping*) con una paciencia de 8 épocas sobre el Macro F_1 de validación (Figura 3.1).

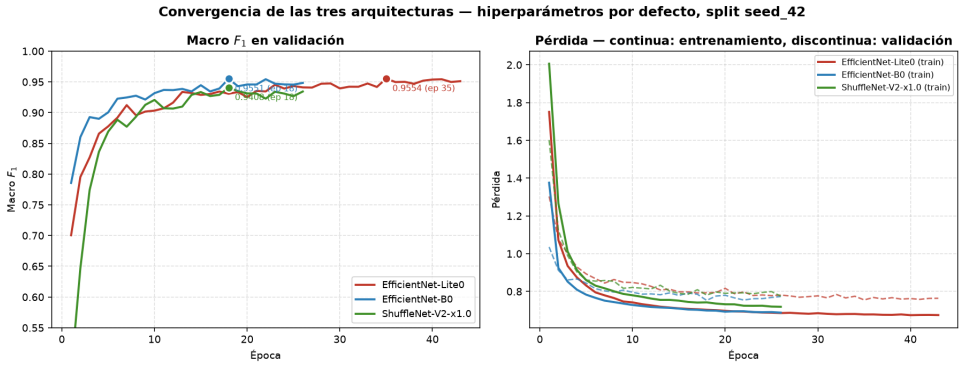


Figura 3.1: Curvas de convergencia: Pérdida y Macro F_1 durante el entrenamiento en Modal.

3.2. Resultados

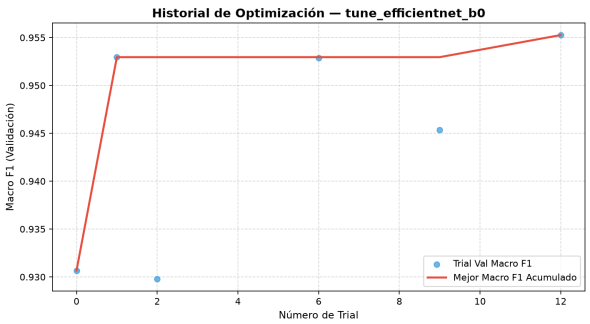
Esta sección reporta el estado de cada criterio de éxito definido en la Tabla 1.1 y, a continuación, el detalle de las mediciones. Cuando un criterio no se cumple, no se midió o depende de una corrida pendiente, la tabla lo indica. Para juzgar la utilidad del sistema en campo pesan más la generalización entre fuentes y las fotografías externas (Secciones 3.2.2 y 3.2.3) que el desempeño en la partición estratificada; el ensamble de la etapa 2 se presenta al final como resultado exploratorio, porque no está desplegado.

Tabla 3.1: Estado de los criterios de éxito al cierre de esta versión

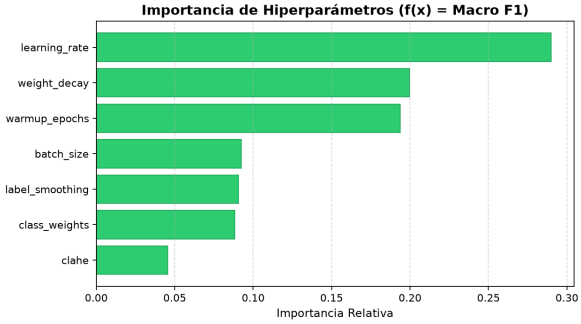
Criterio	**Resultado medido**	**Estado**
Macro $F_1 \geq 0{,}85$ en prueba	0.9480 (baseline vigente, una semilla); 0.9435 $\pm$ 0.0052 en tres semillas.	Cumple
DIR $\geq 0{,}80$ entre laboratorio y campo	0.9636 (Macro F_1) y 0.9956 (exactitud) con el modelo oficial, en las tres clases compartidas; la roya de campo (16 imágenes) queda en $F_1 = 0{,}77$.	Cumple
Solapamiento cero entre particiones	0 de 5 015 imágenes de prueba en entrenamiento o validación, por SHA-256 y por píxeles; 33 437 archivos verificados. No incluye similitud perceptual.	Cumple
Int8 de 20 MB o menos	3.74 MB (3 743 728 bytes) para el modelo oficial `20260921_204608`.	Cumple
Preprocesado e inferencia ≤ 300 ms en teléfono de gama media	Medianas de 98 ms de preprocesado (p95 de 279 ms) y 23 ms de inferencia con el modelo Int8 en un Motorola edge 40 neo (MediaTek Dimensity 7030).	Cumple en la mediana; el p95 de inferencia no se midió
Funcionamiento sin conexión	Clasificación local verificada en un dispositivo.	Cumple

3.2.1. Búsqueda bayesiana de hiperparámetros con poda

El estudio con Optuna exploró 25 ensayos sobre `EfficientNet-Lite0`, con un máximo de 60 épocas cada uno. De ellos, 8 se completaron, 15 fueron podados por *MedianPruner* al quedar por debajo de la mediana tras el periodo de calentamiento (8 épocas) y 2 se interrumpieron por fallos del proceso. El ensayo ganador fue el Trial 0 (época 44), elegido por su Macro F_1 de validación. Los ensayos completados y podados sumaron 453 épocas; las de los dos interrumpidos no se registraron. La búsqueda usó 12.65 horas de GPU, de las cuales 5.58 corresponden a los dos ensayos interrumpidos. No se ejecutó una búsqueda sin poda, por lo que no se puede estimar cuánto cómputo ahorró la poda; además, el entrenamiento ya incluía parada temprana, que también acorta los ensayos. Tampoco se puede descartar que la poda haya eliminado un candidato mejor.



Historial de ensayos de Optuna.



Importancia relativa de hiperparámetros.

Figura 3.2: Dinámica de exploración e impacto relativo de variables en Optuna.

El análisis de importancia (Figura 3.2) reveló que el calentamiento (`warmup_epochs`, 0.52), la ponderación de pérdida (`class_weights`, 0.15), el suavizado de etiquetas (`label_smoothing`, 0.11), la tasa de aprendizaje (`learning_rate`, 0.10) y el tamaño de lote (`batch_size`, 0.09) concentran la mayor parte de la variación del objetivo. La configuración del Trial 0 comparada con la línea base se muestra en la Tabla 3.2.

Tabla 3.2: Comparativa cuantitativa: Baseline sin Optuna vs. Configuración Optimizada (Optuna)

Métrica / Variable	**Sin Optuna (Base)**	**Optimizada (Optuna)**	**Impacto / Delta**
Macro F_1 en Validación	0.9561	0.9573	+0.12 pp
Macro F_1 en Prueba Retenida	0.9480	0.9431	$-0{,}49$ pp
Tasa de Aprendizaje (`lr`)	$1{,}00 \times 10^{-4}$	$8{,}47 \times 10^{-5}$	Valor de búsqueda
Tamaño de Lote (`batch_size`)	32	16	Valor de búsqueda
Calentamiento (`warmup_epochs`)	3	1	Valor de búsqueda
Decaimiento de pesos (`weight_decay`)	$1{,}00 \times 10^{-4}$	$5{,}67 \times 10^{-3}$	Valor de búsqueda
Ponderación de Pérdida	`sqrt_inverse`	`none`	Valor de búsqueda
Suavizado de Etiquetas	0.10	0.075	Valor de búsqueda

Resultado de prueba y decisión de configuración: El ensayo ganador no mejoró el Macro F_1 de prueba frente a la línea base ($-0{,}49$ pp), aunque sí mejoró ligeramente la validación (+0.12 pp). El ganador no se adoptó: la configuración de desarrollo sigue siendo la de la ejecución `20260921_204608` (`learning_rate` 10^{-4}, lote 32, `sqrt_inverse`, suavizado 0.1), con Macro F_1 de prueba de **0.9480** y exactitud de 97.81 %. Esa ejecución, anterior al estudio y primer reentrenamiento completo sobre la materialización corregida de `seed_42`, es la oficial del proyecto y la que despliega la aplicación. El presupuesto de búsqueda se redujo de 60 a 25 intentos después de observar resultados parciales, mediante una enmienda registrada.

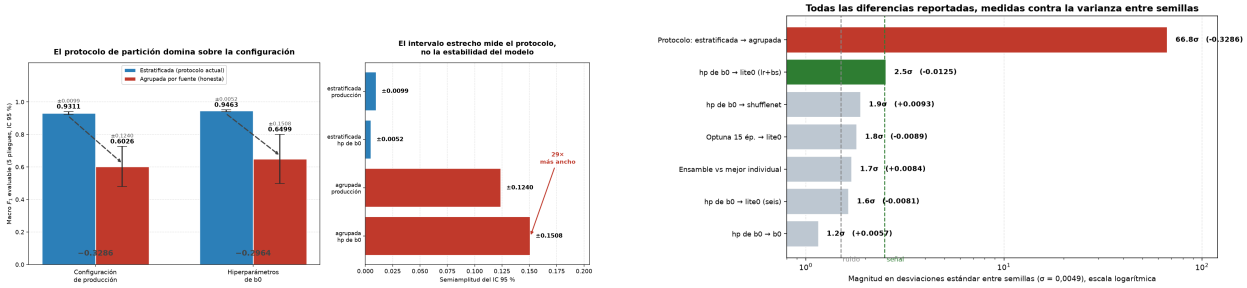
3.2.2. Rendimiento del modelo: generalización entre fuentes

Para poner a prueba los límites del sistema frente al cambio de dominio, se diseñó un experimento cruzado 2×2 de validación cruzada en 5 pliegues sobre `EfficientNet-Lite0`, comparando la partición estratificada habitual frente a una partición agrupada por procedencia que veta cualquier solapamiento de fuentes entre entrenamiento y evaluación (Tabla 3.3 y Figura 3.3).

Tabla 3.3: Resultados del experimento cruzado 2×2 de validación cruzada en 5 pliegues

Configuración de Red	**CV Estratificada (5 folds, media ± IC95)**	**CV Agrupada por Fuente (macro F_1 sobre clases presentes, media ± IC95)**	**Caída Neta (Δ)**
Hiperparámetros base	$0{,}9311 \pm 0{,}0099$	$\mathbf{0{,}6026 \pm 0{,}1240}$	$\mathbf{-0{,}3286}$
Hiperparámetros del trial 12 de B0	$0{,}9463 \pm 0{,}0052$	$0{,}6499 \pm 0{,}1508$	$-0{,}2964$

Todas las filas usan EfficientNet-Lite0. El macro F_1 convencional de 9 clases en la partición agrupada es 0.4359 para la primera fila. Fuentes en validación: repositorios solapados con entrenamiento en la partición estratificada; ninguno en la agrupada.



Diseño del experimento cruzado 2×2. Magnitud de impacto en sigmas (σ).

Figura 3.3: Impacto de la partición frente a la optimización algorítmica.

Hallazgo principal (histórico): En la validación cruzada de cinco pliegues, el cambio de protocolo de partición ($-0{,}3286$ en Macro F_1 sobre la misma escala) es considerablemente mayor que el efecto del ajuste de hiperparámetros ($+0{,}0152$, de 0.9311 a 0.9463). El $-0{,}3286$ compara 9 clases en la partición estratificada con el macro evaluable por pliegue en la agrupada, por lo que no es una resta pareada exacta; el valor pareado es $-0{,}4952$ (0.9311 frente a 0.4359). El ajuste en validación del HPO fue de $+0{,}0012$. Mientras la validación estratificada muestra un intervalo estrecho ($\pm 0{,}0099$), al evaluar fuera de fuente el Macro F_1 evaluable baja a $0{,}6026$ (IC95 $\pm 0{,}1240$), calculado sobre las clases evaluables en cada pliegue. La variabilidad entre tres semillas en la configuración de desarrollo es de $\sigma = 0{,}0052$ (media $0{,}9435$, σ muestral con $n = 3$), y la dispersión entre pliegues estratificados es $\sigma = 0{,}0080$; ambas son mucho

menores que el cambio de protocolo, aunque miden magnitudes distintas (semillas sobre la prueba y pliegues de validación cruzada) y no se dividen entre sí (Figura 3.3). Este resultado es consistente con que las redes entrenadas sobre estos repositorios públicos dependen en parte de la firma visual de cada fuente, aunque el experimento no permite atribuir la caída a un único factor.

Tabla 3.4: Evaluación LOSO con tres semillas: Macro F_1 y exactitud en la fuente retenida

Fuente retenida	**Macro F_1 (media $\pm$ SD)**	**Exactitud (media $\pm$ SD)**	**Semillas**
`maize-diseases`	0.9933 ± 0.0006	$99.37\,\% \pm 0.07$ pp	3
`multicrop-disease-maiz`	0.9019 ± 0.0044	$80.38\,\% \pm 0.32$ pp	3

En ambos casos el modelo se entrenó sin la fuente retenida y se evaluó sobre ella, con selección de checkpoint congelada antes de abrir la evaluación final. La desviación estándar es muestral ($n = 3$). Con tres semillas, estas cifras describen la variabilidad observada, pero no alcanzan para una prueba de significancia.

3.2.3. Rendimiento del modelo: fotografías de campo externas

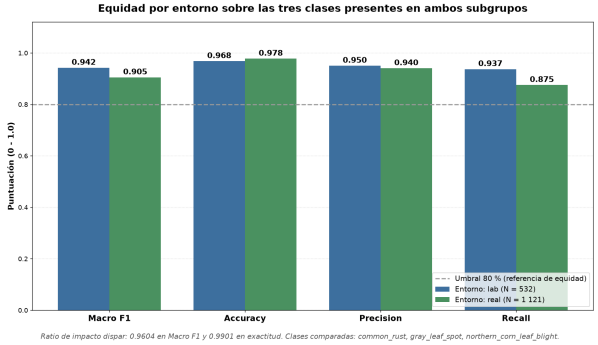
Se evaluó el modelo oficial en 97 fotografías de campo ajenas al corpus de entrenamiento, organizadas en carpetas por clase (una de ellas también figura en el corpus). Con el modelo FP32 en computador y la imagen completa, acertó 41 de 97 (42 %); el detector OOD rechazó 49 de las 97 fotografías. El Lite0 de agosto (`20260812_221429`) acertó 39 de 97 sobre las mismas fotografías, de modo que la diferencia con las métricas de prueba no se explica por el cambio de modelo. Es compatible con una generalización limitada fuera del corpus, como indican LOSO y la validación agrupada por fuente, pero no se aisló de otros factores como el etiquetado y el encuadre de las fotografías. Es la principal limitación del sistema (Tabla 3.5). Se desconocen el lugar, la fecha y el criterio de etiquetado de estas fotografías.

Tabla 3.5: Aciertos del modelo oficial en fotografías de campo externas, por clase

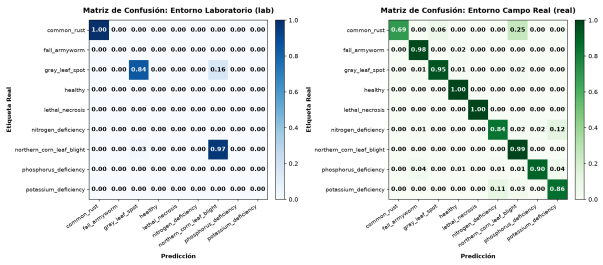
Clase	**Fotografías**	**Aciertos**
Roya común	18	2
Deficiencia de fósforo	10	2
Mancha gris (GLS)	10	10
Deficiencia de nitrógeno	10	6
Deficiencia de potasio	9	4
Tizón foliar (NCLB)	10	5
Gusano cogollero	10	10
Necrosis letal del maíz (MLN)	10	0
Planta sana	10	2
Total	**97**	**41**

3.2.4. Capacidades del diagnóstico: equidad entre entornos

El *Disparate Impact Ratio* (DIR) divide el desempeño del entorno con peor resultado entre el del mejor; la regla de los cuatro quintos lo considera aceptable desde 0.80. Como el subconjunto de laboratorio solo contiene tres clases (roya, mancha gris y tizón), el cálculo se restringe a esas tres clases en ambos entornos: comparar el Macro F_1 de laboratorio (tres clases) con el de campo (nueve clases) mezclaría conjuntos distintos. Con el modelo oficial (`20260921_204608`; 533 imágenes de laboratorio y 1 120 de campo en esas clases), el Macro F_1 es 0.9383 en laboratorio y 0.9041 en campo, de modo que $DIR = 0{,}9636$; sobre exactitud, $DIR = 0{,}9956$. Con el Lite0 de la etapa 2 (`20260812_221429`) los valores fueron 0.9604 y 0.9901. Ambos modelos superan el umbral, pero un DIR cercano a uno no descarta disparidades por clase ni la dependencia del fondo (Sección 3.2.5). El desglose por clase y las figuras siguientes corresponden al checkpoint de la etapa 2 (Figura 3.4).



Disparidad por entorno ambiental.



Matrices desagregadas Lab vs. Campo.

Figura 3.4: Auditoría de equidad e imparcialidad entre condiciones fotográficas.

El análisis granular de la tasa de falsos negativos (FNR) mostró una asimetría relevante, aunque con muestras pequeñas en campo (Tabla 3.6):

- La **Roya Común** es casi infalible en laboratorio ($FNR = 0{,}31\,\%$, 1 fallo en 322 casos) pero **falla en el 31.25 % de los casos en campo real** (5 fallos en 16 casos). Coincide con que el 95 % de las imágenes de roya del corpus (2 150 de 2 256) son de laboratorio. Con el modelo oficial la diferencia persiste: $F_1 = 0{,}998$ en laboratorio frente a 0.77 en campo; con solo 16 imágenes de campo la estimación es poco estable.
- La **Mancha Gris** exhibe el patrón inverso: $15{,}58\,\%$ de error en laboratorio frente a solo $5{,}16\,\%$ en campo auténtico.

Tabla 3.6: Tasa de falsos negativos (FNR) desagregada por clase y entorno, checkpoint de la etapa 2

Patología Evaluada	FNR **Laboratorio**	**Soporte** (N)	FNR **Campo Real**	**Soporte** (N)
Roya Común	0.31 %	322	**31.25 %**	16
Mancha Gris (GLS)	15.58 %	77	5.16 %	213
Tizón Foliar (NCLB)	3.01 %	133	1.01 %	892

3.2.5. Capacidades del diagnóstico: dependencia del fondo

Para desentrañar si el modelo miraba la hoja o el entorno, se ejecutó una auditoría de oclusión espacial geométrica sobre las 5 015 muestras de prueba frente a un predictor nulo constante (Tabla 3.7 y Figura 3.5).

Tabla 3.7: Auditoría de ablación espacial con control nulo en el conjunto de prueba, checkpoint de la etapa 2

Condición de Entrada	**Región Visible**	**Área (%)**	**Exactitud**	**Exceso s/Nulo**	**Conf. Retenida**
Imagen original completa	Toda la escena	100.0 %	97.91 %	+71.77 pp	100.0 %
Oclusión central	**Anillo periférico**	**63.7 %**	**79.46 %**	**+53.32 pp**	**69.16 %**
Oclusión periférica	Caja central	36.3 %	42.25 %	+16.11 pp	42.66 %
Control nulo (sin píxeles)	Clase mayoritaria	0.0 %	26.14 %	0.0 pp	—

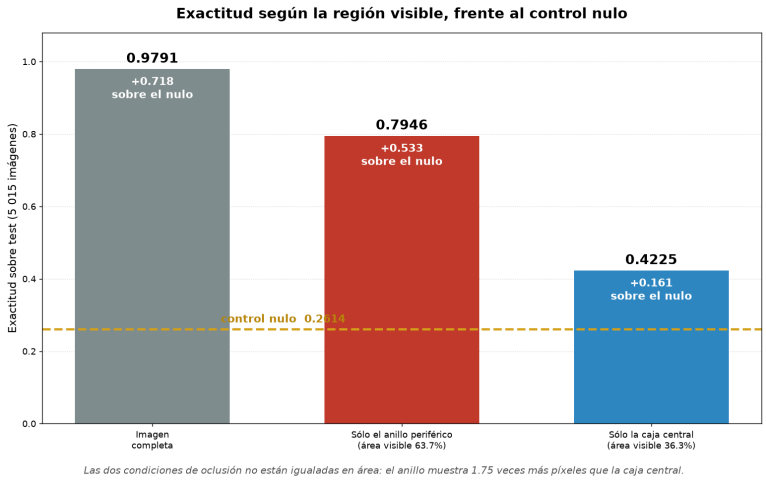


Figura 3.5: Exactitud según la región geométrica visible frente al azar nulo.

Al ocluir la región central de la imagen (36.3 % del área), el clasificador conserva un **79.46 % de exactitud** (riesgo MODERADO, `shortcut_detected = false`). Al ocluir la periferia, la exactitud cae a 42.25 % y el análisis marca dependencia crítica de la región periférica (riesgo CRÍTICO, `shortcut_confirmed`). Las dos condiciones dejan visibles áreas distintas (63.7 % y 36.3 %). Este

hallazgo es consistente con que el fondo aporta señal de clase, aunque el experimento no aisla causalmente la lesión del fondo, por lo que la interpretación debe tomarse como hipótesis de trabajo que motiva el marco guía de captura.

Interpretabilidad con Grad-CAM y SHAP: Al evaluar mapas de calor locales (Figuras 3.6 y 3.7), los métodos de atribución destacan las lesiones visibles. Los mapas se obtuvieron con Grad-CAM, LIME [20] y SHAP [13]. Sin embargo, al medir el **exceso de atribución foliar** (fracción sobre la hoja menos la cobertura de la máscara), el exceso medio de las seis clases con máscara confiable (270 imágenes, máscara del segmentador) fue de apenas **+0.037**, con tres clases por encima del azar y tres por debajo. Una hipótesis compatible con este resultado es que la firma de fondo es un fenómeno difuso de baja frecuencia, distribuido en miles de píxeles, que no satura los mapas locales.

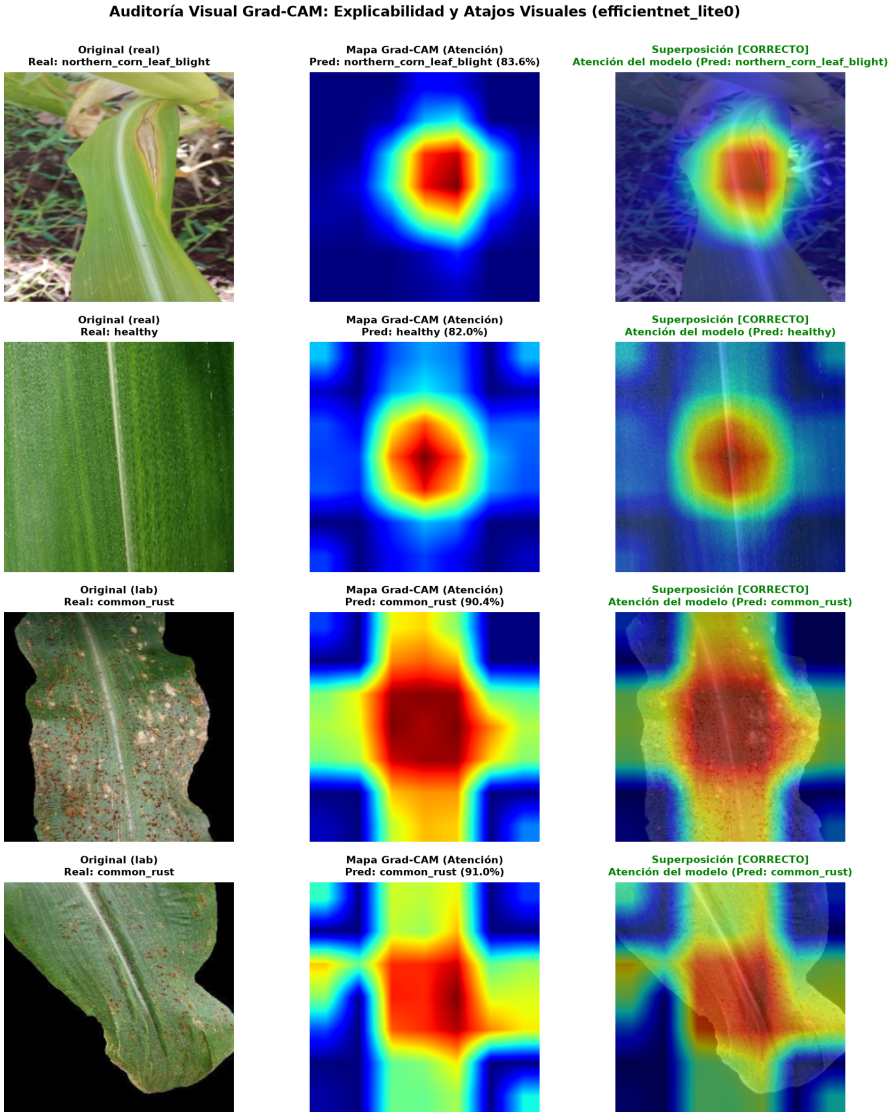


Figura 3.6: Mapas de activación Grad-CAM en muestras de campo real y laboratorio.

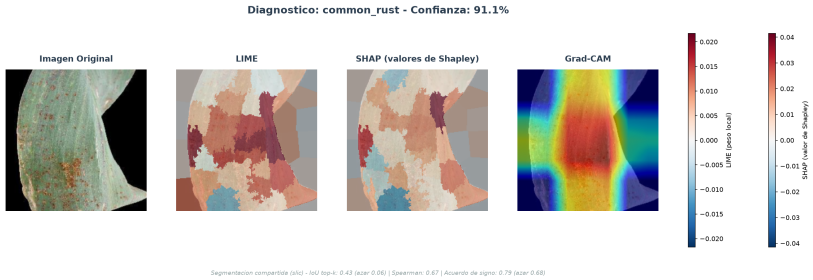


Figura 3.7: Panel comparado de explicabilidad local: LIME, SHAP y Grad-CAM.

3.2.6. Solución integral: prototipo en hardware real

El modelo oficial `EfficientNet-Lite0` (`20260921_204608`) cuantizado a 8 bits (**Int8**) ocupa **3.74 MB** (3 743 728 bytes), una reducción del 72.9 % frente a los 13.79 MB del punto de control FP32. En la prueba completa de 5 015 imágenes, el modelo Int8 obtuvo Macro F_1 de 0.9489 y exactitud de 97.87 %, frente a 0.9480 y 97.81 % de PyTorch, con un acuerdo de predicciones del 99.74 %. La paridad numérica del TFLite FP32 con ONNX y PyTorch fue aprobada (diferencia máxima de probabilidad de $3{,}3 \times 10^{-6}$ en ONNX y $3{,}9 \times 10^{-7}$ en TFLite). La paridad sobre una muestra de 30 imágenes no fue aprobada por una sola imagen límite (diferencia máxima de probabilidad de 0.198 frente a un tope de 0.15).
La aplicación móvil **DoctorMaiz** (React Native, TypeScript y `react-native-fast-tflite`) se instaló y probó en un teléfono **Motorola edge 40 neo** (procesador MediaTek Dimensity 7030 octa-core a 2.5 GHz, 8 GB RAM, Android 15). Todas las mediciones en teléfono provienen de este único dispositivo de gama media; no se probaron dispositivos de gama baja ni con 4 GB de RAM, el mínimo del alcance.
Las latencias del modelo Int8 oficial se midieron en el teléfono como medianas (Tabla 3.8):

- El preprocesado tomó una mediana de **98 ms** (p95 de 279 ms).
- La inferencia en la CPU del teléfono tomó una mediana de **23 ms**.
- Ambas cifras cumplen la meta de 300 ms para preprocesado e inferencia de la Tabla 3.1. El preprocesado supera cuatro veces a la inferencia, de modo que el cuello de botella no es el modelo.
- El flujo interactivo completo (captura, decodificación, inferencia, persistencia en SQLite y renderizado) tomó una mediana de 473 ms en la medición de la etapa 2 con el modelo de agosto; no se repitió con el modelo oficial y no forma parte de la meta.

Tabla 3.8: Latencias medianas en hardware físico (Motorola edge 40 neo)

Fase del proceso	**Modelo**	**Mediana**
Preprocesado	Oficial Int8 (`20260921_204608`)	98 ms
Inferencia	Oficial Int8 (`20260921_204608`)	23 ms
Flujo completo	Etapa 2 (`20260812_221429`)	473 ms

Fidelidad del teléfono frente al servidor: Se procesaron en el teléfono 143 imágenes (95 fotografías de campo externas y 48 del corpus) con el motor de inferencia de la aplicación. La primera medición reveló una diferencia de preprocesado entre entrenamiento y aplicación: las imágenes con algún lado menor de 448 píxeles se escalaban a 224×224 en un solo paso bilineal sin prefiltro, mientras que el entrenamiento usa el redimensionado con antialias de Pillow. Con ello, el teléfono coincidía con el computador solo en el 84 % de las predicciones y el detector OOD rechazaba el doble de imágenes del corpus (16.7 % frente a 8.3 %). Al pasar el tensor del propio teléfono por el modelo Int8 del servidor se reprodujeron sus predicciones, lo que descartó al intérprete como causa. Tras portar a la aplicación el remuestreo de Pillow, verificado byte a byte contra su salida, el teléfono coincide con el Int8 del servidor en las 143 imágenes. En el teléfono, el modelo acertó 45 de 48 imágenes del corpus (93.8 %, con 8.3 % de rechazo OOD) y 38 de 95 fotografías de campo (40.0 %, con 52.6 % de rechazo OOD), cifras equivalentes a las del computador (Sección 3.2.3).

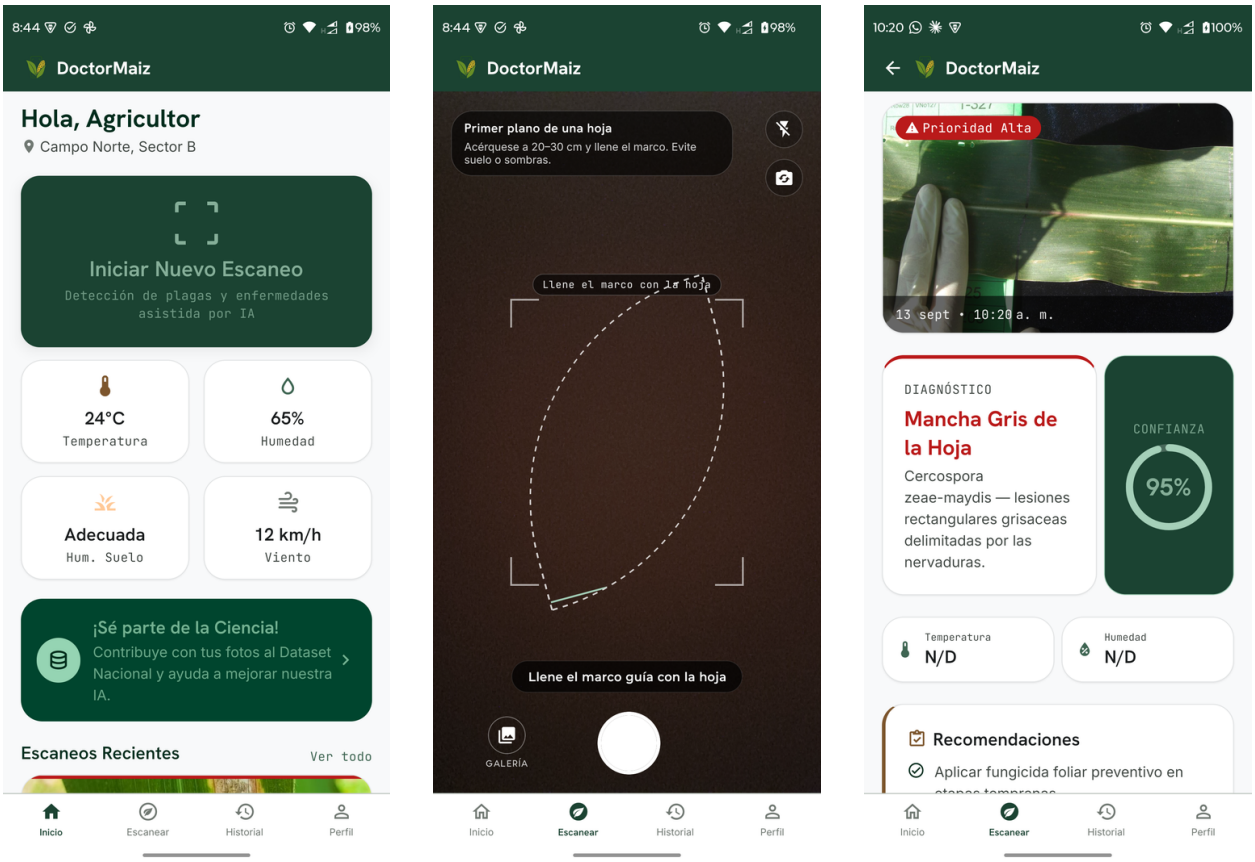
Mecanismos de mitigación en la interfaz de usuario (UI/UX): La aplicación incorpora mecanismos que buscan mitigar las limitaciones del modelo mediante un diseño ergonómico adaptado al productor (Figuras 3.8 y 3.9). Su efecto sobre el error del modelo no se midió ni se evaluó con productores. Los mecanismos son:

1. **Cámara con marco guía foliar (Figura 3.8):** La app instruye al agricultor a encuadrar la hoja y recorta la captura al marco guía con un margen de 15 % (3.02 MP a partir de 12.6 MP, el 24 % de la escena, en el dispositivo de prueba), lo que reduce el fondo visible antes de inferir.

2. **Detector OOD de Mahalanobis (Figura 3.9):** Cuando la distancia multivariada supera el umbral 106.37, el sistema despliega **«Imagen no reconocida»**. El detector rechazó las cinco imágenes sintéticas de prueba (negro, blanco, gris, ruido y azul) y, por error, el 3.8 % de 500 imágenes de prueba válidas.

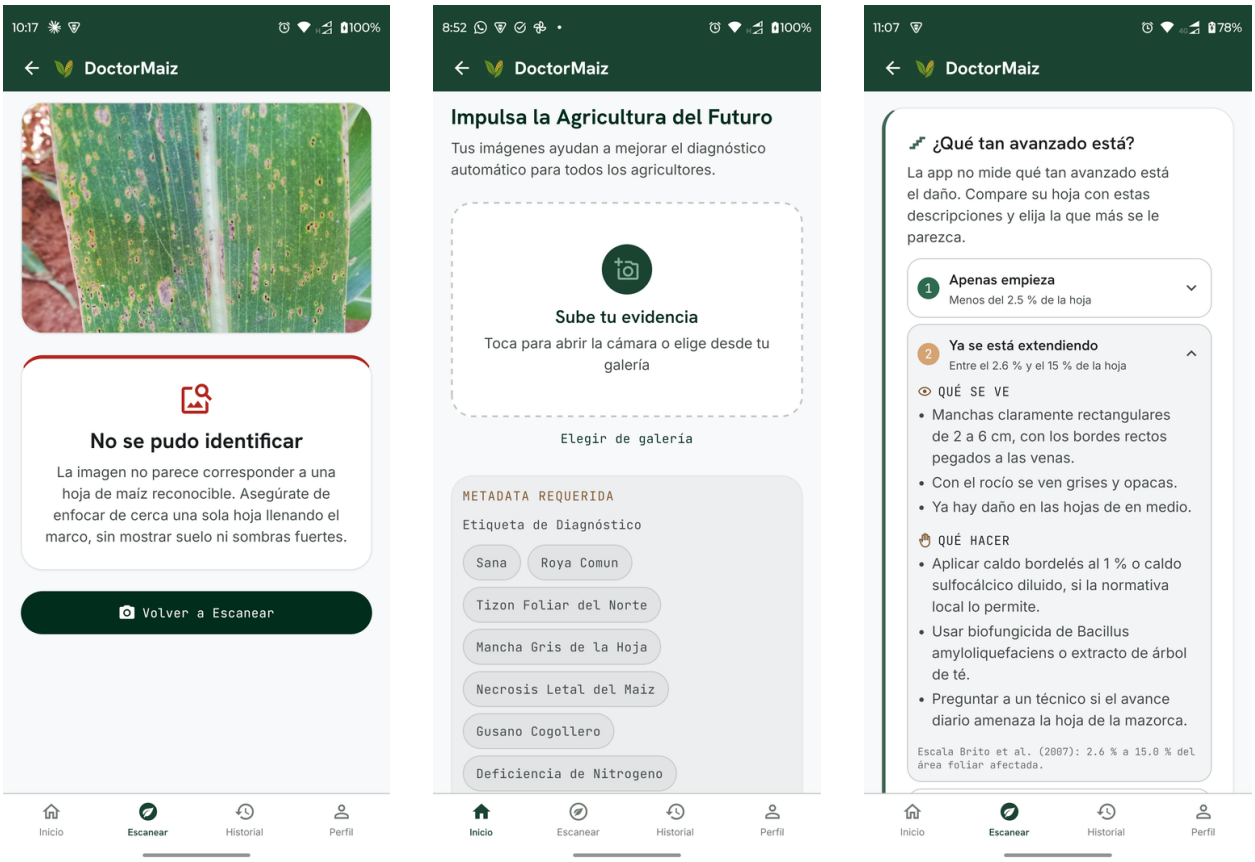
3. **Módulo de contribución comunitaria (Figura 3.9):** Permite almacenar fotos de milpas salvadoreñas para subirlas cuando haya conectividad.

4. **Guías de severidad contextualizadas (Figura 3.9):** Ofrece al productor una guía gráfica de tres grados en lenguaje cotidiano, que él compara con su hoja, con pautas de bioinsumos.



Pantalla de inicio. Marco guía foliar. Diagnóstico obtenido.

Figura 3.8: Flujo principal de la aplicación móvil nativa DoctorMaiz.



Bloqueo seguro por OOD. Aporte comunitario. Guía de severidad.

Figura 3.9: Mecanismos de seguridad, participación comunitaria y escalas agronómicas.

3.2.7. Resultado exploratorio: ensamble de la etapa 2 (no desplegado)

El ensamble heterogéneo por votación suave (*Soft Voting*) superó a las arquitecturas individuales en la partición estratificada histórica (Tabla 3.9 y Figura 3.10). Este resultado es histórico, de una sola semilla y en una partición que mezcla fuentes; bajo validación con fuente no vista la ventaja es mixta (sección de generalización).

Tabla 3.9: Desempeño del ensamble frente a modelos individuales en la prueba de la etapa 2 (corpus de 33 433 imágenes, 5 015 de prueba)

Arquitectura / Modelo	**Exactitud**	**Macro F_1**	**Precision**	**Recall**
ShuffleNet-V2-x1.0 (`20260910_184521`)	97.31 %	0.9330	0.9388	0.9298
EfficientNet-Lite0 (`20260812_221429`)	97.91 %	0.9468	0.9533	0.9413
EfficientNet-B0 (`20260910_170120`)	97.97 %	0.9483	0.9589	0.9400
Ensamble Heterogéneo (Soft Voting)	**98.29 %**	**0.9567**	**0.9642**	**0.9506**
Ganancia neta vs. mejor individual	*+0.32 pp*	*+0.83 pp*	*+0.52 pp*	*+0.93 pp*

Las filas de la Tabla 3.9 proceden de la etapa 2, con el Lite0 de agosto (`20260812_221429`) y una materialización del conjunto de prueba con 338 imágenes de roya común y 290 de mancha gris. El modelo oficial vigente (`20260921_204608`, corpus de 33 429 imágenes, 339 y 289 imágenes en esas clases) obtuvo exactitud 97.81 %, Macro F_1 0.9480, precisión 0.9513 y recall 0.9467 sobre su propia prueba; no se compara de forma pareada con las filas anteriores.

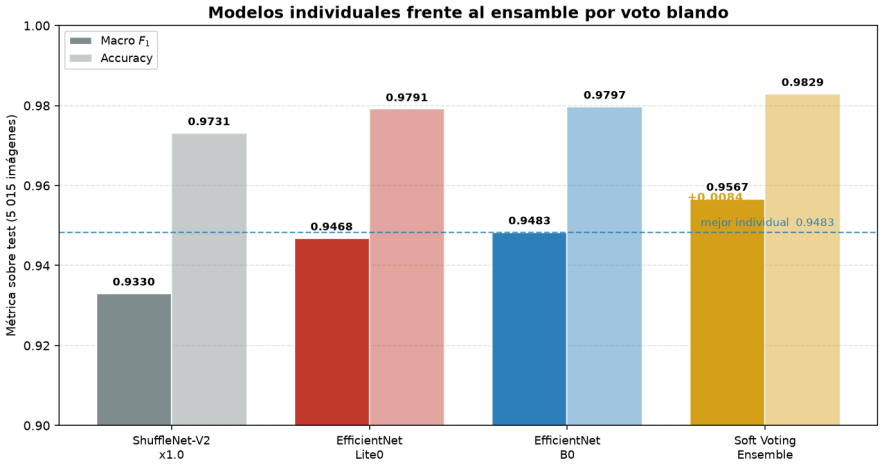


Figura 3.10: Comparativa de desempeño del ensamble frente a modelos individuales.

En el ensamble, que no está desplegado en la aplicación, el resultado más relevante para el diagnóstico es el **Macro Recall de 95.06 %**, porque en fitopatología un falso negativo puede dejar sin atención una infección incipiente. Como muestra la matriz de confusión normalizada del ensamble (Figura 3.11), la **Necrosis Letal del Maíz (MLN)** alcanzó un recall de 100.0 % (963 aciertos sobre 963 casos de prueba), y la roya común y el tizón superaron el 98 % de detección. Ese 100 % corresponde a una partición que mezcla fuentes: bajo LOSO el recall de MLN baja a 0.72–0.81, de modo que no debe leerse como garantía

de detección en campo.

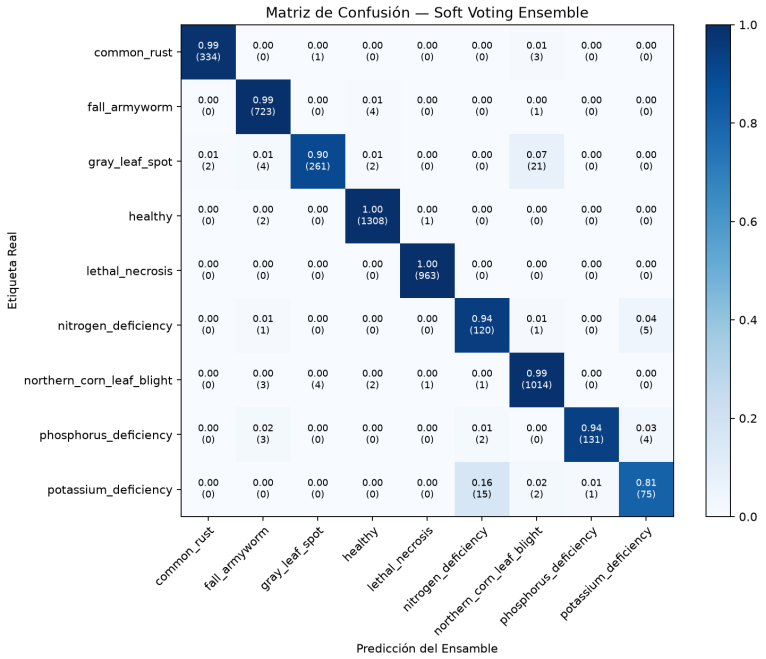


Figura 3.11: Matriz de confusión normalizada del ensamble sobre 5 015 muestras de prueba.

Asimismo, la **deficiencia de potasio**, que en una evaluación previa de la primera fase alcanzaba 0.49 (protocolo y soporte distintos), subió a **0.8475** en el ensamble de la etapa 2 y a 0.8242 en el Lite0 oficial vigente. Esta mejora coincide con la incorporación de nuevos repositorios y con la pérdida ponderada `sqrt_inverse`, pero no se aisló experimentalmente la contribución de cada factor.

Tabla 3.10: Desglose de F_1 por clase en la prueba de la etapa 2 (corpus de 33 433 imágenes; Lite0 `20260812_221429`)

Patología Agronómica	**Soporte**	**Lite0**	**B0**	**ShuffleNet**	**Ensamble**
Necrosis Letal (MLN)	963	**0.9990**	0.9984	0.9974	**0.9990**
Planta Sana (Healthy)	1 311	0.9936	0.9954	0.9901	**0.9958**
Roya Común	338	0.9866	0.9896	0.9867	**0.9911**
Gusano Cogollero	728	0.9814	**0.9877**	0.9815	**0.9877**
Tizón Foliar (NCLB)	1 025	0.9797	0.9769	0.9728	**0.9811**
Mancha Gris (GLS)	290	**0.9451**	0.9194	0.9120	0.9388
Deficiencia de Fósforo	140	0.9403	0.9527	0.9275	**0.9632**
Deficiencia de Nitrógeno	127	0.8664	0.8939	0.8613	**0.9057**
Deficiencia de Potasio	93	0.8290	0.8208	0.7674	**0.8475**
Macro Promedio	**5 015**	0.9468	0.9483	0.9330	**0.9567**

CONCLUSIONES Y RECOMENDACIONES

Conclusiones

La presente investigación pasa de una prueba de concepto a un sistema de diagnóstico foliar de maíz que se ejecuta sin conexión en un teléfono. Por objetivo específico del Capítulo 1, se obtuvo lo siguiente:

- **Corpus:** 33 429 imágenes de 11 fuentes, con cero solapamiento por hash y por píxeles entre particiones.
- **Optimización:** 25 ensayos de Optuna con poda temprana (15 podados, 12.65 horas de GPU). El ganador rindió 0.49 pp menos en prueba y se conservó la configuración inicial.
- **Ensamble:** Macro F_1 de 0.9567 en la etapa 2 con votación suave.
- **Evaluación:** Macro F_1 de 0.6026 en validación agrupada por fuente frente a 0.9311 en la estratificada; la ablación dejó 79.46 % de exactitud al ocluir el centro y 42.25 % al ocluir la periferia.
- **Despliegue móvil:** Modelo Int8 de 3.74 MB, con 98 ms de preprocesado y 23 ms de inferencia en un teléfono de gama media.
- **Propuesta institucional:** Cinco recomendaciones para el MAG y el CENTA, al final de este capítulo.

Las conclusiones se detallan a continuación.

1. **Modelo oficial y su exportación móvil:** El modelo oficial (EfficientNet-Lite0, run `20260921_204608`) obtuvo un Macro F_1 de **0.9480** y una exactitud de 97.81 % sobre 5 015 imágenes de prueba, y 0.9435 $\pm$ 0.0052 con tres semillas. Su versión Int8 pesa **3.74 MB** (72.9 % menos que el punto de control FP32) y obtuvo un Macro F_1 de 0.9489, con 99.74 % de acuerdo con PyTorch. En el Motorola edge 40 neo la mediana fue de 98 ms de preprocesado y 23 ms de inferencia, y el teléfono reproduce las predicciones del Int8 del servidor en 143 de 143 imágenes.
2. **Generalización entre fuentes, limitación principal:** En 97 fotografías de campo externas el modelo acertó 41 (42 %) y el detector OOD rechazó 49. El Lite0 de agosto acertó 39, así que la brecha no se explica por el cambio de modelo. Coincide con la validación agrupada por fuente, donde el Macro F_1 baja de 0.9311 $\pm$ 0.0099 a 0.6026 $\pm$ 0.1240, y con LOSO: 0.9933 $\pm$ 0.0006 sin `maize-diseases` y 0.9019 $\pm$ 0.0044 sin `multicrop-disease-maiz`, fuentes que contienen solo tres clases cada una.

3. **Dependencia del fondo:** El *Disparate Impact Ratio* entre laboratorio y campo, calculado sobre las tres clases presentes en ambos entornos, es 0.9636 con el modelo oficial y supera el umbral de 0.80, pero no refleja la roya de campo, que con 16 imágenes obtiene $F_1 = 0{,}77$ frente a 0.998 en laboratorio. La ablación espacial dejó 79.46 % de exactitud al ocluir el centro y 42.25 % al ocluir la periferia. Es compatible con sensibilidad a la región periférica, pero las áreas visibles difieren y el experimento no separa el fondo de la hoja.

4. **Mitigación en la interfaz:** La aplicación incorporó un marco guía de captura y un detector OOD basado en distancia de Mahalanobis relativa, con umbral 106.37 (percentil 95 de validación). El detector rechazó las 5 imágenes sintéticas de prueba y 3.8 % de 500 imágenes válidas.

5. **Ensamble de la etapa 2:** El ensamble de EfficientNet-Lite0, EfficientNet-B0 y ShuffleNet-V2 alcanzó un Macro F_1 de 0.9567 en una partición que mezcla fuentes y con una sola semilla; no está desplegado. Bajo LOSO el recall de MLN baja a 0.79–0.81 en el ensamble y a 0.72–0.74 en Lite0.

Limitaciones

1. **Generalización:** Fuera de las fuentes de entrenamiento el desempeño cae, de modo que las cifras de la partición estratificada no describen el uso en campo. Además, ciertas fuentes aportan una sola patología y no se midió la similitud perceptual entre particiones.

2. **Cobertura y evidencia de campo:** La taxonomía no incluye la mancha de asfalto y no hay reportes locales de necrosis letal. Se desconocen el lugar, la fecha y el criterio de etiquetado de las 97 fotografías externas, y el sistema no se evaluó con productores.

3. **Dispositivo:** Las mediciones en teléfono provienen de un solo dispositivo de gama media.

4. **Alcance del diagnóstico:** El sistema indica la clase y no mide la severidad; la guía de tres niveles la compara el productor con su hoja.

5. **Búsqueda de hiperparámetros:** Se redujo a 25 ensayos y no se comparó con una búsqueda sin poda, de modo que el ahorro de la poda no se midió.

6. **Beneficio económico:** Al no existir una cuantificación nacional de pérdidas, el ahorro que el diagnóstico podría producir no se estimó.

7. **Licencias:** Tres fuentes (31.1 % del corpus) tienen licencia CC BY-NC-SA 4.0, por lo que el uso comercial y la redistribución requieren una revisión legal.

Trabajo futuro

- Reunir y etiquetar fotografías salvadoreñas con apoyo técnico del CENTA o del MAG, incluida la mancha de asfalto, documentando su procedencia, y reentrenar evaluando con fuentes completas retenidas.
- Medir cobertura y exactitud con distintos umbrales de rechazo y auditar la similitud perceptual entre particiones.
- Probar la aplicación con productores y asesores, y en teléfonos de gama baja.
- Reducir el tiempo de preprocesado en el teléfono.

Recomendaciones

Con base en los resultados, se proponen cinco recomendaciones dirigidas al Ministerio de Agricultura y Ganadería (MAG) y al Centro Nacional de Tecnología Agropecuaria y Forestal (CENTA), que responden a las limitaciones anteriores:

1. **Validación en campo antes de la adopción institucional:** Evaluar la aplicación con promotores del CENTA sobre fotografías propias de cada zona productora, dado que la exactitud en fotografías de campo externas fue de 42 % (Sección 3.2.3).
2. **Banco nacional participativo de datos agrícolas:** Financiar brigadas fotográficas junto a la Universidad de El Salvador para capturar variedades y condiciones locales, con el fin de reducir la brecha de dominio detectada.
3. **Red de alerta fitosanitaria temprana:** Evaluar el uso de los aportes voluntarios sincronizados para un tablero epidemiológico centralizado en el MAG, sujeto a una política explícita de tratamiento de metadatos y ubicación.
4. **Capacitación comunitaria:** Enseñar a cooperativas y ADESCOs el uso del marco guía de captura, posicionando la herramienta como apoyo al criterio del productor.
5. **Software abierto y protección de datos:** Conservar el software bajo licencias de código abierto y definir las condiciones de uso de los datos aportados por los productores.

BIBLIOGRAFÍA

[1] Ahmad, A., El Gamal, A., & Saraswat, D. (2023). Toward generalization of deep learning-based plant disease identification under controlled and field conditions. *IEEE Access*, 11, 9042–9057.

[2] Banco Central de Reserva de El Salvador (BCR). (2023). *Revista Económica: Aporte Agropecuario al Producto Interno Bruto 2022-2023*. San Salvador: BCR.

[3] Centro Nacional de Tecnología Agropecuaria y Forestal "Enrique Álvarez Córdova" (CENTA). (2022). *Guía técnica del cultivo de maíz en El Salvador*. San Salvador: CENTA / Gerencia de Investigación y Transferencia.

[4] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 248–255).

[5] Deras F., H. R., Flor de Serrano, R., Mejía, C., & Moreno, W. (2015). Evaluación de híbridos trilineales de maíz (*Zea mays* L.), por su reacción al Complejo Mancha de asfalto causada por los patógenos (*Phyllachora maydis*, *Monographella maydis* y *Coniothyrium phyllacorae*). *Producción Agropecuaria y Desarrollo Sostenible*, 3, 77–88. https://camjol.info/index.php/PAyDS/article/view/3973

[6] Diario El Mundo. (2025, 7 de febrero). El déficit de granos básicos supera los 9.9 millones de quintales en 2025. https://diario.elmundo.sv/economia/el-deficit-de-granos-basicos-supera-los-9-9-millones-de-quintales-en-2025

[7] Eash, L., Fonte, S. J., Sonder, K., Honsdorf, N., Schmidt, A., Govaerts, B., & Verhulst, N. (2019). Factors contributing to maize and bean yield gaps in Central America vary with site and agroecological conditions. *The Journal of Agricultural Science*, 157(4). https://doi.org/10.1017/S0021859619000571

[8] El Diario de Hoy. (2024, 4 de abril). Las altas temperaturas en El Salvador tendrán efecto en el ciclo agrícola 2024-2025. https://www.elsalvador.com/?p=1134038

[9] Howard, A. G., et al. (2017). MobileNets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*.

[10] Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 7132–7141).

[11] Jacob, B., Kligys, S., Chen, B., Zhu, M., Tang, M., Howard, A., Adam, H., & Kalenichenko, D. (2018). Quantization and training of neural networks for efficient integer-arithmetic-only inference. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 2704–2713).

[12] Lee, K., Lee, K., Lee, H., & Shin, J. (2018). A simple unified framework for detecting out-of-distribution samples and adversarial attacks. En *Advances in Neural Information Processing Systems (NeurIPS)*, 31.

[13] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 4765–4774.

[14] Ma, N., Zhang, X., Zheng, H.-T., & Sun, J. (2018). ShuffleNet V2: Practical guidelines for efficient CNN architecture design. En *Proceedings of the European Conference on Computer Vision (ECCV)* (pp. 116–131).

[15] Mahuku, G., Lockhart, B. E., Wanjala, B., Jones, M. W., Kimunye, J. N., Stewart, L. R., … & Redinbaugh, M. G. (2015). Maize lethal necrosis (MLN), an emerging threat to maize-based food security in sub-Saharan Africa. *Phytopathology*, 105(7), 956–965. https://doi.org/10.1094/PHYTO-12-14-0367-FI

[16] Ministerio de Agricultura y Ganadería (MAG). (2023). *Anuario de Estadísticas Agropecuarias y Seguridad Alimentaria en El Salvador 2022-2023*. San Salvador: MAG / Dirección General de Economía Agropecuaria.

[17] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)* (pp. 2623–2631).

[18] Mueller, M., & Hein, M. (2025). Mahalanobis++: Improving OOD detection via feature normalization. *arXiv preprint arXiv:2505.18032*.

[19] Ren, J., Fort, S., Liu, J., Roy, A. G., Padhy, S., & Lakshminarayanan, B. (2021). A simple fix to Mahalanobis distance for improving near-OOD detection. *arXiv preprint arXiv:2106.09022*.

[20] Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. En *ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)* (pp. 1135–1144).

[21] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 618–626).

[22] Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. En *International Conference on Machine Learning (ICML)* (pp. 6105–6114).

GLOSARIO DE TÉRMINOS

Clever Hans Effect: Fenómeno en el cual un modelo de aprendizaje automático alcanza una aparente alta precisión apoyándose en correlaciones espurias o atajos del entorno (fondos, sensores, marcas de agua) en lugar de las características intrínsecas de la clase.

Disparate Impact Ratio (DIR): Métrica de equidad que cuantifica el cociente entre el desempeño del grupo con peor resultado y el del mejor, aquí medido con Macro F_1 o exactitud. Un valor inferior a 0.80 se toma como indicio de trato dispar.

Macro F_1-Score: Media aritmética no ponderada del valor F_1 calculado independientemente para cada clase. Asigna el mismo peso relativo a clases minoritarias y mayoritarias, siendo la métrica estándar ante conjuntos desbalanceados.

Necrosis Letal del Maíz (MLN): Complejo viral provocado por la coinfección sinérgica del virus del moteado clorótico del maíz (MCMV) y un potyvirus (como SCMV), con pérdidas de rendimiento de hasta 90 % documentadas en Kenia en 2012.

Out-of-Distribution (OOD): Condición que presentan aquellas muestras alimentadas a un clasificador cuyas características estadísticas provienen de una distribución ajena a la utilizada durante el entrenamiento (ej. fotografiar una piedra o una mano frente a un modelo de hojas).

ANEXOS

Anexo A: Registro de Enlaces y Repositorios Abiertos del Proyecto

Los repositorios y recursos de **DoctorMaiz** son los siguientes:

- **Clasificador (*pipeline* de entrenamiento, evaluación y exportación):**

  `https://github.com/daiv05/maize-doctor-classifier`

- **Aplicación móvil DoctorMaiz (React Native, inferencia *offline*):**

  `https://github.com/Edenilson-Molina/maize-doctor-app`

- **API (cuenta de usuario, sincronización opcional y avisos de actualización):**

  `https://github.com/daiv05/maize-doctor-api`

- **Sitio web y documentación técnica:**

  `https://doctor-maiz.deras.dev/es`

- **Dataset consolidado en Hugging Face:**

  `https://huggingface.co/datasets/daiv05/corn-leaf-diseases-pests-and-deficiencies`

  Cada fuente conserva su licencia original (Tabla 2.2).

- **Artefactos de evaluación y modelos exportados:**

  `https://drive.google.com/drive/folders/1OeZdWggfp7nVkaYHW_oOuCma5xbwhns6?usp=drive_link`

Anexo B: Inventario Criptográfico de Checkpoints Respaldados

La tabla siguiente lista los hashes SHA-256 de los modelos que sustentan la reproducibilidad de la tesina.

Hashes SHA-256 de los pesos físicos de los modelos respaldados

Modelo / Protocolo	**Tamaño**	**Hash SHA-256 del Checkpoint (`best.pth`)**
EfficientNet-Lite0 Base (42, oficial)	13.79 MB	`860180f33bf1749ffee9f3cccb9569a47afd9ca0fcef52713e18f99f82a57859`
EfficientNet-Lite0 Int8 (Móvil, `model_int8.tflite`)	3.74 MB	`bb31467a58c11cd474159bd5739a7a57b1f1edfda6b5dbfae8fa91337f3c56b1`
EfficientNet-B0 Referencia	16.36 MB	`0e367a5318c068c9bcc90a6bec0d17a0b029251ca5f98400034bd09de7524fdb`