UNIVERSIDAD DE EL SALVADOR

FACULTAD DE INGENIERÍA Y ARQUITECTURA

ESCUELA DE INGENIERÍA DE SISTEMAS INFORMÁTICOS

CURSO DE ESPECIALIZACIÓN EN MACHINE LEARNING

DISEÑO E IMPLEMENTACIÓN DE DOCTOR MAÍZ: SISTEMA MÓVIL BASADO EN REDES NEURONALES CONVOLUCIONALES PARA LA IDENTIFICACIÓN FITOSANITARIA EN HOJAS DE MAÍZ Y CONTRIBUCIÓN A UN CONJUNTO DE DATOS NACIONAL

PRESENTADO POR:

JOSÍAS ABNER RIVAS FUENTES

DAVID ALEJANDRO DERAS CERROS

ELMER EDENILSON ROSALES MOLINA

PARA OPTAR AL TÍTULO DE:

INGENIERO(A) DE SISTEMAS INFORMÁTICOS

CIUDAD UNIVERSITARIA, 24 DE NOVIEMBRE DE 2026

UNIVERSIDAD DE EL SALVADOR

RECTOR:

MSC. JUAN ROSA QUINTANILLA

SECRETARIO GENERAL:

LCDO. PEDRO ROSALIO ESCOBAR CASTANEDA

FACULTAD DE INGENIERÍA Y ARQUITECTURA

DECANO:

MSC. LUIS SALVADOR BARRERA MANCÍA

SECRETARIO:

ARQ. RAÚL ALEXANDER FABIÁN ORELLANA

ESCUELA DE INGENIERIA DE SISTEMAS INFORMÁTICOS

DIRECTOR:

MSC. CESAR AUGUSTO GONZÁLEZ RODRÍGUEZ

UNIVERSIDAD DE EL SALVADOR

FACULTAD DE INGENIERIA Y ARQUITECTURA

ESCUELA DE INGENIERIA DE SISTEMAS INFORMÁTICOS

Trabajo de Graduación previo a la opción al Grado de:

INGENIERO (A) DE SISTEMAS INFORMÁTICOS

Título:

“DISEÑO E IMPLEMENTACIÓN DE DOCTOR MAÍZ: SISTEMA MÓVIL BASADO EN REDES NEURONALES CONVOLUCIONALES PARA LA IDENTIFICACIÓN FITOSANITARIA EN HOJAS DE MAÍZ Y CONTRIBUCIÓN A UN CONJUNTO DE DATOS NACIONAL”

Presentado por:

JOSÍAS ABNER RIVAS FUENTES

DAVID ALEJANDRO DERAS CERROS

ELMER EDENILSON ROSALES MOLINA

Trabajo de Graduación Aprobado por:

Docentes Asesores:

ING. BLADIMIR DIAZ CAMPOS

ING. KAREN ELVIRA PEÑATE AVILES

ING. RODRIGO ERNESTO VASQUEZ ESCALANTE

SAN SALVADOR, 24 DE NOVIEMBRE DE 2026

Trabajo de Graduación Aprobado por:

Docentes Asesores:

ING. BLADIMIR DIAZ CAMPOS

ING. KAREN ELVIRA PEÑATE AVILES

ING. RODRIGO ERNESTO VASQUEZ ESCALANTE

Agradecimientos

A Dios todopoderoso, por haberme concedido la perseverancia, la sabiduría y la fortaleza necesaria para afrontar cada desafío académico y culminar con éxito esta etapa de mi formación profesional.
A mi familia, por su apoyo incondicional, sus sacrificios y su constante motivación. Gracias por creer en mí en todo momento.
A mis compañeros de tesis y amigos, David y Elmer, por las muchas jornadas de discusión técnica, investigación y programación. Su compromiso y su esfuerzo hicieron posible este trabajo.
A la Universidad de El Salvador y a cada docente de la Escuela de Ingeniería de Sistemas Informáticos, por transmitirme con rigor y vocación los principios científicos que hoy me capacitan como profesional al servicio de la sociedad.

Josias Abner Rivas Fuentes

Agradecimientos

A Dios, por darme salud, fortaleza y la oportunidad de llegar hasta este momento.
A mis padres y hermanos, por su apoyo, paciencia y confianza durante todo este proceso. Gracias por acompañarme y motivarme a seguir adelante, incluso en los momentos difíciles.
A mis compañeros de equipo, Josias y Elmer, por el esfuerzo, la dedicación y el compromiso que compartimos durante el desarrollo de este proyecto. Gracias por el trabajo en equipo, las experiencias y todo lo aprendido en el camino.
A nuestros profesores y asesores, por compartir sus conocimientos, orientarnos y brindarnos su apoyo durante nuestra formación académica y el desarrollo de este trabajo.

David Alejandro Deras Cerros

Agradecimientos

Agradezco profundamente al Todopoderoso, por su gracia inmerecida, sabiduría que me concedió y fortaleza para superar cada desafío a lo largo de este proceso de formación. A él atribuyo la gloria de haber culminado con éxito esta etapa de mi vida académica y profesional.

Además, expreso mi sincero agradecimiento a mis padres, por el apoyo incondicional que me han demostrado en pequeños y grandes detalles. Su motivación constante y su confianza en mis capacidades fueron actos de amor que me ayudaron a vencer el cansancio y me hicieron recordar mis objetivos.

A mis compañeros de graduación, Josias y David, por su amistad. El trabajo en equipo se volvió una experiencia enriquecedora, y el entusiasmo inagotable con el que enfrentamos este reto nos dejó un gran aprendizaje. Reconozco el talento y dedicación que mostraron, que hicieron de cada desafío una oportunidad de crecimiento.

A la gloriosa Universidad de El Salvador, alma mater de generaciones, por abrirme sus puertas y formarme con sentido crítico y compromiso social. A todo el cuerpo docente, por su dedicación y entrega en la formación de profesionales competentes y comprometidos con la sociedad.

Elmer Edenilson Rosales Molina

Resumen Ejecutivo

El maíz es la base de la alimentación de las familias campesinas de El Salvador, y la mayoría de los productores trabaja parcelas pequeñas con poca asistencia técnica. Las enfermedades foliares, las plagas y las deficiencias nutricionales reducen el rendimiento si no se detectan a tiempo. Las herramientas de diagnóstico por visión artificial suelen exigir conexión a internet o teléfonos potentes, o fallan con fotografías distintas a las del entrenamiento.

Esta investigación presenta DoctorMaiz, una aplicación móvil que clasifica nueve condiciones de la hoja de maíz (enfermedades, una plaga y deficiencias nutricionales) con una red convolucional que se ejecuta en el propio teléfono y sin conexión. Incluye un marco guía para la captura, un detector de imágenes fuera de distribución (*Out-of-Distribution*, OOD) y un módulo opcional para aportar fotografías a un conjunto de datos nacional.

Se reunió un corpus de 33 429 imágenes de 11 repositorios internacionales, con control de integridad, revisión de duplicados y registro de la procedencia. El modelo oficial es un modelo EfficientNet-Lite0, que obtuvo un Macro F_1 de 0.9480 y una exactitud de 97.81 % en 5 015 imágenes de prueba ($0{,}9435 \pm 0{,}0052$ con tres semillas). La búsqueda de hiperparámetros con Optuna quedó como experimento complementario al no superar ese resultado en prueba, y se realizó también un ensamble de tres redes, dando como resultado un Macro F_1 de 0.9567.

La principal limitación es la generalización, en fotografías de campo ajenas al corpus el modelo acertó 41 (42 %) y el detector rechazó 49. La validación agrupada por fuente dio un Macro F_1 de $0{,}6026 \pm 0{,}1240$, frente a $0{,}9311 \pm 0{,}0099$ en la partición estratificada. La ablación espacial indica que el modelo se apoya en la periferia de la imagen: la exactitud fue de 79.46 % al ocluir el centro y de 42.25 % al ocluir la periferia.

El modelo se cuantizó a enteros de 8 bits (Int8) y pesa 3.74 MB, 72.9 % menos que en coma flotante, con un Macro F_1 de 0.9489 en la prueba completa. En un teléfono de gama media, las medianas fueron de 98 ms de preprocesado y 23 ms de inferencia. Con esto resultados se proponen cinco recomendaciones al Ministerio de Agricultura y Ganadería (MAG) y al CENTA: validación en campo, un banco nacional de datos, una red de alerta fitosanitaria, capacitación comunitaria y software abierto.

Índice general

1 Especificación del Proyecto **1**

1.1 Situación Actual 1

1.1.1 Antecedentes 1

1.1.2 Descripción del problema 1

1.1.3 Planteamiento del problema 2

1.2 Objetivos 3

1.2.1 Objetivo General 3

1.2.2 Objetivos Específicos 3

1.3 Alcance y Límites del Proyecto 4

1.3.1 Alcance del Proyecto 4

1.3.2 Límites del Proyecto 5

1.4 Hipótesis 5

1.4.1 Hipótesis General 5

1.4.2 Criterios de Éxito Específicos 6

1.5 Justificación 6

1.5.1 Justificación Técnica y Metodológica 6

1.5.2 Justificación Económica 7

1.5.3 Justificación Social y Ambiental 7

1.5.4 Justificación Académica e Institucional 7

1.6 Cronograma de Actividades 7

1.7 Presupuesto Global Estimado 9

2 Análisis y Diseño de la Solución **11**

2.1 Condiciones Agronómicas Objetivo 11

2.2 Recopilación, Depuración y Auditoría de Datos 13

2.2.1 Análisis Exploratorio 13

2.2.2 Auditoría de Duplicados y Partición 15

2.2.3 Trazabilidad de los Datos 15

2.3 Arquitecturas y Búsqueda de Hiperparámetros 15

2.3.1 Familias Convolucionales Seleccionadas 15

2.3.2 Espacio de Búsqueda y Poda Temprana . . . 16
2.3.3 Ensamble Multimodelo por Soft Voting . . . 16
2.4 Despliegue en Dispositivo Móvil . . . 16
2.4.1 Cuantización a Enteros de 8 Bits (Int8) . . . 16
2.4.2 Detector de Anomalías Fuera de Distribución (OOD) . . . 17
2.4.3 Mitigación en la Interfaz . . . 17
2.5 Sincronización y Aportes al Conjunto de Datos . . . 17
2.6 Arquitectura General del Sistema . . . 18

3 Estrategia de Implementación y Análisis de Resultados 20
3.1 Estrategia y Entorno de Implementación . . . 20
3.1.1 Infraestructura de Cómputo y Entrenamiento en la Nube . . . 20
3.2 Resultados . . . 21
3.2.1 Búsqueda Bayesiana de Hiperparámetros . . . 21
3.2.2 Generalización entre Fuentes . . . 22
3.2.3 Fotografías de Campo Externas . . . 25
3.2.4 Equidad entre Laboratorio y Campo . . . 25
3.2.5 Dependencia del Fondo . . . 27
3.2.6 Desempeño en el Teléfono . . . 29
3.2.7 Ensamble . . . 31
3.2.8 Síntesis de los Resultados . . . 33

Conclusiones y Recomendaciones 34

Bibliografía 37

Glosario de Términos 39

Anexos 40

Índice de tablas

1.1 Criterios de éxito del proyecto 6
1.2 Cronograma de actividades por fase (CRISP-DM), con horas por integrante 8
1.3 Presupuesto del proyecto (USD) 9

2.1 Taxonomía agronómica de las nueve clases 11
2.2 Fuentes de datos recopiladas, licencia declarada y distribución de muestras 13
2.3 Espacio de búsqueda de hiperparámetros explorado con Optuna 16
2.4 Tecnologías principales por proyecto 19

3.1 Estado de los criterios de éxito 21
3.2 Configuración inicial frente a la mejor configuración de Optuna 22
3.3 Validación cruzada de 5 pliegues con partición estratificada y agrupada por fuente 23
3.4 Macro F_1 y exactitud en la fuente retenida, evaluación LOSO con tres semillas 23
3.5 Aciertos del modelo oficial en fotografías de campo externas, por clase 25
3.6 Tasa de falsos negativos (FNR) por clase y entorno. 27
3.7 Exactitud al ocultar regiones de la imagen. 27
3.8 Latencias medianas en el Motorola edge 40 neo 29
3.9 Ensamble frente a modelos individuales en la prueba (5 015 imágenes) 31
3.10 F_1 por clase de los modelos individuales y del ensamble 33

Índice de figuras

1.1 Modelo conceptual de caja negra para el diagnóstico fitosanitario móvil. 3
1.2 Diagrama de Gantt del cronograma planificado (Metodología CRISP-DM) 8

2.1 Catálogo fotográfico de las nueve clases agronómicas presentes en el corpus. 12
2.2 Distribución del corpus por clase y por entorno de captura. 14
2.3 Distribución de imágenes por clase y fuente de origen. 14
2.4 Flujo de sincronización de un aporte. 18
2.5 Arquitectura del sistema DoctorMaiz. 19

3.1 Macro F_1 de validación y pérdida por época de las tres arquitecturas con la configuración inicial. 20
3.2 Resultados de la búsqueda con Optuna. 22
3.3 Efecto de la partición frente al ajuste de hiperparámetros. 24
3.4 Desempeño por entorno de captura. 26
3.5 Exactitud según la región visible de la imagen. 28
3.6 Mapas de activación Grad-CAM en imágenes de campo y de laboratorio. 28
3.7 Explicaciones locales de LIME, SHAP y Grad-CAM para la roya común. 29
3.8 Flujo principal de la aplicación DoctorMaiz. 30
3.9 Rechazo de imágenes, aportes y guía de severidad. 31
3.10 Desempeño del ensamble frente a los modelos individuales. 32
3.11 Matriz de confusión normalizada del ensamble sobre 5 015 imágenes de prueba. 32

CAPÍTULO 1

ESPECIFICACIÓN DEL PROYECTO

1.1. Situación Actual

1.1.1. Antecedentes

La agricultura representa el 5.6 % del Producto Interno Bruto (PIB) de El Salvador [2] y sostiene de forma directa a más de dos millones de personas en el sector rural. Para las familias campesinas salvadoreñas, el maíz (*Zea mays L.*) constituye la base diaria de la alimentación familiar, con un consumo promedio reportado que supera los 115 kilogramos por persona al año [3]. De acuerdo con registros oficiales del Ministerio de Agricultura y Ganadería [16], el 82.1 % de los productores nacionales trabajan pequeñas parcelas familiares menores a dos manzanas (1.4 hectáreas), bajo un régimen de agricultura de subsistencia dependiente casi por completo del régimen de lluvias estacionales.

En los últimos años esta producción ha quedado más expuesta a anomalías climáticas y a problemas fitosanitarios [16]. En una milpa con estrés hídrico o térmico también aparecen enfermedades foliares y plagas, y si una infección o un ataque no se atiende a tiempo, reduce el rendimiento de la cosecha.

Pese a esa importancia, el efecto de los problemas fitosanitarios sobre la producción nacional no está cuantificado, la información pública disponible no permite que se hagan estimaciones de cuánto maíz pierde El Salvador por enfermedades foliares, plagas o deficiencias nutricionales. Las pérdidas recientes mejor documentadas son de origen climático: en el ciclo 2023-2024 se reportaron unos 1.46 millones de quintales perdidos, el 9.8 % de los 14.9 millones producidos, con más de 24 % en cada departamento del oriente [8], y en el ciclo 2024-2025 la cosecha fue de 10.9 millones de quintales frente a 18.8 millones requeridos [6].

En el lado fitosanitario solo se dispone de evidencias puntuales: en un ensayo de híbridos del CENTA, los tres sitios con presión de mancha de asfalto rindieron cerca de 51 % menos que los sitios sin la enfermedad [5], y en un ensayo de 2017 en La Libertad el control optimizado de plagas y enfermedades elevó el rendimiento 15 % pero redujo la utilidad neta en US$395 por hectárea [7].

Esa falta de cifras es parte del problema, si no se tiene un registro de diagnósticos nadie puede decir qué enfermedades predominan en cada zona ni cuánto cuestan, al productor tiene que decidir sin tener alguna referencia.

1.1.2. Descripción del problema

En las parcelas rurales salvadoreñas no hay ayuda cercana o directa de especialistas, y el diagnóstico se hace a simple vista, el agricultor observa las manchas o el marchitamiento de la hoja e intenta reconocer

la causa. No es fácil, porque varias condiciones se parecen. Una hoja amarillenta puede deberse a falta de nitrógeno o a una virosis, y las lesiones del tizón foliar se confunden con las de la mancha gris. La Tabla 2.1 describe las nueve condiciones que cubre este trabajo.
La asistencia técnica pública no alcanza para cubrir esa necesidad, hay pocas personas con conocimientos en diagnóstico fitosanitario para todos los productores dispersos en el país, y una visita agronómica puede tardar semanas o no llegar mientras la enfermedades avanzan [3].
Ante el riesgo de perder la siembra, el agricultor suele acudir a un agroservicio, y sin un diagnóstico de por medio, la recomendación tiende a ser un agroquímico de amplio espectro, aun cuando los síntomas se deben a una deficiencia nutricional del suelo, entonces el productor paga por un producto que no resuelve el problema y se aplican químicos de más [3].

1.1.3. Planteamiento del problema

Los técnicos agrícolas no alcanzan para atender a todos los pequeños productores de maíz, y las herramientas digitales que existen se pensaron para condiciones distintas a las del campo salvadoreño, son costosas o resultan poco confiables. Las aplicaciones de diagnóstico por visión artificial suelen tener estas limitaciones:

1. Dependen de la conexión. La mayoría envía la fotografía a un servidor para procesarla. En muchas zonas rurales la cobertura celular es inestable o nula, de modo que no pueden ocupar la herramienta.

2. Exigen teléfonos potentes. Los modelos de aprendizaje profundo convencionales necesitan más memoria y cómputo de los que ofrecen los teléfonos de gama de entrada que usan las familias campesinas. El resultado son bloqueos, esperas largas y un consumo alto de batería.

3. Fallan con fotografías de campo. Se entrenaron sobre todo con imágenes de laboratorio, con fondo neutro y luz pareja. En la milpa aparecen suelo, sombras, maleza y contraluz, y el modelo se equivoca con frecuencia y con una confianza alta [1].

De ahí surge la pregunta de investigación:

> *¿En qué medida puede una aplicación móvil que funciona sin conexión, en teléfonos de gama baja o media, identificar problemas fitosanitarios en fotografías de hojas de maíz tomadas en campo, abstenerse cuando la imagen no es confiable y orientar al agricultor salvadoreño sobre el manejo de su cultivo?*

Modelo conceptual de caja negra del sistema

Para delimitar el problema el sistema se representa como una caja negra (Figura 1.1).

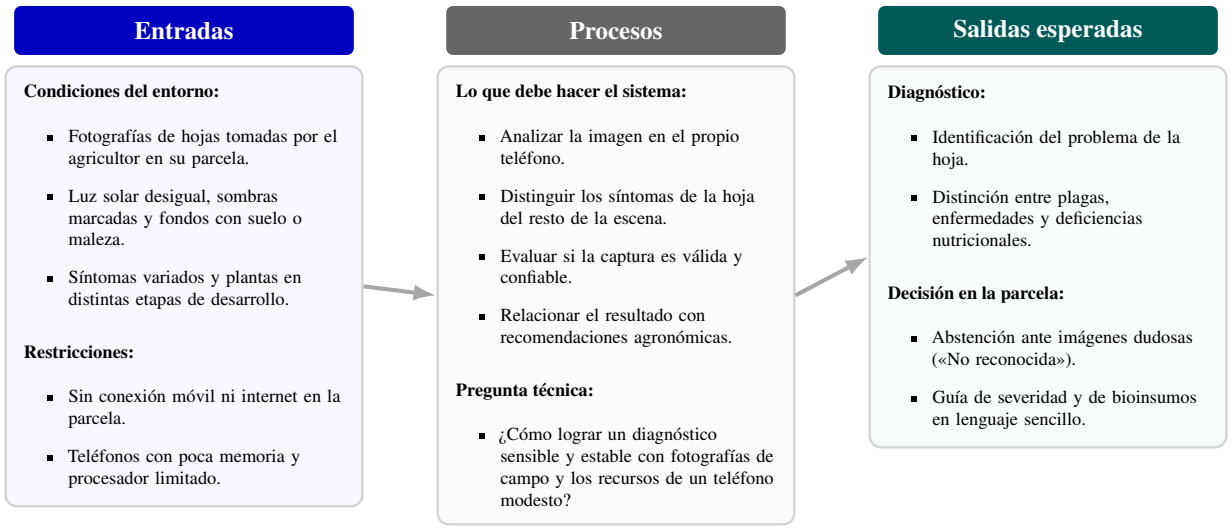


Figura 1.1: Modelo conceptual de caja negra para el diagnóstico fitosanitario móvil.

1.2. Objetivos

1.2.1. Objetivo General

Desarrollar y evaluar un sistema de visión artificial para el diagnóstico fitosanitario de la hoja de maíz en El Salvador, integrado en una aplicación móvil que funcione sin conexión en teléfonos de gama baja o media.

1.2.2. Objetivos Específicos

1. Reunir y depurar un corpus de imágenes de la hoja de maíz en nueve condiciones agronómicas a partir de repositorios públicos, con controles verificables que descarten duplicados y eviten que una misma imagen aparezca en más de una partición.

2. Ajustar una arquitectura convolucional ligera preentrenada mediante búsqueda bayesiana de hiperparámetros (Optuna) con poda temprana, y comprobar si mejora el Macro F_1 de la configuración inicial.

3. Evaluar un ensamble por votación suave (*Soft Voting*) de modelos con arquitecturas distintas, para medir si aumenta la sensibilidad (*recall*) en las enfermedades más graves y en las clases con menos imágenes.

4. Evaluar la generalización del modelo con una validación que separe las fuentes de entrenamiento y de evaluación, con la comparación entre imágenes de laboratorio y de campo, y con un análisis de las regiones de la imagen en que se apoya.

5. Integrar el modelo, cuantizado a enteros de 8 bits (Int8), en una aplicación móvil con apoyo para la captura y un mecanismo de rechazo de imágenes no válidas, y medir su exactitud y su latencia en el teléfono.
6. Incorporar en la aplicación un módulo de aportes voluntarios con el que los productores puedan enviar fotografías etiquetadas de sus parcelas, como base para un conjunto de datos nacional.
7. Formular recomendaciones al Ministerio de Agricultura y Ganadería (MAG) y al CENTA sobre las condiciones para incorporar la herramienta al acompañamiento técnico de los pequeños productores de maíz.

1.3. Alcance y Límites del Proyecto

1.3.1. Alcance del Proyecto

El proyecto abarca el diseño, el desarrollo y la evaluación de una herramienta de diagnóstico fitosanitario para los pequeños productores de maíz en El Salvador. Tiene dos componentes: la aplicación móvil que usa el agricultor y el modelo de visión artificial que se ejecuta dentro de ella.

Alcance de la Aplicación Móvil (DoctorMaiz)

La aplicación incluye:

- **Diagnóstico sin conexión.** El modelo cuantizado se ejecuta en el procesador del teléfono, sin internet ni datos móviles.
- **Captura con marco guía.** La cámara muestra un marco con la silueta de la hoja para que el agricultor la encuadre y deje fuera la mayor parte del suelo, las sombras y la maleza.
- **Rechazo de imágenes dudosas.** Si la captura no parece una hoja de maíz o el modelo no está seguro, la aplicación muestra «No reconocida» en lugar de un diagnóstico.
- **Resultado y guía de severidad.** El resultado se presenta con una explicación sencilla, con una guía visual de tres niveles (baja, moderada y crítica) que el productor compara con su hoja, la aplicación no mide el daño ni la severidad..
- **Historial.** Cada evaluación se guarda en el teléfono con fecha, diagnóstico, severidad y ubicación GPS, para que el agricultor siga la evolución de su parcela durante el ciclo.
- **Aportes voluntarios.** El usuario puede guardar fotografías en el teléfono y enviarlas cuando tenga conexión, con el fin de formar un conjunto de datos nacional que sirva para entrenar modelos futuros.

Alcance del Componente de Inteligencia Artificial

El componente de inteligencia artificial abarca:

- **Nueve clases.** Tres enfermedades causadas por hongos (tizón foliar, mancha gris y roya común), una virosis (necrosis letal del maíz), una plaga (gusano cogollero), tres deficiencias nutricionales (nitrógeno, fósforo y potasio) y la hoja sana.
- **Entrenamiento y exportación.** Búsqueda de hiperparámetros con Optuna y poda temprana, un ensamble por votación suave (*Soft Voting*) y cuantización a 8 bits en formato TensorFlow Lite con litert-torch, con una meta de 300 ms o menos para preprocesado e inferencia en el teléfono.
- **Evaluación de sesgos.** Validación cruzada agrupada por procedencia (*SourceGroupedKFold*) y ablación espacial, para detectar si el modelo se apoya en atajos visuales del fondo (efecto *Clever Hans*).

1.3.2. Límites del Proyecto

El proyecto tiene los siguientes límites:

- El sistema analiza solo síntomas visibles en la lámina de la hoja. No cubre enfermedades de la raíz, daños internos del tallo sin síntomas en la hoja ni plagas del suelo.
- La aplicación funciona solo en Android. Requiere Android 7.0 (API 24) o superior, procesador ARM (v7 o v8), cámara trasera con enfoque automático y al menos 4 GB de RAM. Las pruebas en dispositivo se hicieron en Android 15. No hay versión para iOS.
- El diagnóstico no usa servicios en la nube y no hay sincronización en tiempo real entre varios teléfonos.
- La aplicación orienta al productor, pero no reemplaza los análisis de laboratorio, ni los dictámenes oficiales de cuarentena o certificación fitosanitaria del MAG.
- El corpus procede de 11 repositorios públicos internacionales y no incluye fotografías salvadoreñas. El sistema reconoce solo las nueve clases de ese corpus, por lo que quedan fuera otras enfermedades presentes en el país, como la mancha de asfalto. La aplicación tampoco se probó con productores.

1.4. Hipótesis

1.4.1. Hipótesis General

Un modelo convolucional ligero, cuantizado a enteros de 8 bits y ejecutado sin conexión en un teléfono de gama baja o media, puede clasificar nueve condiciones de la hoja de maíz con un Macro F_1 de al menos

0.85 en una partición de prueba retenida, con 300 ms o menos de preprocesado e inferencia y con un desempeño comparable entre imágenes de laboratorio y de campo. La hipótesis se considera aceptada si se cumplen los criterios de la Tabla 1.1.

1.4.2. Criterios de Éxito Específicos

Tabla 1.1: Criterios de éxito del proyecto

Tema	**Criterio y umbral**	**Métrica**
Rendimiento del modelo	Alcanzar Macro $F_1 \geq 0{,}85$ en la partición de prueba retenida.	Macro F_1
Equidad entre entornos	Mantener un *Disparate Impact Ratio* $\geq 0{,}80$ entre laboratorio y campo real.	DIR
Confiabilidad de la evaluación	Ninguna imagen del conjunto de prueba aparece en entrenamiento ni validación, por hash de archivo y por píxeles.	Solapamiento por SHA-256 y por píxeles
Despliegue en el teléfono	Modelo Int8 de 20 MB o menos, preprocesado e inferencia de 300 ms o menos en un teléfono de gama media o baja y funcionamiento sin conexión.	Tamaño, latencia

1.5. Justificación

1.5.1. Justificación Técnica y Metodológica

La mayoría de los sistemas de diagnóstico foliar por visión artificial procesan la imagen en un servidor, y en las zonas rurales la conexión falla con frecuencia. El diagnóstico tiene que hacerse entonces en el propio teléfono, algo posible con arquitecturas convolucionales diseñadas para dispositivos móviles [9, 22] y con la cuantización a enteros de 8 bits [11].

Además, muchos modelos agrícolas se evalúan con particiones aleatorias de un mismo repositorio, donde el modelo puede apoyarse en el fondo o en la cámara en lugar de la lesión [1]. Un resultado alto obtenido así no garantiza que funcione con fotografías de otra procedencia. Por eso el proyecto incorpora una auditoría de duplicados, una validación que separa las fuentes, mapas de activación [21] y un detector de imágenes que no corresponden a una hoja de maíz [12].

Tampoco hay imágenes salvadoreñas etiquetadas: el corpus reúne 33 429 imágenes de 11 repositorios internacionales y ninguna del país. Por eso la aplicación incluye un módulo de aportes voluntarios, con el que podría formarse con el tiempo un conjunto de datos nacional.

1.5.2. Justificación Económica

La mayoría de los productores de maíz trabaja parcelas pequeñas con márgenes pequeños [16], de modo que un gasto mal hecho puede afectar en gran medida la economía del hogar. Un diagnóstico equivocado puede llevar a comprar un agroquímico que no corresponde, por ejemplo un fungicida para lo que en realidad es una deficiencia nutricional, entonces una aplicación gratuita que funciona en el teléfono del agricultor orienta esa decisión antes de la compra y ayuda a actuar a tiempo contra plagas como el gusano cogollero (*Spodoptera frugiperda*) [3].

1.5.3. Justificación Social y Ambiental

Muchas comunidades rurales tienen poco acceso a apoyo agronómico presencial [3]. Una herramienta que funciona sin conexión en un teléfono de gama baja o media pone información técnica al alcance del productor en su parcela, en un lenguaje que puede entender sin formación especializada. En lo ambiental, un diagnóstico más preciso favorece un mejor manejo de plagas y puede reducir la aplicación de pesticidas cuando no hacen falta.

1.5.4. Justificación Académica e Institucional

Para la Escuela de Ingeniería de Sistemas Informáticos de la Universidad de El Salvador, el proyecto aplica el aprendizaje profundo embebido a un problema del agro nacional y deja disponibles el código, el corpus consolidado y los modelos. Además, documenta un procedimiento de evaluación (auditoría de duplicados, validación por fuente y análisis de la dependencia del fondo) que puede reutilizarse en otros sistemas de visión artificial con poca capacidad de cómputo y conectividad limitada.

1.6. Cronograma de Actividades

El proyecto se organizó según las fases de *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*), con una fase adicional para el desarrollo de la aplicación móvil. Abarca 32 semanas, del 14 de abril al 24 de noviembre de 2026. La Figura 1.2 muestra el diagrama de Gantt y la Tabla 1.2 detalla la duración, las horas y el entregable de cada fase.

Figura 1.2: Diagrama de Gantt del cronograma planificado (Metodología CRISP-DM)

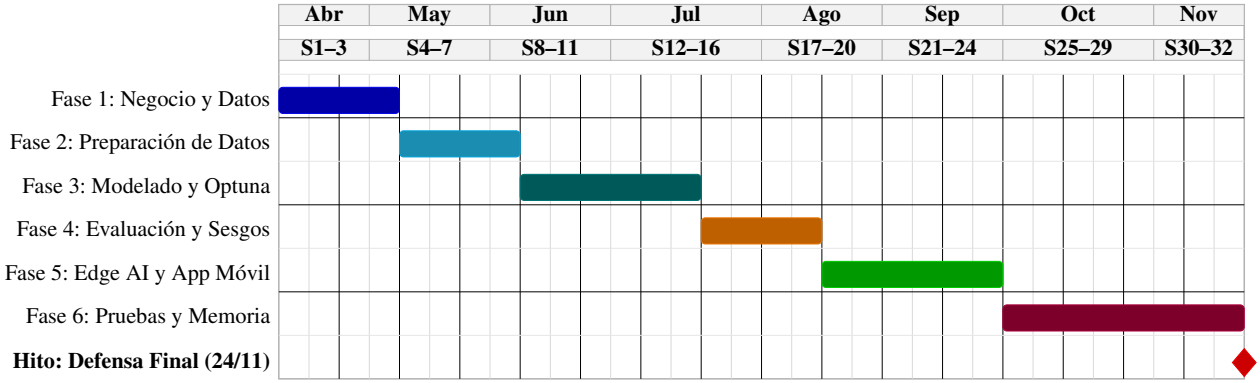


Tabla 1.2: Cronograma de actividades por fase (CRISP-DM), con horas por integrante

Fase	Inicio	Fin	Semanas	Horas	Entregable principal
Fase 1: Comprensión del negocio y de los datos	14/04/26	12/05/26	4	40 h	Requisitos fitosanitarios y selección de repositorios públicos.
Fase 2: Preparación de datos	12/05/26	09/06/26	4	40 h	Corpus consolidado, auditoría de duplicados, balanceo y aumento de datos.
Fase 3: Modelado	09/06/26	21/07/26	6	60 h	Modelos ligeros con transferencia de aprendizaje y búsqueda de hiperparámetros.
Fase 4: Evaluación	21/07/26	18/08/26	4	40 h	Comparación de modelos, evaluación por fuente y en campo, y análisis de explicabilidad.
Fase 5: Despliegue y aplicación móvil	18/08/26	29/09/26	6	60 h	Modelo cuantizado a Int8 y aplicación móvil con inferencia local.
Fase 6: Pruebas finales y memoria	29/09/26	24/11/26	8	80 h	Pruebas en dispositivo físico, memoria técnica y defensa.
Defensa del proyecto	**24 de noviembre de 2026**		**32**	**320 h**	**Sistema DoctorMaiz y memoria final**

1.7. Presupuesto Global Estimado

El presupuesto se organiza en cuatro rubros: el recurso humano, el entrenamiento de los modelos, la inferencia y el despliegue (Tabla 1.3).

Tabla 1.3: Presupuesto del proyecto (USD)

Rubro	**Detalle**	**Costo**
Recurso humano		
Ingeniero de Datos / MLOps	320 h	$3,380.77
Investigador de Deep Learning	320 h	$3,056.53
Desarrollador Móvil Edge AI	320 h	$2,840.39
Entrenamiento		
GPU NVIDIA A10G en Modal	Modelos de referencia, entrenamiento principal, búsqueda de hiperparámetros y experimentos de validación	$250.00
Inferencia		
Inferencia en el teléfono	Sin servidor de inferencia	$0.00
Dispositivo de prueba	Motorola edge 40 neo, aportado por un integrante	$0.00
Despliegue (agosto a noviembre de 2026)		
Servidor Hetzner	API, base de datos y sitio web ($6.00 al mes durante 4 meses)	$24.00
Volumen Hetzner de 100 GB	Fotografías aportadas y respaldos ($7.67 al mes durante 4 meses)	$30.68
Dominio	Registro anual	$12.00
Distribución	APK en GitHub Releases, dataset en Hugging Face	$0.00
Total		**$9,594.37**

Recurso humano

Los salarios mensuales de referencia ($1,500, $1,350 y $1,250) son el punto medio de la escala del sector público salvadoreño para perfiles equivalentes. Se estimó una dedicación de 2 horas diarias de lunes a viernes por integrante (10 horas semanales), que suman 320 horas en las 32 semanas del cronograma (Tabla 1.2).

Entrenamiento

Todo el entrenamiento se ejecutó en GPU NVIDIA A10G de la plataforma Modal, con un presupuesto de $250 en créditos. Ese monto cubrió los modelos de referencia iniciales, el entrenamiento del modelo

oficial, la búsqueda de hiperparámetros con Optuna y los experimentos de validación por fuente, con varias semillas y de explicabilidad. El entrenamiento es un costo de una sola vez: una vez exportado, el modelo no requiere más GPU.

Inferencia

El modelo se ejecuta en el procesador del teléfono, de modo que cada diagnóstico no tiene costo de servidor ni consume datos móviles. El costo de inferencia no crece con el número de usuarios, lo que hace viable distribuir la aplicación de forma gratuita. Las pruebas en dispositivo se hicieron con un teléfono de gama media propiedad de un integrante del equipo.

Despliegue y operación

La API de sincronización, su base de datos y el sitio web del proyecto comparten un servidor en Hetzner, con un volumen adicional de 100 GB para las fotografías aportadas por los usuarios. El APK se compila y publica en GitHub Releases mediante GitHub Actions, y el corpus consolidado se distribuye en Hugging Face, ambos sin costo. Mantener el sistema en operación cuesta $176.04 al año ($72.00 de servidor, $92.04 de volumen y $12.00 de dominio).

CAPÍTULO 2

ANÁLISIS Y DISEÑO DE LA SOLUCIÓN

2.1. Condiciones Agronómicas Objetivo

El sistema clasifica la hoja de maíz en nueve categorías mutuamente excluyentes (Tabla 2.1): tres enfermedades causadas por hongos, un complejo viral, una plaga, tres deficiencias nutricionales y la hoja sana.

Tabla 2.1: Taxonomía agronómica de las nueve clases

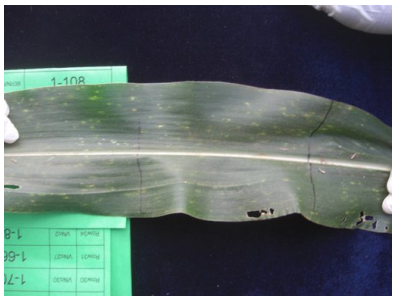
Clase Agronómica	**Agente Causal / Tipo**	**Síntoma Primario**	**Consecuencia en el cultivo**
Roya Común	*Puccinia sorghi* (Hongo)	Pústulas pulverulentas castaño-rojizas en ambas caras.	Reducción del área foliar activa.
Tizón Foliar (NCLB)	*Exserohilum turcicum* (Hongo)	Lesiones alargadas en forma de cigarro o huso (grises).	Necrosis de la lámina, con mayor daño si aparece antes de la floración.
Mancha Gris (GLS)	*Cercospora zeae-maydis* (Hongo)	Manchas rectangulares delimitadas por venas secundarias.	Destrucción del follaje y menor llenado del grano.
Necrosis Letal (MLN)	Complejo viral sinérgico (MCMV + Potyvirus)	Clorosis severa, moteado, necrosis marginal y secado total.	Secado prematuro de la planta y pérdida severa del rendimiento [15].
Gusano Cogollero	*Spodoptera frugiperda* (Plaga/Insecto)	Perforaciones irregulares y excrementos en el cogollo.	Daño al cogollo y al punto de crecimiento.
Deficiencia de Nitrógeno	Desbalance nutricional abiótico	Clorosis en “V” invertida desde la punta hacia la base.	Reducción de porte, espigas pequeñas y bajo llenado.
Deficiencia de Fósforo	Desbalance nutricional abiótico	Coloración púrpura o rojiza en bordes de hojas jóvenes.	Retraso radicular y esterilidad parcial de la mazorca.
Deficiencia de Potasio	Desbalance nutricional abiótico	Clorosis y necrosis marginal desde el ápice foliar.	Acame o volcamiento del tallo y grano liviano.
Planta Sana (Healthy)	Control agronómico	Lámina foliar verde homogénea sin lesiones ni plagas.	Crecimiento óptimo según potencial genético del cultivar.



a) Roya Común



b) Tizón Foliar



c) Mancha Gris



d) Necrosis Letal



e) Gusano Cogollero



f) Deficiencia N



g) Deficiencia P



h) Deficiencia K



i) Planta Sana

Figura 2.1: Catálogo fotográfico de las nueve clases agronómicas presentes en el corpus.

2.2. Recopilación, Depuración y Auditoría de Datos

El corpus final reúne 33 429 imágenes de 11 fuentes públicas (Tabla 2.2).

Tabla 2.2: Fuentes de datos recopiladas, licencia declarada y distribución de muestras

Identificador de Fuente (`source_id`)	**Licencia declarada**	**Muestras**	**Entorno**	**Clases aportadas**
`maize-beans-tomatoes-africa`	Apache 2.0 y CC	12 136	Campo real	4 clases.
`maize-diseases`	CC BY-NC-SA 4.0	6 989	Mixto	3 clases.
`multicrop-disease-maiz`	CC BY 4.0	5 816	Mixto	3 clases.
`corn-leaf-roboflow`	CC BY 4.0	2 919	Campo real	6 clases.
`cropdg-unified-multidomain`	CC BY-NC-SA 4.0	2 562	Mixto	3 clases.
`maize-in-field-dataset`	CC BY-NC-SA 4.0	852	Campo real	3 clases.
`maize-2-roboflow`	CC BY 4.0	846	Campo real	3 clases.
`corn-leaf-diseases-classification-roboflow`	CC BY 4.0	480	Mixto	1 clase.
`maize-nutrient-deficiency`	CC BY 4.0	340	Campo real	4 clases.
`maize-leaf-roboflow`	CC BY 4.0	331	Campo real	1 clase.
`maize-deficiency-scanner-roboflow`	CC BY 4.0	158	Campo real	3 clases.
Total	—	**33 429**	—	**9 clases agronómicas**

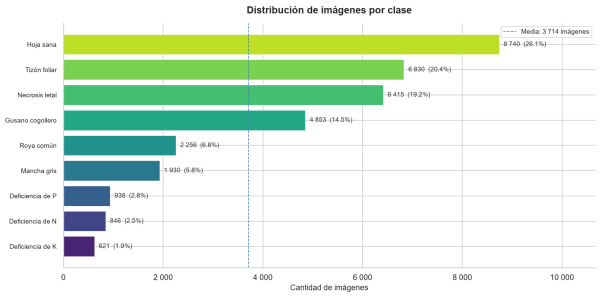
La licencia es la declarada por cada repositorio de origen.

2.2.1. Análisis Exploratorio

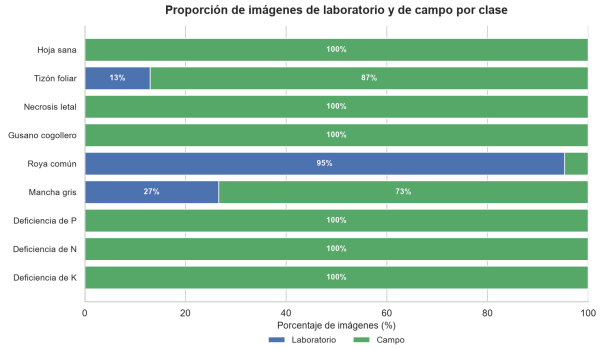
El corpus está fuertemente desbalanceado. La clase sana tiene cerca de 8 700 imágenes y el tizón foliar cerca de 6 800, mientras que la deficiencia de potasio tiene 621, una relación de 14.1:1 (Figura 2.2). Las resoluciones también varían mucho y se agrupan en tres rangos: alrededor de 256 píxeles en las imágenes de laboratorio, alrededor de 640 en las de Roboflow y las deficiencias nutricionales, y entre 3 000 y 5 000 en varias fuentes de campo. Todas se reducen a 224×224 antes de entrar al modelo, de modo que las fotografías grandes pierden parte del detalle fino de las lesiones.

Solo tres clases tienen imágenes de laboratorio, tomadas sobre un fondo controlado: la roya común (95 % de sus imágenes, 2 150 de 2 256), la mancha gris (27 %) y el tizón foliar (13 %). Las otras seis clases son por completo de campo. En conjunto, el laboratorio aporta 3 551 imágenes, el 10.6 % del corpus. Esta composición condiciona la evaluación del Capítulo 3: la comparación entre laboratorio y campo solo

puede hacerse en esas tres clases, y la roya, con apenas 106 imágenes de campo, es la clase con más riesgo de fallar en campo.



a) Imágenes por clase.



b) Laboratorio y campo por clase.

Figura 2.2: Distribución del corpus por clase y por entorno de captura.

Además, la procedencia (la fuente de donde proviene la imagen) y la etiqueta (a que clase pertenece) están asociadas: varias fuentes aportan una sola clase, y una sola fuente, `maize-beans-tomatoes-africa`, aporta 12 136 imágenes, el 36.3 % del corpus (Figura 2.3). Con esa asociación, un modelo puede aprender rasgos propios de cada fuente, como el fondo o la cámara, además de la lesión.

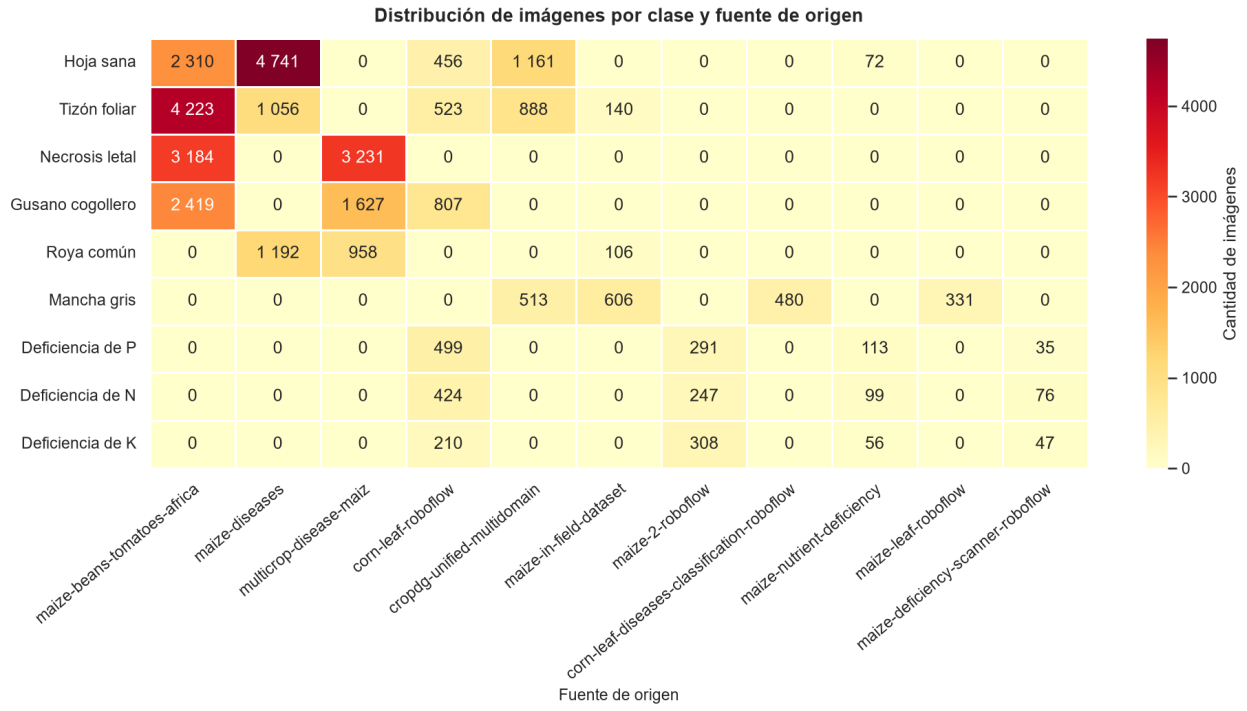


Figura 2.3: Distribución de imágenes por clase y fuente de origen.

2.2.2. Auditoría de Duplicados y Partición

Los repositorios públicos redistribuyen con frecuencia el mismo material, así que la primera depuración se hizo al reunir el corpus. Cada clase se revisó con un hash perceptual (PHash), que agrupa las imágenes visualmente idénticas, y se conservó una sola copia de cada grupo. En las primeras etapas se detectaron más de 8 000 imágenes repetidas, cerca de la mitad de tizón foliar, en una ampliación posterior del corpus se eliminaron otras 61 de las 1 876 imágenes incorporadas.
Sobre el corpus ya depurado se hizo una auditoría final, en la que cada imagen se comparó con el resto mediante dos hashes SHA-256, uno del archivo y otro de los píxeles decodificados. No quedó ningún duplicado, salvo cuatro pares de imágenes idénticas con etiquetas contradictorias, que se excluyeron luego del corpus.
La partición oficial reparte las 33 429 imágenes en 70/15/15, estratificada por clase y entorno: 23 400 de entrenamiento, 5 014 de validación y 5 015 de prueba.

2.2.3. Trazabilidad de los Datos

Cada imagen del corpus tiene un registro con un identificador único, la huella SHA-256 del archivo, la fuente de la que proviene y el entorno de captura (laboratorio o campo). El identificador se calcula a partir de la ruta de la imagen, de modo que una misma imagen conserva su identidad en cualquier ejecución. La huella permite detectar si un archivo cambió entre versiones del corpus, y la fuente y el entorno permiten formar las particiones agrupadas del Capítulo 3.
Las listas de entrenamiento, validación y prueba se guardaron con su propia huella, de modo que cada experimento puede comprobar que usa exactamente la misma partición.
Lo que se busca es que las ejecuciones puedan tener trazabilidad y ofrecer mayor fiabilidad en los resultados, de modo que puedan ser reproducidos y auditados.

2.3. Arquitecturas y Búsqueda de Hiperparámetros

2.3.1. Familias Convolucionales Seleccionadas

Se compararon tres redes convolucionales ligeras, preentrenadas en ImageNet [4], con diseños distintos:

1. **EfficientNet-Lite0**, es la variante de EfficientNet para móviles: sustituye la activación *swish* por ReLU6 y elimina los bloques *Squeeze-and-Excitation* (SE) [10], lo que facilita la cuantización a enteros. Tiene 3.38 millones de parámetros [22].

2. **EfficientNet-B0**, la versión original, con escalado compuesto y bloques SE. Con 4.02 millones de parámetros.

3. **ShuffleNet-V2-x1.0**, que divide y baraja los canales (*channel split* y *channel shuffle*) para reducir los accesos a memoria. Es la más pequeña, con 1.26 millones de parámetros [14].

2.3.2. Espacio de Búsqueda y Poda Temprana

La búsqueda de hiperparámetros se hizo con Optuna [17], usando el estimador de árbol de Parzen multivariado (TPE), con el objetivo de maximizar el Macro F_1 de validación. Para no gastar GPU en configuraciones poco prometedoras se usó *MedianPruner*: tras cinco ensayos iniciales y a partir de la época 8, un ensayo se detiene si su Macro F_1 queda por debajo de la mediana de los ensayos anteriores en la misma época. La Tabla 2.3 muestra los seis hiperparámetros explorados.

Tabla 2.3: Espacio de búsqueda de hiperparámetros explorado con Optuna

Hiperparámetro	**Rango / Opciones**
`learning_rate`	Log-uniforme: $[10^{-5}, 3 \times 10^{-3}]$
`batch_size`	Categórico: $\{16, 32, 64\}$
`weight_decay`	Log-uniforme: $[10^{-7}, 10^{-2}]$
`class_weights`	Categórico: $\{\text{none}, \text{inverse}, \text{sqrt_inverse}\}$
`label_smoothing`	Categórico: $\{0, 0{,}025, \ldots, 0{,}15\}$ en pasos de 0.025
`warmup_epochs`	Entero: $[1, 5]$

2.3.3. Ensamble Multimodelo por Soft Voting

El ensamble promedia las probabilidades de las tres redes, entrenadas por separado, para que los errores de una arquitectura se compensen con las otras:

$$P_{\text{ens}}(y = c \mid x) = \frac{1}{M} \sum_{m=1}^{M} P_m(y = c \mid x) \tag{2.1}$$

donde $M = 3$ es el número de redes y $c \in \{1, \ldots, 9\}$. La clase predicha es la de mayor probabilidad promedio: $\hat{y} = \arg\max_c P_{\text{ens}}(y = c \mid x)$.

2.4. Despliegue en Dispositivo Móvil

2.4.1. Cuantización a Enteros de 8 Bits (Int8)

Para que el modelo funcione en teléfonos de forma eficiente, se decidió realizar una cuantización a enteros de 8 bits después del entrenamiento (*Post-Training Quantization*, PTQ) [11] y se exportó a TensorFlow

Lite con litert-torch. Los pesos $W_{f,c,i}$ de cada canal de salida c se escalan por separado:

$$S_c = \frac{\max_i |W_{f,c,i}|}{127}, \qquad q_{c,i} = \mathrm{clip}\left(\left\lfloor \frac{W_{f,c,i}}{S_c} \right\rceil , \; -127, \; 127 \right) \tag{2.2}$$

2.4.2. Detector de Anomalías Fuera de Distribución (OOD)

El modelo siempre responde con alguna de las clases que aprendió, aunque la fotografía no tenga relación con el maíz. Si se le muestra suelo o un zapato, elegirá de todos modos una enfermedad, a veces incluso con mucha seguridad, porque solo puede repartir su confianza entre las etiquetas que conoce [12]. Por eso, antes de mostrar un diagnóstico, la aplicación comprueba si la imagen se parece a las que el modelo vio durante el entrenamiento.

Para hacerlo aprovecha la descripción numérica que la red construye de cada imagen justo antes de clasificarla, una especie de huella de su contenido. Durante el entrenamiento se registra en qué zona se agrupan las huellas de cada clase. Cuando llega una fotografía nueva, se mide qué tan lejos queda su huella del grupo más cercano con la distancia de Mahalanobis, que considera cuánto varían normalmente las imágenes de ese grupo [18]. A esa medida se le resta la distancia al conjunto completo de entrenamiento, para no castigar rasgos que comparte cualquier fotografía, como la iluminación o el encuadre [19].

El límite de aceptación se fijó de modo que el 95 % de las imágenes del conjunto de validación quede por debajo de él. Además, el diagnóstico se descarta cuando el modelo duda: si la enfermedad más probable no alcanza el 60 % de confianza o aventaja a la segunda por menos de 15 puntos. En cualquiera de estos casos la aplicación muestra «Imagen no reconocida» y no emite diagnóstico.

2.4.3. Mitigación en la Interfaz

La interfaz incorpora dos elementos que complementan al modelo:

1. **Marco guía.** La cámara muestra la silueta de una hoja (*Acérquese a 20–30 cm y llene el marco*) y la imagen se recorta a esa región, con un margen de 15 %, antes de pasar al modelo.

2. **Guía de severidad.** Debajo del diagnóstico se muestra una escala de tres niveles (baja, moderada y crítica), basada en escalas del CIMMYT y de Iowa State University Extension, que el productor compara con su hoja, junto con bioinsumos disponibles en el agroservicio.

2.5. Sincronización y Aportes al Conjunto de Datos

La aplicación no necesita un servidor para diagnosticar, por eso el servidor en la nube solo interviene cuando el productor decide compartir información, y para eso debe crear una cuenta. Puede enviar una corrección, si considera que el diagnóstico fue equivocado, o una fotografía con la etiqueta que él mismo

le asigna, que pasa a formar parte del conjunto de datos colaborativo. Con la fotografía solo viajan la etiqueta, una nota opcional y la fecha.
Como en la parcela puede no haber señal, cada aporte se guarda primero en el teléfono y se envía después, cuando vuelve la conexión o cuando el usuario lo pide (Figura 2.4). En el servidor, la API (FastAPI con MySQL 8.4) rechaza los envíos repetidos y acepta como máximo 30 solicitudes por minuto, para evitar abusos y proteger la base de datos.

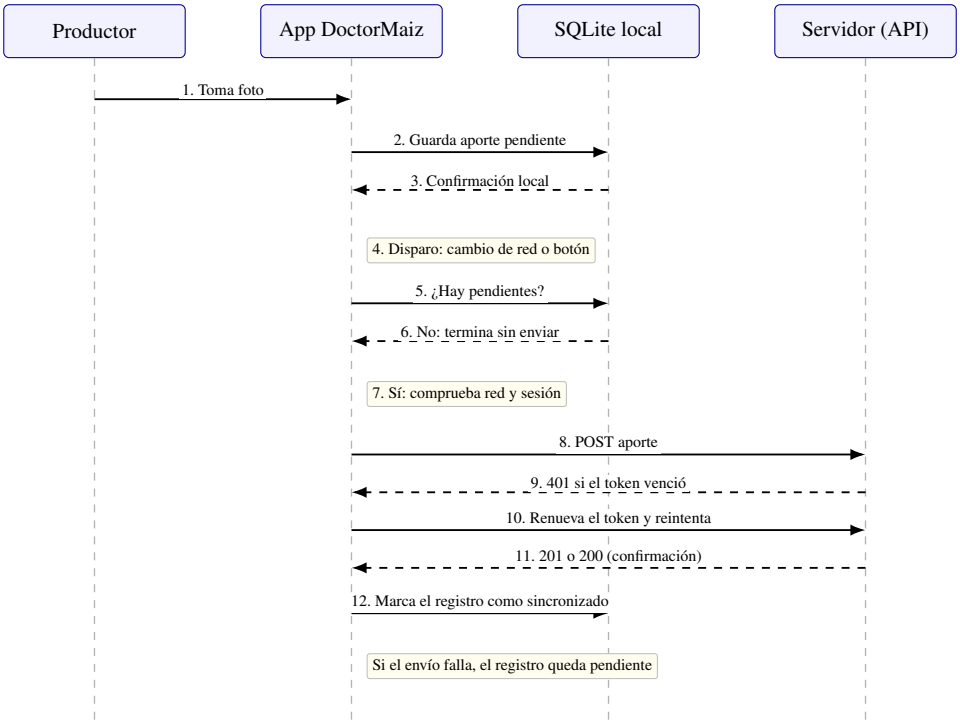


Figura 2.4: Flujo de sincronización de un aporte.

2.6. Arquitectura General del Sistema

El sistema se compone de tres repositorios independientes (Tabla 2.4).

Tabla 2.4: Tecnologías principales por proyecto

Proyecto	**Función**	**Tecnologías**
Pipeline del modelo	Entrenamiento, exportación y explicabilidad	PyTorch, timm, Optuna, litert-torch y ONNX Runtime para exportación, Modal (GPU A10G) para entrenamiento en la nube, SHAP y LIME.
Aplicación móvil	Captura, inferencia local y sincronización	Expo, React Native, TypeScript, `react-native-fast-tflite` para inferencia, WatermelonDB con SQLite local y NativeWind.
API de sincronización	Versión de la app y aportes al dataset colaborativo	FastAPI, SQLAlchemy, Alembic, MySQL en Docker Compose, JWT y bcrypt para autenticación y slowapi para límites de tasa.

La aplicación no tiene dependencia con el entorno de entrenamiento, solo empaqueta el modelo `.tflite`, las etiquetas y los parámetros del detector OOD, y se comunica con la API por HTTP. La Figura 2.5 resume el flujo completo.

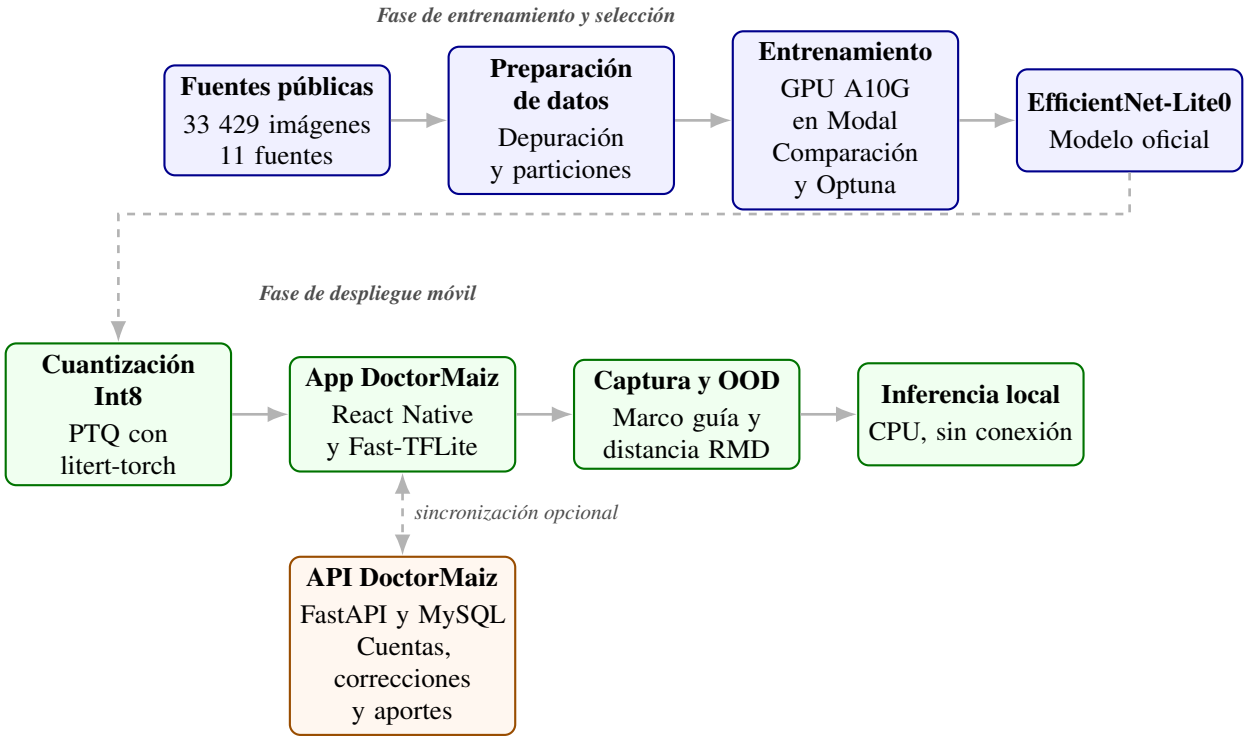


Figura 2.5: Arquitectura del sistema DoctorMaiz.

CAPÍTULO 3

ESTRATEGIA DE IMPLEMENTACIÓN Y ANÁLISIS DE RESULTADOS

3.1. Estrategia y Entorno de Implementación

3.1.1. Infraestructura de Cómputo y Entrenamiento en la Nube

El entrenamiento se realizó en la plataforma Modal, sobre GPU NVIDIA A10G de 24 GB de VRAM, con CUDA 12.6 y PyTorch 2.12.1.

En todos los entrenamientos se utilizó un calendario de tasa de aprendizaje de tipo coseno, precedido por tres épocas de calentamiento lineal. Este calentamiento evita que los primeros pasos de optimización alteren en exceso los pesos preentrenados en ImageNet [4] mientras la red se adapta a las nuevas clases. El entrenamiento se detiene cuando el Macro F_1 de validación no mejora durante 8 épocas consecutivas. Como muestra la Figura 3.1, las tres arquitecturas alcanzan un Macro F_1 cercano a 0.90 en torno a la décima época, y a partir de ese punto las mejoras son graduales.

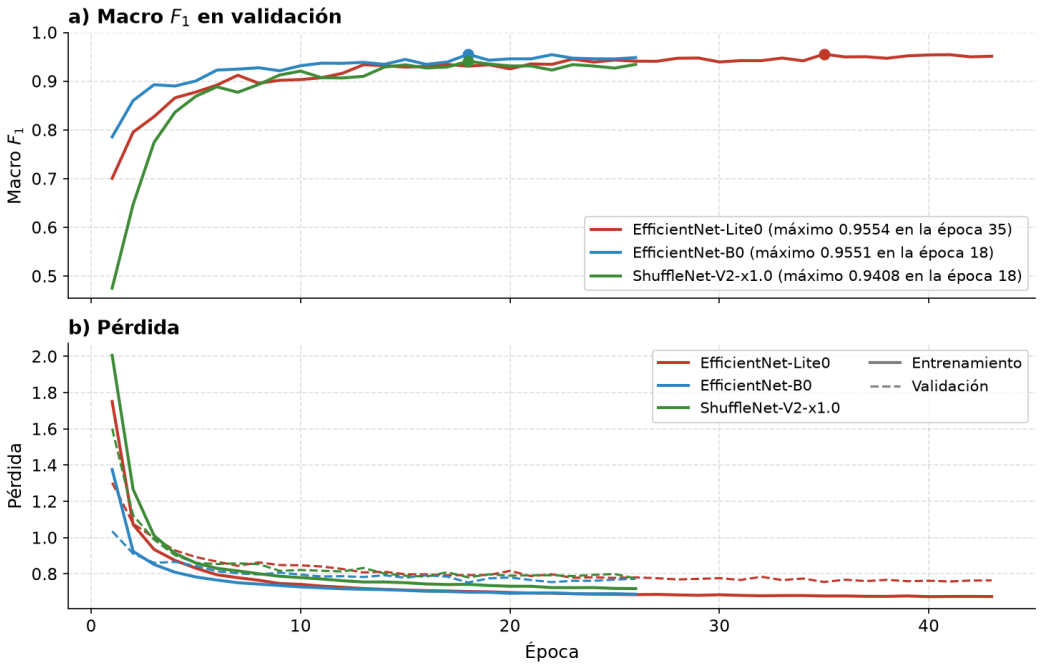


Figura 3.1: Macro F_1 de validación y pérdida por época de las tres arquitecturas con la configuración inicial.

3.2. Resultados

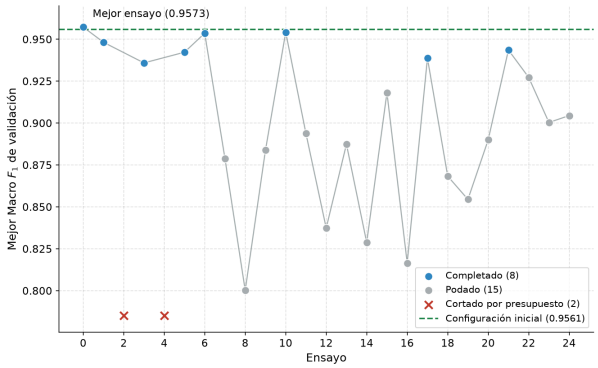
El sistema cumple los seis criterios de éxito (Tabla 3.1). Estos criterios se midieron sobre una partición que mezcla las fuentes, así que el desempeño en campo se analiza aparte, con la validación por fuente y las fotografías externas (Secciones 3.2.2 y 3.2.3).
El modelo oficial elegido es EfficientNet-Lite0 y es el que se usa en la aplicación, esto gracias a que en pruebas realizadas con cada modelo, es el que mejor equilibra exactitud y velocidad de inferencia, además de no verse afectado por la cuantización a Int8.

Tabla 3.1: Estado de los criterios de éxito

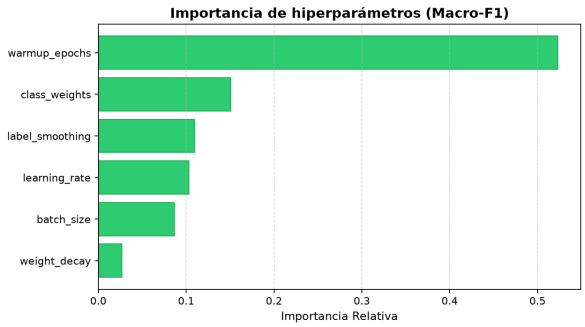
Criterio	**Resultado medido**	**Estado**
Macro $F_1 \geq 0{,}85$ en prueba	0.9480 con una semilla y $0{,}9435 \pm 0{,}0052$ con tres semillas.	Cumple
DIR $\geq 0{,}80$ entre laboratorio y campo	0.9636 en Macro F_1 y 0.9956 en exactitud, sobre las tres clases con imágenes de laboratorio.	Cumple
Solapamiento cero entre particiones	Ninguna de las 5 015 imágenes de prueba aparece en entrenamiento ni en validación.	Cumple
Modelo Int8 de 20 MB o menos	3.74 MB.	Cumple
Preprocesado e inferencia ≤ 300 ms	Medianas de 98 ms de preprocesado y 23 ms de inferencia en un Motorola edge 40 neo.	Cumple
Funcionamiento sin conexión	Clasificación local en el teléfono.	Cumple

3.2.1. Búsqueda Bayesiana de Hiperparámetros

La búsqueda de hiperparámetros con Optuna evaluó 25 configuraciones de EfficientNet-Lite0, cada una con un máximo de 60 épocas. De ellas, 8 completaron el entrenamiento, 15 fueron detenidas por la poda al quedar por debajo de la mediana y 2 quedaron sin terminar porque se alcanzaron los límites de créditos de cómputo. La búsqueda consumió en total 12.65 horas de GPU, y la configuración con mejor Macro F_1 de validación fue la del ensayo 0. Como muestra la Figura 3.2, solo ese ensayo superó, por poco, a la configuración inicial, y los ensayos podados quedaron claramente por debajo.



a) Mejor Macro F_1 de validación de cada ensayo.



b) Importancia de los hiperparámetros.

Figura 3.2: Resultados de la búsqueda con Optuna.

El análisis de importancia (Figura 3.2) indica que el número de épocas de calentamiento es el hiperparámetro que más influye en el resultado, con un peso de 0.52, muy por encima de la ponderación de la pérdida (0.15), el suavizado de etiquetas (0.11), la tasa de aprendizaje (0.10) y el tamaño de lote (0.09). La Tabla 3.2 compara la mejor configuración encontrada con la utilizada inicialmente.

Tabla 3.2: Configuración inicial frente a la mejor configuración de Optuna

Métrica o hiperparámetro	**Inicial**	**Optuna**	**Diferencia**
Macro F_1 en validación	0.9561	0.9573	+0.12 pp
Macro F_1 en prueba	0.9480	0.9431	$-0{,}49$ pp
Tasa de aprendizaje	$1{,}00 \times 10^{-4}$	$8{,}47 \times 10^{-5}$	—
Tamaño de lote	32	16	—
Épocas de calentamiento	3	1	—
Decaimiento de pesos	$1{,}00 \times 10^{-4}$	$5{,}67 \times 10^{-3}$	—
Ponderación de la pérdida	`sqrt_inverse`	`none`	—
Suavizado de etiquetas	0.10	0.075	—

La configuración encontrada por Optuna mejoró en 0.12 puntos porcentuales el Macro F_1 de validación, pero en el conjunto de prueba obtuvo 0.49 puntos menos que la configuración inicial. Una mejora tan pequeña, que además no se traslada a la prueba, es casi insignificante, no representando un cambio real en el desempeño del modelo. Por ese motivo se conservó la configuración inicial (tasa de aprendizaje de 10^{-4}, lote de 32, ponderación `sqrt_inverse` y suavizado de 0.1), con la que el modelo oficial alcanzó en prueba un Macro F_1 de 0.9480 y una exactitud de 97.81 %.

3.2.2. Generalización entre Fuentes

Con el fin de medir cuánto depende el desempeño de las fuentes vistas durante el entrenamiento, se realizó una validación cruzada de 5 pliegues con dos esquemas de partición. El primero es la partición estratifica-

da que se usa normalmente y el segundo agrupa las imágenes por fuente, de modo que ningún repositorio aparece a la vez en entrenamiento y en evaluación. Cada esquema se probó con la configuración inicial y con una configuración ajustada (Optuna) (Tabla 3.3 y Figura 3.3).

Tabla 3.3: Validación cruzada de 5 pliegues con partición estratificada y agrupada por fuente

Configuración	**Estratificada (media ± IC95)**	**Agrupada por fuente (media ± IC95)**	**Diferencia**
Hiperparámetros iniciales	$0{,}9311 \pm 0{,}0099$	$\mathbf{0{,}6026 \pm 0{,}1240}$	$\mathbf{-0{,}3286}$
Hiperparámetros ajustados	$0{,}9463 \pm 0{,}0052$	$0{,}6499 \pm 0{,}1508$	$-0{,}2964$

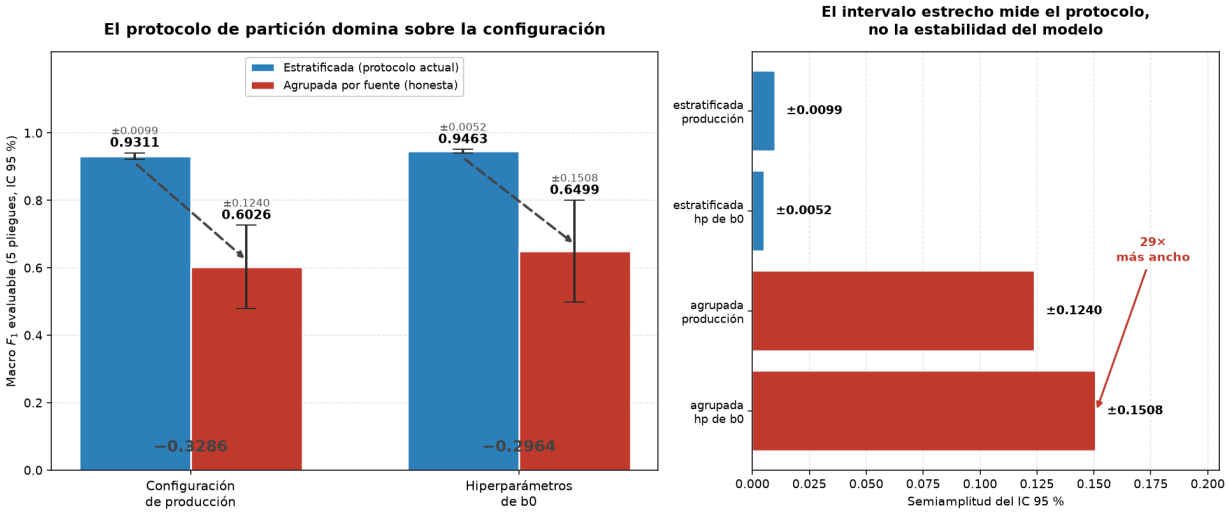
La forma de partir los datos pesa mucho más que los hiperparámetros. Con la partición estratificada el Macro F_1 fue de 0.9311, y al evaluar con fuentes que el modelo no vio durante el entrenamiento bajó a 0.6026. Ajustar los hiperparámetros apenas lo movió, de 0.9311 a 0.9463. El intervalo de confianza también creció, de $\pm 0{,}0099$ a $\pm 0{,}1240$, porque el resultado cambia bastante según qué fuente quede fuera. Una caída de 0.33 no se explica por el azar del entrenamiento, entre tres semillas, el Macro F_1 varió con una desviación estándar de 0.0052, y entre pliegues estratificados, de 0.0080 (Figura 3.3). La conclusión es que el modelo, además de los síntomas y a pesar del preprocesado y aumento de datos, haya aprendido rasgos de cada repositorio, como el fondo, la luz o la cámara, algo que ya se ha observado en otros trabajos con imágenes de cultivos [1].

En la evaluación LOSO (*leave-one-source-out*), el modelo se entrenó sin una fuente completa y se probó solo con las imágenes de esa fuente, con tres semillas (Tabla 3.4). Sin `maize-diseases`, el Macro F_1 quedó en 0.9933, casi igual que si esa fuente se hubiera visto. Con `multicrop-disease-maiz` el resultado fue otro, y la exactitud bajó a 80.38 %.

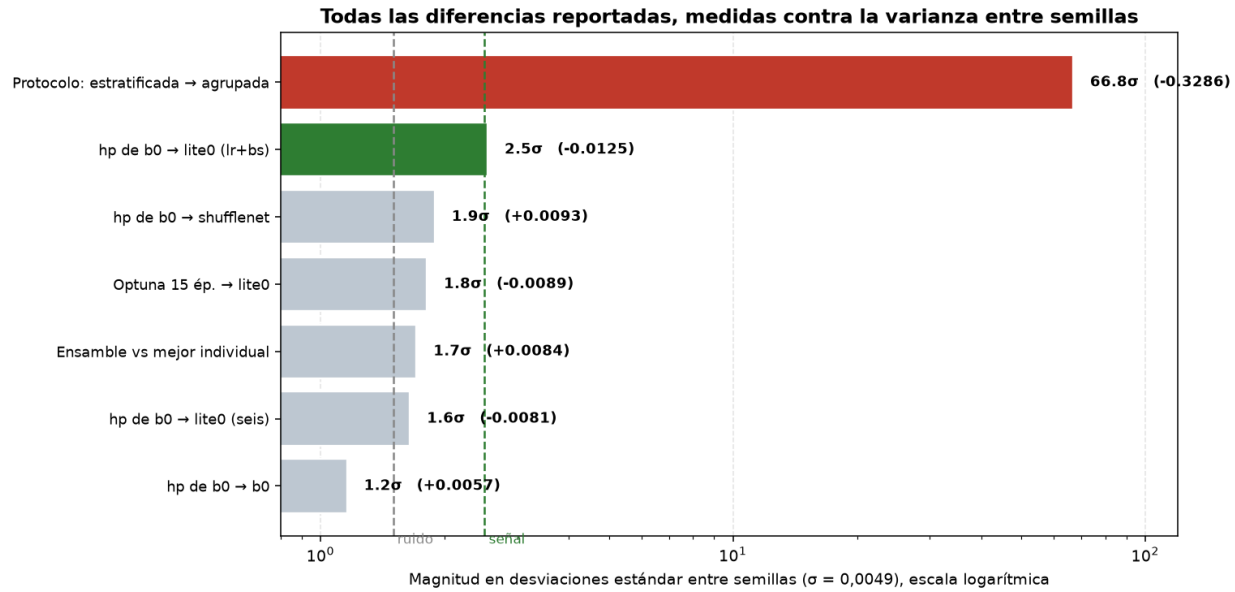
Tabla 3.4: Macro F_1 y exactitud en la fuente retenida, evaluación LOSO con tres semillas

Fuente retenida	**Macro F_1 (media ± DE)**	**Exactitud (media ± DE)**	**Semillas**
`maize-diseases`	0.9933 ± 0.0006	$99.37\,\% \pm 0.07$ pp	3
`multicrop-disease-maiz`	0.9019 ± 0.0044	$80.38\,\% \pm 0.32$ pp	3

Los resultados casi no cambian entre las tres semillas, así que la caída al retirar `multicrop-disease-maiz` no es solo casualidad, la caída depende de qué fuente se deja fuera, y es consistente con la validación cruzada por fuente.



a) Macro F_1 e intervalo de confianza según la partición.



b) Magnitud de cada efecto en desviaciones estándar.

Figura 3.3: Efecto de la partición frente al ajuste de hiperparámetros.

3.2.3. Fotografías de Campo Externas

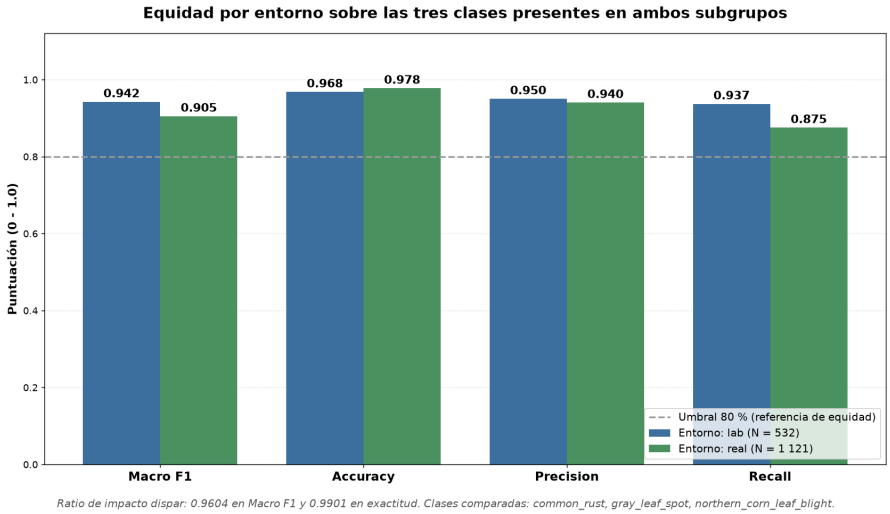
La prueba más cercana al uso real consistió en evaluar el modelo oficial con 97 fotografías de campo ajenas al corpus, organizadas por clase. El modelo acertó 41 de ellas (42 %) y el detector OOD rechazó 49 (Tabla 3.5). Esta cifra concuerda con la caída observada en la validación por fuente y constituye la principal limitación del sistema. El desempeño, además, es muy desigual entre clases. La mancha gris y el gusano cogollero se reconocieron en las 10 fotografías de cada una, mientras que ninguna de las 10 de necrosis letal se clasificó correctamente.

Tabla 3.5: Aciertos del modelo oficial en fotografías de campo externas, por clase

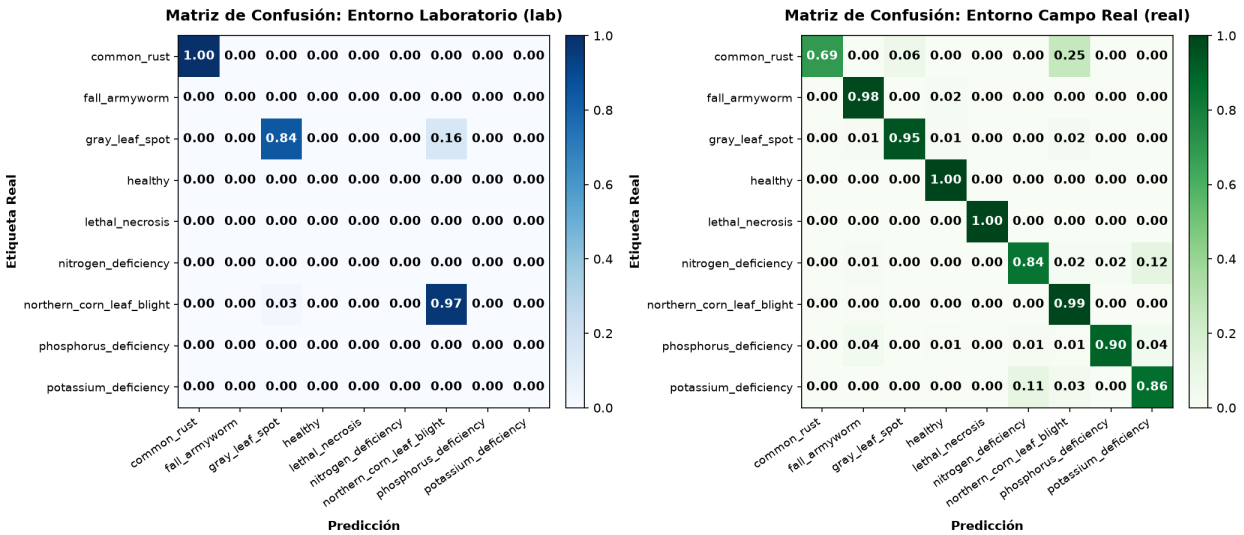
Clase	**Fotografías**	**Aciertos**
Roya común	18	2
Deficiencia de fósforo	10	2
Mancha gris	10	10
Deficiencia de nitrógeno	10	6
Deficiencia de potasio	9	4
Tizón foliar	10	5
Gusano cogollero	10	10
Necrosis letal	10	0
Hoja sana	10	2
Total	**97**	**41**

3.2.4. Equidad entre Laboratorio y Campo

Para comparar el desempeño entre imágenes de laboratorio y de campo se utilizó el *Disparate Impact Ratio* (DIR), que divide el desempeño del entorno con peor resultado entre el del mejor. Según la regla de los cuatro quintos, un valor igual o superior a 0.80 se considera aceptable. Dado que solo la roya, la mancha gris y el tizón cuentan con imágenes de laboratorio, el cálculo se restringió a esas tres clases. Con el modelo oficial, evaluado sobre 533 imágenes de laboratorio y 1 120 de campo, el Macro F_1 fue de 0.9383 y 0.9041, respectivamente, lo que da un DIR de 0.9636 (0.9956 si se calcula sobre la exactitud). Sin embargo, un DIR cercano a uno no implica que todas las clases se comporten igual en ambos entornos. El desglose de falsos negativos (Tabla 3.6) revela diferencias importantes. La roya común apenas falla en laboratorio (1 de 322 casos), pero falla en 5 de los 16 casos de campo (31.25 %), lo que es coherente con que el 95 % de sus imágenes procedan del laboratorio. Esta diferencia se mantiene con el modelo oficial, cuyo F_1 para la roya es de 0.998 en laboratorio y de 0.77 en campo. La mancha gris presenta el patrón contrario, con un 15.58 % de falsos negativos en laboratorio y un 5.16 % en campo.



a) Disparidad por entorno.



b) Matrices de confusión por entorno.

Figura 3.4: Desempeño por entorno de captura.

Tabla 3.6: Tasa de falsos negativos (FNR) por clase y entorno.

Clase	FNR **laboratorio**	**Imágenes**	FNR **campo**	**Imágenes**
Roya común	0.31 %	322	**31.25 %**	16
Mancha gris	15.58 %	77	5.16 %	213
Tizón foliar	3.01 %	133	1.01 %	892

3.2.5. Dependencia del Fondo

Para determinar en qué medida el modelo se apoya en la hoja o en el entorno, se ocultaron distintas regiones de las 5 015 imágenes de prueba y se midió la exactitud con lo que quedaba visible (Tabla 3.7 y Figura 3.5). Como referencia se usó un predictor nulo, que no mira la imagen y lo que hace es responder siempre con la clase más frecuente de la prueba, la hoja sana. Ese predictor acierta el 26.14 % de las veces, así que cualquier exactitud por encima de ese valor indica que la región visible todavía contiene información sobre la clase.

Tabla 3.7: Exactitud al ocultar regiones de la imagen.

Condición	**Región visible**	**Área**	**Exactitud**	**Sobre el nulo**	**Confianza retenida**
Imagen completa	Toda la escena	100.0 %	97.91 %	+71.77 pp	100.0 %
Centro oculto	**Borde**	**63.7 %**	**79.46 %**	**+53.32 pp**	**69.16 %**
Periferia oculta	Centro	36.3 %	42.25 %	+16.11 pp	42.66 %
Predictor nulo	Ninguna	0.0 %	26.14 %	0.0 pp	—

Cuando se oculta el centro de la imagen, el modelo conserva un 79.46 % de exactitud a partir del borde, mientras que al ocultar la periferia la exactitud desciende a 42.25 %. Las dos condiciones no dejan visible la misma superficie (63.7 % y 36.3 %), pero la diferencia es lo bastante amplia para sugerir que el fondo aporta información sobre la clase. Este resultado motivó que la aplicación recorte la captura al marco guía antes de clasificarla, para que la hoja ocupe la mayor parte posible de la región visible.

En los ejemplos analizados, los mapas de Grad-CAM [21], LIME [20] y SHAP [13] coinciden con las lesiones visibles (Figuras 3.6 y 3.7). Para comprobarlo con números se tomaron 270 imágenes de prueba, 30 por clase, y en cada una se midió qué parte de la atribución de SHAP cae sobre la hoja y qué parte de la imagen ocupa la hoja. Si el modelo se fijara sobre todo en la hoja, la primera cifra sería claramente mayor que la segunda. En las seis clases donde la hoja pudo delimitarse bien, la diferencia media fue de apenas +0.037, con tres clases por encima y tres por debajo. El modelo, entonces, casi no atiende a la hoja más de lo que cabría esperar por su tamaño. Una explicación posible de que los mapas no lo muestren es que solo resaltan las zonas de mayor peso, como la lesión. El fondo pesa poco en cada punto, pero ocupa tanta superficie que en conjunto influye casi lo mismo que la hoja.

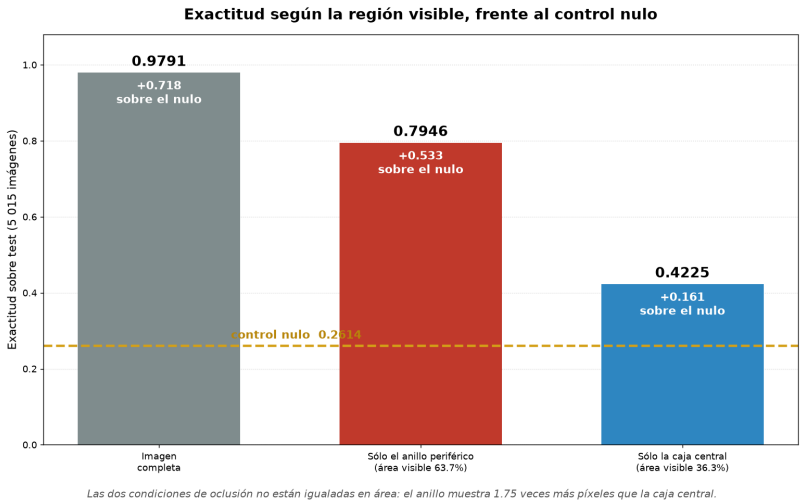


Figura 3.5: Exactitud según la región visible de la imagen.

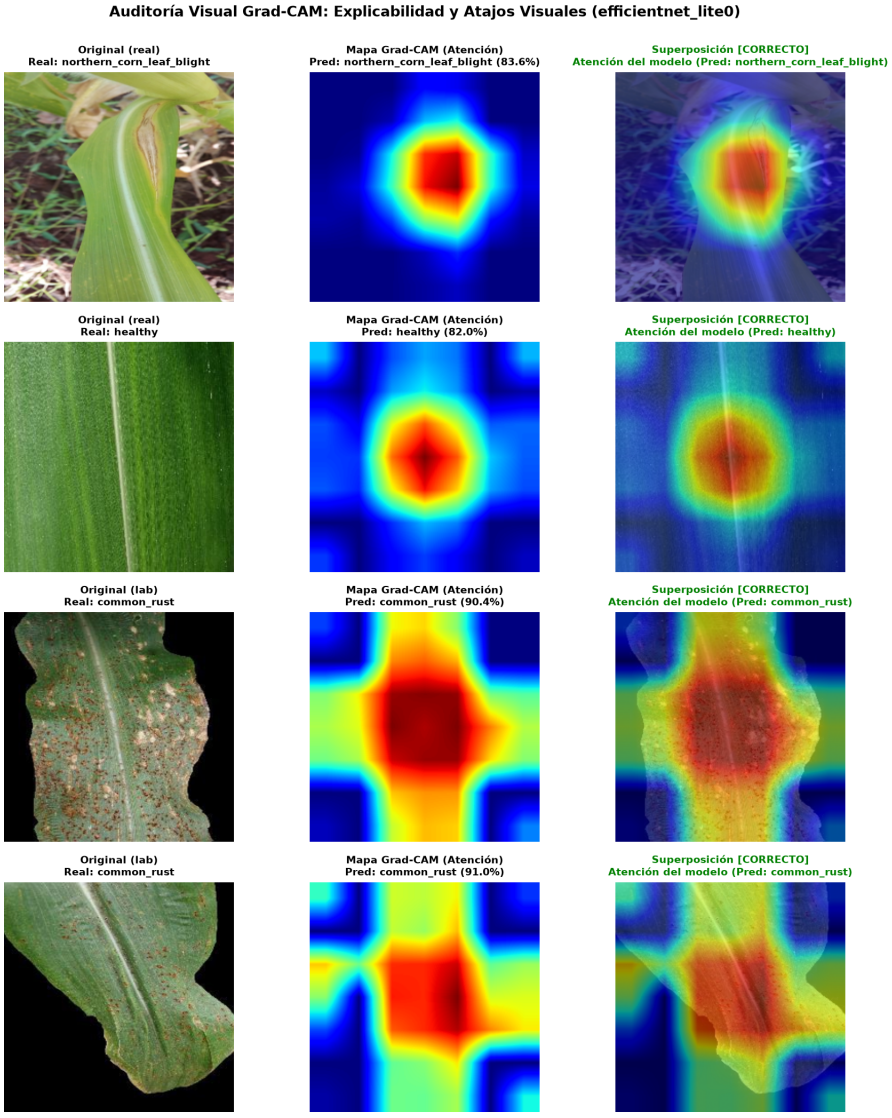


Figura 3.6: Mapas de activación Grad-CAM en imágenes de campo y de laboratorio.

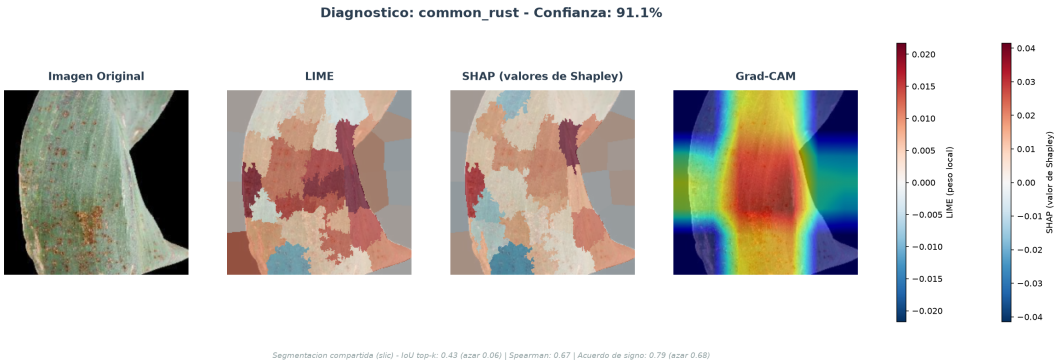


Figura 3.7: Explicaciones locales de LIME, SHAP y Grad-CAM para la roya común.

3.2.6. Desempeño en el Teléfono

Cuantizado a Int8, el modelo oficial pesa 3.74 MB, un 72.9 % menos que la versión en coma flotante (13.79 MB). Esa reducción no le costó precisión. En las 5 015 imágenes de prueba, el modelo Int8 obtuvo un Macro F_1 de 0.9489 y una exactitud de 97.87 %, prácticamente lo mismo que el original (0.9480 y 97.81 %), y coincidió con él en el 99.74 % de las predicciones.

Las pruebas en el teléfono se hicieron en un Motorola edge 40 neo (MediaTek Dimensity 7030, 8 GB de RAM, Android 15), un equipo de gama media. Preparar la imagen tomó una mediana de 98 ms (p95 de 279 ms) y la inferencia, 23 ms (Tabla 3.8), ambos por debajo de la meta de 300 ms. Lo que más tarda, entonces, no es el modelo sino el preprocesado, que se lleva cuatro veces más tiempo que la inferencia. El flujo completo, desde la captura hasta que aparece el resultado, tomó 473 ms.

Tabla 3.8: Latencias medianas en el Motorola edge 40 neo

Fase	**Modelo**	**Mediana**
Preprocesado	Oficial (Int8)	98 ms
Inferencia	Oficial (Int8)	23 ms
Flujo completo	Versión anterior	473 ms

Para verificar que la aplicación produce las mismas predicciones que el modelo evaluado en las secciones anteriores, se procesaron en el teléfono 143 imágenes, 95 fotografías de campo y 48 del corpus. Las predicciones coincidieron con las del modelo Int8 en las 143 imágenes. El teléfono acertó 45 de las 48 imágenes del corpus (93.8 %) y 38 de las 95 fotografías de campo (40.0 %), cifras similares a las obtenidas en las pruebas de las secciones anteriores.

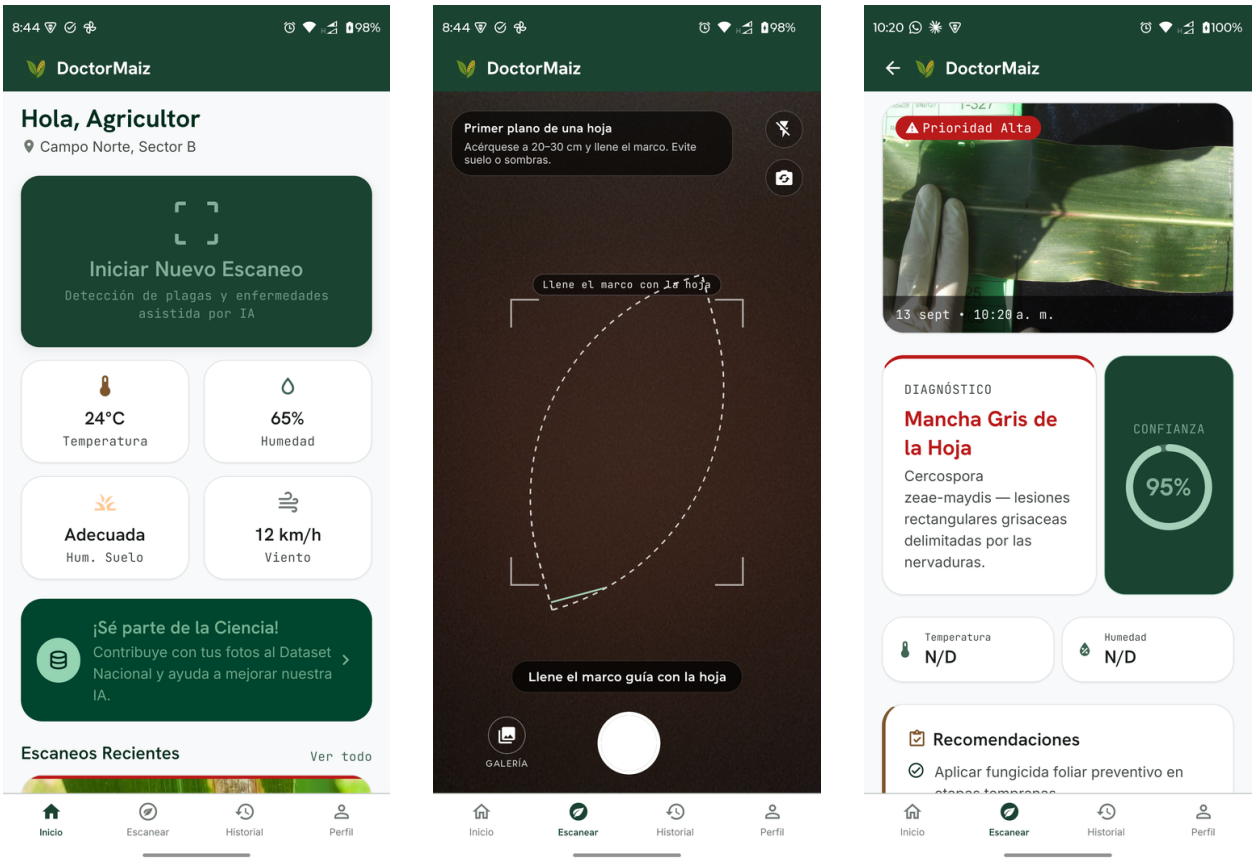
Por último, la interfaz incorpora los elementos descritos en el Capítulo 2 (Figuras 3.8 y 3.9):

1. **Marco guía.** La aplicación recorta la captura al marco con un margen de 15 %. En el teléfono de prueba, la imagen pasa de 12.6 a 3.02 megapíxeles.

2. **Detector OOD.** Cuando la puntuación supera el umbral de 106.37, la aplicación muestra «Imagen no reconocida». El detector rechazó las cinco imágenes sintéticas de prueba (negro, blanco, gris, ruido y azul) y, por error, el 3.8 % de 500 imágenes de prueba válidas.

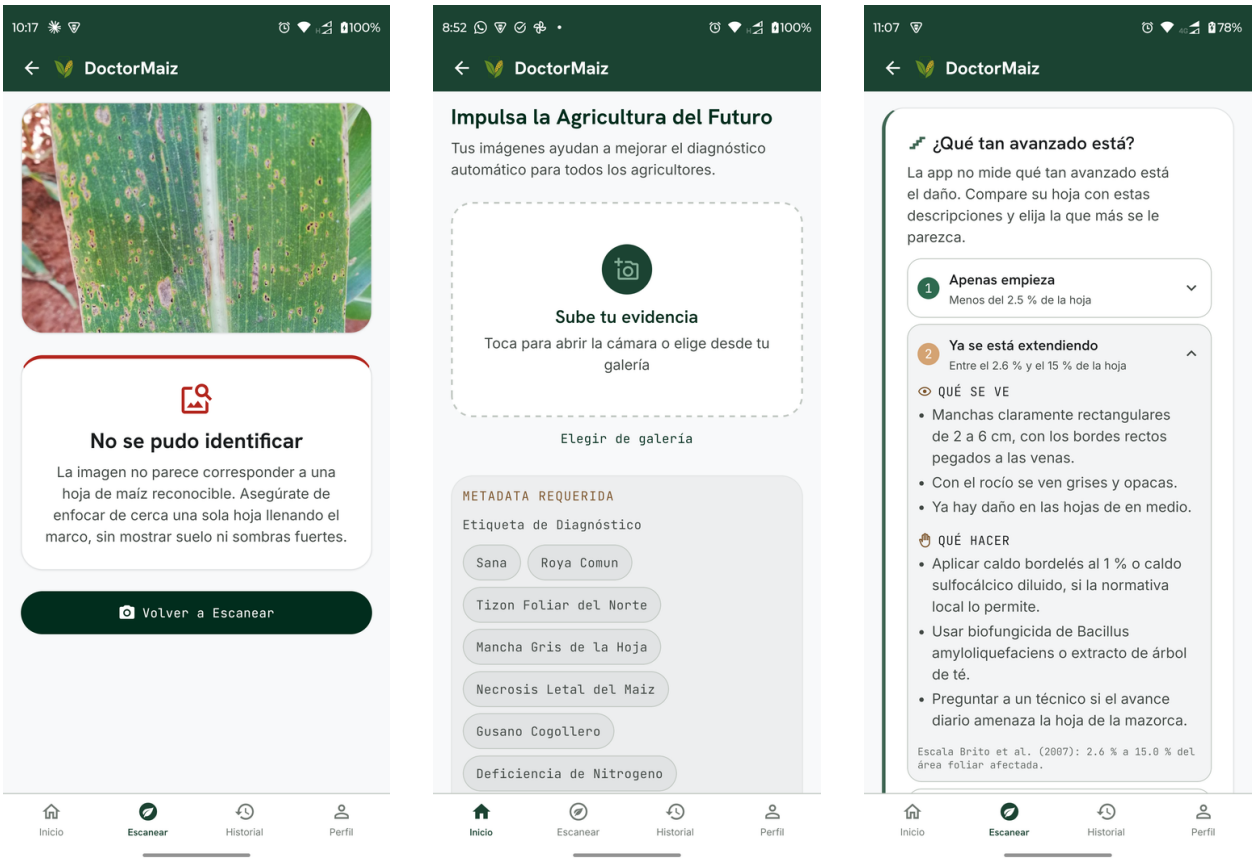
3. **Aportes.** El productor puede guardar fotografías de su milpa para enviarlas cuando haya conexión.

4. **Guía de severidad.** Muestra una escala de tres niveles que el productor compara con su hoja, con pautas de bioinsumos.



a) Pantalla de inicio. b) Marco guía. c) Diagnóstico.

Figura 3.8: Flujo principal de la aplicación DoctorMaiz.



a) Imagen no reconocida. b) Aporte de fotografías. c) Guía de severidad.

Figura 3.9: Rechazo de imágenes, aportes y guía de severidad.

3.2.7. Ensamble

También se evaluó un ensamble por votación suave de las tres arquitecturas, que superó a cada una por separado en la partición estratificada (Tabla 3.9 y Figura 3.10). Para el ensamble se usaron entrenamientos históricos de cada arquitectura, hechos específicamente para esta comparación.

Tabla 3.9: Ensamble frente a modelos individuales en la prueba (5 015 imágenes)

Modelo	**Exactitud**	**Macro F_1**	**Precisión**	**Recall**
ShuffleNet-V2-x1.0	97.31 %	0.9330	0.9388	0.9298
EfficientNet-Lite0	97.91 %	0.9468	0.9533	0.9413
EfficientNet-B0	97.97 %	0.9483	0.9589	0.9400
Ensamble (votación suave)	**98.29 %**	**0.9567**	**0.9642**	**0.9506**
Ganancia frente al mejor individual	*+0.32 pp*	*+0.83 pp*	*+0.52 pp*	*+0.93 pp*

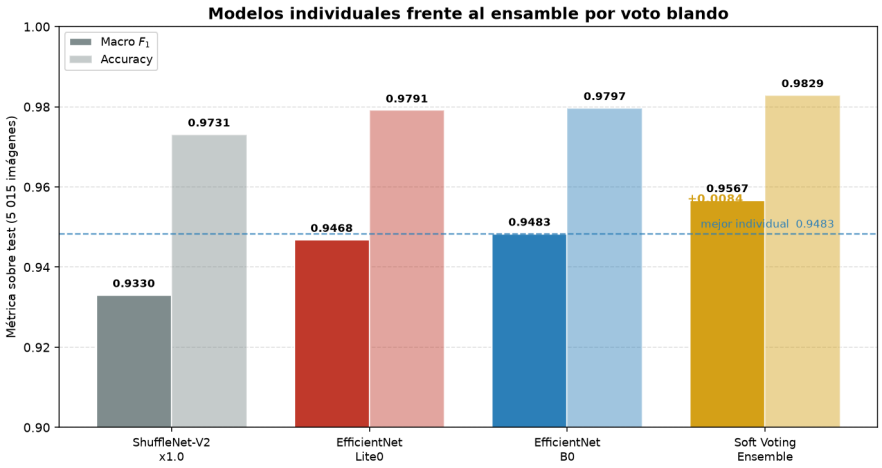


Figura 3.10: Desempeño del ensamble frente a los modelos individuales.

En un sistema de diagnóstico el recall tiene cierta mayor importancia, porque cada falso negativo deja sin atención una infección. El ensamble alcanzó un recall macro de 95.06 %, y su matriz de confusión (Figura 3.11) muestra que detectó los 963 casos de necrosis letal de la prueba y más del 98 % de los de roya y tizón. Con fuentes no vistas, en cambio, el recall de necrosis letal se redujo a valores entre 0.72 y 0.81 en la evaluación LOSO.

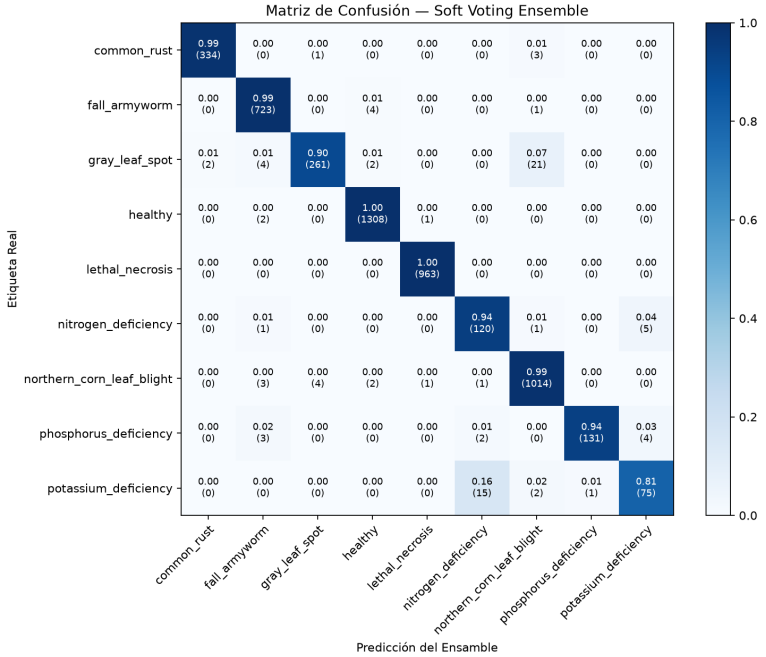


Figura 3.11: Matriz de confusión normalizada del ensamble sobre 5 015 imágenes de prueba.

El caso de la deficiencia de potasio nos muestra el efecto de ampliar el corpus de entrenamiento, ya que esta clase, que en los primeros entrenamientos tenía un F_1 de 0.49, alcanzó 0.8475 en el ensamble y 0.8242

en el modelo oficial (Tabla 3.10). La mejora coincide precisamente con la incorporación de nuevos repositorios de deficiencias nutricionales y con el uso de la ponderación `sqrt_inverse` en la función de pérdida.

Tabla 3.10: F_1 por clase de los modelos individuales y del ensamble

Clase	**Imágenes**	**Lite0**	**B0**	**ShuffleNet**	**Ensamble**
Necrosis letal	963	**0.9990**	0.9984	0.9974	**0.9990**
Hoja sana	1 311	0.9936	0.9954	0.9901	**0.9958**
Roya común	338	0.9866	0.9896	0.9867	**0.9911**
Gusano cogollero	728	0.9814	**0.9877**	0.9815	**0.9877**
Tizón foliar	1 025	0.9797	0.9769	0.9728	**0.9811**
Mancha gris	290	**0.9451**	0.9194	0.9120	0.9388
Deficiencia de fósforo	140	0.9403	0.9527	0.9275	**0.9632**
Deficiencia de nitrógeno	127	0.8664	0.8939	0.8613	**0.9057**
Deficiencia de potasio	93	0.8290	0.8208	0.7674	**0.8475**
Promedio macro	**5 015**	0.9468	0.9483	0.9330	**0.9567**

3.2.8. Síntesis de los Resultados

Los resultados dejan dos conclusiones:

En la partición de prueba el modelo cumple lo que se propuso: obtiene un Macro F_1 de 0.9480, la cuantización no le resta desempeño y en el teléfono responde por debajo de la meta de 300 ms. La búsqueda de hiperparámetros y el ensamble aportaron poco frente a eso. La configuración de Optuna no mejoró el resultado en prueba, y el ensamble ganó menos de un punto de Macro F_1 pero exigiría ejecutar tres redes en el teléfono.

Fuera de esa partición la lectura es bastante distinta, con fuentes que el modelo no vio, el Macro F_1 bajó a 0.6026, y en las fotografías de campo externas acertó 41 de 97. La ablación apunta en la misma dirección, porque el modelo sigue acertando la mayoría de las veces cuando solo ve el borde de la imagen. Las tres pruebas indican que parte de lo que aprendió es propio de los repositorios de origen y no de la enfermedad. Por eso el sistema queda, por ahora, como una herramienta de orientación. Es poco probable que otra arquitectura o más ajuste de hiperparámetros cambien ese resultado. Lo que falta son fotografías tomadas en parcelas salvadoreñas, y a eso responden el módulo de aportes y las recomendaciones del cierre.

CONCLUSIONES Y RECOMENDACIONES

Conclusiones

El proyecto permitió construir una aplicación móvil que diagnostica nueve condiciones de la hoja de maíz, sin necesidad de conexión a internet. El sistema funciona en el teléfono, se abstiene ante imágenes que no reconoce y orienta al productor con una guía de manejo, pero todavía reconoce con dificultad los síntomas en fotografías de campo de otra procedencia.

El sistema cumplió con lo que planteaba la hipótesis, según los criterios de la Tabla 1.1. El modelo obtuvo un Macro F_1 de 0.9480 en la partición de prueba, con medianas de 98 ms de preprocesado y 23 ms de inferencia, y un desempeño comparable entre laboratorio y campo (DIR de 0.9636). Pero es importante destacar que esta aceptación tiene un alcance limitado, ya que los criterios se midieron sobre una partición en la que las mismas fuentes aparecen en entrenamiento y en prueba.

En cuanto a la pregunta de investigación, la aplicación cumple solo una parte de lo que se esperaba. Funciona sin conexión, avisa cuando la imagen no es confiable en lugar de arriesgar un diagnóstico y acompaña cada resultado con una guía de manejo. Lo que todavía no logra es reconocer bien las fotografías tomadas fuera del corpus: de 97 fotos de campo externas acertó 41, el 42 %. Por eso, en su estado actual, la aplicación sirve para orientar al productor, pero su diagnóstico todavía no es confiable en la parcela.

Las conclusiones por objetivo son las siguientes:

1. El corpus reúne 33 429 imágenes de 11 repositorios públicos, sin duplicados entre particiones según los hashes de archivo y de píxeles. Su principal debilidad es la composición, ya que varias fuentes aportan una sola clase y solo tres clases tienen imágenes de laboratorio, lo que facilita que el modelo asocie la fuente con la etiqueta.

2. La búsqueda con Optuna evaluó 25 configuraciones. La mejor superó por poco a la inicial en validación, pero rindió 0.49 puntos menos en prueba, así que se conservó la configuración inicial. Con este corpus, el ajuste de hiperparámetros pesó mucho menos que la forma de partir los datos.

3. El ensamble por votación suave alcanzó un Macro F_1 de 0.9567 y detectó todos los casos de necrosis letal de la partición estratificada. Con fuentes no vistas, el recall de esa clase bajó a 0.79–0.81 en el ensamble y a 0.72–0.74 en EfficientNet-Lite0.

4. La evaluación con fuentes separadas es el resultado más importante del trabajo, el Macro F_1 cayó de 0.9311 a 0.6026 al evaluar sobre fuentes no vistas, y en 97 fotografías de campo externas el modelo acertó 41 (42 %). La ablación y el desglose por clase también muestran este comportamiento, el modelo conserva un 79.46 % de exactitud viendo solo el borde de la imagen, y la roya común, casi toda de laboratorio, falla en 5 de 16 casos de campo.

5. Cuantizado a Int8, el modelo pesa 3.74 MB y mantiene el desempeño del original (Macro F_1 de 0.9489). En el dispositivo móvil, las medianas fueron de 98 ms de preprocesado y 23 ms de inferencia, y las predicciones del teléfono coincidieron con las del modelo, por lo que no se observó degradación por la cuantización.

6. El módulo de aportes quedó integrado en la aplicación. Guarda cada fotografía en el teléfono y la envía al servidor cuando hay conexión. Con él existe el medio para reunir un conjunto de datos nacional.

Limitaciones

1. **Generalización.** El Macro F_1 de 0.9480 se calculó con imágenes de las mismas fuentes usadas en el entrenamiento, por lo que no describe el uso en campo. Cuando el modelo se evaluó con fuentes que no había visto, el Macro F_1 bajó a 0.6026, y con fotografías de campo externas acertó el 42 % de las veces. Mientras el corpus no incluya imágenes salvadoreñas, es razonable esperar en una parcela del país un desempeño más cercano a estas últimas cifras.

2. **Severidad.** El modelo indica qué condición presenta la hoja, pero no cuánto daño tiene. La guía de tres niveles ayuda al productor a estimarlo comparando su hoja con las descripciones, aunque esa valoración depende de su criterio y no se validó en campo. Para medir el porcentaje de área afectada haría falta un modelo que segmente las lesiones, algo que queda fuera del alcance de este trabajo.

3. **Beneficio económico.** No se estimó cuánto podría ahorrar un productor al usar la aplicación, porque en El Salvador no existe una cuantificación nacional de las pérdidas por enfermedades foliares, plagas o deficiencias nutricionales. Los datos disponibles son ensayos puntuales, como los citados en el Capítulo 1, que no permiten calcular un ahorro por hectárea ni por ciclo.

Trabajo futuro

- Reunir y etiquetar fotografías salvadoreñas con apoyo del CENTA o del MAG, y reentrenar el modelo evaluándolo con fuentes completas fuera del entrenamiento.
- Probar la aplicación con productores y técnicos.
- Reducir el tiempo de preprocesado en el teléfono.

Recomendaciones

Con base en los resultados, se proponen cinco recomendaciones al Ministerio de Agricultura y Ganadería (MAG) y al Centro Nacional de Tecnología Agropecuaria y Forestal (CENTA).

1. **Validar en campo antes de adoptar la herramienta.** Evaluar la aplicación con promotores del CENTA usando fotografías de cada zona productora, ya que la exactitud con fotografías de campo externas fue de 42 % (Sección 3.2.3).

2. **Crear un banco nacional de imágenes.** Financiar, junto con la Universidad de El Salvador, la captura de fotografías de variedades y condiciones locales para reentrenar el modelo.

3. **Aprovechar los aportes para la vigilancia fitosanitaria.** Evaluar el uso de las fotografías aportadas por los usuarios en un tablero de vigilancia del MAG, con reglas claras sobre el uso de los datos y de la ubicación.

4. **Capacitar a las comunidades.** Enseñar a cooperativas y ADESCOs a usar el marco guía de captura y presentar la herramienta como un apoyo al criterio del productor.

5. **Mantener el software abierto.** Conservar el código bajo licencias abiertas y definir las condiciones de uso de los datos que aporten los productores.

BIBLIOGRAFÍA

[1] Ahmad, A., El Gamal, A., & Saraswat, D. (2023). Toward generalization of deep learning-based plant disease identification under controlled and field conditions. *IEEE Access*, 11, 9042–9057.

[2] Banco Central de Reserva de El Salvador (BCR). (2023). *Revista Económica: Aporte Agropecuario al Producto Interno Bruto 2022-2023*. San Salvador: BCR.

[3] Centro Nacional de Tecnología Agropecuaria y Forestal "Enrique Álvarez Córdova" (CENTA). (2022). *Guía técnica del cultivo de maíz en El Salvador*. San Salvador: CENTA / Gerencia de Investigación y Transferencia.

[4] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 248–255).

[5] Deras F., H. R., Flor de Serrano, R., Mejía, C., & Moreno, W. (2015). Evaluación de híbridos trilineales de maíz (*Zea mays* L.), por su reacción al Complejo Mancha de asfalto causada por los patógenos (*Phyllachora maydis*, *Monographella maydis* y *Coniothyrium phyllacorae*). *Producción Agropecuaria y Desarrollo Sostenible*, 3, 77–88. https://camjol.info/index.php/PAyDS/article/view/3973

[6] Diario El Mundo. (2025, 7 de febrero). El déficit de granos básicos supera los 9.9 millones de quintales en 2025. https://diario.elmundo.sv/economia/el-deficit-de-granos-basicos-supera-los-9-9-millones-de-quintales-en-2025

[7] Eash, L., Fonte, S. J., Sonder, K., Honsdorf, N., Schmidt, A., Govaerts, B., & Verhulst, N. (2019). Factors contributing to maize and bean yield gaps in Central America vary with site and agroecological conditions. *The Journal of Agricultural Science*, 157(4). https://doi.org/10.1017/S0021859619000571

[8] El Diario de Hoy. (2024, 4 de abril). Las altas temperaturas en El Salvador tendrán efecto en el ciclo agrícola 2024-2025. https://www.elsalvador.com/?p=1134038

[9] Howard, A. G., et al. (2017). MobileNets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*.

[10] Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 7132–7141).

[11] Jacob, B., Kligys, S., Chen, B., Zhu, M., Tang, M., Howard, A., Adam, H., & Kalenichenko, D. (2018). Quantization and training of neural networks for efficient integer-arithmetic-only inference. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 2704–2713).

[12] Lee, K., Lee, K., Lee, H., & Shin, J. (2018). A simple unified framework for detecting out-of-distribution samples and adversarial attacks. En *Advances in Neural Information Processing Systems (NeurIPS)*, 31.

[13] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 4765–4774.

[14] Ma, N., Zhang, X., Zheng, H.-T., & Sun, J. (2018). ShuffleNet V2: Practical guidelines for efficient CNN architecture design. En *Proceedings of the European Conference on Computer Vision (ECCV)* (pp. 116–131).

[15] Mahuku, G., Lockhart, B. E., Wanjala, B., Jones, M. W., Kimunye, J. N., Stewart, L. R., … & Redinbaugh, M. G. (2015). Maize lethal necrosis (MLN), an emerging threat to maize-based food security in sub-Saharan Africa. *Phytopathology*, 105(7), 956–965. https://doi.org/10.1094/PHYTO-12-14-0367-FI

[16] Ministerio de Agricultura y Ganadería (MAG). (2023). *Anuario de Estadísticas Agropecuarias y Seguridad Alimentaria en El Salvador 2022-2023*. San Salvador: MAG / Dirección General de Economía Agropecuaria.

[17] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)* (pp. 2623–2631).

[18] Mueller, M., & Hein, M. (2025). Mahalanobis++: Improving OOD detection via feature normalization. *arXiv preprint arXiv:2505.18032*.

[19] Ren, J., Fort, S., Liu, J., Roy, A. G., Padhy, S., & Lakshminarayanan, B. (2021). A simple fix to Mahalanobis distance for improving near-OOD detection. *arXiv preprint arXiv:2106.09022*.

[20] Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. En *ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)* (pp. 1135–1144).

[21] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 618–626).

[22] Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. En *International Conference on Machine Learning (ICML)* (pp. 6105–6114).

GLOSARIO DE TÉRMINOS

Ablación espacial: Prueba en la que se oculta una parte de la imagen, el centro o la periferia, y se mide cuánto cambia la exactitud del modelo. Sirve para saber en qué zona de la imagen se apoya.

ADESCO: Asociación de Desarrollo Comunal. Organización de vecinos con reconocimiento legal que gestiona proyectos en su comunidad.

Cuantización a enteros de 8 bits (Int8): Conversión de los pesos del modelo, guardados originalmente en coma flotante de 32 bits, a enteros de 8 bits. Reduce el tamaño del modelo y el costo de cada inferencia.

Disparate Impact Ratio (DIR): Cociente entre el desempeño del grupo con peor resultado y el del mejor. Aquí se mide con Macro F_1 o exactitud entre imágenes de laboratorio y de campo. Un valor inferior a 0.80 se toma como indicio de trato dispar.

Edge AI: Ejecución de un modelo de inteligencia artificial en el propio dispositivo del usuario, en este caso el teléfono, sin enviar los datos a un servidor.

Efecto Clever Hans: Ocurre cuando un modelo acierta apoyándose en pistas ajenas a lo que debe reconocer, como el fondo, la cámara o una marca de agua, y no en las características de la clase.

Grad-CAM: Técnica que genera un mapa de calor sobre la imagen para mostrar qué regiones influyeron más en la predicción de una red convolucional.

Leave-One-Source-Out (LOSO): Forma de validación en la que el modelo se entrena sin una fuente de datos completa y se evalúa solo con las imágenes de esa fuente. Sirve para medir cómo se comporta el modelo ante imágenes de una procedencia que no vio durante el entrenamiento.

LIME y SHAP: Técnicas de explicabilidad que estiman cuánto aporta cada región de la imagen a la predicción del modelo.

Macro F_1: Promedio simple del F_1 de cada clase. Da el mismo peso a las clases con pocas imágenes que a las que tienen muchas, por lo que se usa en conjuntos desbalanceados.

Necrosis Letal del Maíz (MLN): Enfermedad causada por la infección simultánea del virus del moteado clorótico del maíz (MCMV) y un potyvirus, como el SCMV. En Kenia se documentaron en 2012 pérdidas de rendimiento de hasta 90 %.

Out-of-Distribution (OOD): Imagen distinta a las que el modelo vio durante el entrenamiento, por ejemplo una piedra o una mano ante un modelo entrenado con hojas.

Recall (sensibilidad): Proporción de los casos reales de una clase que el modelo detecta. Un recall bajo significa muchos falsos negativos.

Votación suave (*Soft Voting*): Forma de combinar varios modelos promediando las probabilidades que cada uno asigna a cada clase.

ANEXOS

Anexo A: Repositorios y Enlaces del Proyecto

Los repositorios y recursos de **DoctorMaiz** son los siguientes:

- **Clasificador (*pipeline* de entrenamiento, evaluación y exportación):**

  `https://github.com/daiv05/maize-doctor-classifier`

- **Aplicación móvil DoctorMaiz (React Native, inferencia *offline*):**

  `https://github.com/Edenilson-Molina/maize-doctor-app`

- **API (cuenta de usuario, sincronización opcional y avisos de actualización):**

  `https://github.com/daiv05/maize-doctor-api`

- **Sitio web y documentación técnica:**

  `https://doctor-maiz.deras.dev/es`

- **Dataset consolidado en Hugging Face:**

  `https://huggingface.co/datasets/daiv05/corn-leaf-diseases-pests-and-deficiencies`

  Cada fuente conserva su licencia original (Tabla 2.2).

- **Artefactos de evaluación y modelos exportados:**

  `https://drive.google.com/drive/folders/1OeZdWggfp7nVkaYHW_oOuCma5xbwhns6?usp=drive_link`

Anexo B: Hashes de los Modelos Respaldados

La tabla siguiente lista los hashes SHA-256 de los modelos, para comprobar que un archivo descargado es el mismo que se evaluó en este trabajo.

Hashes SHA-256 de los modelos respaldados

Modelo	**Tamaño**	**Hash SHA-256 del Checkpoint (`best.pth`)**
EfficientNet-Lite0 Base (42, oficial)	13.79 MB	`860180f33bf1749ffee9f3cccb9569a47afd9ca0fcef52713e18f99f82a57859`
EfficientNet-Lite0 Int8 (Móvil, `model_int8.tflite`)	3.74 MB	`bb31467a58c11cd474159bd5739a7a57b1f1edfda6b5dbfae8fa91337f3c56b1`
EfficientNet-B0 Referencia	16.36 MB	`0e367a5318c068c9bcc90a6bec0d17a0b029251ca5f98400034bd09de7524fdb`