UNIVERSIDAD DE EL SALVADOR

FACULTAD DE INGENIERÍA Y ARQUITECTURA

ESCUELA DE INGENIERÍA DE SISTEMAS INFORMÁTICOS

CURSO DE ESPECIALIZACIÓN EN MACHINE LEARNING

DISEÑO E IMPLEMENTACIÓN DE DOCTOR MAÍZ: SISTEMA MÓVIL BASADO EN REDES NEURONALES CONVOLUCIONALES PARA LA IDENTIFICACIÓN FITOSANITARIA EN HOJAS DE MAÍZ Y CONTRIBUCIÓN A UN CONJUNTO DE DATOS NACIONAL

PRESENTADO POR:

JOSÍAS ABNER RIVAS FUENTES

DAVID ALEJANDRO DERAS CERROS

ELMER EDENILSON ROSALES MOLINA

PARA OPTAR AL TÍTULO DE:

INGENIERO(A) DE SISTEMAS INFORMÁTICOS

CIUDAD UNIVERSITARIA, OCTUBRE DE 2026

UNIVERSIDAD DE EL SALVADOR

RECTOR:

MSC. JUAN ROSA QUINTANILLA

SECRETARIO GENERAL:

LCDO. PEDRO ROSARIO ESCOBAR CASTANEDA

FACULTAD DE INGENIERÍA Y ARQUITECTURA

DECANO:

MSC. LUIS SALVADOR BARRERA MANCÍA

SECRETARIO:

ARQ. RAÚL ALEXANDER FABIÁN ORELLANA

ESCUELA DE INGENIERIA DE SISTEMAS INFORMÁTICOS

DIRECTOR:

MSC. CESAR AUGUSTO GONZÁLEZ RODRÍGUEZ

UNIVERSIDAD DE EL SALVADOR

FACULTAD DE INGENIERIA Y ARQUITECTURA

ESCUELA DE INGENIERIA DE SISTEMAS INFORMÁTICOS

Trabajo de Graduación previo a la opción al Grado de:

INGENIERO (A) DE SISTEMAS INFORMÁTICOS

Título:

"DISEÑO E IMPLEMENTACIÓN DE DOCTOR MAÍZ: SISTEMA MÓVIL BASADO EN REDES NEURONALES CONVOLUCIONALES PARA LA IDENTIFICACIÓN FITOSANITARIA EN HOJAS DE MAÍZ Y CONTRIBUCIÓN A UN CONJUNTO DE DATOS NACIONAL"

Presentado por:

JOSÍAS ABNER RIVAS FUENTES

DAVID ALEJANDRO DERAS CERROS

ELMER EDENILSON ROSALES MOLINA

Trabajo de Graduación Aprobado por:

Docente Asesor(a):

ING. BLADIMIR DIAZ CAMPOS

SAN SALVADOR, OCTUBRE DE 2026

Trabajo de Graduación Aprobado por:

Docente Asesor:

ING. BLADIMIR DIAZ CAMPOS

Agradecimientos

A Dios todopoderoso, por haberme concedido la perseverancia, la sabiduría y la fortaleza necesaria para afrontar cada desafío académico y culminar con éxito esta etapa de mi formación profesional.
A mi familia, cuyo respaldo incondicional, sacrificios silenciosos y constante motivación fueron el cimiento sobre el cual pude edificar cada meta. Gracias por creer en mí en todo instante.
A mis compañeros de tesis y amigos entrañables, David y Elmer, por las incontables jornadas de discusión técnica, investigación y programación. Su compromiso y esfuerzo conjunto hicieron posible que esta investigación trascendiera el aula para convertirse en un aporte tangible al agro salvadoreño.
A la Universidad de El Salvador y a cada docente de la Escuela de Ingeniería de Sistemas Informáticos, por transmitirme con rigor y vocación los principios científicos que hoy me capacitan como profesional al servicio de la sociedad.

Josias Abner Rivas Fuentes

Agradecimientos

A Dios, por guiar mis pasos, iluminar mi entendimiento y brindarme salud y perseverancia en cada tramo de este largo camino universitario.
A mis padres y hermanos, por su amor inquebrantable, su fe en mis capacidades y por enseñarme que ningún obstáculo es insuperable cuando se trabaja con disciplina y honestidad. Cada página de este esfuerzo también les pertenece.
A mis compañeros de equipo, Josias y Elmer, por compartir la misma pasión por la excelencia tecnológica y el rigor científico. Las largas noches resolviendo problemas de modelos y arquitecturas forjaron no solo un gran proyecto, sino una amistad inquebrantable.
A todos los profesores y asesores que nos exigieron dar lo mejor de nosotros y nos enseñaron a buscar siempre el impacto social de la informática.

David Alejandro Deras Cerros

Agradecimientos

A Dios, principio y fin de todas las cosas, por derramar sobre mi vida bendiciones inmerecidas, paciencia ante la adversidad y la capacidad de culminar mi carrera profesional.
A mi amada familia, por su apoyo moral y material constante, por sus oraciones y por ser el refugio que siempre me impulsó a seguir adelante sin desfallecer.
A mis colegas y compañeros de graduación, Josias y David, por la lealtad, el trabajo en equipo y el entusiasmo inagotable con el que enfrentamos este reto. Su talento y dedicación hicieron que cada desafío fuera una oportunidad de aprendizaje mutuo.
A la gloriosa Universidad de El Salvador, alma mater de generaciones, por abrirme sus puertas y formarme con sentido crítico y compromiso hacia los sectores más desprotegidos de nuestra patria.

Elmer Edenilson Rosales Molina

Resumen Ejecutivo

El cultivo del maíz constituye un componente fundamental de la seguridad alimentaria y de los medios de vida de numerosos productores en El Salvador, especialmente de aquellos que trabajan en pequeñas parcelas y disponen de acceso limitado a asistencia técnica especializada. En este contexto, las enfermedades foliares, las plagas y las deficiencias nutricionales pueden comprometer el rendimiento de los cultivos y dificultar la identificación oportuna de problemas agronómicos. Las soluciones de diagnóstico basadas en visión artificial ofrecen una alternativa tecnológica, aunque su aplicación en entornos rurales plantea desafíos relacionados con la conectividad, los recursos computacionales de los dispositivos móviles y la capacidad de generalización ante imágenes capturadas en condiciones distintas de aquellas utilizadas durante el entrenamiento.

Esta investigación aborda dichos desafíos mediante el análisis, diseño, desarrollo y evaluación de **Doctor Maíz**, un sistema móvil de visión artificial basado en redes neuronales convolucionales (CNN) y técnicas de inteligencia artificial en el borde (*Edge AI*). La solución está orientada a la clasificación de nueve condiciones agronómicas foliares, que comprenden enfermedades, plagas y deficiencias nutricionales, mediante inferencia local en dispositivos móviles. Asimismo, incorpora mecanismos de captura y contribución voluntaria de imágenes, cuya sincronización permite sentar las bases para la conformación de un conjunto de datos nacional sobre condiciones fitosanitarias del maíz.

Para el desarrollo experimental se recopiló y depuró un corpus de **33 429 imágenes** procedentes de 11 repositorios internacionales. Se implementó un flujo de procesamiento reproducible que incluyó controles de integridad, revisión de duplicados y verificación de la procedencia de las imágenes. La optimización de hiperparámetros se realizó mediante optimización bayesiana con Optuna y poda temprana mediante MedianPruner, explorando seis dimensiones de configuración y registrando los tiempos de cómputo en GPU de cada ensayo.

El modelo oficial es una EfficientNet-Lite0 entrenada sobre el corpus de 33 429 imágenes, que en un conjunto de prueba retenida de 5 015 imágenes obtuvo un Macro F_1 de **0.9480** y una exactitud de 97.81 %; en tres semillas, la media fue de $0{,}9435 \pm 0{,}0052$. Un ensamble heterogéneo de EfficientNet-Lite0, EfficientNet-B0 y ShuffleNet-V2 con votación suave (*Soft Voting*), evaluado en el corpus de 33 433 imágenes de una etapa previa, alcanzó un Macro F_1 de 0.9567 y una exactitud de 98.29 %, sin que se haya desplegado. Estos resultados corresponden al protocolo experimental empleado y no constituyen una garantía del rendimiento en condiciones reales de campo.

La evaluación de generalización es la principal limitación del trabajo. En 97 fotografías de campo externas al corpus, el modelo oficial acertó 41 (42 %) y el detector de entradas fuera de distribución (*Out-of-Distribution*, OOD) rechazó 49; el modelo de agosto acertó 39, por lo que la brecha no se explica por el cambio de modelo y es compatible con una generalización limitada fuera del corpus. La validación cruzada agrupada por fuente (*SourceGroupedKFold*) produjo un Macro F_1 de $0{,}6026 \pm 0{,}1240$ (IC95, sobre las clases presentes en cada pliegue; 0.4359 con el macro F_1 convencional) frente a $0{,}9311 \pm 0{,}0099$ en la partición estratificada. Además, un experimento de ablación espacial mostró que, al ocluir la región

central de la imagen, el modelo conservó un **79.46 % de exactitud** con el 63.7 % periférico visible, y al ocluir la periferia cayó a 42.25 % con el 36.3 % central visible; las dos condiciones tienen áreas distintas y el experimento no aisla el fondo de la hoja. Como medidas de mitigación, se incorporaron un marco guía para la captura de imágenes y un detector OOD basado en la distancia de Mahalanobis, con umbral 106.37 calibrado al percentil 95 de validación; su efecto sobre el sesgo de procedencia no se midió.

Para el despliegue móvil, el modelo oficial se cuantizó a enteros de 8 bits (**Int8**), con un tamaño de **3.74 MB** (72.9 % menos que el modelo en coma flotante). En la prueba completa, el modelo Int8 obtuvo un Macro F_1 de 0.9489 y una exactitud de 97.87 %, con 99.74 % de acuerdo con el modelo original. En un dispositivo físico Motorola edge 40 neo con Android 15, las medianas fueron de 98 ms de preprocesado y 23 ms de inferencia, y el teléfono reproduce las predicciones del modelo Int8 del servidor en 143 de 143 imágenes. La inferencia local permite realizar clasificaciones sin conexión a internet, mientras que las funciones de sincronización de imágenes requieren conectividad.

En conjunto, Doctor Maíz integra clasificación mediante aprendizaje profundo, ejecución en dispositivos móviles y mecanismos de recopilación colaborativa de imágenes. Los resultados muestran que la implementación es técnicamente viable en el dispositivo probado y, al mismo tiempo, ponen de manifiesto la necesidad de fortalecer la generalización entre fuentes y validar el comportamiento del sistema con imágenes representativas de condiciones reales de cultivo. Finalmente, se proponen cinco recomendaciones dirigidas al Ministerio de Agricultura y Ganadería (MAG) y al Centro Nacional de Tecnología Agropecuaria y Forestal (CENTA), orientadas a la validación en campo, la transferencia tecnológica y el desarrollo progresivo de un conjunto de datos nacional de acceso abierto.

Índice general

1 Especificación del Proyecto **1**

1.1 Situación Actual . . . 1

1.1.1 Antecedentes: El maíz como sustento y la emergencia productiva . . . 1

1.1.2 Descripción del problema: El diagnóstico a ciegas en el surco . . . 1

1.1.3 Planteamiento del problema . . . 3

1.2 Objetivos . . . 6

1.2.1 Objetivo General . . . 6

1.2.2 Objetivos Específicos . . . 7

1.3 Alcance y Límites del Proyecto . . . 7

1.3.1 Alcance del Proyecto . . . 7

1.3.2 Límites y Fronteras del Proyecto . . . 9

1.4 Hipótesis . . . 10

1.4.1 Hipótesis General . . . 10

1.4.2 Criterios de Éxito Específicos . . . 10

1.5 Justificación . . . 11

1.5.1 Justificación Técnica y Metodológica . . . 11

1.5.2 Justificación Económica . . . 12

1.5.3 Justificación Social y Ambiental . . . 12

1.5.4 Justificación Académica e Institucional . . . 12

1.6 Cronograma de Actividades . . . 13

1.7 Presupuesto Global Estimado . . . 14

2 Análisis y Diseño de la Solución **17**

2.1 Metodología de Trabajo y Gobernanza MLOps . . . 17

2.2 Clases Agronómicas Objetivo . . . 18

2.3 Recopilación, Depuración y Auditoría de Datos . . . 20

2.3.1 Data Profiling y Análisis Exploratorio de Datos (EDA) . . . 20

2.3.2 Auditoría Criptográfica de Píxeles . . . 21

2.4 Arquitecturas y Búsqueda de Hiperparámetros . . . 22

2.4.1 Familias Convolucionales Seleccionadas . . . 22

2.4.2 Espacio de Búsqueda y Poda Temprana . . . 23
2.4.3 Ensamble Multimodelo por Soft Voting . . . 23
2.5 Despliegue en Dispositivo Móvil . . . 24
2.5.1 Cuantización a Enteros de 8 Bits (Int8) . . . 24
2.5.2 Detector de Anomalías Fuera de Distribución (OOD) . . . 24
2.5.3 Mitigación en la Interfaz: Marco Guía y Severidad . . . 25
2.6 Segmentación de Hojas: dos usos y resultados . . . 26
2.7 Sincronización y Contribución al Dataset Colaborativo . . . 27
2.8 Arquitectura General del Sistema . . . 27
2.8.1 Tecnologías por proyecto . . . 27

3 Estrategia de Implementación y Análisis de Resultados 29
3.1 Estrategia y Entorno de Implementación . . . 29
3.1.1 Infraestructura de Cómputo y Entrenamiento en la Nube . . . 29
3.2 Resultados . . . 30
3.2.1 Ahorro de entrenamiento: búsqueda bayesiana con poda . . . 31
3.2.2 Rendimiento del modelo: ensamble y bioseguridad . . . 33
3.2.3 Rendimiento del modelo: generalización entre fuentes . . . 35
3.2.4 Rendimiento del modelo: fotografías de campo externas . . . 37
3.2.5 Capacidades del diagnóstico: equidad entre entornos . . . 37
3.2.6 Capacidades del diagnóstico: dependencia del fondo . . . 39
3.2.7 Solución integral: prototipo en hardware real . . . 42
3.3 Impacto Social y Recomendaciones de Política Pública . . . 45

Conclusiones y Recomendaciones 47

Bibliografía 50

Glosario de Términos 52

Anexos 54

Índice de tablas

1.1 Criterios de éxito del proyecto, agrupados por tema 11
1.2 Cronograma planificado de actividades y fases del proyecto (CRISP-DM) 14
1.3 Presupuesto proyectado: Cálculo del salario base por rol (280 horas) 15
1.4 Presupuesto proyectado: Cargas y prestaciones patronales sobre el salario base 15
1.5 Presupuesto: Infraestructura Cloud y Licencias 16
1.6 Resumen presupuestario global de la investigación 16

2.1 Taxonomía agronómica de las nueve clases integradas en DoctorMaiz 18
2.2 Fuentes de datos recopiladas y distribución de muestras 20
2.3 Espacio de búsqueda de hiperparámetros explorado con Optuna 23
2.4 Tecnologías principales por proyecto 28

3.1 Estado de los criterios de éxito al cierre de esta versión 31
3.2 Comparativa cuantitativa: Baseline sin Optuna vs. Configuración Optimizada (Optuna) . . . 32
3.3 Desempeño del ensamble frente a modelos individuales en la prueba de la etapa 2 (corpus de 33 433 imágenes, 5 015 de prueba) 33
3.4 Desglose de F_1 por clase en la prueba de la etapa 2 (corpus de 33 433 imágenes; Lite0 `20260812_221429`) 35
3.5 Resultados del experimento cruzado 2×2 de validación cruzada en 5 pliegues 35
3.6 Evaluación LOSO con tres semillas: Macro F_1 y exactitud en la fuente retenida 36
3.7 Aciertos del modelo oficial en fotografías de campo externas, por clase 37
3.8 Tasa de falsos negativos (FNR) desagregada por clase y entorno, checkpoint de la etapa 2 . 38
3.9 Auditoría de ablación espacial con control nulo en el conjunto de prueba, checkpoint de la etapa 2 39
3.10 Latencias medianas en hardware físico (Motorola edge 40 neo) 42
3.11 Hashes SHA-256 de los pesos físicos de los modelos respaldados 55

Índice de figuras

1.1 Diversidad morfológica, fondos rústicos y heterogeneidad geométrica en las afecciones foliares del maíz. 3
1.2 Modelo conceptual de caja negra para el diagnóstico fitosanitario móvil. 6
1.3 Diagrama de Gantt del cronograma planificado (Metodología CRISP-DM) 13

2.1 Catálogo fotográfico de las nueve clases agronómicas presentes en el corpus. 19
2.2 Análisis exploratorio de distribución y balance ambiental del corpus. 21
2.3 Concentración de procedencia y heterogeneidad geométrica en las imágenes. 21
2.4 Diagrama de flujo arquitectónico integral del sistema DoctorMaiz. 28

3.1 Curvas de convergencia: Pérdida y Macro F_1 durante el entrenamiento en Modal. 30
3.2 Dinámica de exploración e impacto relativo de variables en Optuna. 32
3.3 Comparativa de desempeño del ensamble frente a modelos individuales. 34
3.4 Matriz de confusión normalizada del ensamble sobre 5 015 muestras de prueba. 34
3.5 Impacto de la partición frente a la optimización algorítmica. 36
3.6 Auditoría de equidad e imparcialidad entre condiciones fotográficas. 38
3.7 Exactitud según la región geométrica visible frente al azar nulo. 39
3.8 Mapas de activación Grad-CAM en muestras de campo real y laboratorio. 41
3.9 Panel comparado de explicabilidad local: LIME, SHAP y Grad-CAM. 41
3.10 Flujo principal de la aplicación móvil nativa DoctorMaiz. 44
3.11 Mecanismos de seguridad, participación comunitaria y escalas agronómicas. 45

CAPÍTULO 1

ESPECIFICACIÓN DEL PROYECTO

1.1. Situación Actual

1.1.1. Antecedentes: El maíz como sustento y la emergencia productiva

La agricultura representa el 5.6 % del Producto Interno Bruto (PIB) de El Salvador [2] y sostiene de forma directa a más de dos millones de personas en el sector rural. Para las familias campesinas salvadoreñas, el maíz (*Zea mays L.*) constituye la base diaria de la alimentación familiar, con un consumo promedio reportado que supera los 115 kilogramos por persona al año [3]. De acuerdo con registros oficiales del Ministerio de Agricultura y Ganadería [11], el 82.1 % de los productores nacionales trabajan pequeñas parcelas familiares menores a dos manzanas (1.4 hectáreas), bajo un régimen de agricultura de subsistencia dependiente casi por completo del régimen de lluvias estacionales.

En los últimos años, esta base productiva ha enfrentado una vulnerabilidad creciente frente a anomalías climáticas e incidencia fitosanitaria [11]. En una milpa sometida a estrés hídrico o térmico, la aparición de enfermedades foliares o plagas no es un fenómeno aislado: si una infección o ataque no se detecta y atiende de forma oportuna, compromete severamente el llenado de grano y la productividad de la cosecha [3], amenazando de manera directa la seguridad alimentaria y la subsistencia del hogar campesino.

1.1.2. Descripción del problema: El diagnóstico a ciegas en el surco

En las parcelas rurales salvadoreñas no existen microscopios ni laboratorios cercanos. El diagnóstico fitosanitario diario descansa por completo en los ojos del agricultor, quien recorre el surco bajo el sol, entre polvo y calor, tratando de interpretar manchas y marchitamientos complejos:

- **Tizón foliar (*Exserohilum turcicum*) y mancha gris (*Cercospora zeae-maydis*):** Colonizan la

lámina verde con lesiones alargadas o rectangulares que secan la hoja y detienen el llenado de la mazorca.

- **Gusano cogollero (*Spodoptera frugiperda*):** Mastica los verticilos tiernos y destruye el punto de crecimiento de la planta.
- **Necrosis letal del maíz (MLN):** Complejo viral altamente destructivo que marchita la planta de raíz a espiga y anula el 100 % de la cosecha.
- **Deficiencias nutricionales de nitrógeno, fósforo y potasio (N-P-K):** Provocan clorosis en "V", pigmentaciones púrpuras y secado marginal que a simple vista se confunden fácilmente con hongos o virus.

Esta dificultad se agrava ante la marcada limitación de cobertura en la asistencia técnica pública presencial. La relación entre el personal técnico extensionista disponible y el número global de productores agrícolas dispersos en la geografía rural salvadoreña genera una brecha estructural de atención, donde una visita agronómica especializada suele demorar semanas o no llegar a materializarse durante la ventana crítica de la infección [3].

Ante la incertidumbre y el riesgo inminente de pérdida de la siembra, el agricultor acude frecuentemente a puntos comerciales de agroservicios. En estos espacios, la falta de diagnóstico instrumental propicia recomendaciones empíricas basadas en agroquímicos de amplio espectro para síntomas que corresponden a deficiencias nutricionales de suelo. Esta situación ocasiona pérdidas económicas significativas para el presupuesto familiar al incurrir en gastos fitosanitarios ineficaces, además de generar impactos ambientales negativos por sobreaplicación de químicos y retrasar la atención correctiva adecuada de patógenos severos [3].

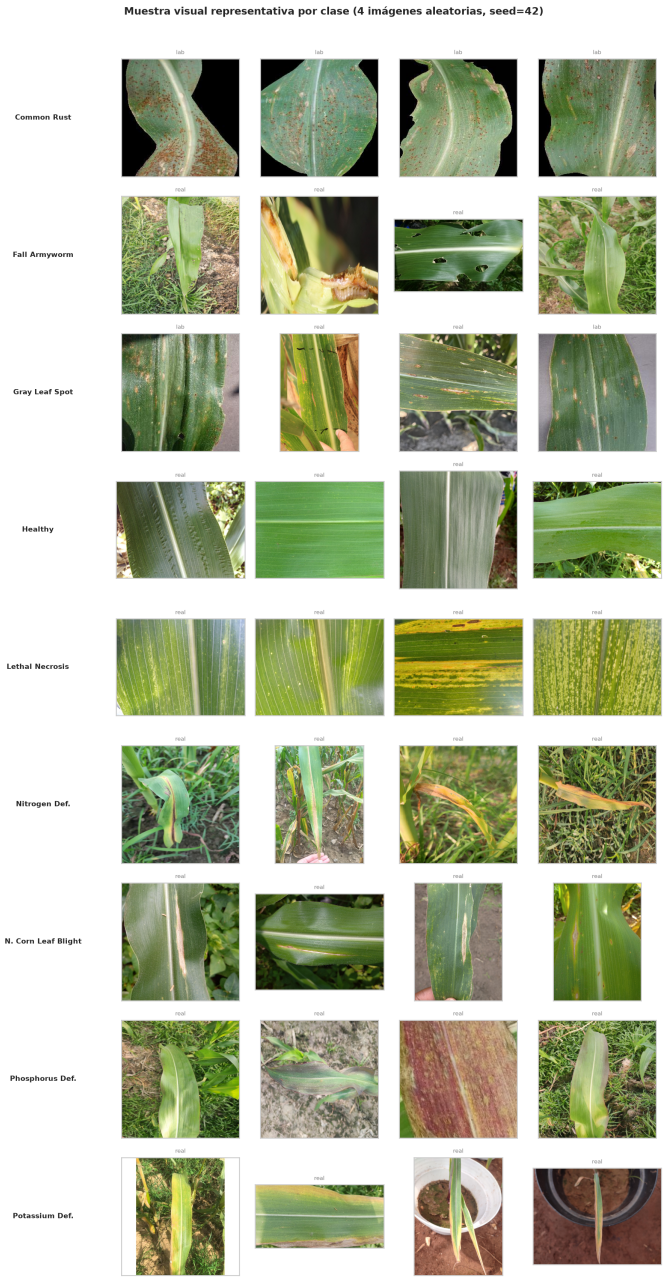


Figura 1.1: Diversidad morfológica, fondos rústicos y heterogeneidad geométrica en las afecciones foliares del maíz.

1.1.3. Planteamiento del problema

A partir de la situación descrita, se constata que los mecanismos tradicionales de extensión agronómica resultan insuficientes para brindar cobertura a los pequeños productores de maíz en El Salvador, mientras que las herramientas digitales contemporáneas han sido concebidas bajo premisas incompatibles con la

realidad rural. En la práctica, las soluciones comerciales de visión artificial presentan tres limitaciones críticas:

1. **Dependencia de conectividad de red:** La mayor parte de las aplicaciones disponibles requieren comunicación permanente con servidores en la nube para procesar las capturas. En el agro salvadoreño, donde extensas zonas rurales presentan cobertura celular inestable o nula y los agricultores no disponen de planes continuos de transmisión de datos, esta dependencia anula la utilidad práctica de las herramientas en el propio surco.

2. **Incompatibilidad con terminales básicos:** Los modelos de aprendizaje profundo convencionales demandan una capacidad de cómputo y memoria que excede con creces los recursos de los teléfonos inteligentes accesibles para las familias campesinas (dispositivos de gama de entrada con 2 a 4 GB de RAM), provocando bloqueos, latencias intolerables y un rápido consumo de batería.

3. **Vulnerabilidad ante la variabilidad del entorno real:** Al haber sido entrenados mayoritariamente sobre imágenes de laboratorio con fondos neutros e iluminación homogénea, los algoritmos colapsan al exponerse a la milpa, donde la presencia de suelos rústicos, sombras irregulares, malezas y contraluz induce clasificaciones erróneas emitidas con un alto grado de sobreconfianza.

Frente a este escenario, surge la necesidad de replantear el diagnóstico automatizado desde las restricciones materiales del entorno agrícola. Una herramienta orientada a cerrar esta brecha debe operar directamente en manos del productor, fundamentándose en cuatro requerimientos operacionales esenciales:

- **Autonomía operativa local:** La capacidad diagnóstica debe ejecutarse de forma integral en el propio dispositivo, asegurando disponibilidad inmediata en la parcela sin supeditar su funcionamiento a redes de telecomunicaciones.

- **Austeridad y eficiencia computacional:** El procesamiento debe ajustarse estrictamente a las capacidades técnicas de los teléfonos básicos predominantes en las zonas rurales, garantizando tiempos de respuesta cortos y un consumo mínimo de energía.

- **Resiliencia y bioseguridad ante la captura:** El sistema debe ser capaz de discriminar la sintomatología foliar frente al ruido visual del campo y, de manera primordial, reconocer situaciones de

incertidumbre o tomas no válidas para abstenerse de emitir diagnósticos infundados que perjudiquen la economía familiar.

- **Traducción agronómica orientada a la acción:** El diagnóstico visual debe complementarse con una evaluación comprensible del nivel de daño y con alternativas concretas de manejo integrado basadas en bioinsumos accesibles, facilitando una intervención oportuna y viable para el productor.

Con base en estas consideraciones, se formula la problemática central de la investigación:

¿En qué medida es factible concebir, desarrollar y evaluar una aplicación móvil de diagnóstico fitosanitario que opere de manera autónoma en teléfonos inteligentes de gama baja o media, capaz de discernir patologías foliares en condiciones reales de campo, gestionar la incertidumbre de la captura y orientar oportunamente al agricultor salvadoreño en el manejo integrado de su cultivo?

Modelo conceptual de caja negra del sistema

Con el propósito de delimitar analíticamente este problema sin prejuzgar la arquitectura interna que deberá investigarse y validarse experimentalmente en los capítulos posteriores, el sistema se conceptualiza mediante el modelo de caja negra (Figura 1.2). En la ingeniería de sistemas, este enfoque formaliza la relación entre los estímulos y restricciones del entorno problemático (entradas) y los resultados requeridos para mitigar la problemática (salidas), definiendo el núcleo del sistema como el proceso de transformación tecnológica que constituye el objeto de estudio de esta investigación:

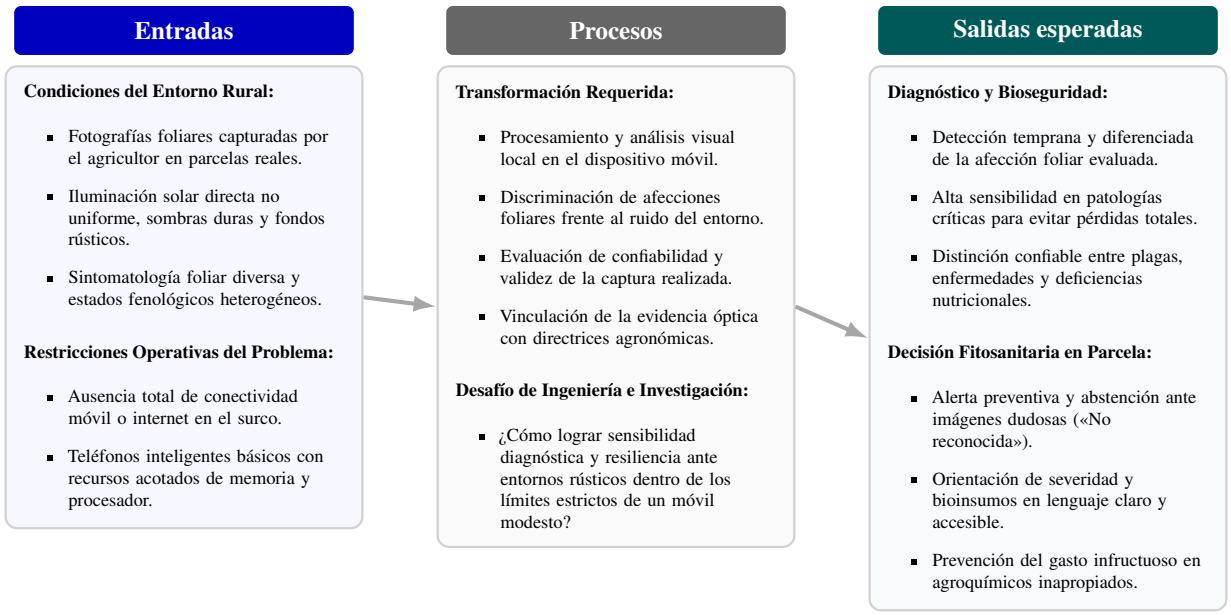


Figura 1.2: Modelo conceptual de caja negra para el diagnóstico fitosanitario móvil.

Como sintetiza la Figura 1.2, el modelo de caja negra formaliza la lógica de la investigación: establece cómo las restricciones de campo y los desafíos visuales del cultivo ingresan a un proceso de transformación móvil concebido para generar diagnósticos confiables y decisiones fitosanitarias oportunas para el campesino. A partir de esta delimitación del problema, se formulan a continuación los objetivos de la investigación.

1.2. Objetivos

1.2.1. Objetivo General

Desarrollar, evaluar e implementar un sistema de visión artificial embebido (*Edge AI*) para el diagnóstico fitosanitario a partir de imágenes de la hoja de maíz en El Salvador, desplegado mediante una aplicación móvil nativa de operación completamente desconectada (*offline*), capaz de clasificar afecciones foliares con alta sensibilidad y baja latencia en teléfonos inteligentes de gama baja o media.

1.2.2. Objetivos Específicos

1. Consolidar, depurar y auditar criptográficamente un conjunto de más de 33 000 imágenes de la hoja de maíz distribuidas en 9 condiciones agronómicas, estableciendo contratos de datos verificables para descartar duplicados y prevenir filtraciones entre particiones.

2. Optimizar arquitecturas convolucionales ligeras preentrenadas mediante búsqueda bayesiana de hiperparámetros (Optuna) y algoritmos de poda temprana, maximizando el Macro F_1-Score con un uso eficiente del cómputo en GPU.

3. Diseñar una estrategia de ensamble por votación suave (*Soft Voting*) que combine modelos con diferentes sesgos inductivos, con el fin de elevar la sensibilidad diagnóstica en patologías críticas de la hoja de maíz y mitigar el desbalance de clases.

4. Evaluar el desempeño del sistema bajo protocolos de validación cruzada agrupada por procedencia (*SourceGroupedKFold*), cuantificando la disparidad de impacto entre laboratorio y campo real, así como la atribución espacial mediante técnicas de explicabilidad y ablación de fondo.

5. Cuantizar la arquitectura neuronal a enteros de 8 bits (Int8) e integrarla en una aplicación móvil nativa provista de marco guía de encuadre y detector de tomas anómalas, validando su precisión y fluidez en teléfonos inteligentes físicos de gama baja o media.

6. Formular una propuesta estratégica de integración institucional y políticas públicas orientada al Ministerio de Agricultura y Ganadería (MAG) y al CENTA, que facilite la transferencia tecnológica y el acompañamiento técnico a los pequeños productores de maíz.

1.3. Alcance y Límites del Proyecto

1.3.1. Alcance del Proyecto

El alcance del presente proyecto comprende la investigación, diseño, desarrollo e implementación de una solución integral de diagnóstico fitosanitario orientada a los pequeños productores de maíz en El Salvador.

La solución se materializa en dos componentes tecnológicos articulados: la aplicación móvil nativa para el usuario final y el motor analítico de visión artificial embebida.

Alcance de la Aplicación Móvil (DoctorMaiz)

La aplicación móvil constituye el punto de interacción directa en manos del agricultor y abarca las siguientes capacidades funcionales:

- **Inferencia local autónoma (*Offline*):** Ejecución integral del motor neuronal en el procesador del teléfono mediante modelos cuantizados, asegurando diagnósticos instantáneos en el surco sin requerir conexión a internet ni datos móviles.
- **Captura asistida con marco guía foliar:** Interfaz de cámara con retícula visual ergonómica que orienta al agricultor a encuadrar la lámina de la hoja, reduciendo la captura de fondos distractores (suelo, sombras o maleza) antes de procesar la imagen.
- **Detección preventiva de capturas anómalas (Seguridad OOD):** Módulo de rechazo ante muestras fuera de dominio capaz de evaluar si la captura no corresponde a una hoja de maíz o presenta incertidumbre excesiva, notificando un estado de «No reconocida» para evitar diagnósticos engañosos.
- **Diagnóstico y valoración de severidad:** Presentación de resultados en lenguaje claro y accesible, con una guía visual de severidad en tres niveles (baja, moderada y crítica) que el productor compara con su hoja; la aplicación no mide el daño.
- **Catálogo de manejo integrado y bioinsumos:** Guía fitosanitaria práctica vinculada al diagnóstico que ofrece alternativas de bioinsumos y manejo cultural de bajo costo, previniendo gastos perjudiciales en agroquímicos inapropiados.
- **Historial y georreferenciación de muestreos:** Registro local persistente de cada evaluación (fecha, diagnóstico, severidad y ubicación GPS) para que el agricultor monitoree la evolución de sus parcelas a lo largo del ciclo agrícola.

- **Contribución comunitaria y sincronización voluntaria:** Módulo opcional que permite almacenar imágenes validadas localmente para compartirlas cuando se cuente con conectividad, contribuyendo al monitoreo fitosanitario colectivo.

Alcance del Componente de Inteligencia Artificial Embebida

El núcleo de aprendizaje profundo embebido abarca:

- **Cobertura taxonómica de 9 clases en hoja de maíz:** Clasificación supervisada de signos y síntomas foliares, cubriendo enfermedades causadas por hongos (tizón foliar, mancha gris y roya común), virosis crítica (necrosis letal del maíz), plagas directas (gusano cogollero), deficiencias nutricionales de suelo (nitrógeno, fósforo y potasio) y lámina foliar sana.
- **Optimización bayesiana, ensamble y cuantización Int8:** Búsqueda automatizada de hiperparámetros (Optuna con poda temprana), combinación estratégica por votación suave (*Soft Voting*) y cuantización a 8 bits exportada en formato TensorFlow Lite mediante litert-torch, para inferencia en procesadores móviles ($\leq$ 300 ms).
- **Auditoría de sesgos y generalización:** Protocolo de evaluación cruzada agrupada por procedencia (*SourceGroupedKFold*) y pruebas de ablación espacial de fondo para auditar el fenómeno de atajos visuales (*Clever Hans effect*).

1.3.2. Límites y Fronteras del Proyecto

Con el fin de delimitar con precisión la cobertura de la investigación, se definen los siguientes límites operacionales:

- **Límite biológico y sintomático:** El sistema se restringe exclusivamente al análisis de afecciones visibles en la lámina foliar del maíz. Quedan fuera del alcance patologías radiculares, afecciones del tallo interno sin expresión foliar y el monitoreo de plagas subterráneas.
- **Límite de plataforma y compatibilidad de hardware:** La solución móvil se enfoca en dispositivos con sistema operativo Android 7.0 (API 24) o superior, el mínimo del proyecto, con arquitectura de procesador ARM (v7 o v8); las pruebas en dispositivo se hicieron en Android 15, cámara trasera

con enfoque automático y al menos 2 GB de memoria RAM. No se contempla desarrollo nativo para iOS ni para teléfonos sin capacidades inteligentes.

- **Límite de infraestructura y red:** La aplicación está diseñada para operar desconectada; no existe dependencia de servicios en la nube para emitir el diagnóstico, ni se incluye sincronización transaccional en tiempo real entre múltiples terminales.
- **Límite legal y de diagnóstico fitopatológico:** La herramienta constituye un asistente técnico de orientación y apoyo agronómico para el productor. En ningún caso reemplaza los ensayos fitopatológicos de laboratorio (cultivos, aislamiento microbiano o pruebas PCR), ni sustituye los dictámenes oficiales de cuarentena o certificación fitosanitaria del Ministerio de Agricultura y Ganadería.

1.4. Hipótesis

1.4.1. Hipótesis General

El diseño propone un sistema de visión artificial embebido en una aplicación móvil nativa, con captura asistida y operación completamente desconectada, capaz de clasificar nueve condiciones agronómicas de la hoja de maíz en teléfonos inteligentes de gama baja o media del sector rural salvadoreño. Se considera alcanzado el objetivo general si se cumplen los criterios de la Tabla 1.1.

1.4.2. Criterios de Éxito Específicos

Los criterios siguientes son las condiciones que el sistema debe cumplir para considerar alcanzado cada objetivo. Se verifican en el capítulo de resultados y se agrupan en cinco temas.

Tabla 1.1: Criterios de éxito del proyecto, agrupados por tema

Tema	**Criterio y umbral**	**Métrica**
Ahorro de entrenamiento	El total de épocas ejecutadas por la búsqueda no supera el 50 % del máximo teórico (25 ensayos $\times$ 60 épocas).	Épocas ejecutadas por la búsqueda
Rendimiento del modelo	Alcanzar Macro $F_1 \geq 0{,}85$ en la partición de prueba retenida, con recall de la necrosis letal (MLN) $\geq 95\,\%$.	Macro F_1, recall por clase
Capacidades del diagnóstico	Mantener un *Disparate Impact Ratio* $\geq 0{,}80$ entre laboratorio y campo real.	DIR
Confiabilidad de la evaluación	Ninguna imagen del conjunto de prueba aparece en entrenamiento ni validación, por hash de archivo y por píxeles.	Solapamiento por SHA-256 y por píxeles
Solución integral	Modelo Int8 de 20 MB o menos, preprocesado e inferencia de 300 ms o menos en un teléfono de gama media y funcionamiento sin conexión.	Tamaño, latencia

1.5. Justificación

1.5.1. Justificación Técnica y Metodológica

La presente investigación se justifica técnicamente al trasladar el procesamiento de aprendizaje profundo desde arquitecturas dependientes de servidores en la nube hacia el borde del dispositivo móvil (*Edge AI*). En la literatura especializada de visión por computadora aplicada a la agricultura, predomina el entrenamiento de modelos convolucionales de alta complejidad evaluados sobre particiones aleatorias convencionales, las cuales frecuentemente sufren de fuga de información e introducen atajos visuales ligados a fondos controlados [1]. El presente proyecto aborda esta limitación mediante una metodología rigurosa basada en auditoría de duplicados a nivel de píxel, esquemas de validación cruzada agrupada por procedencia y técnicas de cuantización simétrica a enteros de 8 bits (*Int8*) que reducen la demanda computacional [5, 17]. Asimismo, integra salvaguardas operacionales como el filtrado de muestras fuera de dominio (*OOD*) [8] y mecanismos de explicabilidad visual mediante mapas de activación [16], con el fin de que las predicciones se apoyen en características de la lámina foliar; la verificación de este objetivo se presenta en el capítulo de resultados.

1.5.2. Justificación Económica

Para las pequeñas familias productoras de maíz en El Salvador, el margen de rentabilidad agrícola por ciclo es sumamente reducido y altamente vulnerable a sobrecostos imprevistos [11]. Un diagnóstico fitosanitario erróneo conduce a la compra e intoxicación del cultivo con agroquímicos comerciales inadecuados, mermando el escaso capital de trabajo disponible. Proveer una aplicación móvil de uso autónomo, gratuito y local en el propio teléfono inteligente del agricultor permite orientar de manera precisa la intervención fitosanitaria, evitando gastos innecesarios en plaguicidas ante síntomas provocados por deficiencias nutricionales y facilitando una acción temprana contra plagas destructivas como el gusano cogollero (*Spodoptera frugiperda*) antes de que comprometan el rendimiento económico de la milpa [3].

1.5.3. Justificación Social y Ambiental

Desde la perspectiva social, la implementación de *DoctorMaiz* contribuye a reducir la brecha tecnológica en comunidades rurales con acceso limitado o nulo a servicios presenciales de extensión agronómica [3]. Al transformar un teléfono celular común de gama baja o media en un asistente de orientación fitopatológica disponible en el surco, se empodera al productor con información técnica comprensible y oportuna. En la dimensión ambiental, un diagnóstico certero fomenta el manejo integrado de plagas, desincentivando la aplicación indiscriminada de pesticidas sintéticos y coadyuvando a la protección de los recursos hídricos y la salud de las comunidades rurales.

1.5.4. Justificación Académica e Institucional

En el ámbito académico e institucional, este proyecto representa una contribución significativa para la Escuela de Ingeniería de Sistemas Informáticos de la Universidad de El Salvador (UES), al articular la investigación aplicada en inteligencia artificial embebida con la solución de problemas prioritarios del desarrollo agropecuario nacional. La investigación sienta un precedente metodológico formal para el desarrollo, evaluación imparcial y despliegue de sistemas de visión artificial adaptados a contextos de recursos computacionales y conectividad restringidos en Centroamérica.

1.6. Cronograma de Actividades

La planificación y ejecución del proyecto se estructuró bajo las fases de la metodología *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*), adaptada a los requerimientos de desarrollo de aprendizaje profundo embebido (*Edge AI*) e ingeniería de software móvil. El cronograma abarcó un periodo de 28 semanas calendario, iniciando formalmente el 14 de abril de 2026 y culminando con el hito de presentación y defensa final el 29 de octubre de 2026.

La Figura 1.3 ilustra el diagrama temporal de Gantt y la concurrencia operativa de las fases a lo largo de las 28 semanas del ciclo, mientras que la Tabla 1.2 detalla la distribución de actividades, duración, horas estimadas y entregables técnicos por cada etapa.

Figura 1.3: Diagrama de Gantt del cronograma planificado (Metodología CRISP-DM)

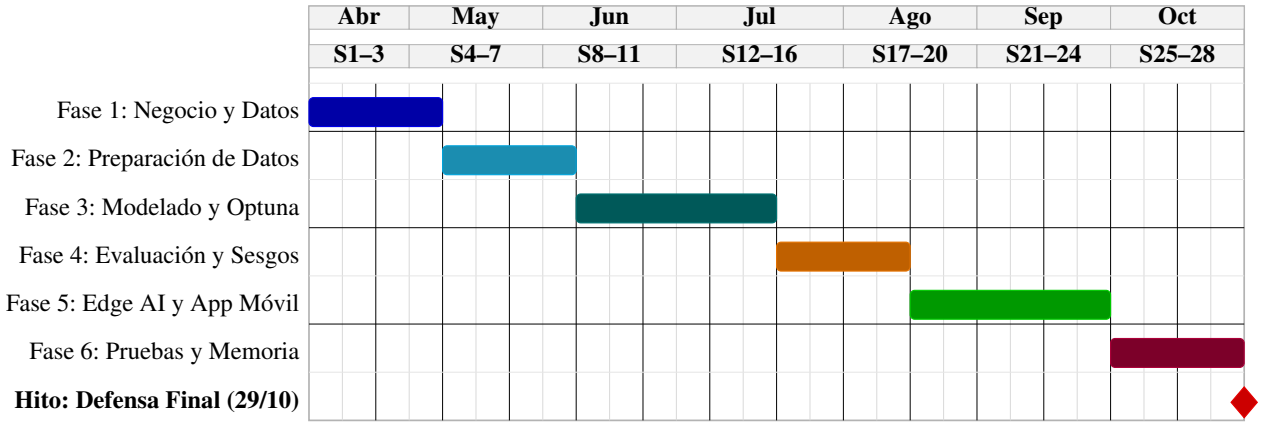


Tabla 1.2: Cronograma planificado de actividades y fases del proyecto (CRISP-DM)

Fase / Actividad Operativa	Inicio	Fin	Semanas	Horas	Entregable Principal
Fase 1: Comprensión del Negocio y Datos	14/04/26	12/05/26	4	40 h	Requisitos fitosanitarios y corpus consolidado (>33K imágenes).
Fase 2: Preparación de Datos	12/05/26	09/06/26	4	40 h	Auditoría criptográfica de duplicados, balanceo y data augmentation.
Fase 3: Modelado Algorítmico	09/06/26	21/07/26	6	60 h	Transfer learning en arquitecturas ligeras y optimización con Optuna.
Fase 4: Evaluación y Auditoría de Sesgos	21/07/26	18/08/26	4	40 h	Ensamble Soft Voting, evaluación ciega de campo y análisis XAI (Grad-CAM).
Fase 5: Optimización Edge y App Móvil	18/08/26	29/09/26	6	60 h	Modelo Int8 (3.74 MB), detector OOD y app DoctorMaiz (React Native/Expo).
Fase 6: Pruebas Finales y Memoria	29/09/26	29/10/26	4	40 h	Evaluación física en Motorola edge 40 neo, memoria técnica y defensa final.
Hito Final: Defensa de Proyecto	**29 de octubre de 2026**		**28 sem**	**280 h**	**Sistema DoctorMaiz liberado**

1.7. Presupuesto Global Estimado

El presupuesto del desarrollo y evaluación de la solución analítica y embebida abarcó dos categorías esenciales: recurso humano especializado e infraestructura de cómputo acelerado en la nube (Tablas 1.3 a 1.6). Las horas de GPU son la suma de las duraciones de los 25 ensayos del estudio de optimización (`trials.csv`, 45 523 s), incluidos los dos ensayos interrumpidos, que aportan 20 102 s; el resto de rubros son proyecciones.

Tabla 1.3: Presupuesto proyectado: Cálculo del salario base por rol (280 horas)

Rol Profesional	**Salario mensual de referencia**	**Meses equivalentes (280 h)**	**Salario base (USD)**
Ingeniero de Datos / MLOps	$1,500.00	1.6154	$2,423.08
Investigador de Deep Learning	$1,350.00	1.6154	$2,180.77
Desarrollador Móvil Edge AI	$1,250.00	1.6154	$2,019.23
Total salario base	**$4,100.00**	—	**$6,623.08**

Tabla 1.4: Presupuesto proyectado: Cargas y prestaciones patronales sobre el salario base

Rol Profesional	**ISSS 7.5 %**	**AFP 7.75 %**	**INSAFORP 1 %**	**Aguinaldo y vacaciones**	**Total cargas**	**Costo total**
Ingeniero de Datos / MLOps	$121.15	$187.79	$24.23	$201.92	$535.09	$2,958.17
Investigador de Deep Learning	$121.15	$169.01	$21.81	$181.73	$493.70	$2,674.47
Desarrollador Móvil Edge AI	$121.15	$156.49	$20.19	$168.27	$466.10	$2,485.33
Total Recurso Humano	**$363.45**	**$513.29**	**$66.23**	**$551.92**	**$1,494.89**	**$8,117.97**

Los salarios mensuales corresponden al punto medio de la escala de referencia del sector público salvadoreño para Gobierno Central y Ministerios, aplicada a perfiles equivalentes: Ingeniero de Datos / MLOps (rango de $1,200 a $1,800, equivalente a Especialista de Base de Datos o Analista de Sistemas), Investigador de Deep Learning (rango de $1,100 a $1,600, equivalente a Especialista en Análisis de Datos) y Desarrollador Móvil (rango de $1,000 a $1,500, equivalente a Analista Programador). La Tabla 1.3 calcula el salario base por rol y la Tabla 1.4 desglosa las cargas patronales y el costo total. El costo se estima solo por las horas efectivas de trabajo. Cada integrante trabaja de lunes a viernes, menos de 2 horas diarias; para la estimación se usan 2 horas diarias como cota superior, es decir 10 horas semanales, lo que suma 280 horas en las 28 semanas del cronograma (Tabla 1.2). Equivale a 1.62 meses de una jornada de 40 horas, por lo que el salario mensual de referencia se prorrateó por esa proporción. Las cargas consideran: cuota patronal al ISSS de 7.5 % sobre un salario base máximo de $1,000.00 mensual; cuota patronal a la AFP de 7.75 %; contribución al INSAFORP de 1 %; y aguinaldo y vacaciones de ley prorrateados.

Tabla 1.5: Presupuesto: Infraestructura Cloud y Licencias

Rubro	**Detalle Técnico**	**Métrica / Cantidad**	**Subtotal**
Instancias GPU Modal	NVIDIA A10G (24 GB VRAM)	12.65 horas del estudio de optimización (7.06 sin los ensayos interrumpidos) $\times$ \$1.10/h de lista	\$13.92
Almacenamiento Cloud	Cloud Volumes y respaldos de pesos	100 GB $\times$ 6 meses	\$30.00
Licenciamiento software	PyTorch, Expo, React Native, Optuna	Licencias Open Source / MIT	\$0.00
Total Infraestructura Cloud y Licencias	—	—	**\$43.92**

Tabla 1.6: Resumen presupuestario global de la investigación

Rubro de Inversión	**Monto Total (USD)**	**Porcentaje (%)**
Recursos Humanos de Investigación	\$8,117.97	99.46 %
Servicios de cómputo en la nube (GPU/Storage)	\$43.92	0.54 %
Total General	**\$8,161.89**	**100.00 %**

La ejecución financiera demuestra que, gracias al aprovechamiento de tecnologías de código abierto y la utilización estratégica de clústeres serverless con parada automática, el costo directo de infraestructura computacional se estima en \$43.92 USD, de los cuales \$13.92 corresponden a las 12.65 horas de GPU del estudio de optimización a tarifa de lista (incluidos los intentos interrumpidos) y \$30.00 son una proyección de almacenamiento. El cómputo de los demás entrenamientos no se contabiliza.

CAPÍTULO 2

ANÁLISIS Y DISEÑO DE LA SOLUCIÓN

2.1. Metodología de Trabajo y Gobernanza MLOps

Para garantizar que los hallazgos científicos de esta investigación sean verificables y reproducibles, se adoptó una metodología de ingeniería de software y operaciones de aprendizaje automático (*MLOps*) basada en contratos de datos inmutables y trazabilidad criptográfica. En proyectos de visión artificial complejos, los errores silenciosos de preparación —tales como la fuga de datos (*data leakage*), la reordenación no determinista de lotes o la sustitución inadvertida de imágenes corruptas— invalidan cualquier conclusión teórica.

La arquitectura de datos de DoctorMaiz desacopla tres conceptos fundamentales:

1. **Identidad (`sample_id`):** Cada fotografía del corpus posee un identificador único e inmutable calculado como SHA-256(ruta lógica normalizada en UTF-8). Esto previene que el orden de lectura en el disco o la asignación estocástica de hilos (*workers*) altere la identidad de la muestra.

2. **Integridad (`sha256`):** Se calcula el hash criptográfico SHA-256 directo sobre los bytes crudos del archivo de imagen. Esto permite auditar de forma automática si un archivo sufrió alteraciones, corrupción o recomposición entre distintas versiones de entrenamiento.

3. **Procedencia y Grupo (`source_id` y `effective_group_id`):** Cada registro conserva su fuente de origen, derivada del nombre del archivo, y su entorno de captura (laboratorio o campo). Las particiones agrupadas usan `effective_group_id`, que es el grupo declarado en un manifiesto o, en su defecto, la fuente; la partición oficial no agrupa.

Todos los conjuntos de entrenamiento, validación y prueba quedaron sellados mediante manifiestos contractuales (`manifest.lock.json`), que fijan los SHA-256 de los CSV de cada partición; la ausencia de solapamientos se verificó en la auditoría descrita más abajo.

2.2. Clases Agronómicas Objetivo

El sistema clasifica el estado de salud de la hoja de maíz en nueve categorías mutuamente excluyentes (Tabla 2.1), abarcando los principales patógenos fúngicos, virales, plagas insectiles y deficiencias nutricionales de impacto económico en Centroamérica.

Tabla 2.1: Taxonomía agronómica de las nueve clases integradas en DoctorMaiz

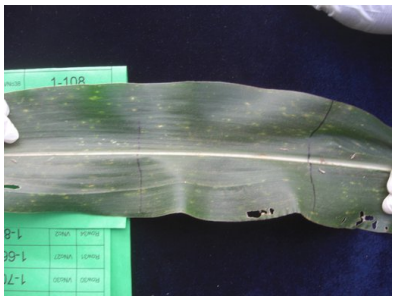
Clase Agronómica	**Agente Causal / Tipo**	**Síntoma Primario**	**Riesgo / Impacto en Rendimiento**
Roya Común	*Puccinia sorghi* (Hongo)	Pústulas pulverulentas castaño-rojizas en ambas caras.	Pérdida del 15 % al 30 % en áreas húmedas y altas.
Tizón Foliar (NCLB)	*Exserohilum turcicum* (Hongo)	Lesiones alargadas en forma de cigarro o huso (grises).	Necrosis masiva, pérdidas de hasta 50 % antes de floración.
Mancha Gris (GLS)	*Cercospora zeae-maydis* (Hongo)	Manchas rectangulares delimitadas por venas secundarias.	Destrucción del follaje superior, reducción del grano hasta 40 %.
Necrosis Letal (MLN)	Complejo viral sinérgico (MCMV + Potyvirus)	Clorosis severa, moteado, necrosis marginal y secado total.	**Pérdida del 100 % de la cosecha**; patología de bioseguridad crítica.
Gusano Cogollero	*Spodoptera frugiperda* (Plaga/Insecto)	Perforaciones irregulares y excrementos en el cogollo.	Destrucción meristemática; caída de rendimiento del 20 % al 60 %.
Deficiencia de Nitrógeno	Desbalance nutricional abiótico	Clorosis en “V” invertida desde la punta hacia la base.	Reducción de porte, espigas pequeñas y bajo llenado.
Deficiencia de Fósforo	Desbalance nutricional abiótico	Coloración púrpura o rojiza en bordes de hojas jóvenes.	Retraso radicular y esterilidad parcial de la mazorca.
Deficiencia de Potasio	Desbalance nutricional abiótico	Clorosis y necrosis marginal desde el ápice foliar.	Acame o volcamiento del tallo y grano liviano.
Planta Sana (Healthy)	Control agronómico	Lámina foliar verde homogénea sin lesiones ni plagas.	Crecimiento óptimo según potencial genético del cultivar.



a) Roya Común



b) Tizón Foliar



c) Mancha Gris



d) Necrosis Letal



e) Gusano Cogollero



f) Deficiencia N



g) Deficiencia P



h) Deficiencia K



i) Planta Sana

Figura 2.1: Catálogo fotográfico de las nueve clases agronómicas presentes en el corpus.

2.3. Recopilación, Depuración y Auditoría de Datos

El corpus final se conformó mediante la integración de **33 429 imágenes elegibles** provenientes de 11 fuentes internacionales consolidadas (Tabla 2.2). Para resolver el cuello de botella identificado en la primera fase del proyecto —donde la deficiencia de potasio obtuvo un F_1 de 0.49 a 0.62 con solo 40 imágenes de prueba—, se incorporaron repositorios dirigidos a deficiencias minerales, de modo que hoy cada deficiencia (N, P, K) proviene de cuatro fuentes.

Tabla 2.2: Fuentes de datos recopiladas y distribución de muestras

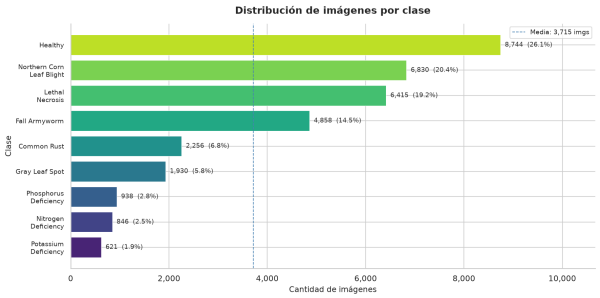
Identificador de Fuente (`source_id`)	**Muestras**	**Entorno**	**Patologías Principales Aportadas**
`maize-beans-tomatoes-africa`	12 136	Campo real	4 clases.
`maize-diseases`	6 989	Mixto	3 clases.
`multicrop-disease-maiz`	5 816	Mixto	3 clases, incluida necrosis letal (MLN).
`corn-leaf-roboflow`	2 919	Campo real	6 clases.
`cropdg-unified-multidomain`	2 562	Mixto	3 clases.
`maize-in-field-dataset`	852	Campo real	3 clases.
`maize-2-roboflow`	846	Campo real	3 clases.
`corn-leaf-diseases-classification-roboflow`	480	Mixto	1 clase (`gray_leaf_spot`).
`maize-nutrient-deficiency`	340	Campo real	4 clases.
`maize-leaf-roboflow`	331	Campo real	1 clase.
`maize-deficiency-scanner-roboflow`	158	Campo real	3 clases de deficiencia.
Total Elegible Auditado	**33 429**	—	**9 clases agronómicas**

2.3.1. Data Profiling y Análisis Exploratorio de Datos (EDA)

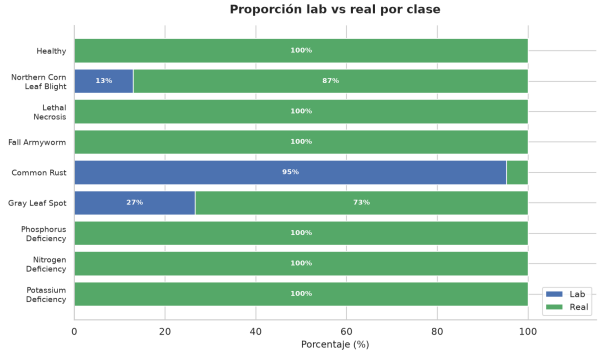
El análisis exploratorio evidenció tres retos estructurales:

- **Desbalance intrínseco:** La clase sana concentra cerca de 8 700 imágenes y el tizón foliar cerca de 6 800, mientras que la deficiencia de potasio cuenta con 621 ejemplares (desbalance de 14.1:1 en el corpus vigente, frente a 32.9:1 antes de la ampliación).
- **Heterogeneidad de resolución y cámaras:** Las resoluciones van desde sensores rústicos de 256×256 píxeles hasta capturas semiprofesionales de 4000×3000 píxeles (Figura 2.2).

- **Asociación espuria fuente-clase:** La asociación estadística entre la procedencia y la etiqueta arrojó una **V de Cramér de 0.5030**, indicando que ciertas fuentes públicas aportan exclusivamente una sola patología, lo que puede favorecer que las redes utilicen señales del entorno además de la lesión foliar. Esta relación es descriptiva y no establece una causa.

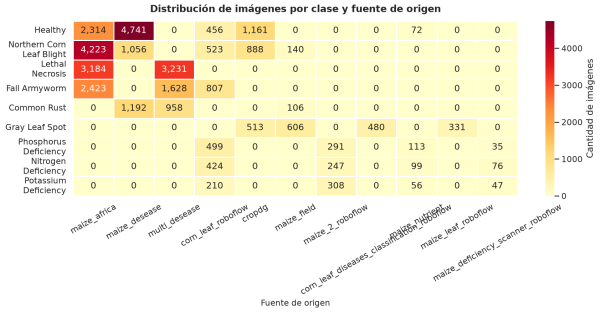


Distribución de muestras por clase.

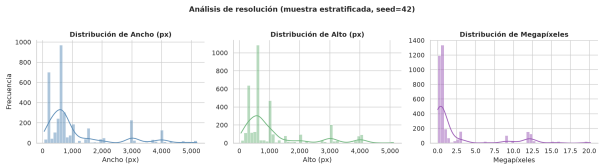


Proporción Laboratorio vs. Campo Real.

Figura 2.2: Análisis exploratorio de distribución y balance ambiental del corpus.



Matriz de contingencia fuente vs. patología.



Distribución de resoluciones espaciales.

Figura 2.3: Concentración de procedencia y heterogeneidad geométrica en las imágenes.

2.3.2. Auditoría Criptográfica de Píxeles

Para descartar que la precisión reportada se inflara por duplicados idénticos en entrenamiento y prueba, se ejecutó la auditoría `PIXEL_DUPLICATE_AUDIT`. Se calcularon hashes SHA-256 sobre el raster RGB decodificado (ancho, alto y píxeles, tras la orientación EXIF) y sobre los bytes de cada archivo. Entre las **33 429 muestras elegibles no hay grupos duplicados** por píxeles ni por archivo, y ninguno cruza particiones. Las únicas coincidencias son cuatro grupos (ocho archivos) con etiquetas contradictorias,

de la fuente `maize-beans-tomatoes-africa`, que ya estaban excluidos por contrato; con ellos se verificaron 33 437 archivos.

La partición de desarrollo oficial (`seed_42`) quedó estructurada en un reparto estratificado 70/15/15:

- **Entrenamiento:** 23 400 imágenes.
- **Validación:** 5 014 imágenes.
- **Prueba independiente (Test retenido):** 5 015 imágenes.

Limitación de la partición de desarrollo. La partición `seed_42` es estratificada por `label + environment` y mezcla las fuentes conocidas entre entrenamiento, validación y prueba. Esta configuración es adecuada para desarrollo *in-distribution*, pero no demuestra generalización a una cámara, parcela o repositorio nuevo. Además, la materialización se generó con `deduplicate_perceptual=false`, por lo que la posible fuga por imágenes casi duplicadas no fue medida en este trabajo. La evaluación agrupada por fuente y el estudio *leave-one-source-out* se presentan en el capítulo de resultados.

2.4. Arquitecturas y Búsqueda de Hiperparámetros

2.4.1. Familias Convolucionales Seleccionadas

Se seleccionaron tres redes convolucionales modernas de alta eficiencia, representativas de diversas hipótesis inductivas:

1. **EfficientNet-Lite0 (Modelo móvil desplegado):** Variante diseñada específicamente para inferencia móvil y cuantización. Elimina las activaciones no lineales complejas (*swish*) sustituyéndolas por ReLU6, y suprime los bloques de atención *Squeeze-and-Excitation* (SE) [6] para mantener compatibilidad plena con aceleradores de enteros (3.38 millones de parámetros) [17].
2. **EfficientNet-B0 (Referencia de capacidad):** Arquitectura balanceada con escalado compuesto y bloques SE con atención por canal (4.02 millones de parámetros).
3. **ShuffleNet-V2-x1.0 (Eficiencia extrema):** Basada en división de canales (*Channel Split*) y barajado (*Channel Shuffle*) para maximizar el flujo de información minimizando los accesos a memoria

DRAM (1.26 millones de parámetros) [10].

2.4.2. Espacio de Búsqueda y Poda Temprana

La optimización de hiperparámetros se formuló mediante un estudio bayesiano en **Optuna** [12] con el estimador de árbol de Parzen multivariado (TPE). La función objetivo maximizó el Macro F_1 sobre el conjunto de validación oficial. Para no desperdiciar horas de GPU en configuraciones no prometedoras, se incorporó el algoritmo **MedianPruner**: tras cinco ensayos iniciales sin poda y a partir de la época 8 (periodo de calentamiento), si el Macro F_1 de un ensayo se sitúa por debajo de la mediana histórica de los ensayos precedentes, el entrenamiento se detiene automáticamente (*PRUNED*).
El espacio de exploración abarcó seis parámetros, más `clahe` fijo (Tabla 2.3).

Tabla 2.3: Espacio de búsqueda de hiperparámetros explorado con Optuna

Hiperparámetro	**Rango / Opciones**	**Fundamento Ingenieril**
`learning_rate`	Log-uniforme: $[10^{-5}, 3 \times 10^{-3}]$	Control de convergencia en optimizador AdamW.
`batch_size`	Categórico: $\{16, 32, 64\}$	Estabilidad del gradiente estocástico y saturación de GPU.
`weight_decay`	Log-uniforme: $[10^{-7}, 10^{-2}]$	Regularización L_2 para mitigar memorización de fondos.
`class_weights`	Categórico: $\{\text{none}, \text{inverse}, \text{sqrt_inverse}\}$	Ponderación de pérdida para compensar desbalance de clases.
`label_smoothing`	Categórico: $\{0, 0{,}025, \ldots, 0{,}15\}$ en pasos de 0.025	Calibración probabilística y prevención de sobreconfianza.
`warmup_epochs`	Entero: $[1, 5]$	Calentamiento lineal para proteger pesos preentrenados.
`clahe`	Fijo en `False`	Ecualización adaptativa excluida de la búsqueda; se evaluó aparte.

2.4.3. Ensamble Multimodelo por Soft Voting

Para mitigar el riesgo de diagnósticos erróneos causados por las zonas ciegas de una sola arquitectura, se implementó un ensamble heterogéneo por votación suave. El ensamble calcula el vector de probabilidades promedio:

$$P_{\text{ens}}(y = c \mid x) = \frac{1}{M} \sum_{m=1}^{M} P_m(y = c \mid x) \tag{2.1}$$

donde $M = 3$ corresponde a las tres redes entrenadas independientemente y $c \in \{1, \ldots, 9\}$. La decisión final se obtiene por consenso máximo: $\hat{y} = \arg\max_c P_{\text{ens}}(y = c \mid x)$.

2.5. Despliegue en Dispositivo Móvil

2.5.1. Cuantización a Enteros de 8 Bits (Int8)

Para permitir que `EfficientNet-Lite0` opere en teléfonos sin unidad de procesamiento neuronal (*NPU*), se realizó una cuantización posterior al entrenamiento (*Post-Training Quantization*, PTQ) [7] hacia enteros de 8 bits, exportando el modelo mediante litert-torch. El esquema es simétrico (punto cero $Z = 0$) y dinámico: las escalas de activación se calculan en tiempo de ejecución, por lo que no requiere un conjunto de calibración. En el backbone, cada canal de salida c tiene su propia escala S_c, que mapea los pesos en coma flotante $W_{f,c,i}$ a enteros con signo:

$$S_c = \frac{\max_i |W_{f,c,i}|}{127}, \qquad q_{c,i} = \text{clip}\left(\left\lfloor \frac{W_{f,c,i}}{S_c} \right\rceil, \; -127, \; 127 \right) \tag{2.2}$$

La capa lineal final usa una única escala por tensor, porque el kernel de TFLite para `FULLY_CONNECTED` dinámico aplica una sola escala. Con escalas por canal, los logits de esa capa quedan multiplicados por una constante distinta por clase sin que el runtime lo señale. Cuantizar todas las capas por tensor, en cambio, degrada las convoluciones *depthwise* de EfficientNet, cuyos pesos tienen rangos muy distintos entre canales; por ello el backbone se cuantiza por canal. La operación permite que las multiplicaciones de matrices de convolución se resuelvan con instrucciones vectoriales enteras en la CPU móvil. El modelo `.tflite` desplegado ocupa 3 743 728 bytes (3.74 MB), 72.9 % menos que los 13.79 MB del punto de control en coma flotante. El consumo energético no fue medido en este trabajo.

2.5.2. Detector de Anomalías Fuera de Distribución (OOD)

Las redes neuronales pueden emitir clasificaciones con alta confianza cuando reciben imágenes que no pertenecen a ninguna de sus clases, por ejemplo suelo, calzado o malezas, porque la confianza softmax solo mide la elección entre las etiquetas conocidas [8]. Para detectar este caso, DoctorMaiz extrae el vector

de activación de la capa previa a la clasificación ($d = 1\,280$ dimensiones), lo normaliza a norma L2 unitaria [13], reduce su dimensionalidad mediante PCA a 182 componentes que retienen el 99.01 % de la varianza y evalúa la **Distancia Relativa de Mahalanobis (RMD)** [14], con distancias al cuadrado. La puntuación resta la distancia a un modelo de fondo global, para no penalizar características genéricas de cualquier fotografía, y es

$$\mathrm{RMD}(z) = D_M^2(z \mid \mu_{c^*}, \Sigma) - D_M^2(z \mid \mu_0, \Sigma_0) \tag{2.3}$$

donde μ_{c^*} es el centroide de la clase más cercana, Σ es la covarianza agrupada entre clases y μ_0, Σ_0 describen una gaussiana de fondo sobre todo el conjunto de entrenamiento. Ambas covarianzas se regularizan con un término ridge proporcional a su traza antes de invertirlas.

El umbral se calibra sobre el conjunto de validación, no visto durante el entrenamiento, como el percentil 95 de la puntuación de cada muestra de validación medida contra el centroide de su propia clase. Para el modelo oficial (run `20260921_204608`) el umbral es 106.37. Las cinco imágenes sintéticas de prueba (negro, blanco, gris, ruido y azul) obtuvieron RMD entre 539 y 955 y fueron rechazadas en los cinco casos, mientras que 3.8 % de 500 imágenes de prueba válidas fueron rechazadas por error. Si la puntuación supera el umbral, la aplicación muestra la advertencia **«Imagen no reconocida»** y no emite diagnóstico. La misma advertencia se activa si la probabilidad de la clase más probable es menor que 0.6 o si su diferencia con la segunda es menor que 0.15, reglas que se aplican además del detector.

2.5.3. Mitigación en la Interfaz: Marco Guía y Severidad

El capítulo de resultados muestra dependencia de la región periférica y una generalización limitada entre fuentes. Por ello, la aplicación incorpora dos medidas, cuyo efecto sobre esos sesgos no se midió:

1. **Cámara con marco guía foliar y recorte automático:** La interfaz superpone una silueta ergonómica de la hoja con la instrucción explícita: *«Acérquese a 20–30 cm y llene el marco»*. La aplicación recorta la imagen capturada a la región del marco guía, ampliada un 15 % como margen, antes de pasarla al modelo, de modo que este recibe la región central de la captura y no la escena completa.

2. **Guía de severidad en lenguaje campesino:** Dado que los modelos de clasificación no pueden predecir el porcentaje de área foliar comprometida, la app despliega debajo de la etiqueta una es-

cala visual de tres niveles (baja, moderada, crítica) con descripciones que el productor compara con su hoja, referidas a escalas del CIMMYT y de Iowa State University Extension, en términos coloquiales y con bioinsumos accesibles en el agroservicio local.

2.6. Segmentación de Hojas: dos usos y resultados

El proyecto utilizó la segmentación foliar en dos líneas distintas, con evidencia y estado diferentes. Ninguna de ellas forma parte de la predicción de la aplicación instalada, que recorta geométricamente la imagen con el marco guía.

Primer uso: presegmentación y entrenamiento sobre corpus enmascarado. El pipeline del clasificador incluye un módulo de segmentación (`src/segmentation`) que genera un corpus con máscaras de hoja. Se entrenó un modelo sobre ese corpus (run `20260907_163546`, EfficientNet-Lite0, sobre el split `seed_42_segmented`). Su Macro F_1 en prueba fue de **0.7191** y su accuracy de 0.8903, frente a 0.9480 del baseline de imagen completa vigente. Esta comparación no es pareada: el conjunto de prueba segmentado no comparte ninguna imagen con el conjunto de prueba original (0 de 5 015 rutas coinciden). El perfil de máscara usado para generar el corpus no está registrado en el resumen del run, por lo que el resultado no permite atribuir la caída a un perfil concreto. El proyecto clasifica este uso como experimental y no como preprocesamiento general.

Segundo uso: segmentador de instancias para aislar la hoja. En un repositorio independiente se entrenó un segmentador YOLO (`yolo26n-seg`) para seleccionar la hoja principal, evaluado únicamente sobre validación y con una sola semilla. Sus métricas no se reproducen en este trabajo porque su evidencia no está versionada en este repositorio; el segmentador no se evaluó sobre el conjunto de prueba ni sobre fuentes externas.

La implicación para el diseño es que una máscara puede eliminar señal útil del fondo. Por ello el proyecto no aplica segmentación de forma universal, y la comparación formal entre imagen completa y segmentada sigue pendiente.

2.7. Sincronización y Contribución al Dataset Colaborativo

La aplicación funciona sin servidor. La sincronización opcional se implementa en el repositorio de la API (FastAPI y MySQL 8.4) con dos endpoints de escritura, `POST /corrections` y `POST /dataset-contributions`, que reciben correcciones de diagnóstico y aportes fotográficos de usuarios registrados. Una cola local reintenta el envío cuando hay conexión y marca cada registro como sincronizado solo tras la confirmación del servidor; sin sesión iniciada el servidor no lo acepta y el registro queda pendiente en el teléfono.

El aporte fotográfico incluye la fotografía, la etiqueta elegida, una nota opcional y la fecha del aporte; la corrección incluye la etiqueta observada, una nota, su estado y el identificador del escaneo, sin fotografía. Ninguno incluye nombre, teléfono, correo ni coordenadas GPS del historial. La aplicación no elimina los metadatos EXIF de la fotografía antes de enviarla. La idempotencia por el par `(user_id, client_id)`, el límite de 30 solicitudes por minuto y la validación del archivo de imagen forman parte del diseño de la API; las pruebas de integración de estas propiedades no se ejecutaron en este trabajo.

2.8. Arquitectura General del Sistema

2.8.1. Tecnologías por proyecto

El sistema se compone de cuatro repositorios independientes. La Tabla 2.4 resume la pila tecnológica de cada uno, con las versiones fijadas en sus archivos de dependencias.

Tabla 2.4: Tecnologías principales por proyecto

Proyecto	Función	Tecnologías
Pipeline del modelo	Entrenamiento, exportación y explicabilidad	PyTorch (`torch` 2.4 a 2.12), timm, Optuna, litert-torch y ONNX Runtime para exportación, Modal (GPU A10) para entrenamiento en la nube, SHAP y LIME.
Aplicación móvil	Captura, inferencia local y sincronización	Expo 57, React Native 0.86, TypeScript 6, `react-native-fast-tflite` 3 para inferencia, WatermelonDB 0.28 con SQLite local, NativeWind 4.
API de sincronización	Versión de la app y aportes al dataset colaborativo	FastAPI 0.115, SQLAlchemy 2.0, Alembic 1.13, MySQL 8.4 en Docker Compose, aiomysql, JWT y bcrypt para autenticación, slowapi para límites de tasa.
Segmentador de hojas	Aislamiento de la lámina foliar (experimental)	Ultralytics con modelo `yolo26n-seg`, PyTorch 2.2 a 2.12, Modal para entrenamiento, Pillow y NumPy.

La separación en repositorios tiene una consecuencia práctica: la aplicación no depende del entorno de entrenamiento. Solo consume un archivo `.tflite`, un `labels.json` y un `ood_stats.json` empaquetados. La API y la aplicación se comunican por HTTP y MySQL solo existe en el servidor.

La Figura 2.4 sintetiza la arquitectura de extremo a extremo que conecta la fase de experimentación con el despliegue móvil y la extensión institucional.

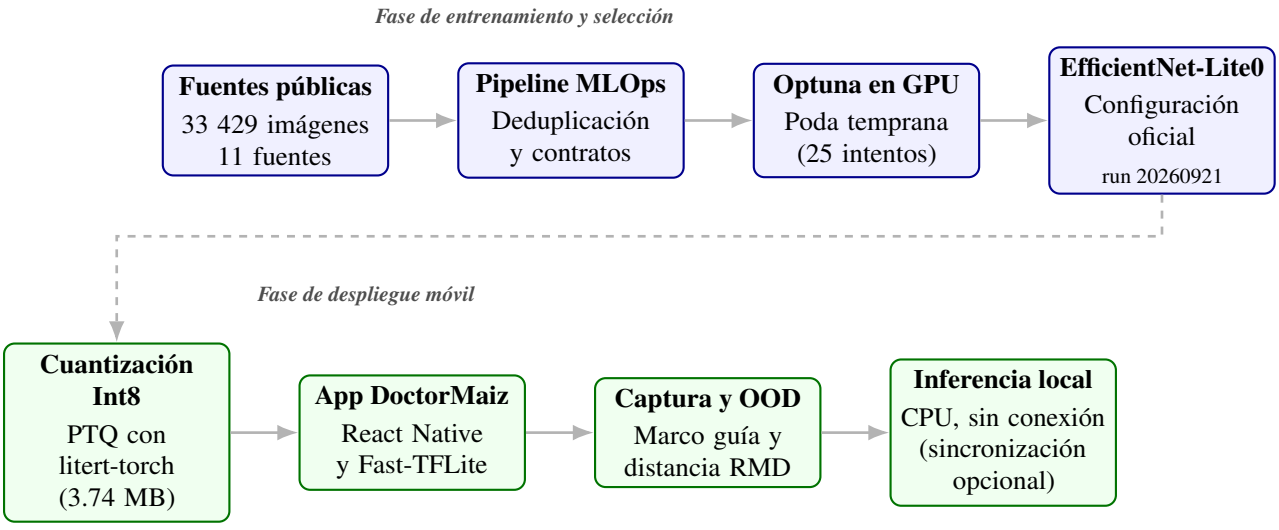


Figura 2.4: Diagrama de flujo arquitectónico integral del sistema DoctorMaiz.

CAPÍTULO 3

ESTRATEGIA DE IMPLEMENTACIÓN Y ANÁLISIS DE RESULTADOS

3.1. Estrategia y Entorno de Implementación

El desarrollo computacional del proyecto se articuló en una arquitectura híbrida que desacopla la fase de entrenamiento a gran escala en la nube (*Cloud Training*) de la fase de operación local en el teléfono (*Edge Inference*).

3.1.1. Infraestructura de Cómputo y Entrenamiento en la Nube

Los modelos se entrenaron sobre instancias aceleradas por hardware en la plataforma Modal, empleando unidades de procesamiento gráfico **NVIDIA A10G** (24 GB de VRAM) montadas sobre entornos Linux con CUDA 12.6 y PyTorch 2.12.1.

El régimen de entrenamiento incorporó un programador de tasa de aprendizaje por recocido cosenoidal con calentamiento lineal (*Cosine Annealing with Warmup*) durante tres épocas iniciales, estabilizando los pesos procedentes de ImageNet [4] antes de permitir gradientes elevados. Como salvaguarda frente al sobreajuste, se aplicó parada temprana (*Early Stopping*) con una paciencia de 8 épocas sobre el Macro F_1 de validación (Figura 3.1).

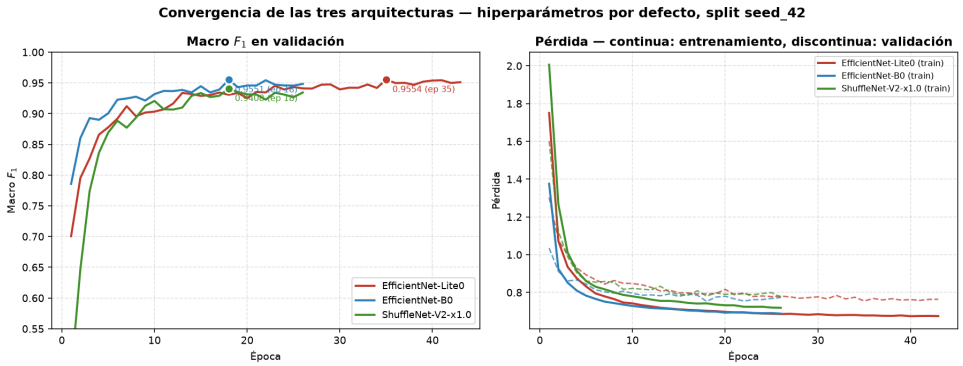


Figura 3.1: Curvas de convergencia: Pérdida y Macro F_1 durante el entrenamiento en Modal.

3.2. Resultados

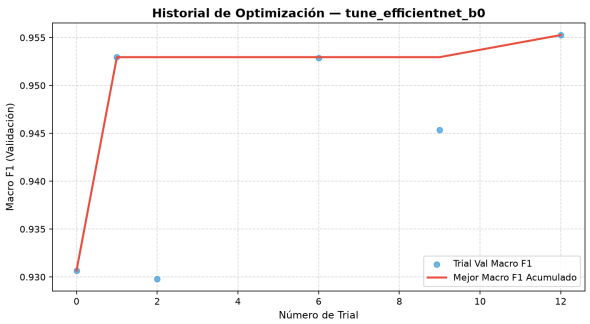
Esta sección reporta el estado de cada criterio de éxito definido en la Tabla 1.1 y, a continuación, el detalle de las mediciones. Cuando un criterio no se cumple, no se midió o depende de una corrida pendiente, la tabla lo indica.

Tabla 3.1: Estado de los criterios de éxito al cierre de esta versión

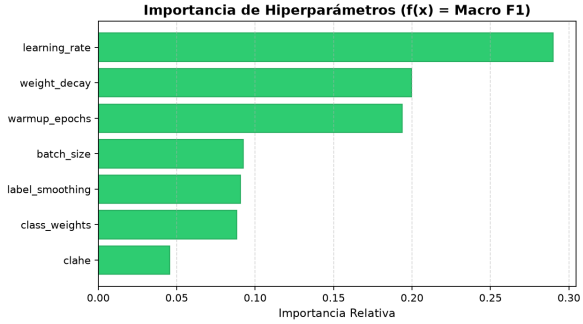
Criterio	**Resultado medido**	**Estado**
Épocas de la búsqueda $\leq 50\,\%$ del máximo teórico	453 de 1 500 épocas (30.2 %) en 25 ensayos.	Cumple
Macro $F_1 \geq 0{,}85$ en prueba	0.9480 (baseline vigente, una semilla); 0.9435 $\pm$ 0.0052 en tres semillas.	Cumple
Recall de MLN $\geq 95\,\%$ en prueba	100.0 % en la partición histórica del ensamble; 0.72–0.81 bajo LOSO.	Cumple solo en partición de desarrollo
DIR $\geq 0{,}80$ entre laboratorio y campo	0.9636 (Macro F_1) y 0.9956 (exactitud) con el modelo oficial, en las tres clases compartidas; la roya de campo (16 imágenes) queda en $F_1 = 0{,}77$.	Cumple
Solapamiento cero entre particiones	0 de 5 015 imágenes de prueba en entrenamiento o validación, por SHA-256 y por píxeles; 33 437 archivos verificados. No incluye similitud perceptual.	Cumple
Int8 de 20 MB o menos	3.74 MB (3 743 728 bytes) para el modelo oficial `20260921_204608`.	Cumple
Preprocesado e inferencia ≤ 300 ms en teléfono de gama media	Medianas de 98 ms de preprocesado (p95 de 279 ms) y 23 ms de inferencia con el modelo Int8 en un Motorola edge 40 neo (MediaTek Dimensity 7030).	Cumple en la mediana; el p95 de inferencia no se midió
Funcionamiento sin conexión	Clasificación local verificada en un dispositivo.	Cumple

3.2.1. Ahorro de entrenamiento: búsqueda bayesiana con poda

El estudio bayesiano ejecutado con Optuna exploró 25 intentos sobre la arquitectura `EfficientNet-Lite0`, de los cuales 8 se completaron, 15 fueron podados por el algoritmo *MedianPruner* al no superar la mediana de sus pares tras el periodo de calentamiento (8 épocas), y 2 se interrumpieron por fallos de proceso. El ensayo ganador fue el Trial 0 (época 44), seleccionado por su mejor Macro F_1 de validación. La eficiencia de la búsqueda se mide en épocas ejecutadas: 453 de 1 500 posibles (25 ensayos de 60 épocas), es decir, el 30.2 %, por debajo del límite de 50 %. Las épocas de los dos ensayos interrumpidos no se registraron y quedan fuera del numerador, mientras que el denominador los cuenta completos. El criterio original, horas de GPU frente a una búsqueda sin poda, no se evaluó porque exige una corrida sin poda que no se ejecutó; la medida en épocas se definió después de observar los datos. La medida no demuestra que la poda no haya descartado un candidato mejor.



Historial de ensayos de Optuna.



Importancia relativa de hiperparámetros.

Figura 3.2: Dinámica de exploración e impacto relativo de variables en Optuna.

El análisis de importancia (Figura 3.2) reveló que el calentamiento (`warmup_epochs`, 0.52), la ponderación de pérdida (`class_weights`, 0.15), el suavizado de etiquetas (`label_smoothing`, 0.11), la tasa de aprendizaje (`learning_rate`, 0.10) y el tamaño de lote (`batch_size`, 0.09) concentran la mayor parte de la variación del objetivo. La configuración del Trial 0 comparada con la línea base se muestra en la Tabla 3.2.

Tabla 3.2: Comparativa cuantitativa: Baseline sin Optuna vs. Configuración Optimizada (Optuna)

Métrica / Variable	**Sin Optuna (Base)**	**Optimizada (Optuna)**	**Impacto / Delta**
Macro F_1 en Validación	0.9561	0.9573	+0.12 pp
Macro F_1 en Prueba Retenida	0.9480	0.9431	$-0{,}49$ pp
Tasa de Aprendizaje (`lr`)	$1{,}00 \times 10^{-4}$	$8{,}47 \times 10^{-5}$	Valor de búsqueda
Tamaño de Lote (`batch_size`)	32	16	Valor de búsqueda
Calentamiento (`warmup_epochs`)	3	1	Valor de búsqueda
Decaimiento de pesos (`weight_decay`)	$1{,}00 \times 10^{-4}$	$5{,}67 \times 10^{-3}$	Valor de búsqueda
Ponderación de Pérdida	`sqrt_inverse`	`none`	Valor de búsqueda
Suavizado de Etiquetas	0.10	0.075	Valor de búsqueda

Resultado de prueba y decisión de configuración: El ensayo ganador no mejoró el Macro F_1 de prueba frente a la línea base ($-0{,}49$ pp), aunque sí mejoró ligeramente la validación (+0.12 pp). El ganador no se adoptó: la configuración de desarrollo sigue siendo la de la ejecución `20260921_204608` (`learning_rate` 10^{-4}, lote 32, `sqrt_inverse`, suavizado 0.1), con Macro F_1 de prueba de **0.9480** y exactitud de 97.81 %. Esa ejecución, anterior al estudio y primer reentrenamiento completo sobre la materialización corregida de `seed_42`, es la oficial del proyecto y la que despliega la aplicación. El presupuesto de búsqueda se redujo de 60 a 25 intentos después de observar resultados parciales, mediante una

enmienda registrada.

3.2.2. Rendimiento del modelo: ensamble y bioseguridad

El ensamble heterogéneo por votación suave (*Soft Voting*) superó a las arquitecturas individuales en la partición estratificada histórica (Tabla 3.3 y Figura 3.3). Este resultado es histórico, de una sola semilla y en una partición que mezcla fuentes; bajo validación con fuente no vista la ventaja es mixta (sección de generalización).

Tabla 3.3: Desempeño del ensamble frente a modelos individuales en la prueba de la etapa 2 (corpus de 33 433 imágenes, 5 015 de prueba)

Arquitectura / Modelo	**Exactitud**	**Macro F_1**	**Precision**	**Recall**
ShuffleNet-V2-x1.0 (`20260910_184521`)	97.31 %	0.9330	0.9388	0.9298
EfficientNet-Lite0 (`20260812_221429`)	97.91 %	0.9468	0.9533	0.9413
EfficientNet-B0 (`20260910_170120`)	97.97 %	0.9483	0.9589	0.9400
Ensamble Heterogéneo (Soft Voting)	**98.29 %**	**0.9567**	**0.9642**	**0.9506**
Ganancia neta vs. mejor individual	*+0.32 pp*	*+0.83 pp*	*+0.52 pp*	*+0.93 pp*

Las filas de la Tabla 3.3 proceden de la etapa 2, con el Lite0 de agosto (`20260812_221429`) y una materialización del conjunto de prueba con 338 imágenes de roya común y 290 de mancha gris. El modelo oficial vigente (`20260921_204608`, corpus de 33 429 imágenes, 339 y 289 imágenes en esas clases) obtuvo exactitud 97.81 %, Macro F_1 0.9480, precisión 0.9513 y recall 0.9467 sobre su propia prueba; no se compara de forma pareada con las filas anteriores.

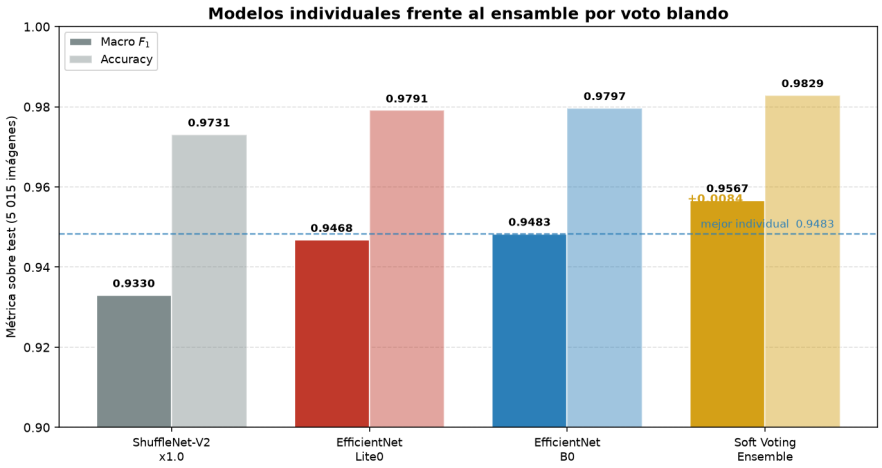


Figura 3.3: Comparativa de desempeño del ensamble frente a modelos individuales.

El hallazgo de mayor trascendencia agronómica reside en el **Macro Recall de 95.06 %**. En fitopatología, el costo de un falso negativo es devastador: omitir una infección incipiente permite que el hongo o virus arrase con la parcela. Como lo demuestra la matriz de confusión normalizada del ensamble (Figura 3.4), la **Necrosis Letal del Maíz (MLN)** alcanzó un **Recall perfecto del 100.0 % (963 aciertos sobre 963 casos de prueba, cero falsos negativos)**. La roya común y el tizón superaron el 98 % de detección.

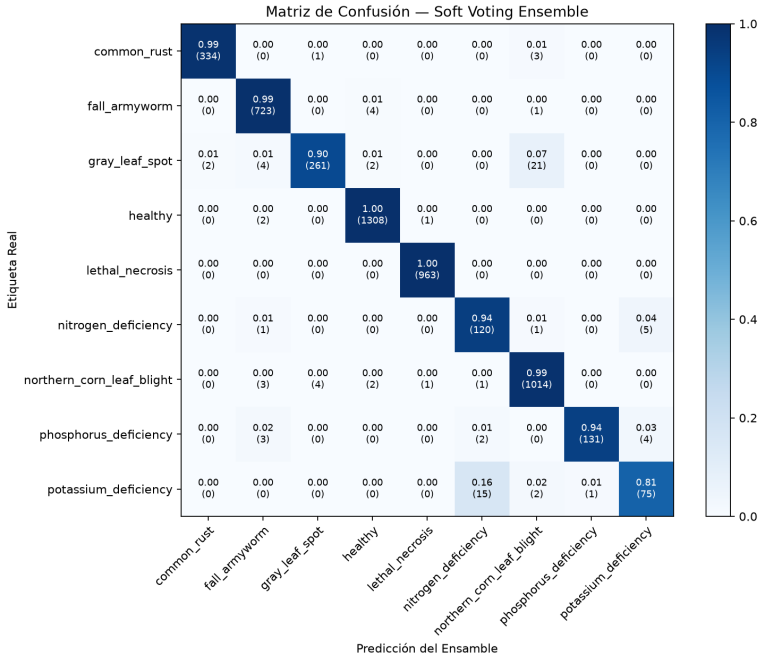


Figura 3.4: Matriz de confusión normalizada del ensamble sobre 5 015 muestras de prueba.

Asimismo, la **deficiencia de potasio**, que en una evaluación previa de la primera fase alcanzaba 0.49 (protocolo y soporte distintos), subió a **0.8475** en el ensamble de la etapa 2 y a 0.8242 en el Lite0 oficial vigente. Esta mejora coincide con la incorporación de nuevos repositorios y con la pérdida ponderada `sqrt_inverse`, pero no se aisló experimentalmente la contribución de cada factor.

Tabla 3.4: Desglose de F_1 por clase en la prueba de la etapa 2 (corpus de 33 433 imágenes; Lite0 `20260812_221429`)

Patología Agronómica	Soporte	Lite0	B0	ShuffleNet	Ensamble
Necrosis Letal (MLN)	963	**0.9990**	0.9984	0.9974	**0.9990**
Planta Sana (Healthy)	1 311	0.9936	0.9954	0.9901	**0.9958**
Roya Común	338	0.9866	0.9896	0.9867	**0.9911**
Gusano Cogollero	728	0.9814	**0.9877**	0.9815	**0.9877**
Tizón Foliar (NCLB)	1 025	0.9797	0.9769	0.9728	**0.9811**
Mancha Gris (GLS)	290	**0.9451**	0.9194	0.9120	0.9388
Deficiencia de Fósforo	140	0.9403	0.9527	0.9275	**0.9632**
Deficiencia de Nitrógeno	127	0.8664	0.8939	0.8613	**0.9057**
Deficiencia de Potasio	93	0.8290	0.8208	0.7674	**0.8475**
Macro Promedio	**5 015**	0.9468	0.9483	0.9330	**0.9567**

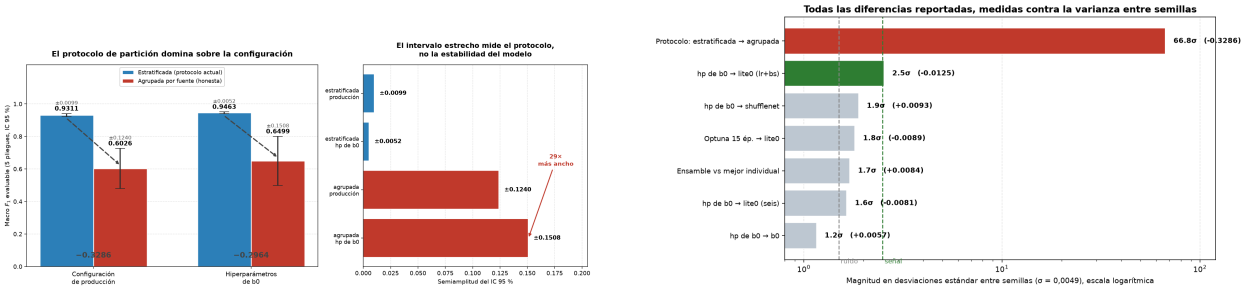
3.2.3. Rendimiento del modelo: generalización entre fuentes

Para poner a prueba los límites del sistema frente al cambio de dominio, se diseñó un experimento cruzado 2×2 de validación cruzada en 5 pliegues sobre `EfficientNet-Lite0`, comparando la partición estratificada habitual frente a una partición agrupada por procedencia que veta cualquier solapamiento de fuentes entre entrenamiento y evaluación (Tabla 3.5 y Figura 3.5).

Tabla 3.5: Resultados del experimento cruzado 2×2 de validación cruzada en 5 pliegues

Configuración de Red	CV Estratificada (5 folds, media $\pm$ IC95)	CV Agrupada por Fuente (macro F_1 sobre clases presentes, media $\pm$ IC95)	Caída Neta (Δ)
Hiperparámetros base	$0{,}9311 \pm 0{,}0099$	$\mathbf{0{,}6026 \pm 0{,}1240}$	$\mathbf{-0{,}3286}$
Hiperparámetros del trial 12 de B0	$0{,}9463 \pm 0{,}0052$	$0{,}6499 \pm 0{,}1508$	$-0{,}2964$

Todas las filas usan EfficientNet-Lite0. El macro F_1 convencional de 9 clases en la partición agrupada es 0.4359 para la primera fila. Fuentes en validación: repositorios solapados con entrenamiento en la partición estratificada; ninguno en la agrupada.



Diseño del experimento cruzado 2×2. Magnitud de impacto en sigmas (σ).

Figura 3.5: Impacto de la partición frente a la optimización algorítmica.

Hallazgo principal (histórico): En la validación cruzada de cinco pliegues, el cambio de protocolo de partición ($-0{,}3286$ en Macro F_1 sobre la misma escala) es considerablemente mayor que el efecto del ajuste de hiperparámetros ($+0{,}0152$, de 0.9311 a 0.9463). El $-0{,}3286$ compara 9 clases en la partición estratificada con el macro evaluable por pliegue en la agrupada, por lo que no es una resta pareada exacta; el valor pareado es $-0{,}4952$ (0.9311 frente a 0.4359). El ajuste en validación del HPO fue de $+0{,}0012$. Mientras la validación estratificada muestra un intervalo estrecho ($\pm 0{,}0099$), al evaluar fuera de fuente el Macro F_1 evaluable baja a $0{,}6026$ (IC95 $\pm 0{,}1240$), calculado sobre las clases evaluables en cada pliegue. La variabilidad entre tres semillas en la configuración de desarrollo es de $\sigma = 0{,}0052$ (media $0{,}9435$, σ muestral con $n = 3$), y la dispersión entre pliegues estratificados es $\sigma = 0{,}0080$; ambas son mucho menores que el cambio de protocolo, aunque miden magnitudes distintas (semillas sobre la prueba y pliegues de validación cruzada) y no se dividen entre sí (Figura 3.5). Este resultado es consistente con que las redes entrenadas sobre estos repositorios públicos dependen en parte de la firma visual de cada fuente, aunque el experimento no permite atribuir la caída a un único factor.

Tabla 3.6: Evaluación LOSO con tres semillas: Macro F_1 y exactitud en la fuente retenida

Fuente retenida	**Macro F_1 (media $\pm$ SD)**	**Exactitud (media $\pm$ SD)**	**Semillas**
`maize-diseases`	0.9933 ± 0.0006	$99.37\,\% \pm 0.07$ pp	3
`multicrop-disease-maiz`	0.9019 ± 0.0044	$80.38\,\% \pm 0.32$ pp	3

En ambos casos el modelo se entrenó sin la fuente retenida y se evaluó sobre ella, con selección de checkpoint congelada antes de abrir la evaluación final. La desviación estándar es muestral ($n = 3$). Con tres

semillas, estas cifras describen la variabilidad observada, pero no alcanzan para una prueba de significancia.

3.2.4. Rendimiento del modelo: fotografías de campo externas

Se evaluó el modelo oficial en 97 fotografías de campo ajenas al corpus de entrenamiento, organizadas en carpetas por clase (una de ellas también figura en el corpus). Con el modelo FP32 en computador y la imagen completa, acertó 41 de 97 (42 %); el detector OOD rechazó 49 de las 97 fotografías. El Lite0 de agosto (`20260812_221429`) acertó 39 de 97 sobre las mismas fotografías, de modo que la diferencia con las métricas de prueba no se explica por el cambio de modelo. Es compatible con una generalización limitada fuera del corpus, como indican LOSO y la validación agrupada por fuente, pero no se aisló de otros factores como el etiquetado y el encuadre de las fotografías. Es la principal limitación del sistema (Tabla 3.7).

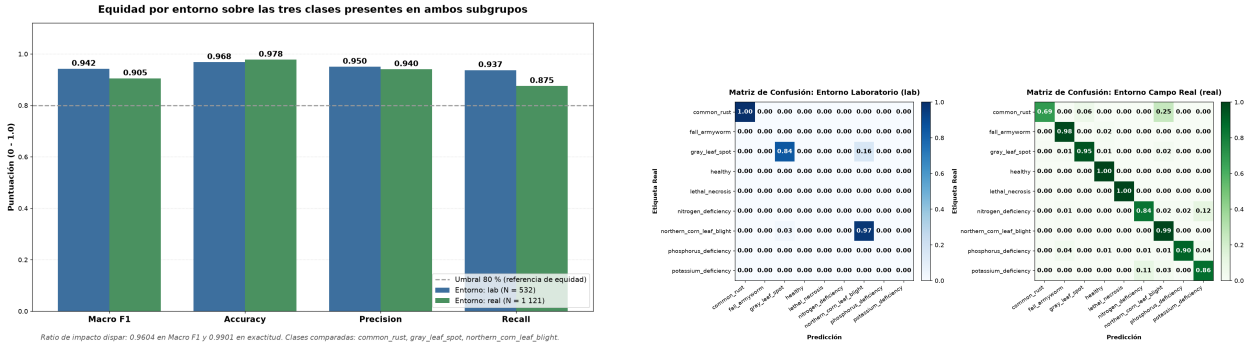
Tabla 3.7: Aciertos del modelo oficial en fotografías de campo externas, por clase

Clase	**Fotografías**	**Aciertos**
Roya común	18	2
Deficiencia de fósforo	10	2
Mancha gris (GLS)	10	10
Deficiencia de nitrógeno	10	6
Deficiencia de potasio	9	4
Tizón foliar (NCLB)	10	5
Gusano cogollero	10	10
Necrosis letal del maíz (MLN)	10	0
Planta sana	10	2
Total	**97**	**41**

3.2.5. Capacidades del diagnóstico: equidad entre entornos

El *Disparate Impact Ratio* (DIR) divide el desempeño del entorno con peor resultado entre el del mejor; la regla de los cuatro quintos lo considera aceptable desde 0.80. Como el subconjunto de laboratorio solo contiene tres clases (roya, mancha gris y tizón), el cálculo se restringe a esas tres clases en ambos entornos: comparar el Macro F_1 de laboratorio (tres clases) con el de campo (nueve clases) mezclaría conjuntos distintos. Con el modelo oficial (`20260921_204608`; 533 imágenes de laboratorio y 1 120 de campo en

esas clases), el Macro F_1 es 0.9383 en laboratorio y 0.9041 en campo, de modo que $DIR = 0{,}9636$; sobre exactitud, $DIR = 0{,}9956$. Con el Lite0 de la etapa 2 (`20260812_221429`) los valores fueron 0.9604 y 0.9901. Ambos modelos superan el umbral, pero un DIR cercano a uno no descarta disparidades por clase ni la dependencia del fondo (Sección 3.2.6). El desglose por clase y las figuras siguientes corresponden al checkpoint de la etapa 2 (Figura 3.6).



Disparidad por entorno ambiental. Matrices desagregadas Lab vs. Campo.

Figura 3.6: Auditoría de equidad e imparcialidad entre condiciones fotográficas.

El análisis granular de la tasa de falsos negativos (FNR) mostró una asimetría relevante, aunque con muestras pequeñas en campo (Tabla 3.8):

- La **Roya Común** es casi infalible en laboratorio ($FNR = 0{,}31\,\%$, 1 fallo en 322 casos) pero **falla en el 31.25 % de los casos en campo real** (5 fallos en 16 casos). Coincide con que el 95 % de las imágenes de roya del corpus (2 150 de 2 256) son de laboratorio. Con el modelo oficial la diferencia persiste: $F_1 = 0{,}998$ en laboratorio frente a 0.77 en campo; con solo 16 imágenes de campo la estimación es poco estable.
- La **Mancha Gris** exhibe el patrón inverso: $15{,}58\,\%$ de error en laboratorio frente a solo $5{,}16\,\%$ en campo auténtico.

Tabla 3.8: Tasa de falsos negativos (FNR) desagregada por clase y entorno, checkpoint de la etapa 2

Patología Evaluada	FNR **Laboratorio**	**Soporte** (N)	FNR **Campo Real**	**Soporte** (N)
Roya Común	0.31 %	322	**31.25 %**	16
Mancha Gris (GLS)	15.58 %	77	5.16 %	213
Tizón Foliar (NCLB)	3.01 %	133	1.01 %	892

3.2.6. Capacidades del diagnóstico: dependencia del fondo

Para desentrañar si el modelo miraba la hoja o el entorno, se ejecutó una auditoría de oclusión espacial geométrica sobre las 5 015 muestras de prueba frente a un predictor nulo constante (Tabla 3.9 y Figura 3.7).

Tabla 3.9: Auditoría de ablación espacial con control nulo en el conjunto de prueba, checkpoint de la etapa 2

Condición de Entrada	Región Visible	Área (%)	Exactitud	Exceso s/Nulo	Conf. Retenida
Imagen original completa	Toda la escena	100.0 %	97.91 %	+71.77 pp	100.0 %
Oclusión central	**Anillo periférico**	**63.7 %**	**79.46 %**	**+53.32 pp**	**69.16 %**
Oclusión periférica	Caja central	36.3 %	42.25 %	+16.11 pp	42.66 %
Control nulo (sin píxeles)	Clase mayoritaria	0.0 %	26.14 %	0.0 pp	—

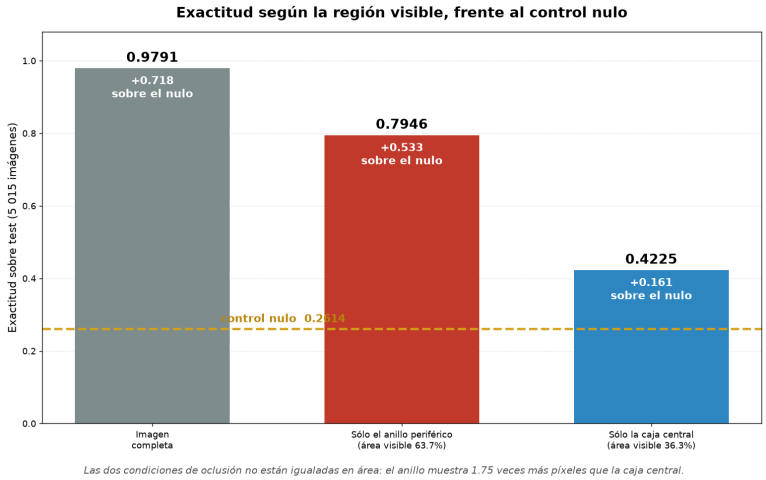


Figura 3.7: Exactitud según la región geométrica visible frente al azar nulo.

Al ocluir la región central de la imagen (36.3 % del área), el clasificador conserva un **79.46 % de exactitud** (riesgo MODERADO, `shortcut_detected = false`). Al ocluir la periferia, la exactitud cae a 42.25 % y el análisis marca dependencia crítica de la región periférica (riesgo CRÍTICO, `shortcut_confirmed`). Las dos condiciones dejan visibles áreas distintas (63.7 % y 36.3 %). Este hallazgo es consistente con que el fondo aporta señal de clase, aunque el experimento no aisla causalmente la lesión del fondo, por lo que la interpretación debe tomarse como hipótesis de trabajo que motiva el marco guía de captura.

Segmentación como preprocesamiento experimental: Un modelo entrenado sobre un corpus con máscaras de hoja alcanzó un Macro F_1 de **0.7191** en prueba, frente a 0.9480 del baseline de imagen completa.

La comparación no es pareada, porque el conjunto de prueba segmentado no comparte imágenes con el original, y el perfil de máscara no está registrado en el run. Se presenta como evidencia de que eliminar el fondo puede costar señal útil, no como una atribución causal (Sección 2.6).

Interpretabilidad con Grad-CAM y SHAP: Al evaluar mapas de calor locales (Figuras 3.8 y 3.9), los métodos de atribución destacan las lesiones visibles. Los mapas se obtuvieron con Grad-CAM, LIME [15] y SHAP [9]. Sin embargo, al medir el **exceso de atribución foliar** (fracción sobre la hoja menos la cobertura de la máscara), el exceso medio de las seis clases con máscara confiable (270 imágenes, máscara del segmentador; tres clases se descartaron por máscaras no interpretables) fue de apenas **+0.037**, con tres clases por encima del azar y tres por debajo. Una hipótesis compatible con este resultado es que la firma de fondo es un fenómeno difuso de baja frecuencia, distribuido en miles de píxeles, que no satura los mapas locales; esta hipótesis no fue medida directamente.

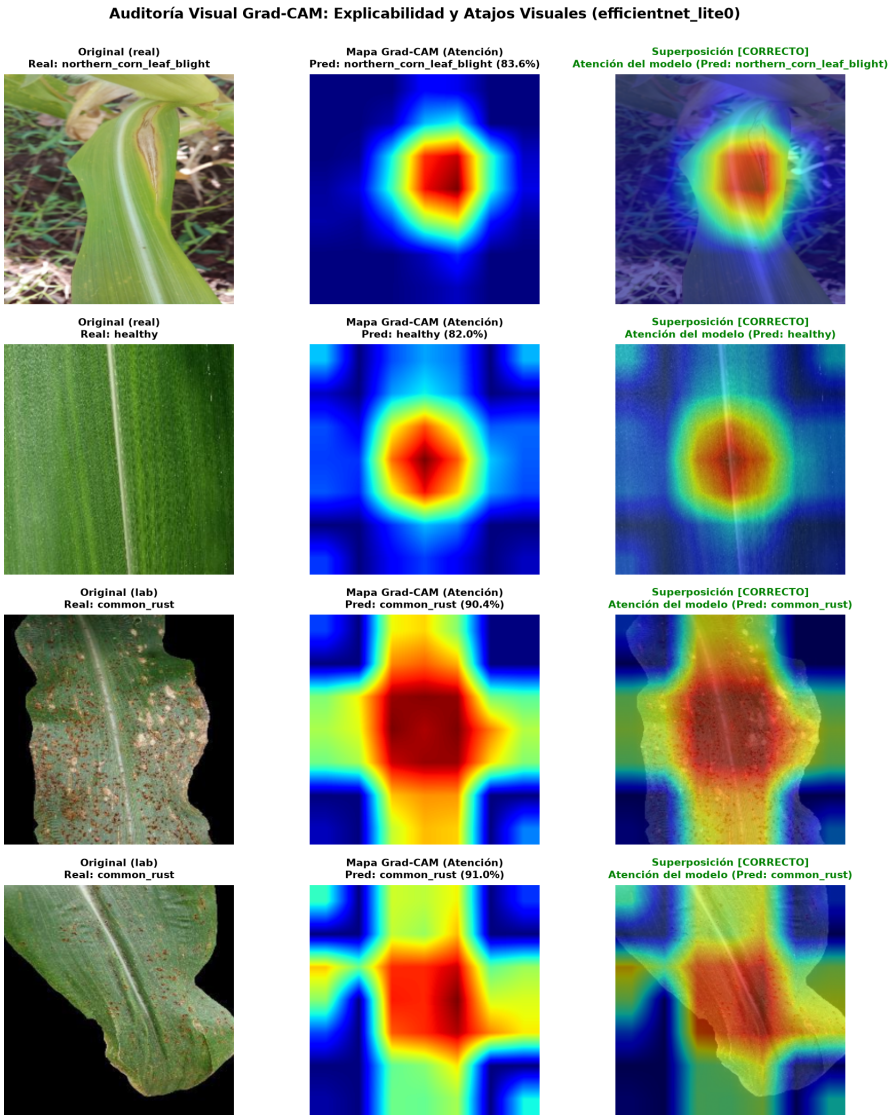


Figura 3.8: Mapas de activación Grad-CAM en muestras de campo real y laboratorio.

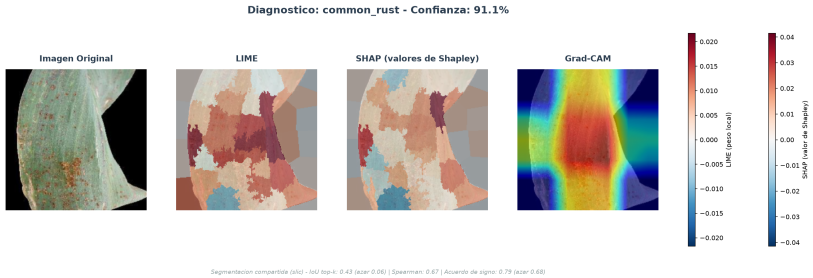


Figura 3.9: Panel comparado de explicabilidad local: LIME, SHAP y Grad-CAM.

3.2.7. Solución integral: prototipo en hardware real

El modelo oficial `EfficientNet-Lite0` (`20260921_204608`) cuantizado a 8 bits (**Int8**) ocupa **3.74 MB** (3 743 728 bytes), una reducción del 72.9 % frente a los 13.79 MB del punto de control FP32. En la prueba completa de 5 015 imágenes, el modelo Int8 obtuvo Macro F_1 de 0.9489 y exactitud de 97.87 %, frente a 0.9480 y 97.81 % de PyTorch, con un acuerdo de predicciones del 99.74 %. La paridad numérica del TFLite FP32 con ONNX y PyTorch fue aprobada (diferencia máxima de probabilidad de $3{,}3 \times 10^{-6}$ en ONNX y $3{,}9 \times 10^{-7}$ en TFLite). La paridad sobre una muestra de 30 imágenes no fue aprobada por una sola imagen límite (diferencia máxima de probabilidad de 0.198 frente a un tope de 0.15).

La aplicación móvil **DoctorMaiz** (React Native, TypeScript y `react-native-fast-tflite`) se instaló y probó en un teléfono **Motorola edge 40 neo** (procesador MediaTek Dimensity 7030 octa-core a 2.5 GHz, 8 GB RAM, Android 15).

Las latencias del modelo Int8 oficial se midieron en el teléfono como medianas (Tabla 3.10):

- El preprocesado tomó una mediana de **98 ms** (p95 de 279 ms).
- La inferencia en la CPU del teléfono tomó una mediana de **23 ms**.
- Ambas cifras cumplen la meta de 300 ms para preprocesado e inferencia de la Tabla 3.1.
- El flujo interactivo completo (captura, decodificación, inferencia, persistencia en SQLite y renderizado) tomó una mediana de 473 ms en la medición de la etapa 2 con el modelo de agosto; no se repitió con el modelo oficial y no forma parte de la meta.

Tabla 3.10: Latencias medianas en hardware físico (Motorola edge 40 neo)

Fase del proceso	**Modelo**	**Mediana**
Preprocesado	Oficial Int8 (`20260921_204608`)	98 ms
Inferencia	Oficial Int8 (`20260921_204608`)	23 ms
Flujo completo	Etapa 2 (`20260812_221429`)	473 ms

Fidelidad del teléfono frente al servidor: Se procesaron en el teléfono 143 imágenes (95 fotografías de campo externas y 48 del corpus) con el motor de inferencia de la aplicación. La primera medición reveló una diferencia de preprocesado entre entrenamiento y aplicación: las imágenes con algún lado menor de

448 píxeles se escalaban a 224×224 en un solo paso bilineal sin prefiltro, mientras que el entrenamiento usa el redimensionado con antialias de Pillow. Con ello, el teléfono coincidía con el computador solo en el 84 % de las predicciones y el detector OOD rechazaba el doble de imágenes del corpus (16.7 % frente a 8.3 %). Al pasar el tensor del propio teléfono por el modelo Int8 del servidor se reprodujeron sus predicciones, lo que descartó al intérprete como causa. Tras portar a la aplicación el remuestreo de Pillow, verificado byte a byte contra su salida, el teléfono coincide con el Int8 del servidor en las 143 imágenes. En el teléfono, el modelo acertó 45 de 48 imágenes del corpus (93.8 %, con 8.3 % de rechazo OOD) y 38 de 95 fotografías de campo (40.0 %, con 52.6 % de rechazo OOD), cifras equivalentes a las del computador (Sección 3.2.4).

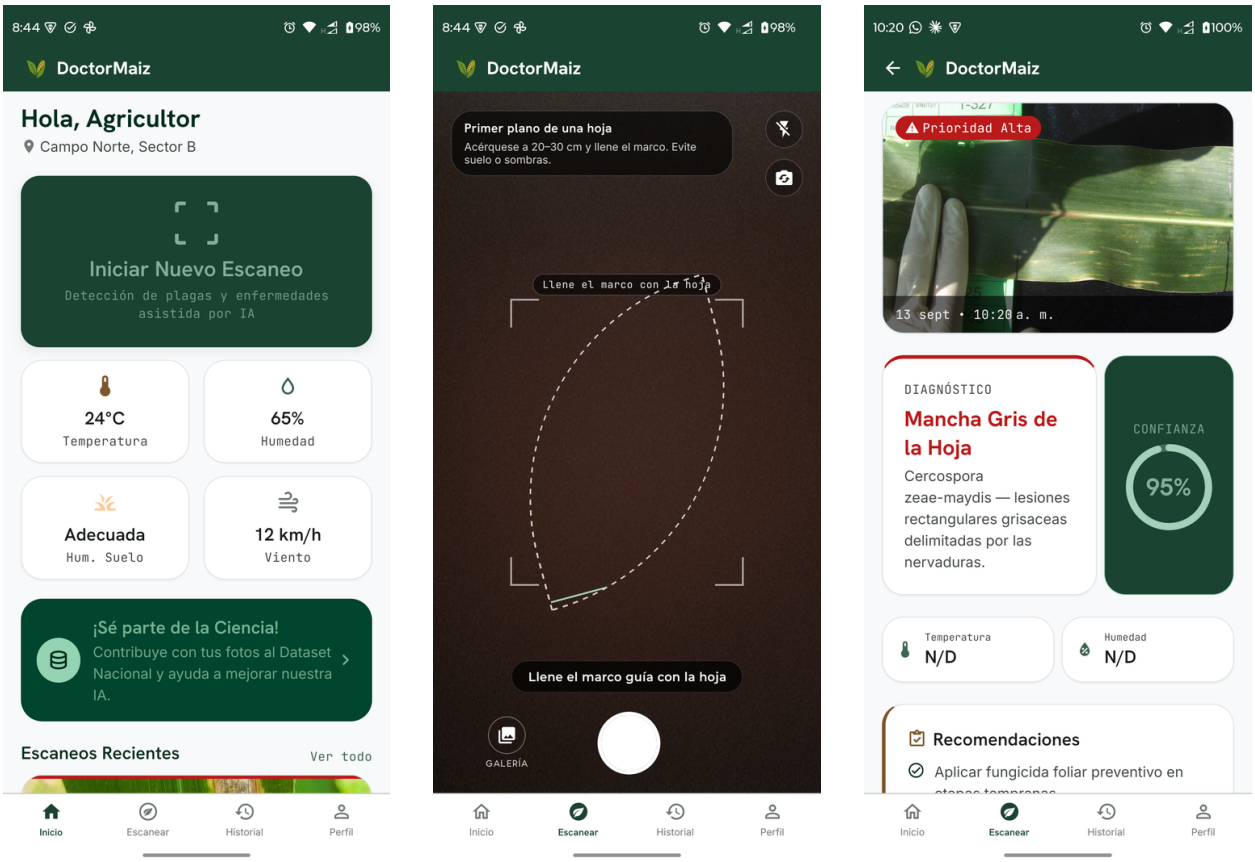
Comprobación de la mitigación en la Interfaz de Usuario (UI/UX): La aplicación solventa las limitaciones del modelo mediante un diseño ergonómico adaptado al productor (Figuras 3.10 y 3.11):

1. **Cámara con marco guía foliar (Figura 3.10):** La app instruye al agricultor a encuadrar la hoja y recorta la captura al marco guía con un margen de 15 % (3.02 MP a partir de 12.6 MP, el 24 % de la escena, en el dispositivo de prueba), lo que reduce el fondo visible antes de inferir.

2. **Detector OOD de Mahalanobis (Figura 3.11):** Cuando la distancia multivariada supera el umbral 106.37, como ocurrió con las cinco imágenes sintéticas de prueba, el sistema despliega **«Imagen no reconocida»**; manos, suelo y ropa no se evaluaron de forma cuantificada.

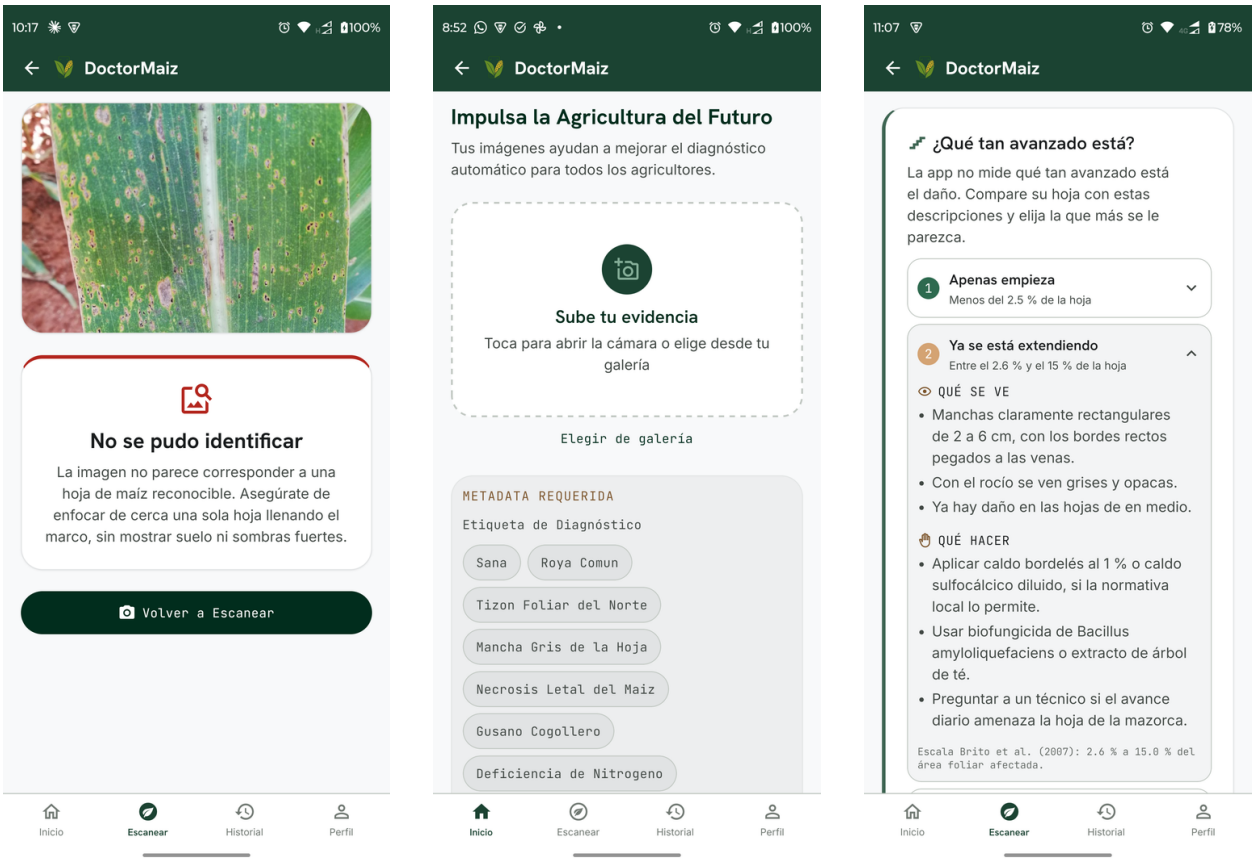
3. **Módulo de contribución comunitaria (Figura 3.11):** Permite almacenar fotos de milpas salvadoreñas para subirlas cuando haya conectividad.

4. **Guías de severidad contextualizadas (Figura 3.11):** Ofrece al productor una guía gráfica de tres grados en lenguaje cotidiano, que él compara con su hoja, con pautas de bioinsumos.



Pantalla de inicio. Marco guía foliar. Diagnóstico obtenido.

Figura 3.10: Flujo principal de la aplicación móvil nativa DoctorMaiz.



Bloqueo seguro por OOD. Aporte comunitario. Guía de severidad.

Figura 3.11: Mecanismos de seguridad, participación comunitaria y escalas agronómicas.

3.3. Impacto Social y Recomendaciones de Política Pública

Con base en los resultados, se proponen cinco recomendaciones dirigidas al Ministerio de Agricultura y Ganadería (MAG) y al Centro Nacional de Tecnología Agropecuaria y Forestal (CENTA):

1. **Validación en campo antes de la adopción institucional:** Evaluar la aplicación con promotores del CENTA sobre fotografías propias de cada zona productora, dado que la exactitud en fotografías de campo externas fue de 42 % (Sección 3.2.4).

2. **Banco nacional participativo de datos agrícolas:** Financiar brigadas fotográficas junto a la Universidad de El Salvador para capturar variedades y condiciones locales, con el fin de reducir la brecha de dominio detectada.

3. **Red de alerta fitosanitaria temprana:** Evaluar el uso de los aportes voluntarios sincronizados para un tablero epidemiológico centralizado en el MAG, sujeto a una política explícita de tratamiento de metadatos y ubicación.

4. **Capacitación comunitaria:** Enseñar a cooperativas y ADESCOs el uso del marco guía de captura, posicionando la herramienta como apoyo al criterio del productor.

5. **Software abierto y protección de datos:** Conservar el software bajo licencias de código abierto y definir las condiciones de uso de los datos aportados por los productores.

CONCLUSIONES Y RECOMENDACIONES

Conclusiones

La presente investigación consolida la transición desde una prueba de concepto preliminar hacia un sistema de diagnóstico foliar de maíz que se ejecuta sin conexión en dispositivos móviles. A partir de los resultados obtenidos, se concluye:

1. **Modelo oficial y su exportación móvil:** El modelo oficial (EfficientNet-Lite0, run `20260921_204608`) obtuvo un Macro F_1 de **0.9480** y una exactitud de 97.81 % sobre 5 015 imágenes de prueba, y 0.9435 $\pm$ 0.0052 como media y desviación muestral de tres semillas. Su versión Int8 pesa **3.74 MB** (72.9 % menos que el punto de control FP32 de 13.79 MB) y en la prueba completa obtuvo Macro F_1 de 0.9489 y exactitud de 97.87 %, con 99.74 % de acuerdo con las predicciones de PyTorch. En el teléfono Motorola edge 40 neo, la mediana fue de 98 ms de preprocesado y 23 ms de inferencia, y el dispositivo reproduce las predicciones del modelo Int8 del servidor en 143 de 143 imágenes.

2. **Ensamble de la etapa 2:** El ensamble por votación suave entre EfficientNet-Lite0, EfficientNet-B0 y ShuffleNet-V2 alcanzó un Macro F_1 de 0.9567, una exactitud de 98.29 % y un Macro Recall de 95.06 % en el corpus de 33 433 imágenes de esa etapa, con los 963 casos de necrosis letal del maíz (MLN) clasificados correctamente. Es un resultado de una sola semilla en una partición que mezcla fuentes, y el ensamble no está desplegado. Bajo validación con fuente no vista (LOSO sobre `multicrop-disease-maiz`, tres semillas), el recall de MLN baja a 0.79–0.81 en el ensamble y a 0.72–0.74 en Lite0.

3. **Generalización entre fuentes, limitación principal:** En 97 fotografías de campo externas, el modelo oficial acertó 41 (42 %) y el detector OOD rechazó 49; el Lite0 de agosto acertó 39, por lo que la brecha no se explica por el cambio de modelo y es compatible con una generalización limitada fuera del corpus. Coincide con la validación cruzada agrupada por fuente, donde el Macro

F_1 pasa de 0.9311 $\pm$ 0.0099 (estratificada) a 0.6026 $\pm$ 0.1240 (IC95, sobre las clases presentes en cada pliegue; 0.4359 con el macro F_1 convencional de nueve clases). Con LOSO en tres semillas, el modelo entrenado sin `maize-diseases` obtiene 0.9933 $\pm$ 0.0006 en esa fuente y el entrenado sin `multicrop-disease-maiz` obtiene 0.9019 $\pm$ 0.0044 en la suya; cada fuente retenida contiene solo tres clases.

4. **Dependencia del fondo:** El *Disparate Impact Ratio* entre laboratorio y campo, calculado sobre las tres clases presentes en ambos entornos, es 0.9636 sobre Macro F_1 y 0.9956 sobre exactitud con el modelo oficial (0.9604 y 0.9901 con el modelo de la etapa 2). Supera el umbral de 0.80, pero no refleja la roya de campo, que con 16 imágenes de prueba obtiene $F_1 = 0{,}77$ frente a 0.998 en laboratorio. La ablación espacial mostró que al ocluir el centro de la imagen el modelo conserva 79.46 % de exactitud y que al ocluir la periferia cae a 42.25 %; es compatible con sensibilidad a la región periférica, pero las áreas visibles difieren y el experimento no separa el fondo de la hoja.

5. **Mitigación en la interfaz:** La aplicación incorporó un marco guía de captura y un detector OOD basado en distancia de Mahalanobis relativa con umbral 106.37 (percentil 95 de validación). El detector rechazó las 5 imágenes sintéticas de prueba y 3.8 % de 500 imágenes de prueba válidas. El efecto del marco guía sobre el sesgo de procedencia no se midió.

6. **Segmentación de la hoja, línea experimental:** Un modelo entrenado sobre un corpus enmascarado alcanzó un Macro F_1 de 0.7191 en prueba, sin pareamiento con el conjunto original. La aplicación no aplica segmentación y la comparación formal entre imagen completa y segmentada sigue pendiente.

Recomendaciones

1. **Validación en campo antes de la adopción institucional:** Evaluar la aplicación con promotores del CENTA sobre fotografías propias de cada zona productora, dado que la exactitud en fotografías de campo externas fue de 42 %.

2. **Banco nacional participativo de datos agrícolas:** Financiar brigadas fotográficas junto a la Universidad de El Salvador para capturar variedades y condiciones locales, con el fin de reducir la brecha

de dominio detectada.

3. **Red de alerta fitosanitaria temprana:** Evaluar el uso de los aportes voluntarios sincronizados para un tablero epidemiológico centralizado en el MAG, sujeto a una política explícita de tratamiento de metadatos y ubicación.

4. **Capacitación comunitaria:** Enseñar a cooperativas y ADESCOs el uso del marco guía de captura, posicionando la herramienta como apoyo al criterio del productor.

5. **Software abierto y protección de datos:** Conservar el software bajo licencias de código abierto y definir las condiciones de uso de los datos aportados por los productores.

BIBLIOGRAFÍA

[1] Ahmad, A., El Gamal, A., & Saraswat, D. (2023). Toward generalization of deep learning-based plant disease identification under controlled and field conditions. *IEEE Access*, 11, 9042–9057.

[2] Banco Central de Reserva de El Salvador (BCR). (2023). *Revista Económica: Aporte Agropecuario al Producto Interno Bruto 2022-2023*. San Salvador: BCR.

[3] Centro Nacional de Tecnología Agropecuaria y Forestal "Enrique Álvarez Córdova" (CENTA). (2022). *Guía técnica del cultivo de maíz en El Salvador*. San Salvador: CENTA / Gerencia de Investigación y Transferencia.

[4] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 248–255).

[5] Howard, A. G., et al. (2017). MobileNets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*.

[6] Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 7132–7141).

[7] Jacob, B., Kligys, S., Chen, B., Zhu, M., Tang, M., Howard, A., Adam, H., & Kalenichenko, D. (2018). Quantization and training of neural networks for efficient integer-arithmetic-only inference. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 2704–2713).

[8] Lee, K., Lee, K., Lee, H., & Shin, J. (2018). A simple unified framework for detecting out-of-distribution samples and adversarial attacks. En *Advances in Neural Information Processing Systems (NeurIPS)*, 31.

[9] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 4765–4774.

[10] Ma, N., Zhang, X., Zheng, H.-T., & Sun, J. (2018). ShuffleNet V2: Practical guidelines for efficient CNN architecture design. En *Proceedings of the European Conference on Computer Vision (ECCV)* (pp. 116–131).

[11] Ministerio de Agricultura y Ganadería (MAG). (2023). *Anuario de Estadísticas Agropecuarias y Seguridad Alimentaria en El Salvador 2022-2023*. San Salvador: MAG / Dirección General de Economía Agropecuaria.

[12] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)* (pp. 2623–2631).

[13] Mueller, M., & Hein, M. (2025). Mahalanobis++: Improving OOD detection via feature normalization. *arXiv preprint arXiv:2505.18032*.

[14] Ren, J., Fort, S., Liu, J., Roy, A. G., Padhy, S., & Lakshminarayanan, B. (2021). A simple fix to Mahalanobis distance for improving near-OOD detection. *arXiv preprint arXiv:2106.09022*.

[15] Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. En *ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD)* (pp. 1135–1144).

[16] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 618–626).

[17] Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. En *International Conference on Machine Learning (ICML)* (pp. 6105–6114).

GLOSARIO DE TÉRMINOS

Clever Hans Effect: Fenómeno en el cual un modelo de aprendizaje automático alcanza una aparente alta precisión apoyándose en correlaciones espurias o atajos del entorno (fondos, sensores, marcas de agua) en lugar de las características intrínsecas de la clase.

Cosine Annealing: Esquema de planificación de tasa de aprendizaje que reduce gradualmente el paso de optimización siguiendo la curva de un coseno hasta un mínimo establecido, facilitando que el optimizador escape de mínimos locales.

Disparate Impact Ratio (DIR): Métrica de equidad que cuantifica el cociente entre el desempeño del grupo con peor resultado y el del mejor, aquí medido con Macro F_1 o exactitud. Un valor inferior a 0.80 se toma como indicio de trato dispar.

Edge AI: Paradigma de inteligencia artificial donde los modelos entrenados se ejecutan directamente en hardware local (dispositivos móviles, microcontroladores) sin enviar datos a servidores en la nube.

Macro F_1-Score: Media aritmética no ponderada del valor F_1 calculado independientemente para cada clase. Asigna el mismo peso relativo a clases minoritarias y mayoritarias, siendo la métrica estándar ante conjuntos desbalanceados.

MLOps (Machine Learning Operations): Conjunto de prácticas de ingeniería de software destinadas a automatizar, versionar y garantizar la reproducibilidad y monitoreo de pipelines de aprendizaje automático en producción.

Necrosis Letal del Maíz (MLN): Complejo viral devastador provocado por la coinfección sinérgica del virus del moteado clorótico del maíz (MCMV) y un potyvirus (como SCMV), capaz de destruir el 100 % de una plantación.

Out-of-Distribution (OOD): Condición que presentan aquellas muestras alimentadas a un clasificador cuyas características estadísticas provienen de una distribución ajena a la utilizada durante el entrenamiento (ej. fotografiar una piedra o una mano frente a un modelo de hojas).

Post-Training Quantization (PTQ): Técnica de optimización que convierte los pesos y activaciones de una red neuronal entrenada en coma flotante (FP32) a enteros de precisión reducida (Int8), disminuyendo el tamaño del modelo y la latencia en CPU.

Soft Voting: Mecanismo de ensamble multimodelo que promedia las probabilidades continuas asignadas por cada red individual mediante la función Softmax, seleccionando la clase con el máximo consenso medio.

ANEXOS

Anexo A: Registro de Enlaces y Repositorios Abiertos del Proyecto

Los repositorios y recursos de **DoctorMaiz** son los siguientes:

- **Clasificador (*pipeline* de entrenamiento, evaluación y exportación):**

  `https://github.com/daiv05/maize-doctor-classifier`

- **Aplicación móvil DoctorMaiz (React Native, inferencia *offline*):**

  `https://github.com/Edenilson-Molina/maize-doctor-app`

- **Segmentador foliar (detección y segmentación de instancias de hoja):**

  `https://github.com/abner-rivas/maize-doctor-segmenter-leaf`

- **API (cuenta de usuario, sincronización opcional y avisos de actualización):**

  `https://github.com/daiv05/maize-doctor-api`

- **Sitio web y documentación técnica:**

  `https://doctor-maiz.deras.dev/es`

- **Dataset consolidado en Hugging Face:**

  `https://huggingface.co/datasets/daiv05/corn-leaf-diseases-pests-and-deficiencies`

- **Artefactos de evaluación y modelos exportados:**

  `https://drive.google.com/drive/folders/1OeZdWggfp7nVkaYHW_oOuCma5xbwhns6?usp=drive_link`

Anexo B: Inventario Criptográfico de Checkpoints Respaldados

La Tabla 3.11 detalla los hashes SHA-256 de los principales modelos físicos que sustentan la reproducibilidad de la tesina.

Tabla 3.11: Hashes SHA-256 de los pesos físicos de los modelos respaldados

Modelo / Protocolo	**Tamaño**	**Hash SHA-256 del Checkpoint (`best.pth`)**
EfficientNet-Lite0 Base (42, oficial)	13.79 MB	`860180f33bf1749ffee9f3cccb9569a4 7afd9ca0fcef52713e18f99f82a57859`
EfficientNet-Lite0 Int8 (Móvil, `model_int8.tflite`)	3.74 MB	`bb31467a58c11cd474159bd5739a7a57 b1f1edfda6b5dbfae8fa91337f3c56b1`
EfficientNet-B0 Referencia	16.36 MB	`0e367a5318c068c9bcc90a6bec0d17a0 b029251ca5f98400034bd09de7524fdb`
ShuffleNet-V2-x1.0 Referencia	5.22 MB	`b681a3fd5fffaa5d078802369dff04b4 6c91cbfed7b333ea80c9d6965fd82c9e`